ΕΛΛΗΝΙΚΟ ΜΕΣΟΓΕΙΑΚΟ ΠΑΝΕΠΙΣΤΗΜΙΟ

ΤΜΗΜΑ ΜΟΥΣΙΚΗΣ ΤΕΧΝΟΛΟΓΙΑΣ

ΠΜΣ ΜΟΥΣΙΚΗ ΤΕΧΝΟΛΟΓΙΑ ΚΑΙ ΕΦΑΡΜΟΓΕΣ

ΔΙΠΛΩΜΑΤΙΚΗ ΕΡΓΑΣΙΑ

Του

ΣΠΥΡΙΔΑΚΗ ΓΕΩΡΓΙΟΥ

mta53@edu.hmu.gr

Τίτλος: «Αυτόματη Ταξινόμηση των Τρόπων Δόνησης σε Όργανα της Οικογένειας του Μπουζουκιού μέσω Τεχνικών Μηχανικής Μάθησης και Προηγμένης Επεξεργασίας Συμβολομετρικών Εικόνων»

"Automated Classification of Vibration Modes in Bouzouki Family Instruments via Machine Learning Techniques and Advanced Interferometric Image Processing"

Επιβλέπων: Καλιακάτσος-Παπακώστας Μάξιμος

Τριμελής επιτροπή:

1. Καλιακάτσος-Παπακώστας Μάξιμος
2. Ορφανός Ιωάννης
3. Κασέλουρης Ευάγγελος

ΜΑΡΤΙΟΣ 2026

Περίληψη

Η παρούσα διπλωματική εργασία επαναπροσδιορίζει την αυτοματοποιημένη ανάλυση συμβολομετρικών εικόνων ηλεκτρονικών κηλίδων (ESPI), προτείνοντας μια στρατηγική μετάβαση από τα αδιαφανή μοντέλα «μαύρου κουτιού» (black-box) σε αρχιτεκτονικές μηχανικής μάθησης καθοδηγούμενης από τη φυσική (physics-informed machine learning). Ενώ οι συμβατικές, αμιγώς δεδομενοκεντρικές (data-driven) προσεγγίσεις βαθιάς μάθησης επιχειρούν να εξάγουν γνώση αποκλειστικά από τα εικονοστοιχεία, η παρούσα έρευνα αποδεικνύει ότι η ρητή ενσωμάτωση πρότερων πληροφοριών θεμελιωμένων στη φυσική (physics priors) στη διαδικασία μάθησης είναι καθοριστική για την επίτευξη υψηλής ακρίβειας και ερμηνευσιμότητας.

Στο προτεινόμενο πλαίσιο, η αναγνώριση των ιδιομορφών δόνησης δεν αντιμετωπίζεται ως ένα απλό πρόβλημα υπολογιστικής όρασης, αλλά ως φυσικό πρόβλημα με αυστηρές δεσμεύσεις. Αντί της χρήσης νευρωνικών δικτύων τύπου End-to-End (CNNs), αναπτύχθηκε ένας ερμηνεύσιμος υβριδικός ταξινομητής Random Forest (Hybrid Random Forest). Το μοντέλο αυτό συνθέτει μορφολογικούς δείκτες των κομβικών γραμμών με **εκ των προτέρων συχνοτικές παραδοχές** (frequency priors), οι οποίες απορρέουν απευθείας από τη θεωρία ταλάντωσης πλακών.

Η εκτενής συγκριτική αξιολόγηση σε ένα νέο, πρότυπο σύνολο δεδομένων 3.443 εικόνων ESPI, το οποίο χαρακτηρίζεται από έντονη ανισορροπία κλάσεων, κατέδειξε τη σαφή υπεροχή της προσέγγισης «καθοδηγούμενης από τη φυσική». Το υβριδικό μοντέλο υπερέχει αισθητά του ισχυρού data-driven αλγορίθμου ResNet-18, επιτυγχάνοντας συνολική ακρίβεια 97,85% (έναντι 93,76%) και, το σημαντικότερο, αυξάνοντας τη μετρική Macro-F1 στο 95,15% (έναντι 88,11%).

Η υπεροχή αυτή ερμηνεύεται θεωρητικά μέσω της επιβεβαίωσης της **«Υπόθεσης Αποπλοκής»** (Disentanglement Hypothesis): της ικανότητας του συστήματος να διαχωρίζει την τοπολογική πληροφορία (αναλλοίωτη) από τις φασματικές ιδιότητες του υλικού (μεταβαλλόμενες). Η προτεινόμενη μεθοδολογία όχι μόνο θωρακίζει το σύστημα απέναντι στην έλλειψη δεδομένων (data scarcity), αλλά ανοίγει τον δρόμο για τη χρήση της μηχανικής μάθησης ως διαφανούς και φυσικά ερμηνεύσιμου εργαλείου, ξεπερνώντας τα όρια της απλής στατιστικής συσχέτισης.

Λέξεις-κλειδιά: Μηχανική μάθηση καθοδηγούμενη από τη φυσική, Συμβολομετρία ηλεκτρονικών κηλίδων (ESPI), Ταξινόμηση ιδιομορφών δόνησης, Ερμηνευσιμότητα μοντέλων, Μηχανική χαρακτηριστικών, Υβριδικό Random Forest.

Abstract

This diploma thesis redefines the automated classification of vibration modes in bouzouki-family instruments from Electronic Speckle Pattern Interferometry (ESPI) images by shifting from conventional black-box deep learning models to a physics-informed machine learning framework. While purely data-driven approaches rely solely on pixel-level information, this work demonstrates that the explicit integration of physics-based priors is essential for achieving both high accuracy and physical interpretability.

Within the proposed framework, the identification of vibration modes is not treated as a generic computer vision task but as a constrained physical problem. Instead of end-to-end convolutional neural networks (CNNs), we develop an interpretable Hybrid Random Forest classifier that fuses morphological descriptors of nodal lines with frequency priors derived directly from thin-plate vibration theory.

The model is rigorously evaluated on a newly constructed, severely imbalanced dataset of 3,443 time-averaged ESPI images, revealing the clear superiority of the physics-informed approach. Compared to a strong data-driven ResNet-18 baseline, the hybrid model attains 97.85% overall accuracy (versus 93.76%) and, more importantly, boosts the Macro-F1 score to 95.15% (versus 88.11%).

These improvements are theoretically grounded in the confirmation of the Disentanglement Hypothesis, namely the model's capacity to separate material-invariant topological information from material-dependent spectral characteristics. The proposed methodology not only enhances robustness under speckle noise and data scarcity but also establishes machine learning as a transparent and physically meaningful tool for full-field modal analysis, going beyond mere statistical correlation.

Keywords: Physics-informed machine learning, Electronic Speckle Pattern Interferometry (ESPI), Vibration mode classification, Model interpretability, Feature engineering, Hybrid Random Forest.

ΠΙΝΑΚΑΣ ΠΕΡΙΕΧΟΜΕΝΩΝ

ΠΙΝΑΚΑΣ ΠΕΡΙΕΧΟΜΕΝΩΝ 4
ΚΕΦΑΛΑΙΟ 1: ΕΙΣΑΓΩΓΗ 16
1.1 Πλαίσιο και Κίνητρο Έρευνας 16
1.1.1 Η Σημασία της Ανάλυσης Ιδιομορφών στα Μουσικά Όργανα 16
1.1.2 Ηλεκτρονική Συμβολομετρία Κηλίδων (ESPI) 16
1.1.3 Η Πρόκληση του Θορύβου Κηλίδων (Speckle Noise) 17
1.1.4 Η Ανάγκη για Αυτοματοποίηση 18
1.2 Ερευνητικό Πρόβλημα και Στόχοι 19
1.2.1 Διατύπωση του Προβλήματος 19
1.2.2 Ερευνητικά Ερωτήματα 19
1.2.3 Ερευνητικοί Στόχοι 20
1.3 Συνεισφορά της Εργασίας 21
1.3.1 Μεθοδολογικές Καινοτομίες 21
1.3.2 Πρακτικές και Ακουστικές Συνεισφορές 22
1.3.3 Επιστημονικές Διαπιστώσεις και Αρνητικά Ευρήματα 23
1.3.4 Περιορισμοί και Όρια Γενίκευσης 24
1.4 Δομή της Εργασίας 24
ΚΕΦΑΛΑΙΟ 2: ΘΕΩΡΗΤΙΚΟ ΥΠΟΒΑΘΡΟ 28
2.1 Η ανάγκη για Μηχανική Μάθηση στην αυτόματη ταξινόμηση ιδιόμορφών δόνησης 28
2.1.1 Η ανθρώπινη ταξινόμηση ως μοντέλο αναφοράς (baseline) στο εργαστήριο 28
2.1.2 Περιορισμοί της Χειροκίνητης Ταξινόμησης 29
2.1.3 Αντικείμενο και Εύρος της Αυτοματοποίησης 30
2.2 Φυσική δονήσεων και δομή καπακιού (soundboard): θεμελίωση της ανάλυσης ιδιομορφών (modal analysis) 33
2.2.1 Ανάλυση ιδιομορφών (modal analysis): ορισμοί και βασικές έννοιες 33
2.2.2 Θεωρία λεπτών πλακών και (m,n) modes: από το ιδανικό στο πραγματικό καπάκι 34
2.2.3 Ορθοτροπία ξύλου, ανομοιογένεια και συνοριακές συνθήκες: γιατί τα modes «σπάνε» και γιατί η τοπολογία επιμένει 35

2.2.4 Συζευγμένο σύστημα (χορδή-καβαλάρης-καπάκι-αέρας): από ιδιομορφές σε πραγματική ακουστική συμπεριφορά 36

2.2.5 Υλική Ετερογένεια και Φασματική Μετατόπιση: Ξύλο έναντι Ανθρακονημάτων 37

2.3 ESPI: Θεμελιώδεις Αρχές και Μηχανισμός Απεικόνισης 39

2.3.1 Θεμελιώδεις Αρχές Συμβολομετρίας και Φαινόμενο Speckle 40

2.3.2 ESPI χρονικού μέσου όρου: Η Φυσική της Απεικόνισης Δονήσεων 42

2.3.3 Μορφολογική ερμηνεία fringe maps 42

2.3.4 Εξαγωγή Φάσης και Αλγοριθμική Ροή Επεξεργασίας Βασισμένη σε FFT (FFT-based Pipeline) 43

2.3.5 Δομή και Περιεχόμενο του Συνόλου Δεδομένων (Dataset) 46

2.4 Θόρυβος κηλίδων (speckle) και αποθορυβοποίηση 49

2.4.1 Speckle ως πολλαπλασιαστικός θόρυβος: στατιστική περιγραφή 50

2.4.2 Μοντελοποίηση speckle με Burr Type XII: κίνητρο και ιδιότητες 51

2.4.3 Χρονική συσχέτιση και averaging: από την οπτική ολοκλήρωση στο multi-frame 52

2.4.4 Ο Χρονικός Μέσος Όρος (Multi-frame Averaging) ως Φυσικά Συνεπές Σημείο Αναφοράς 52

2.4.5 Ασυμφωνία Στόχων (Task Misalignment): Οι Περιορισμοί των Μετρικών PSNR/SSIM 53

2.4.6 Παραγωγή Ρεαλιστικών Ψευδο-θορυβωδών Δεδομένων και Βαθμονόμηση 55

2.4.7 Θεωρητικό υπόβαθρο αποθορυβοποίησης, DnCNN και Efficient Channel Attention (ECA) 57

2.5 Διατύπωση του Προβλήματος Μηχανικής Μάθησης 61

2.5.1 Από το ESPI στη διατύπωση εποπτευόμενης ταξινόμησης 61

2.5.2 Ορισμός εισόδων, μεταβλητών και επιπέδων αναπαράστασης 62

2.5.3 Ταξινομική δομή κλάσεων (labels) και κριτήρια επισήμανσης 63

2.5.4 Σύνθεση του συνόλου δεδομένων και στατιστικά κατανομής 64

2.5.5 Η κλάση other_unknown και η μετάβαση από 6-class σε 5-class (production) 66

2.5.6 Σύνοψη και Γέφυρα προς το Μεθοδολογικό Πλαίσιο Αξιολόγησης 66

2.6 Θεμελιώδεις Έννοιες Μηχανικής Μάθησης και Πρωτόκολλα Αξιολόγησης .. 67

2.6.1 Διαχωρισμοί Δεδομένων (Splits) και Διαρροή Πληροφορίας (Data Leakage) 68
2.6.2 Πρωτόκολλα Cross-Validation: K-Fold, LOBO και LODO 70
2.6.3 Μετρικές για Ανισόρροπα Δεδομένα: Accuracy, Macro-F1 και Per-Class Ανάλυση 72
2.6.4 Αβεβαιότητα, Στατιστικός Έλεγχος και Συγκρίσεις Μοντέλων 74
2.7 Μηχανική Μάθηση Καθοδηγούμενη από τη Φυσική: Το Κεντρικό Αφήγημα 76
2.7.1 Τι σημαίνει «Physics-Informed» στην παρούσα εργασία 76
2.7.2 Μηχανική Χαρακτηριστικών: Φυσική Αναπαράσταση και Κωδικοποίηση 77
2.7.3 Γιατί τα frequency priors «δουλεύουν» - θεωρητική ερμηνεία 80
2.7.4 Ερμηνευσιμότητα, σημαντικότητα χαρακτηριστικών και εμπειρική απόδειξη 81
2.7.5 Από τον Μετασχηματισμό FFT στο LeFFT: Η Φυσική Εξέλιξη της Αναπαράστασης 82
2.8 Μοντέλα που χρησιμοποιούνται στην παρούσα εργασία 85
2.8.1 Random Forest: Ενσωμάτωση Φυσικής Γνώσης και Ταξινόμηση 85
2.8.2 ResNet-18: Το Αμιγώς Data-Driven Πρότυπο Αναφοράς 86
2.8.3 Ο Ρόλος του DnCNN στην Αποθορυβοποίηση: Μηχανισμός και Περιορισμοί 87
2.9 Συνθετική Θεώρηση: Οδικός Χάρτης της εργασίας (Κεφάλαια 3-6) 91
2.9.1 Μεθοδολογική End-to-End Ροή Εργασίας 92
2.9.2 Διασύνδεση Θεωρίας και Πειραματικής Επαλήθευσης 92
2.9.3 Η Αλυσίδα Τεκμηρίωσης της Υπόθεσης 93
2.9.4 Διευκρινίσεις Ορολογίας και Μεθοδολογικής Συνέπειας 93
ΚΕΦΑΛΑΙΟ 3: ΜΕΘΟΔΟΛΟΓΙΑ 95
3.1 Πειραματική Διάταξη και Συλλογή Δεδομένων 95
3.1.1 Διαμόρφωση του Συστήματος ESPI 95
3.1.2 Προετοιμασία Πειραματικών Αντικειμένων (specimens) και Δεδομένα 95
3.2 Κατασκευή Συνόλου Δεδομένων και Προεπεξεργασία 97
3.2.1 Σύνολο Εκπαίδευσης για το Τμήμα Αποθορυβοποίησης 97
3.2.2 Χαρακτηρισμός Θορύβου 97

3.3 Τμήμα Αποθορυβοποίησης: Αρχιτεκτονική DnCNN-ECA 98
3.3.1 Αρχιτεκτονική Δικτύου 98
3.3.2 Σχεδιασμός Μονάδας ECA 99
3.3.3 Διαμόρφωση Εκπαίδευσης 100
3.4 Εξαγωγή Φάσης και Ποιοτικός Έλεγχος 101
3.4.1 Προεπεξεργασία Εισόδου και Εφαρμογή ROI μάσκας 101
3.4.2 Εξαγωγή Φάσης μέσω Μετασχηματισμού Fourier 103
3.4.3 Ποιοτικός Έλεγχος (QC) και Ευθυγράμμιση έναντι Αναφοράς 107
3.5 Μηχανική Χαρακτηριστικών για Ταξινόμηση Ιδιομορφών 107
3.5.1 Χαρακτηριστικά Μοτίβου (16 χαρακτηριστικά) 108
3.5.2 Χαρακτηριστικά Συχνότητας (6 χαρακτηριστικά) 110
3.6 Ορισμός Κλάσεων Ιδιομορφών 110
3.6.1 Πραγματική αντιστοίχιση κλάσεων (Master Verified Mapping) 111
3.6.2 Ερμηνεία και κριτήρια ομαδοποίησης 112
3.6.3 Σχόλια για την ανισορροπία κλάσεων και επιπτώσεις στην εκπαίδευση 112
3.6.4 Περιορισμοί και πρακτικές αποφάσεις 113
3.7 Μοντέλα Ταξινόμησης 114
3.7.1 Random Forest Μόνο Μοτίβου (Pattern-only Random Forest) 114
3.7.2 Υβριδικό Random Forest (Hybrid Random Forest) 114
3.7.3 Συνελικτικό Νευρωνικό Δίκτυο (CNN - ResNet-18) 115
3.8 Μεθοδολογία Επικύρωσης 116
3.8.1 Διαστρωματωμένος Διαχωρισμός Εκπαίδευσης/Δοκιμής 116
3.8.2 Διαστήματα Εμπιστοσύνης μέσω Bootstrap 116
3.8.3 Αφαίρεση Μίας Συχνοτικής Ζώνης (LOBO) 116
3.8.4 Αφαίρεση Ενός Πειραματικού αντικειμένου (LODO) 117
3.8.5 Ζευγαρωμένος Στατιστικός Έλεγχος 117
3.9 Μετρικές Αξιολόγησης 117
3.9.1 Κύρια Μετρική: Βαθμολογία Μακρο-F1 117
3.9.2 Δευτερεύουσες Μετρικές 117
3.10 Λεπτομέρειες Υλοποίησης 118
3.10.1 Περιβάλλον Λογισμικού 118

3.10.2 Υπολογιστικοί Πόροι 119
ΚΕΦΑΛΑΙΟ 4: ΑΠΟΤΕΛΕΣΜΑΤΑ ΚΑΙ ΣΥΖΗΤΗΣΗ 120
4.1 Προετοιμασία δεδομένων 120
4.1.1 Σύνθεση συνόλου δεδομένων εκπαίδευσης για αποθορυβοποίηση 120
4.1.2 Μαζική Επεξεργασία και Επέκταση Συνόλου Δεδομένων 121
4.1.3 Εξαγωγή φάσης και σύνολο δεδομένων ταξινόμησης 121
4.2 Συνθετική Παραγωγή Θορύβου: Η Γεννήτρια Ψευδο-θορυβωδών Δεδομένων (pseudo-noisy generator) 124
4.2.1 Σκοπός και Αρχές Σχεδίασης 124
4.2.2 Θεωρητικό μοντέλο παρατήρησης: αλυσίδα θορύβου ESPI 125
4.2.3 Χειρισμός στο λογαριθμικό πεδίο για θόρυβο κηλίδων (speckle noise) . 127
4.2.4 Αλγόριθμος Παραγωγής Ψευδο-θορυβωδών Δεδομένων 128
4.2.5 Βαθμονόμηση v2.0: Από Μεμονωμένες Λήψεις σε Ζεύγη Μέσου Όρου 129
4.2.6 Λειτουργικές Διαμορφώσεις και Ρυθμίσεις Γεννήτριας 131
4.2.7 Μετρικές Ποιότητας και Κριτήρια Αποδοχής (QC) 132
4.2.8 Αποτελέσματα - Συγκριτική Σύνοψη ανά δοκίμιο (specimen) 133
4.2.9 Ανάλυση ανά Συχνοτική Ζώνη 136
4.2.10 Αξιολόγηση Διατήρησης Κροσσών (Modal Pattern Preservation) 138
4.2.11 Οπτική Αξιολόγηση και Ποιοτική Ανάλυση 140
4.2.12 Πρακτικές Παρατηρήσεις και Τεχνικές Προκλήσεις 141
4.2.13 Συμπέρασμα Ενότητας 143
4.3 Αποθορυβοποίηση με DnCNN-ECA 144
4.3.1 Εισαγωγή και αναγκαιότητα αποθορυβοποίησης 144
4.3.2 Αρχιτεκτονική DnCNN-Lite και θεωρητική τεκμηρίωση 145
4.3.3 Ενσωμάτωση Efficient Channel Attention (ECA) 146
4.3.4 Διαμόρφωση εκπαίδευσης και συνάρτηση απώλειας 147
4.3.5 Επίδραση αποθορυβοποίησης στην τελική (downstream) ταξινόμηση (Noisy → Denoised) 150
4.3.6 Μελέτη αφαίρεσης στοιχείων (ablation): ECA έναντι non-ECA 151
4.3.7 Τεχνική επαλήθευση της σύγκρισης (checkpoint integrity και ενεργοποίηση ECA) 156

4.3.8 Ανάλυση ισοδυναμίας σε επίπεδο κινητής υποδιαστολής (float-level equivalence) 156
4.3.9 Επαλήθευση διατήρησης φέρουσας χωρικής συχνότητας (FFT alignment) 157
4.3.10 Συνοπτική αποτίμηση 158
4.4 Εξαγωγή Χαρακτηριστικών 159
4.4.1 Χαρακτηριστικά Συχνότητας (Frequency Features - 6 χαρακτηριστικά) 160
4.4.2 Ανάλυση Σημαντικότητας Χαρακτηριστικών (Feature Importance Analysis) 161
4.5 Συγκριτική Ανάλυση: Random Forest έναντι CNN 162
4.5.1 Συνολική Σύγκριση Απόδοσης 162
4.5.2 Αναλυτική Αξιολόγηση Μοντέλων 164
4.5.3 Ανάλυση Απόδοσης Ανά Κλάση (Per-Class Analysis) 165
4.5.4 Αναδιάταξη Σημαντικότητας Χαρακτηριστικών (Feature Importance Shift) 167
4.5.5 Ανάλυση Πίνακα Σύγχυσης 169
4.5.6 Συγκριτική Ανάλυση: Συμβιβασμοί και Συνέργειες (Trade-offs & Synergies) 172
4.6 Ανάλυση Ανθεκτικότητας και Στατιστική Επαλήθευση 174
4.6.1 Bootstrap επαλήθευση (1.000 επαναλήψεις) 174
4.6.2 Ανάλυση Cross-Validation (3-πτυχη στρωματοποιημένη επικύρωση) ... 175
4.6.3 Ανάλυση Γενίκευσης Συχνότητας: Μέθοδος Leave-One-Band-Out (LOBO) 176
4.6.4 Ανάλυση Leave-One-Dataset-Out (LODO): Δομική Γενίκευση υλικού. 180
4.6.5 LOBO vs LODO Comparison 183
4.6.6 Στατιστικοί έλεγχοι σημαντικότητας και επεκτάσεις στιβαρότητας (robustness) 184
4.6.7 Περιορισμοί και Μελλοντική Εργασία 188
4.7 Συζήτηση Αποτελεσμάτων 190
4.7.1 Κύρια Ευρήματα 190
4.7.2 Υπεροχή της Προσέγγισης Καθοδηγούμενης από τη Φυσική: Τεκμηρίωση και Επικύρωση 191
4.7.3 Διαχείριση Ακραίας Ανισορροπίας Κλάσεων 194

4.7.4 Πρωτόκολλα Γενίκευσης και Εύρος Εγκυρότητας 194
4.7.5 Κεντρικές Συνεισφορές της Ανάλυσης 195
4.7.6 Πρακτικές Επιπτώσεις 196
4.8 Συμπεράσματα Κεφαλαίου 196
ΚΕΦΑΛΑΙΟ 5: ΣΥΖΗΤΗΣΗ ΚΑΙ ΑΝΑΛΥΣΗ ΕΥΡΗΜΑΤΩΝ 198
5.1 Εισαγωγή 198
5.2 Κατανόηση της Ανισορροπίας Κλάσεων και της Ετερογένειας Δεδομένων . 198
5.2.1 Ανάλυση του Προβλήματος Ανισορροπίας Κλάσης 198
5.2.2 Ανάλυση της Ανισορροπίας κατά Δοκίμιο 199
5.2.3 Μηχανισμοί Πόλωσης Δεδομένων και Επιπτώσεις 200
5.3 Αποτίμηση του Πλαισίου Ψευδο-Θορύβου και της Αποθορυβοποίησης 201
5.3.1 Η Περίπτωση Οριοθέτησης του W02 201
5.3.2 Ασυμφωνία Αντικειμενικών Στόχων (Task Mismatch) 202
5.4 Ανάλυση του Υβριδικού Ταξινομητή Random Forest 203
5.4.1 Δομή και Κίνητρα της Υβριδικής Προσέγγισης 203
5.4.2 Σύγκριση με CNN και Baseline 203
5.4.3 Θεμελίωση της Επιλογής Hybrid RF έναντι CNN 207
5.5 Κριτική Αποτίμηση του Μηχανισμού ECA 208
5.5.1 Η Αξία του Αρνητικού Ευρήματος 208
5.5.2 Regime-Dependent Συμπεριφορά 208
5.6 Σύνθεση της Ανάλυσης Γενίκευσης: LOBO έναντι LODO 209
5.6.1 Διχοτομία στη Συμπεριφορά Γενίκευσης 209
5.7 Συνολική Ερμηνεία και Σύνθεση Ευρημάτων 210
5.7.1 Σύνοψη Ευρημάτων 210
5.7.2 Κρίσιμοι Περιορισμοί των Ευρημάτων 211
5.8 Περιορισμοί της Μεθοδολογίας και της Πειραματικής Διαδικασίας 212
5.8.1 Μεθοδολογικοί Περιορισμοί (Implementation Limitations) 212
5.8.2 Πειραματικοί Περιορισμοί (Experimental Constraints) 213
5.9 Συμπεράσματα και Τελική Αποτίμηση 214
ΚΕΦΑΛΑΙΟ 6: ΣΥΜΠΕΡΑΣΜΑΤΑ 215
6.1 Σύνοψη 215

6.2 Απαντήσεις στα ερευνητικά ερωτήματα 215
6.2.1 RQ1: Επιρροή της αποθορυβοποίησης στην ταξινόμηση 215
6.2.2 RQ2: Στρατηγική αντιμετώπισης της σπανιότητας δεδομένων 216
6.2.3 RQ3: Ο ρόλος της προσοχής καναλιών (ECA) 216
6.2.4 RQ4: Η αξία της πρότερης φυσικής γνώσης 216
6.2.5 RQ5: Όρια γενίκευσης και ανθεκτικότητα 217
6.3 Θεωρητικές συνεισφορές 217
6.4 Πρωτοτυπία και κύριες νέες συνεισφορές 217
6.5 Θεωρητικές προεκτάσεις 218
6.6 Περιορισμοί και αρνητικά ευρήματα 218
6.7 Μελλοντικές προεκτάσεις της παρούσας έρευνας 219
6.7.1 Θεμελίωση και βελτίωση του υφιστάμενου pipeline 219
6.7.2 Γενίκευση σε σύνθετα υλικά και ετερογενή πειραματικά πεδία 220
6.7.3 Οριοθέτηση των μακροπρόθεσμων προεκτάσεων 220
6.8 Πρακτικές επιπτώσεις και κατευθυντήριες οδηγίες 221
6.9 Αναπαραγωγιμότητα 221
6.10 Συγκεντρωτικός πίνακας κύριων ευρημάτων 222
6.11 Τελικό συμπέρασμα 223
ΠΑΡΑΡΤΗΜΑΤΑ 224
ΠΑΡΑΡΤΗΜΑ Α: ΤΕΧΝΙΚΕΣ ΛΕΠΤΟΜΕΡΕΙΕΣ ΥΛΟΠΟΙΗΣΗΣ 224
A.1 DnCNN-ECA Architecture 224
A.1.1 Βασική Δομή Δικτύου 224
A.1.2 ECA Module Integration 224
A.1.3 Training Configuration 225
A.2 Υλοποίηση Random Forest (implementation) 225
A.2.1 Feature Set - 16 Pattern Features 225
A.2.2 Hybrid RF - 6 Frequency Features (Physics-Informed) 225
A.3 Υλοποίηση CNN ResNet-18 (implementation) 226
ΠΑΡΑΡΤΗΜΑ Β: ΠΑΡΑΜΕΤΡΟΙ ΔΙΑΜΟΡΦΩΣΗΣ 226
B.1 Διαμόρφωση συνόλου δεδομένων (σύνολο δεδομένων (dataset) configuration) 226

B.2 Cross-Validation Protocols 227
ΠΑΡΑΡΤΗΜΑ Γ: ΛΕΠΤΟΜΕΡΗ ΑΠΟΤΕΛΕΣΜΑΤΑ 228
Γ.1 Σύνοψη αποτελεσμάτων ταξινόμησης (classification results summary) 228
Γ.2 Per-Class Performance (Hybrid RF) 228
Γ.3 Ανάλυση Σημαντικότητας Χαρακτηριστικών (Feature Importance) 228
Γ.4 Generalization Tests 229
Γ.5 Statistical Tests 229
ΠΑΡΑΡΤΗΜΑ Δ: ΟΔΗΓΙΕΣ ΑΝΑΠΑΡΑΓΩΓΙΜΟΤΗΤΑΣ 230
Δ.1 Environment Setup 230
Δ.2 Execution Workflow 230
ΠΑΡΑΡΤΗΜΑ Ε: ΘΕΩΡΗΤΙΚΗ ΑΝΑΛΥΣΗ ΑΡΧΙΤΕΚΤΟΝΙΚΩΝ 231
Ε.1 DnCNN vs Multi-frame Averaging 231
Ε.2 ResNet-18 vs Deeper Networks 231
Ε.3 Hybrid RF: Σχεδιασμός Καθοδηγούμενος από τη Φυσική 231
ΠΑΡΑΡΤΗΜΑ Ζ: Συμπληρωματικό υλικό 232
Ζ.1 Εισαγωγή 232
Ζ.2 Υπολογισμός Gini Importance 232
Ζ.2.1 Θεωρητικό Υπόβαθρο 232
Ζ.2.2 Κώδικας Εξαγωγής Gini Importance 232
Ζ.2.3 Υπολογισμός Συνεισφοράς ανά Κατηγορία 234
Ζ.3 Επαλήθευση με Permutation Importance 235
Ζ.3.1 Σημαντικότητα MDI/Gini (Mean Decrease in Impurity) 235
Ζ.3.2 Σημαντικότητα με αναδιάταξη (Permutation importance) ως επαλήθευση 235
ΠΑΡΑΡΤΗΜΑ Η: ΜΑΘΗΜΑΤΙΚΗ ΘΕΜΕΛΙΩΣΗ 238
Η.0 Σκοπός και συμβάσεις 238
Η.1 Φυσική της Συμβολομετρίας (ESPI χρονικού μέσου όρου) 238
Η.1.1 Μιγαδικά πεδία και ένταση 238
Η.1.2 Ημιτονική out-of-plane δόνηση και φασική διαμόρφωση 239
Η.1.3 Time averaging και εμφάνιση $\boldsymbol{J0}$(τεκμηρίωση) 239
Η.2 Fringe analysis με FFT (Takeda) και φάση 240

H.2.1 Μοντέλο carrier fringes 240
H.2.2 Ανάκτηση φάσης με Fourier-transform μέθοδο 240
H.3 Μοντελοποίηση δονήσεων και ιδιομορφών (modes/plates) 240
H.3.1 Γενικό ιδιοτιμικό πρόβλημα modal ανάλυσης 240
H.3.2 Ενδεικτική PDE λεπτής πλάκας (Kirchhoff-Love) 241
H.4 Speckle / θόρυβος και averaging 241
H.4.1 Speckle contrast 241
H.4.2 Multi-frame averaging και βελτίωση SNR 241
H.4.3 Μικτό μοντέλο Speckle-Poisson-Gaussian και VST 241
H.5 Μηχανική Μάθηση: Random Forest 242
H.5.1 Ensemble κανόνας απόφασης 242
H.5.2 Gini impurity και επιλογή split 242
H.5.3 Feature importance (MDI / Gini importance) 242
H.6 Βαθιά Μάθηση: DnCNN (Residual Learning) 243
H.6.1 Διατύπωση προβλήματος denoising 243
H.6.2 Συνάρτηση κόστους (MSE στο residual) 243
H.7 Efficient Channel Attention (ECA) 243
H.7.1 GAP και channel descriptor 243
H.7.2 1D convolution, sigmoid και re-weighting 243
H.8 Μετρικές αξιολόγησης (Denoising & Classification) - εκτενής διατύπωση 244
H.8.1 MSE και PSNR 244
H.8.2 SSIM 246
H.8.3 Precision, Recall, F1-score και Macro-F1 στην Πολυταξική Ταξινόμηση. 247
H.9 Στατιστική τεκμηρίωση (Confidence intervals & significance) 248
H.9.1 Bootstrap confidence intervals 248
H.9.2 McNemar test 248
H.10 Μαθηματική διατύπωση splits γενίκευσης και leakage (LOBO/LODO) 249
H.11 Μαθηματικοί ορισμοί “Pattern features” (όπως στο Κεφ.2) 249
H.11.1 ROI features (validpx, areaextent) 249
H.11.2 Pattern FringesGeometry 249

H.11.3 Pattern SymmetryMoments 251
H.11.4 Pattern NodalTopology 252
H.11.5 Pattern Spectral (FFT-based) 253
H.12 Γέφυρα φυσικής → features → ταξινόμηση 254
ΠΑΡΑΡΤΗΜΑ Θ: Μελέτη Αφαίρεσης DnCNN-ECA — Μαθηματική Θεμελίωση και Εκτεταμένα Αποτελέσματα 255
Θ.0 Σύνδεση με τον κύριο κορμό 255
Θ.1 Ερευνητικό ερώτημα 255
Θ.2 Αρχιτεκτονικές παραλλαγές DnCNN-Lite 255
Θ.2.1 Μαθηματική διατύπωση μηχανισμού ECA 256
Θ.3 Μηχανισμοί απορρόφησης του channel scaling 256
Θ.3.1 Αναλλοιότητα κλίμακας στην Batch Normalization 256
Θ.3.2 Group Normalization 257
Θ.3.3 Απορρόφηση σε επόμενη συνέλιξη 257
Θ.4 Συγκεντρωτικά αποτελέσματα 257
Θ.4.1 Downstream ταξινόμηση ανά καθεστώς εποπτείας 257
Θ.4.2 Stress test υπό έντονο πρόσθετο θόρυβο (σ = 25) 258
Θ.4.3 Υπολογιστική πολυπλοκότητα (RTX 3060, batch = 1, 256 × 256) 258
Θ.5 Σύνθεση και περιορισμοί 259
ΠΑΡΑΡΤΗΜΑ Ι: Μαθηματική και Πειραματική Διατύπωση των Ταξινομητών Random Forest 260
Ι.1 Σκοπός και θέση στο pipeline 260
Ι.2 Δεδομένα, κλάσεις και συμβολισμοί 260
Ι.3 Τρεις εκδόσεις RF (ablation ladder) και feature vectors 261
Ι.3.1 RF metadata-only (naïve baseline, χωρίς pattern features) 261
Ι.3.2 RF pattern-only (baseline με 16 μορφολογικά features) 262
Ι.3.3 Hybrid RF (16 pattern + 6 priors = 22 features) 262
Ι.4 Κανονικοποίηση συχνότητας 263
Ι.5 Ορισμός frequency priors τύπου dist_mode_* (πυρήνας του Hybrid) 263
Ι.6 Random Forest: ορισμός, πρόβλεψη και κριτήριο split 264
Ι.7 Μετρικές και framing αξιολόγησης 265

Ι.8 Έλεγχοι αποφυγής διαρροής πληροφορίας (leakage) και QC 265

Ι.9 Αναπαραγωγιμότητα και συμπέρασμα 266

ΠΑΡΑΡΤΗΜΑ Κ: Μαθηματική και Μεθοδολογική Θεμελίωση της Βαθμονομημένης Γεννήτριας Συνθετικού Θορύβου ESPI 267

Κ.0 Σύνδεση με τον Κύριο Κορμό και Σύνοψη Μεθοδολογίας 267

Κ.1 Σύνδεση με τον κύριο κορμό της εργασίας 268

Κ.2 Σκοπός, συμβολισμοί και φυσικό μοντέλο παρατήρησης 268

Κ.3 Βαθμονόμηση της γεννήτριας από πραγματικά ζεύγη 270

Κ.4 Πρωτόκολλο αξιολόγησης και ρόλος του fixed probe 270

Κ.5 Μελέτη Αφαίρεσης υπό Ελεγχόμενη Σφοδρότητα (Severity-Controlled Ablation) και Ερμηνεία των Καθεστώτων Λειτουργίας 271

Κ.6 Μεθοδολογική αναπαραγωγιμότητα και v3.2 271

Κ.7 Σύνθεση και όρια εγκυρότητας 272

ΓΛΩΣΣΑΡΙ ΟΡΩΝ 273

Α. Οπτική Συμβολομετρία και ESPI 273

Β. Ακουστική, Δονήσεις και Ανάλυση Ιδιοσυχνοτήτων274Β. Ακουστική, Δονήσεις και Ανάλυση Ιδιομορφών 279

Γ. Μηχανική Μάθηση και Αξιολόγηση 275

ΑΝΑΛΥΤΙΚΗ ΒΙΒΛΙΟΓΡΑΦΙΑ 278

ΚΕΦΑΛΑΙΟ 1: ΕΙΣΑΓΩΓΗ

1.1 Πλαίσιο και Κίνητρο Έρευνας

1.1.1 Η Σημασία της Ανάλυσης Ιδιομορφών στα Μουσικά Όργανα

Τα μουσικά όργανα λειτουργούν ως σύνθετα μηχανικά συστήματα όπου η δομή και οι φυσικές τους ιδιότητες καθορίζουν ουσιαστικά την ακουστική τους απόκριση. Στα έγχορδα όργανα, το αντηχείο (soundboard) αποτελεί το πρωταρχικό ακουστικό στοιχείο που μετατρέπει τη μηχανική ενέργεια των ταλαντούμενων χορδών σε ηχητική ακτινοβολία. Κάθε αντηχείο χαρακτηρίζεται από ένα μοναδικό σύνολο ιδιομορφών ταλάντωσης (mode shapes)—δηλαδή χωρικών μορφών δόνησης που εκδηλώνονται σε συγκεκριμένες ιδιοσυχνότητες (natural frequencies). Αυτές οι ιδιομορφές αποτελούν τη φασματική υπογραφή του οργάνου και επηρεάζουν καθοριστικά τη δυναμική απόκρισή του σε διάφορες μουσικές νότες.

Η ανάλυση των ιδιομορφών δεν αποτελεί απλώς ένα ερευνητικό εργαλείο, αλλά και βασική πρακτική για την κατασκευή και συντήρηση οργάνων υψηλής ποιότητας. Οι κατασκευαστές μουσικών οργάνων αξιοποιούν την ανάλυση ιδιομορφών (modal analysis) για να βελτιστοποιήσουν το πάχος, τη γεωμετρία και την ενίσχυση του αντηχείου, επιτυγχάνοντας συγκεκριμένες ακουστικές απαιτήσεις. Παράλληλα, η μελέτη των ιδιομορφών επιτρέπει τη διάγνωση δομικών ελαττωμάτων, όπως ρωγμές ή ανομοιομορφίες στο υλικό, οι οποίες εμφανίζονται ως ανωμαλίες στα μορφολογικά πρότυπα δόνησης. Ειδικά το μπουζούκι αποτελεί ιδιαίτερα ενδιαφέρον αντικείμενο μελέτης, καθώς συνδυάζει σύνθετη γεωμετρία αντηχείου και υψηλή οργανοποιητική σημασία, με αποτέλεσμα ακόμη και μικρές δομικές μεταβολές να έχουν αισθητή ακουστική επίδραση.

1.1.2 Ηλεκτρονική Συμβολομετρία Κηλίδων (ESPI)

Η Ηλεκτρονική Συμβολομετρία Κηλίδων (Electronic Speckle Pattern Interferometry, ESPI) αποτελεί μια προηγμένη μη καταστρεπτική οπτική τεχνική που επιτρέπει τη λεπτομερή χαρτογράφηση των δονητικών πεδίων επιφανειών. Η μέθοδος βασίζεται στη συμβολή δύο σύμφωνων δεσμών laser: μιας δέσμης αναφοράς και μιας δέσμης αντικειμένου, οι οποίες συμβάλλουν στον ανιχνευτή και δημιουργούν ένα χαρακτηριστικό συμβολόγραμμα με σχηματισμό κροσσών συμβολής (fringe pattern). Στην περίπτωση της ESPI

χρονικού μέσου όρου (Time-averaged ESPI), όταν η επιφάνεια ταλαντώνεται αρμονικά σε μια συγκεκριμένη συχνότητα, οι κροσσοί αποτυπώνουν τις κομβικές γραμμές—δηλαδή τις περιοχές μηδενικής μετατόπισης—οι οποίες ορίζουν τη χωρική δομή της ιδιομορφής.

Η σημαντικότερη ιδιότητα του ESPI είναι η ικανότητα πλήρους κάλυψης του πεδίου (full-field measurement), η οποία επιτρέπει την ταυτόχρονη λήψη πληροφορίας από ολόκληρη την επιφάνεια του δοκιμίου σε μία μόνο απεικόνιση. Σε αντίθεση με τις μεθόδους σάρωσης ή τις επαφικές τεχνικές (όπως η δονομετρία laser με σάρωση σημείου προς σημείο), το ESPI καταγράφει την ιδιομορφή ολιστικά, μειώνοντας τον χρόνο μέτρησης και παρέχοντας υψηλή χωρική ανάλυση χωρίς την ανάγκη φυσικής επαφής με το όργανο.

Για την επικύρωση της προτεινόμενης μεθοδολογίας, τα πειραματικά δεδομένα και τα δοκίμια που αξιοποιούνται στην παρούσα εργασία προέρχονται από το ευρύτερο έργο «Carbon Fiber Bouzouki Design», στο οποίο κατασκευάστηκαν και μετρήθηκαν πρωτότυπα ξύλινων (W01–W03) και ανθρακονημάτινων (C01–C03) μπουζουκιών με ESPI, σε συνδυασμό με συμπληρωματικές ακουστικές μετρήσεις. Στο πλαίσιο της διπλωματικής δίνεται έμφαση στο υπολογιστικό σκέλος (επεξεργασία εικόνων και ταξινόμηση ιδιομορφών), ενώ η ύπαρξη ανθρακονημάτινων δοκιμίων αποτελεί φυσικό σενάριο μετατόπισης πεδίου (domain shift) για την αξιολόγηση της γενίκευσης.

1.1.3 Η Πρόκληση του Θορύβου Κηλίδων (Speckle Noise)

Παρά τα σημαντικά πλεονεκτήματα της τεχνικής ESPI, η εφαρμογή της περιορίζεται από ένα εγγενές φυσικό μειονέκτημα: τον έντονο πολλαπλασιαστικό **θόρυβο κηλίδων (speckle noise)**. Το φαινόμενο αυτό πηγάζει από τη σύμφωνη (coherent) φύση του φωτισμού laser. Κατά την αλληλεπίδραση του οπτικού κύματος με την τραχύτητα της επιφάνειας του δοκιμίου σε μικροσκοπική κλίμακα, δημιουργείται ένα τυχαίο, κοκκώδες μοτίβο συμβολής.

Συνέπεια αυτής της στοχαστικής διαμόρφωσης είναι η σημαντική μείωση του **λόγου σήματος προς θόρυβο (Signal-to-Noise Ratio, SNR)**, γεγονός που δυσχεραίνει τόσο την οπτική ερμηνεία όσο και την ακριβή εξαγωγή ποσοτικής πληροφορίας από τα παραγόμενα συμβολογράμματα.

Το πρόβλημα επιδεινώνεται σε ευαίσθητες μουσικές κατασκευές, όπου τα πλάτη δόνησης είναι συχνά μικρά και οι κροσσοί συμβολής λεπτοί και πυκνά κατανεμημένοι. Η παρουσία έντονου θορύβου κηλίδων οδηγεί σε ασαφείς ή διακοπτόμενες κομβικές γραμμές, καθιστώντας την οπτική ερμηνεία των συμβολογραμμάτων δύσκολη ακόμα και για έμπειρους ερευνητές. Αυτό το χαρακτηριστικό υπογραμμίζει την ανάγκη αξιόπιστων υπολογιστικών μεθόδων αποθορυβοποίησης (denoising) που διατηρούν τις λεπτομερείς δομές των κροσσών, οι οποίες είναι κρίσιμες για την ανάκτηση της φάσης και την επακόλουθη ταξινόμηση ιδιομορφών.

1.1.4 Η Ανάγκη για Αυτοματοποίηση

Η παραδοσιακή μέθοδος ανάλυσης ESPI εικόνων βασίζεται στη χειροκίνητη επιθεώρηση και ταξινόμηση από εξειδικευμένους τεχνικούς, οι οποίοι συγκρίνουν τα παρατηρούμενα μορφολογικά μοτίβα με γνωστά θεωρητικά πρότυπα ή εμπειρικές κατηγορίες. Αυτή η διαδικασία είναι χρονοβόρα, υποκειμενική και δεν κλιμακώνεται για εφαρμογές που απαιτούν ανάλυση μεγάλου όγκου δεδομένων. Για παράδειγμα, σε ένα τυπικό συχνοτικό σάρωμα ενός μουσικού οργάνου από 40 Hz έως 1500 Hz με βήμα 5 Hz, συλλέγονται εκατοντάδες εικόνες, εκ των οποίων μόνο ένα μικρό υποσύνολο αντιστοιχεί σε σαφώς ορισμένες ιδιομορφές.

Η αυτοματοποίηση της ταξινόμησης προσφέρει τη δυνατότητα επεξεργασίας πολλαπλών δοκιμίων σε σύντομο χρονικό διάστημα, εξάλειψης της υποκειμενικότητας και ομοιογενοποίησης των κριτηρίων ταξινόμησης. Επιπλέον, μια αυτοματοποιημένη μέθοδος μπορεί να ενσωματώσει φυσική γνώση—όπως οι αναμενόμενες συχνότητες εμφάνισης συγκεκριμένων ιδιομορφών ή η σχέση μεταξύ του αριθμού κομβικών γραμμών και της τάξης του mode—για να βελτιώσει την ακρίβεια και την ερμηνευσιμότητα των αποτελεσμάτων. Αυτή η προσέγγιση καθοδηγούμενη από τη φυσική (physics-informed) αποτελεί το κεντρικό στοιχείο της παρούσας εργασίας.

1.2 Ερευνητικό Πρόβλημα και Στόχοι

1.2.1 Διατύπωση του Προβλήματος

Η παρούσα διπλωματική εργασία αντιμετωπίζει το πρόβλημα της αυτοματοποιημένης ταξινόμησης ιδιομορφών από εικόνες ESPI σε μουσικά όργανα (συγκεκριμένα μπουζούκια). Το πρόβλημα χαρακτηρίζεται από πολλαπλές προκλήσεις:

1. **Υψηλός θόρυβος κηλίδων**: Το πολλαπλασιαστικό speckle noise υποβαθμίζει σημαντικά την ποιότητα των εικόνων.
2. **Πολύπλοκα μορφολογικά μοτίβα**: Οι ιδιομορφές παρουσιάζουν μεγάλη ποικιλία στον αριθμό και τη γεωμετρία των κομβικών γραμμών.
3. **Ισχυρή ανισορροπία κλάσεων**: Οι απλούστερες ιδιομορφές εμφανίζονται πολύ συχνότερα από τις πολύπλοκες (λόγος 30,9:1).
4. **Μετατόπιση πεδίου (domain shift)**: Τα δοκίμια διαφέρουν σημαντικά μεταξύ τους λόγω υλικού (ξύλο vs. ανθρακόνημα), κατασκευαστικής ποιότητας και φυσικών παραμέτρων.

Το κεντρικό ερευνητικό ερώτημα είναι: Πώς μπορεί η ενσωμάτωση πρότερων πληροφοριών θεμελιωμένων στη φυσική (physics-informed priors) να βελτιώσει την αυτόματη ταξινόμηση ιδιομορφών δόνησης από θορυβώδεις εικόνες ESPI;

1.2.2 Ερευνητικά Ερωτήματα

Η παρούσα διπλωματική εργασία επικεντρώνεται στη διερεύνηση πέντε κεντρικών ερευνητικών ερωτημάτων (Research Questions - RQ), τα οποία διατρέχουν ολόκληρο το μεθοδολογικό φάσμα: από τη συνθετική παραγωγή δεδομένων και την προεπεξεργασία, έως την εξαγωγή χαρακτηριστικών και την τελική ταξινόμηση.

- **RQ1: Επιρροή της Αποθορυβοποίησης στην Ταξινόμηση (Denoising for Downstream Tasks)** Ποιος μηχανισμός (βαθιά μάθηση έναντι χρονικού μέσου όρου) βελτιστοποιεί την ισορροπία μεταξύ της καταστολής του θορύβου κηλίδων και της διατήρησης της τοπολογίας των κροσσών (fringe fidelity), ώστε να μεγιστοποιηθεί η αξιοπιστία της τελικής ταξινόμησης;

- **RQ2: Στρατηγική Αντιμετώπισης Σπανιότητας Δεδομένων (Data Scarcity Strategy)** Σε ποιον βαθμό η παραγωγή ψευδο-θορυβωδών δεδομένων, καθοδηγούμενη από ένα φυσικό μοντέλο αλλοίωσης (physics-informed noise), μπορεί να υποκαταστήσει τα περιορισμένα πραγματικά δεδομένα για την αποτελεσματική εκπαίδευση βαθέων νευρωνικών δικτύων στην τεχνική ESPI;
- **RQ3: Ο Ρόλος του Μηχανισμού Προσοχής (Role of Channel Attention)** Ποια είναι η πραγματική επίδραση της ενσωμάτωσης μονάδων προσοχής καναλιών (ECA) στο δίκτυο αποθορυβοποίησης ως προς τη διατήρηση των δομικών λεπτομερειών, και πώς αυτή μεταφράζεται λειτουργικά (downstream) στην ακρίβεια του ταξινομητή;
- **RQ4: Η Αξία της Πρότερης Φυσικής Γνώσης (Physics-Informed Priors)** Πώς η ενσωμάτωση της συχνότητας διέγερσης ως ρητής φυσικής παραδοχής (physics prior) και η υβριδική σύζευξή της με τα οπτικά μορφολογικά χαρακτηριστικά επηρεάζει τη διαχωριστική ικανότητα, τη σταθερότητα και την ερμηνευσιμότητα του μοντέλου;
- **RQ5: Όρια Γενίκευσης και Ανθεκτικότητα (Generalization Boundaries)** Υπό ποιες προϋποθέσεις το σύστημα επιτυγχάνει στιβαρή γενίκευση σε αθέατες συχνότητες, και ποια είναι τα όρια ανθεκτικότητάς του (domain shift) όταν καλείται να αναγνωρίσει ιδιομορφές σε εντελώς άγνωστα δοκίμια.

1.2.3 Ερευνητικοί Στόχοι

Για την τεκμηριωμένη απάντηση των παραπάνω ερωτημάτων, η εργασία θέτει έξι διακριτούς ερευνητικούς στόχους:

1. **Ανάπτυξη Ροής Αποθορυβοποίησης (Denoising Pipeline):** Σχεδιασμός και υλοποίηση της αρχιτεκτονικής DnCNN (με και χωρίς μηχανισμούς ECA), με στόχο τη βέλτιστη μείωση του speckle χωρίς την ισοπέδωση των υψηλής συχνότητας δομικών στοιχείων των κροσσών.
2. **Αντιμετώπιση Έλλειψης Δεδομένων (Data Scarcity Mitigation):** Ανάπτυξη και αυστηρή εμπειρική βαθμονόμηση μιας γεννήτριας ψευδο-θορυβωδών δεδομένων, βασισμένης σε φυσικό μοντέλο, ικανής να παράγει ρεαλιστικά ζεύγη εκπαίδευσης.

3. **Εξαγωγή Χαρακτηριστικών Θεμελιωμένων στη Φυσική (Physics-Informed Extraction):** Υλοποίηση ενός υβριδικού συστήματος που συγκεράζει 16 μορφολογικούς περιγραφείς με 6 συχνοτικές παραδοχές, ενισχύοντας τη διακριτική ισχύ της αναπαράστασης.
4. **Συγκριτική Αξιολόγηση και Ερμηνευσιμότητα:** Αντιπαραβολή ερμηνεύσιμων δενδρικών ταξινομητών (Pattern-only και Hybrid Random Forest) με αρχιτεκτονικές αμιγώς δεδομενοκεντρικές (ResNet-18), εστιάζοντας στην υπολογιστική αποδοτικότητα και την ανάλυση σημαντικότητας χαρακτηριστικών (feature importance).
5. **Ποσοτικοποίηση της Γενίκευσης (Generalization Assessment):** Εφαρμογή εξειδικευμένων πρωτοκόλλων διασταυρούμενης επικύρωσης (LOBO, LODO) για τον αυστηρό έλεγχο της μεταφοράς μάθησης σε νέες συχνότητες και εντελώς νέα υλικά.
6. **Οριοθέτηση Πεδίου Εφαρμογής (Boundary Definitions):** Συστηματική καταγραφή των περιορισμών, των αρνητικών ευρημάτων (null results) και των περιπτώσεων αστοχίας (failure cases), ως θεμελιώδες στοιχείο επιστημονικής διαφάνειας και καθοδήγησης για τη μελλοντική έρευνα.

1.3 Συνεισφορά της Εργασίας

Η παρούσα διπλωματική εργασία συνεισφέρει ενεργά στη διεπαφή της Οπτικής Μετρολογίας με τη Μηχανική Μάθηση, οργανώνοντας την προστιθέμενη αξία της σε δύο βασικούς άξονες: τον μεθοδολογικό και τον πρακτικό.

1.3.1 Μεθοδολογικές Καινοτομίες

Η πρώτη κατηγορία συνεισφορών αφορά τον ίδιο τον πυρήνα της υπολογιστικής προσέγγισης, επιδιώκοντας τη στενή σύζευξη των αλγορίθμων μηχανικής μάθησης με τους αυστηρούς φυσικούς κανόνες που διέπουν το πρόβλημα. Ειδικότερα, οι μεθοδολογικές καινοτομίες της παρούσας μελέτης επικεντρώνονται σε δύο αλληλένδετους άξονες: την ανάπτυξη ενός νέου σχήματος ταξινόμησης και την αντιμετώπιση των πειραματικών περιορισμών μέσω της παραγωγής αξιόπιστων συνθετικών δεδομένων:

- **Πρόταση Υβριδικού Πλαισίου Ταξινόμησης (Hybrid Random Forest):** Αναπτύχθηκε μια πρωτότυπη αρχιτεκτονική η οποία συγκεράζει 16 μορφολογικούς περιγραφείς (εξαγόμενους μέσω μετασχηματισμού FFT από τις αποθορυβοποιημένες εικόνες) με 6 ρητές παραδοχές συχνότητας (frequency priors). Η συγκεκριμένη προσέγγιση επιτυγχάνει εξαιρετική συνολική ακρίβεια (97,85%) και δείκτη Macro-F1 (95,15%), υπερτερώντας συστηματικά τόσο των αμιγώς μορφολογικών όσο και των δεδομενοκεντρικών (CNN) προτύπων. Η καινοτομία της μεθόδου επικυρώνεται από την ανάλυση σημαντικότητας χαρακτηριστικών, η οποία απέδωσε το 96,86% της διακριτικής ικανότητας στα συχνοτικά δεδομένα, επιβεβαιώνοντας απόλυτα την υπεροχή των μοντέλων που καθοδηγούνται από τη φυσική (physics-informed).
- **Γεννήτρια Δεδομένων Βάσει Φυσικού Μοντέλου (Physics-Informed Data Generator):** Για την αντιμετώπιση της εγγενούς έλλειψης δεδομένων εκπαίδευσης, αναπτύχθηκε και βαθμονομήθηκε μια παραμετρική γεννήτρια ψευδο-θορυβωδών δεδομένων. Προσομοιώνοντας ρεαλιστικά την αλυσίδα παραγωγής του θορύβου στην οπτική συμβολομετρία (Speckle $\rightarrow$ Poisson $\rightarrow$ Gaussian), η γεννήτρια επέτρεψε την αποτελεσματική εκπαίδευση βαθέων δικτύων αποθορυβοποίησης, καταργώντας την ανάγκη για χρονοβόρες και κοστοβόρες καταγραφές χιλιάδων φυσικών πειραμάτων.

1.3.2 Πρακτικές και Ακουστικές Συνεισφορές

Πέρα από την αλγοριθμική του καινοτομία, η ουσιαστική αξία του συστήματος αναδεικνύεται στην πράξη. Λειτουργεί ως ένα προηγμένο εργαλείο μη καταστροφικού ελέγχου (NDT), το οποίο καταφέρνει να αποκωδικοποιεί τα κρίσιμα ακουστικά χαρακτηριστικά που ορίζουν την ηχητική ταυτότητα του οργάνου:

- **Αναγνώριση της Ακουστικής «Υπογραφής» (Κλάση 2,1):** Το πλέον αξιοσημείωτο πρακτικό εύρημα της ταξινόμησης είναι η επίτευξη απόλυτης ακρίβειας (100% F1-score) στη σπάνια κλάση (2,1), η οποία αντιστοιχεί μόλις στο 1,7% του συνόλου δεδομένων. Ακουστικά, η συγκεκριμένη ιδιομορφή καθορίζει την ευκρίνεια (definition) και την προβολή του ήχου στις μεσαίες συχνότητες, αποτελώντας τον βασικό δείκτη που διαχωρίζει ένα εξαιρετικό χειροποίητο όργανο από μια μέτρια

κατασκευή. Η στοχευμένη αναγνώριση αυτής της «μειονοτικής» κλάσης προσφέρει στους οργανοποιούς ένα αξιόπιστο κριτήριο ποιοτικού ελέγχου υψηλής στάθμης.

- **Διαχωρισμός Ακουστικής Λαμπρότητας από τον Υψίσυχνο Θόρυβο (Κλάση Higher):** Η αξιόπιστη ταξινόμηση της ευρείας κλάσης "Higher" (> 680 Hz) αποτελεί την αυστηρότερη δοκιμασία για τη στρατηγική αποθορυβοποίησης. Στο συγκεκριμένο φασματικό εύρος, η αυξημένη πυκνότητα ιδιομορφών παράγει εξαιρετικά λεπτοφυή χωρικά μοτίβα, τα οποία συχνά συγχέονται οπτικά με τον θόρυβο κηλίδων. Η ικανότητα του συστήματος να αποπλέκει (disentangle) το χρήσιμο σήμα, το οποίο προσδίδει τη χαρακτηριστική «λαμπρότητα» (brilliance) στο όργανο, από τον παρασιτικό θόρυβο, διασφαλίζει ότι η τελική αξιολόγηση βασίζεται σε πραγματικά φυσικά δεδομένα και όχι σε οπτικά τεχνουργήματα (artifacts).
- **Διασφάλιση της Ακουστικής Ισχύος (Θεμελιώδεις Κλάσεις 1,1):** Η ορθή αναγνώριση των κλάσεων της κατηγορίας (1,1) επιβεβαιώνει τη δομική ακεραιότητα της βάσης του ήχου. Η αξιοπιστία του μοντέλου σε αυτές τις χαμηλές συχνότητες λειτουργεί ως δικλείδα ασφαλείας, διασφαλίζοντας τον έγκαιρο εντοπισμό ηχείων με ανεπαρκή δομική απόκριση, τα οποία θα παρήγαγαν έναν ακουστικά αδύναμο ή «κούφιο» ήχο.

1.3.3 Επιστημονικές Διαπιστώσεις και Αρνητικά Ευρήματα

Ένα σημαντικό συμπέρασμα της εργασίας προέκυψε από την αξιολόγηση των μηχανισμών προσοχής. Πειραματικά, διαπιστώθηκε ότι η ενσωμάτωση των μονάδων **ECA (Efficient Channel Attention)** δεν προσέφερε ουσιαστική βελτίωση ούτε στην ποιότητα της εικόνας (PSNR) ούτε στην ακρίβεια της ταξινόμησης. Η ανάλυση έδειξε ότι αυτό οφείλεται στον ανταγωνισμό με την Κανονικοποίηση Δέσμης (Batch Normalization), η οποία τείνει να εξουδετερώνει τις λεπτές ρυθμίσεις βαρών που επιχειρεί το ECA. Το εύρημα αυτό είναι χρήσιμο καθώς αποτρέπει την άσκοπη αύξηση της πολυπλοκότητας του δικτύου σε παρόμοιες εφαρμογές.

Παράλληλα, η σύγκριση των μεθόδων αποθορυβοποίησης ανέδειξε ένα ενδιαφέρον παράδοξο: η παραδοσιακή μέθοδος της **Χρονικής Ολοκλήρωσης (Multi-frame Averaging)** απέδωσε ελαφρώς καλύτερα αποτελέσματα ταξινόμησης (89,09% Macro-F1) σε

σχέση με το βαθύ δίκτυο DnCNN (86,94%). Αυτό υποδηλώνει ότι, όταν οι συνθήκες το επιτρέπουν (στατικό πείραμα), οι κλασικές μέθοδοι διατηρούν καλύτερα τη φυσική πληροφορία των κροσσών απ' ό,τι η «επιθετική» επεξεργασία των νευρωνικών δικτύων.

1.3.4 Περιορισμοί και Όρια Γενίκευσης

Στο πλαίσιο της επιστημονικής διαφάνειας, καταγράφονται δύο βασικοί περιορισμοί που οριοθετούν την εμβέλεια της παρούσας μεθόδου:

Πρώτον, κατά τη δοκιμασία σε εντελώς άγνωστο όργανο (**πρωτόκολλο LOBO**), η απόδοση παρουσίασε διακυμάνσεις (91,83% ±8,9%). Η υψηλή τυπική απόκλιση φανερώνει ότι το μοντέλο παραμένει ευαίσθητο στα ιδιαίτερα χαρακτηριστικά κάθε κατασκευής (όπως το κούρδισμα ή η πυκνότητα του ξύλου), υποδεικνύοντας ότι απαιτείται μεγαλύτερη ποικιλομορφία δεδομένων εκπαίδευσης για να επιτευχθεί καθολική γενίκευση.

Δεύτερον, στο αυστηρότερο σενάριο αφαίρεσης μιας κατεύθυνσης μέτρησης (**πρωτόκολλο LODO**), παρατηρήθηκε σημαντική πτώση της ακρίβειας. Το αποτέλεσμα αυτό ήταν αναμενόμενο και επιβεβαιώνει την έντονη ανισοτροπία των μετρήσεων ESPI. Καταδεικνύει δε, ότι η γενίκευση σε επίπεδο φυσικής συμπεριφοράς δεν μπορεί να βασιστεί αποκλειστικά στην εικόνα (morphology), αλλά απαιτεί μελλοντικά την ενσωμάτωση βαθύτερης φυσικής γνώσης (physics priors) στην αρχιτεκτονική του δικτύου.

1.4 Δομή της Εργασίας

Η παρούσα διπλωματική εργασία οργανώνεται σε έξι κύρια κεφάλαια, έτσι ώστε να αναδεικνύεται με σαφήνεια ο βασικός ερευνητικός πυρήνας χωρίς εκτεταμένες παρεκβάσεις μελλοντοστραφούς χαρακτήρα. Η δομή αυτή επιτρέπει την ομαλή μετάβαση από τη φυσική θεμελίωση και τη μεθοδολογία, στα πειραματικά αποτελέσματα, τη σύνθεση και ερμηνεία τους, και την τελική αποτίμηση.

Κάθε κεφάλαιο συνεισφέρει αθροιστικά στην απάντηση του κεντρικού ερευνητικού ερωτήματος: πώς η ενσωμάτωση πρότερων πληροφοριών θεμελιωμένων στη φυσική (physics-informed priors) μπορεί να βελτιστοποιήσει την αυτόματη ταξινόμηση ιδιομορφών δόνησης από θορυβώδεις εικόνες ESPI.

Η διάρθρωση της εργασίας έχει ως εξής:

- **Κεφάλαιο 2: Θεωρητικό Υπόβαθρο.** Θεμελιώνεται η επιστημονική βάση της εργασίας στη φυσική των δονήσεων, στις αρχές της ESPI, στη φύση του θορύβου κηλίδων και στα πρωτόκολλα μηχανικής μάθησης και αξιολόγησης που χρησιμοποιούνται στη συνέχεια.
- **Κεφάλαιο 3: Μεθοδολογία.** Περιγράφεται η πειραματική διάταξη, η κατασκευή των συνόλων δεδομένων, η ανάπτυξη του αποθορυβοποιητή DnCNN-ECA, η εξαγωγή φάσης και χαρακτηριστικών, καθώς και η διαμόρφωση των μοντέλων ταξινόμησης και των πρωτοκόλλων επικύρωσης.
- **Κεφάλαιο 4: Αποτελέσματα.** Παρουσιάζονται τα κύρια πειραματικά αποτελέσματα για τη γεννήτρια ψευδο-θορύβου, την αποθορυβοποίηση, την εξαγωγή χαρακτηριστικών, τη συγκριτική αξιολόγηση των μοντέλων Random Forest και CNN, καθώς και οι έλεγχοι ανθεκτικότητας και γενίκευσης.
- **Κεφάλαιο 5: Συζήτηση και Ανάλυση Ευρημάτων.** Συντίθενται και ερμηνεύονται τα βασικά ευρήματα της εργασίας, με έμφαση στην ανισορροπία κλάσεων, στη γεννήτρια ψευδο-θορύβου που βασίζεται σε φυσικό μοντέλο, στον ρόλο της μονάδας ECA και στα όρια γενίκευσης που αναδείχθηκαν από τα πρωτόκολλα LOBO και LODO.
- **Κεφάλαιο 6: Συμπεράσματα.** Συνοψίζονται οι συνεισφορές της εργασίας, επανεξετάζονται τα ερευνητικά ερωτήματα, καταγράφονται οι περιορισμοί και οριοθετούνται οι βασικές, ρεαλιστικές μελλοντικές προεκτάσεις της παρούσας έρευνας.

Παραρτήματα

Η εργασία πλαισιώνεται από ένα συνοπτικό αλλά επαρκές σύνολο παραρτημάτων, τα οποία λειτουργούν ως πυλώνες τεκμηρίωσης, αναπαραγωγιμότητας και μαθηματικής αυστηρότητας.

- **Παράρτημα Α: Τεχνικές Λεπτομέρειες Υλοποίησης.** Αναλύει τις αρχιτεκτονικές των νευρωνικών δικτύων και τη δομή του διανύσματος των χαρακτηριστικών.
- **Παράρτημα Β: Παράμετροι Διαμόρφωσης.** Καταγράφει τις λεπτομέρειες του συνόλου δεδομένων και τις προδιαγραφές των πρωτοκόλλων LOBO/LODO.

- **Παράρτημα Γ: Λεπτομερή Αποτελέσματα.** Περιλαμβάνει τους πλήρεις πίνακες μετρικών, τους πίνακες σύγχυσης και τους στατιστικούς ελέγχους.
- **Παράρτημα Δ: Οδηγίες Αναπαραγωγιμότητας.** Παρέχει τις προδιαγραφές του περιβάλλοντος εκτέλεσης και τη ροή εργασίας για την επαλήθευση των αποτελεσμάτων.
- **Παράρτημα Ε: Θεωρητική Ανάλυση Αρχιτεκτονικών.** Εμβαθύνει στη σύγκριση μεταξύ της αποθορυβοποίησης βαθιάς μάθησης (deep denoising) και του χρονικού μέσου όρου, καθώς και στη λογική της προσέγγισης που είναι καθοδηγούμενη από τη φυσική.
- **Παράρτημα Ζ: Συμπληρωματικό Υλικό.** Συγκεντρώνει το συνοδευτικό υπολογιστικό και ερμηνευτικό υλικό για την ανάλυση σημαντικότητας των χαρακτηριστικών.
- **Παράρτημα Η: Μαθηματική Θεμελίωση.** Παρέχει την αυστηρή μαθηματική διατύπωση των φυσικών μοντέλων, των μετασχηματισμών FFT και των βασικών μετρικών και πρωτοκόλλων αξιολόγησης.
- **Παράρτημα Θ: Μελέτη Αφαίρεσης DnCNN-ECA — Μαθηματική Θεμελίωση και Εκτεταμένα Αποτελέσματα. Αναλύει τον ρόλο και τη συμβολή της μονάδας προσοχής στην ενίσχυση της ικανότητας αποθορυβοποίησης και την ανάδειξη των σημαντικών χαρακτηριστικών από το δίκτυο.**
- **Παράρτημα Ι: Μαθηματική και Πειραματική Διατύπωση των Ταξινομητών Random Forest.** Παρέχει πλήρη και αυτοτελή περιγραφή των ταξινομητών Random Forest και της θέσης τους στη ροή επεξεργασίας.
- **Παράρτημα Κ: Μαθηματική και Μεθοδολογική Θεμελίωση της Βαθμονομημένης Γεννήτριας Συνθετικού Θορύβου ESPI. Συγκεντρώνει τη λεπτομερή ανάπτυξη της αλυσίδας Speckle→Poisson→Gaussian, της βαθμονόμησης και των σχετικών πειραματικών πρωτοκόλλων για την ESPI.**

Γλωσσάρι και Βιβλιογραφία

- **Γλωσσάρι Όρων:** Ένας αναλυτικός οδηγός που αποσαφηνίζει και συσχετίζει την ορολογία από την οπτική συμβολομετρία, την ανάλυση ιδιομορφών και τη μηχανική μάθηση, διευκολύνοντας την ανάγνωση από αναγνώστες διαφορετικών ειδικοτήτων.
- **Αναλυτική Βιβλιογραφία:** Η εργασία ολοκληρώνεται με την αναλυτική βιβλιογραφία, η οποία οργανώνεται θεματικά ώστε να καλύπτει το διεπιστημονικό εύρος της έρευνας. Ιδιαίτερη έμφαση δίνεται στις κλασικές εργασίες για την ESPI και την ανάλυση κροσσών συμβολής, στη βιβλιογραφία της φυσικής των ιδιομορφών και των ανθρακονημάτων, καθώς και στις βασικές αναφορές για το DnCNN, το ResNet, τα Random Forest και τη στατιστική αξιολόγηση.

ΚΕΦΑΛΑΙΟ 2: ΘΕΩΡΗΤΙΚΟ ΥΠΟΒΑΘΡΟ

2.1 Η ανάγκη για Μηχανική Μάθηση στην αυτόματη ταξινόμηση ιδιόμορφών δόνησης

Στο εργαστήριο, η αναγνώριση των ιδιόμορφών δόνησης (modes) πραγματοποιείται παραδοσιακά με οπτική επιθεώρηση των time-averaged εικόνων ESPI: ένας ειδικός εξετάζει τη μορφολογία των κροσσών (fringes), τον αριθμό/προσανατολισμό των κομβικών γραμμών (nodal lines) και τη συμμετρία του μοτίβου, και αποδίδει την εικόνα σε μία κλάση ιδιομορφής. Αυτή η διαδικασία αποτελεί ένα ισχυρό «ανθρώπινο πρότυπο αναφοράς», επειδή αξιοποιεί άμεσα τη φυσική ερμηνεία του μοτίβου. Ωστόσο, καθώς το μέγεθος του συνόλου δεδομένων αυξάνει και καθώς εμφανίζονται μεταβολές συνθηκών (διαφορετικά δοκίμια/όργανα, διαφορετικά υλικά ή επίπεδα θορύβου), η χειροκίνητη ταξινόμηση γίνεται δύσκολη να κλιμακωθεί, δύσκολη να αναπαραχθεί και δύσκολη να τεκμηριωθεί πλήρως. Ο στόχος της παρούσας εργασίας είναι να μετατρέψει αυτή τη γνώση σε ένα σύστημα αυτόματης ταξινόμησης που να είναι (α) επαναλήψιμο, (β) μετρήσιμο, και (γ) ικανό να γενικεύει πέρα από τις αρχικές συνθήκες μέτρησης, χωρίς να «χάνει» τη φυσική ερμηνεία που κάνει τον άνθρωπο αποτελεσματικό.

Η μηχανική μάθηση (machine learning, ML) προσφέρει το τυπικό πλαίσιο για να μοντελοποιηθεί ένας κανόνας απόφασης από δεδομένα παρατήρησης: ένα μοντέλο μαθαίνει από παραδείγματα (εικόνα ESPI, ετικέτα τρόπου) και στη συνέχεια προβλέπει την ετικέτα νέων εικόνων. Στη διπλωματική αυτή, το ML δεν χρησιμοποιείται ως «μαύρο κουτί», αλλά ως εργαλείο που συνδυάζεται με ενσωματωμένη φυσική γνώση, ώστε η απόφαση να στηρίζεται σε αναγνώσιμα, φυσικά ερμηνεύσιμα σήματα (π.χ. μορφολογία μοτίβου και συχνοτική πληροφορία). Αυτή η επιλογή διαφοροποιεί την εργασία από μια καθαρά data-driven προσέγγιση και αποτελεί το κεντρικό αφήγημα των Κεφαλαίων 3–8.

2.1.1 Η ανθρώπινη ταξινόμηση ως μοντέλο αναφοράς (baseline) στο εργαστήριο

Η χειροκίνητη ταξινόμηση βασίζεται σε ένα σύνολο από διαισθητικούς αλλά ουσιαστικά φυσικούς κανόνες. Ο ειδικός αναγνωρίζει (i) τον αριθμό και τη γεωμετρία των κομβικών γραμμών, (ii) την κατανομή των κοιλιών (lobes/antinodes), και (iii) τη συνολική «πολυπλοκότητα» του μοτίβου, η οποία αυξάνει γενικά με την τάξη του τρόπου. Σε πολλές

περιπτώσεις χρησιμοποιείται επικουρικά και η συχνότητα διέγερσης, επειδή το mapping τρόπου–συχνότητας ακολουθεί ισχυρούς φυσικούς περιορισμούς.

Η πρακτική αξία αυτού του προτύπου αναφοράς είναι διπλή: αφενός δείχνει ότι υπάρχει πραγματική πληροφορία στις εικόνες (δεν είναι «τυχαίος θόρυβος»), αφετέρου δείχνει ποια είδη οπτικής πληροφορίας είναι πιθανό να είναι σημαντικά για ένα υπολογιστικό σύστημα (π.χ. fringe density, συμμετρίες, topology). Στη συνέχεια (βλ. §2.7 και Κεφάλαιο 4), αυτά τα κριτήρια μεταφράζονται σε μετρήσιμα χαρακτηριστικά (features).

2.1.2 Περιορισμοί της Χειροκίνητης Ταξινόμησης

Αν και η ανθρώπινη ταξινόμηση παραμένει λειτουργική σε περιορισμένα σύνολα δεδομένων, η εφαρμογή της σε ευρεία κλίμακα παρουσιάζει εγγενείς αδυναμίες που υπονομεύουν τη συστηματική έρευνα και την εξαγωγή γενικεύσιμων συμπερασμάτων. Οι κυριότεροι περιορισμοί συνοψίζονται ως εξής:

- **Κλιμάκωση (Scalability):** Η επεξεργασία χιλιάδων εικόνων καθίσταται χρονοβόρα και ψυχοφθόρα, αυξάνοντας την πιθανότητα σφάλματος λόγω κόπωσης και εισάγοντας μη ελεγχόμενη μεταβλητότητα (inconsistency) μεταξύ διαφορετικών συνεδριών ταξινόμησης.

- **Υποκειμενικότητα και Δια-αξιολογητική Συμφωνία (Inter-rater Reliability):** Η ανθρώπινη κρίση είναι επιρρεπής σε διαφωνίες, ιδιαίτερα σε οριακές περιπτώσεις όπου οι κομβικές γραμμές είναι αχνές ή παρατηρείται επικάλυψη ιδιομορφών (modal overlap). Η απουσία στατιστικής αποτίμησης της συμφωνίας μεταξύ κριτών (π.χ. μέσω δείκτη Cohen’s κ) καθιστά τα αποτελέσματα λιγότερο στιβαρά.

- **Αναπαραγωγιμότητα και Ιχνηλασιμότητα:** Οι άτυποι κανόνες απόφασης σπάνια καταγράφονται με συστηματικό τρόπο. Ως αποτέλεσμα, δεν είναι πάντα σαφές ποια κριτήρια εφαρμόστηκαν για την κατάταξη αμφίβολων δειγμάτων, γεγονός που δυσχεραίνει την επαλήθευση και την πιστή αναπαραγωγή της διαδικασίας από τρίτους ερευνητές.

- **Μετατόπιση Πεδίου (Domain Shift):** Οι μεταβολές στο δοκίμιο (π.χ. W01–W03), στο υλικό κατασκευής (ξύλο → ανθρακόνημα) ή στην ποιότητα των

δεδομένων (averaged → noisy single-frame) αλλοιώνουν τόσο τη συχνοτική θέση όσο και τη μορφολογία των κροσσών. Σε αυτές τις συνθήκες, καθίσταται εξαιρετικά δύσκολο να ποσοτικοποιηθεί αντικειμενικά η προσαρμοστικότητα της ανθρώπινης κρίσης και να συγκριθούν μετρήσιμα οι στρατηγικές αντιμετώπισης.

- **Ανάγκη Αντικειμενικής Σύγκρισης Μεθόδων:** Η παρούσα διπλωματική εργασία αξιολογεί συγκριτικά πολλαπλές τεχνικές προσεγγίσεις (Pattern-only vs Hybrid, Multi-frame vs Deep Denoising, RF vs CNN). Μια τέτοια αξιολόγηση απαιτεί αυτοματοποιημένες διαδικασίες με σταθερά πρωτόκολλα και αμερόληπτες μετρικές (π.χ. Macro-F1 σε ανισόρροπα δεδομένα), οι οποίες δεν μπορούν να εξασφαλιστούν μέσω χειροκίνητης καταγραφής.

2.1.3 Αντικείμενο και Εύρος της Αυτοματοποίησης

Στο πλαίσιο της παρούσας εργασίας, η αυτοματοποίηση ορίζεται ως η διαδικασία αλγοριθμικής χαρτογράφησης μιας πειραματικής καταγραφής ESPI στην αντίστοιχη κλάση τρόπου ταλάντωσης (mode). Μαθηματικά, το πρόβλημα διατυπώνεται ως η προσέγγιση μιας συνάρτησης ταξινόμησης f: $\mathcal{X} \rightarrow \mathcal{Y}$, όπου το διάνυσμα εισόδου $\mathbf{x} \in \mathcal{X}$ αντιπροσωπεύει την επεξεργασμένη time-averaged εικόνα (ή τα εξαγόμενα χαρακτηριστικά της) και $y \in \mathcal{Y}$ την ετικέτα της αναγνωρισμένης ιδιομορφής.

Η ανάλυση στο κύριο σώμα της διπλωματικής εργασίας (Κεφάλαια 2–8) εστιάζει αποκλειστικά στο σχήμα των 6 κλάσεων, καλύπτοντας το πλήρες φασματικό εύρος των παρατηρούμενων ιδιομορφών. Συμπληρωματικά, στο μελλοντική ερευνητική κατεύθυνση (έκδοση v6.1+), παρουσιάζεται μια παραλλαγή 5 κλάσεων, η οποία προέκυψε ως βιομηχανική προέκταση (deployment version) μέσω της συγχώνευσης ή απαλοιφής μη αντιπροσωπευτικών κατηγοριών.

Η μεθοδολογική ροή εργασίας (pipeline) αναλύεται διεξοδικά στα επόμενα κεφάλαια και διαρθρώνεται στα εξής διακριτά στάδια:

- **Λήψη (Acquisition):** Συλλογή δεδομένων ESPI χρονικού μέσου όρου σε στοχευμένες συχνότητες διέγερσης.

- **Προεπεξεργασία (Preprocessing):** Εφαρμογή ελέγχων ποιότητας και τεχνικών βελτίωσης σήματος, με το *multi-frame averaging* να λειτουργεί ως το «φυσικό» πρότυπο αναφοράς (reference baseline).

- Αναπαράσταση (Representation): Εξαγωγή ενός υβριδικού διανύσματος 22 χαρακτηριστικών, το οποίο συνθέτει 16 μορφολογικούς δείκτες (pattern features) και 6 πρότερες συχνοτικές πληροφορίες θεμελιωμένες στη φυσική (frequency priors). Παράλληλα, εξετάζεται συγκριτικά η χρήση Συνελικτικών Νευρωνικών Δικτύων (CNN) για μάθηση End-to-End.

- **Εκπαίδευση και Αξιολόγηση (Training & Evaluation):** Εφαρμογή αυστηρών πρωτοκόλλων διασταυρούμενης επικύρωσης για τον έλεγχο της γενίκευσης σε άγνωστες συχνότητες (**LOBO**) και άγνωστα δοκίμια (**LODO**), αξιοποιώντας μετρικές κατάλληλες για ανισόρροπα δεδομένα (Macro-F1).

- **Ερμηνεία (Interpretation):** Τεκμηρίωση της συμβολής της φυσικής γνώσης μέσω ανάλυσης σημαντικότητας χαρακτηριστικών (feature importance) και στατιστικών ελέγχων (ablation studies).

Μέσω της προτεινόμενης μεθοδολογίας, η παραδοσιακά υποκειμενική εργαστηριακή ερμηνεία μετασχηματίζεται σε μια αυστηρά τυποποιημένη και ποσοτικά επαληθεύσιμη διαδικασία. Η εγκυρότητα της προσέγγισης θεμελιώνεται στα στιβαρά πειραματικά ευρήματα του κύριου συνόλου δεδομένων ( ), όπου, παρά την ακραία ανισορροπία κλάσεων (λόγος 30,9:1), η στρατηγική ενσωμάτωση των φυσικών περιορισμών αποδείχθηκε καθοριστική. Συγκεκριμένα, η υιοθέτηση του αλγορίθμου Hybrid Random Forest επέφερε θεαματική αύξηση της μετρικής Macro-F1 κατά 25,24 ποσοστιαίες μονάδες (από 69,91% στο αμιγώς μορφολογικό μοντέλο σε 95,15%), με τη συνολική ακρίβεια να αγγίζει το 97,85%. Τα αποτελέσματα αυτά δεν πιστοποιούν απλώς την υπεροχή του υβριδικού μοντέλου, αλλά παρέχουν ισχυρή εμπειρική απόδειξη ότι η αναπαράσταση «καθοδηγούμενη από τη φυσική» (physics-informed) αποτελεί τη βέλτιστη στρατηγική για την αποκωδικοποίηση της σύνθετης δομής του προβλήματος, γεφυρώνοντας το χάσμα μεταξύ της φυσικής θεωρίας και της μηχανικής μάθησης.

Πίνακας 2.1: *Συγκριτική αποτίμηση Χειροκίνητης Ταξινόμησης έναντι Αυτοματοποιημένης Προσέγγισης*

Διάσταση Αξιολόγησης	**Χειροκίνητη Ταξινόμηση (Baseline)**	**ML Σύστημα (Προτεινόμενο)**	**Σημασία για τη Διπλωματική**
Ταχύτητα / Κλίμακα	Περιορισμένη από τον χρόνο του εμπειρογνώμονα.	Μαζική επεξεργασία (batch inference) σε πραγματικό χρόνο.	Επιτρέπει τη σύγκριση πολλαπλών πειραμάτων και ablation studies.
Συνέπεια	Ευάλωτη σε υποκειμενικότητα και κόπωση.	Σταθερός, αμερόληπτος κανόνας απόφασης.	Διασφαλίζει αναπαραγωγιμότητα και δίκαιη αξιολόγηση.
Τεκμηρίωση	Δυσχερής η πλήρης ιχνηλάτηση των κριτηρίων απόφασης.	Πλήρης καταγραφή μετρικών και πρωτοκόλλων.	Παροχή στατιστικών ελέγχων και διαστημάτων εμπιστοσύνης.
Γενίκευση	Εμπειρική, δύσκολα ποσοτικοποιήσιμη.	Ελεγχόμενη μέσω LOBO/LODO για μετατόπιση πεδίου.	Ποσοτική μέτρηση της αντοχής σε νέες συχνότητες και δοκίμια.
Ερμηνευσιμότητα	Υψηλή (διαισθητική φυσική εξήγηση).	Υψηλή (μέσω physics-informed features).	Χρήση της σημαντικότητας χαρακτηριστικών ως επιστημονικό επιχείρημα.

2.2 Φυσική δονήσεων και δομή καπακιού (soundboard): θεμελίωση της ανάλυσης ιδιομορφών (modal analysis)

Η παρούσα ενότητα εισάγει το φυσικό υπόβαθρο που απαιτείται για να ερμηνευτούν οι ιδιομορφές (mode shapes) και οι ιδιοσυχνότητες ενός καπακιού/αντηχείου, καθώς και ο τρόπος με τον οποίο η γεωμετρία, οι συνοριακές συνθήκες και οι ιδιότητες του υλικού καθορίζουν τη δομή των παρατηρούμενων μοτίβων. Η κατανόηση αυτή είναι κρίσιμη για τη διπλωματική διότι: (α) θεμελιώνει γιατί η πληροφορία συχνότητας αποτελεί ισχυρό prior για την ταυτότητα ενός mode, (β) εξηγεί γιατί οι χωρικές μορφολογίες (κομβικές γραμμές/κοιλίες) παραμένουν διακριτικές ακόμη και σε θόρυβο και μεταβολές πειραματικής διάταξης, και (γ) προετοιμάζει τη συζήτηση domain shift σε αλλαγές δοκιμίου/οργάνου και υλικού (ξύλο έναντι ανθρακονημάτων).

2.2.1 Ανάλυση ιδιομορφών (modal analysis): ορισμοί και βασικές έννοιες

Στη γραμμική ελαστική περιοχή και για μικρά πλάτη ταλάντωσης, η δυναμική ενός μηχανικού συστήματος μπορεί να προσεγγιστεί από ένα ιδιοπρόβλημα, όπου οι ιδιομορφές αντιστοιχούν σε «φυσικούς τρόπους ταλάντωσης» με συγκεκριμένες ιδιοσυχνότητες. Στη διακριτοποιημένη (π.χ. FEM) μορφή, το πρόβλημα γράφεται τυπικά ως:

$$\boldsymbol{K\,\varphi = \omega^2\, M\,\varphi} \qquad (2.1)$$

όπου K ο πίνακας δυσκαμψίας, M ο πίνακας μάζας, φ το ιδιοδιάνυσμα (μορφή δόνησης) και ω η κυκλική ιδιοσυχνότητα (ω = 2πf). Οι ιδιομορφές είναι ορθογώνιες ως προς τον M (mass-orthogonality), γεγονός που επιτρέπει τη modal υπέρθεση: η συνολική απόκριση μπορεί να γραφτεί ως άθροισμα επιμέρους modal συνιστωσών (Ewins, 2000).

Για τις ανάγκες της παρούσας εργασίας, η έννοια «mode» συνδέεται άμεσα με δύο παρατηρήσιμες οντότητες:

- Το χωρικό μοτίβο μετατόπισης/πλάτους: κομβικές γραμμές (nodes) και κοιλίες (antinodes).
- Τη συχνότητα στην οποία το μοτίβο εμφανίζεται ισχυρότερα (σε forced response, κοντά σε συντονισμό).

Στην πειραματική πραγματικότητα ενός καπακιού οργάνου, οι «καθαρές» ιδιομορφές δεν παρατηρούνται απομονωμένα. Η διέγερση είναι εξαναγκασμένη (forced) και το

σύστημα έχει απόσβεση και σύζευξη με άλλα υποσυστήματα. Παρόλα αυτά, κοντά σε μια ιδιοσυχνότητα η απόκριση κυριαρχείται συνήθως από έναν ή λίγους γειτονικούς τρόπους, οπότε η εικόνα ESPI χρονικού μέσου όρου μπορεί να αντιμετωπιστεί ως proxy του αντίστοιχου mode shape (Fletcher & Rossing, 1998; Rossing, 2007).

2.2.2 Θεωρία λεπτών πλακών και (m,n) modes: από το ιδανικό στο πραγματικό καπάκι

Ένα πρώτο θεωρητικό μοντέλο για το καπάκι είναι η «λεπτή πλάκα», όπου το πάχος h είναι μικρό σε σχέση με τις χαρακτηριστικές διαστάσεις (Kirchhoff–Love plate theory). Για ισότροπες πλάκες, η γενική εξίσωση κίνησης και η καμπτική δυσκαμψία D ορίζονται αντίστοιχα ως:

$$\boldsymbol{D\nabla^4 w + \rho h \frac{\partial^2 w}{\partial t^2} = 0} \qquad (2.2)$$

$$\boldsymbol{D = \frac{E h^3}{12(1-\nu^2)}} \qquad (2.3)$$

όπου E είναι το μέτρο ελαστικότητας (Young's modulus), ν ο λόγος Poisson, ρ η πυκνότητα του υλικού και w η εγκάρσια μετατόπιση.

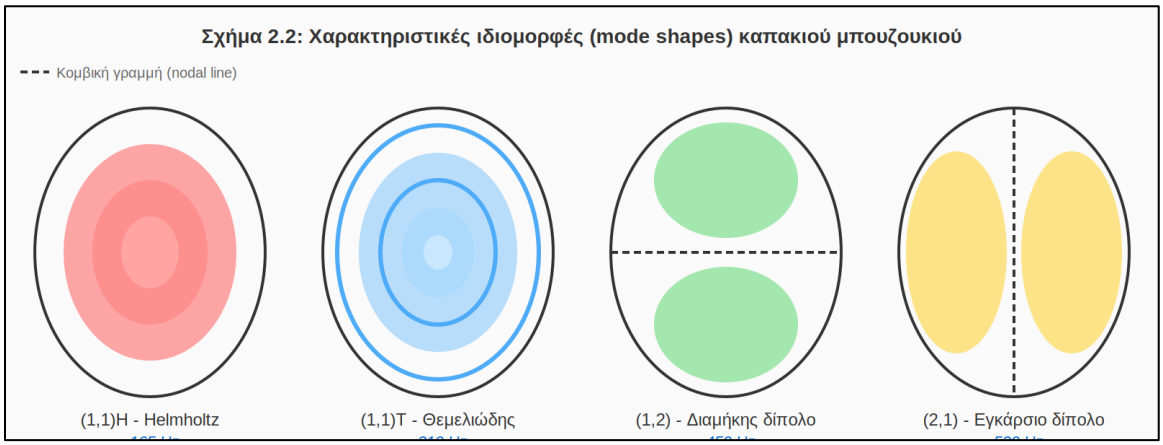
Για μια ορθογώνια πλάκα με απλά στηρίγματα, οι ιδιομορφές μπορούν να εκφραστούν (ιδανικά) με συναρτήσεις ημιτόνου και να ταξινομηθούν από δύο ακέραιους δείκτες (m,n) που αντιστοιχούν στον αριθμό των ημιπεριόδων κατά τις δύο κύριες διευθύνσεις. Η (προσεγγιστική) σχέση των ιδιοσυχνοτήτων f_{mn} παίρνει τη μορφή:

$$\boldsymbol{f_{mn} = \frac{\pi}{2}\sqrt{\frac{D}{\rho h}}\left(\frac{m^2}{a^2} + \frac{n^2}{b^2}\right)} \qquad (2.4)$$

με ρ την πυκνότητα και a, b τις πλευρές της πλάκας (Timoshenko & Woinowsky-Krieger, 1959; Leissa, 1969). Παρότι ένα πραγματικό μουσικό καπάκι (ιδίως με καμάρια και ενισχύσεις) αποκλίνει από το ιδανικό, η λογική των «διακριτών χωρικών μορφών» και η έννοια της τάξης (χαμηλής / μεσαίας / υψηλής) παραμένουν θεμελιώδεις.

Στην πράξη, η γεωμετρία του καπακιού, οι οπές/διακοπές, οι εσωτερικές ενισχύσεις και οι σύνθετες στηρίξεις δημιουργούν μικτές συνοριακές συνθήκες. Αυτό οδηγεί σε:

- μετατοπίσεις των ιδιοσυχνοτήτων σε σχέση με το ιδανικό θεωρητικό μοντέλο,
- τοπικές παραμορφώσεις και καμπυλώσεις των κομβικών γραμμών (nodal lines), και
- σύζευξη ιδιομορφών (mode coupling) και λύσιμο των θεωρητικών συμμετριών, με αποτέλεσμα την εμφάνιση πιο περίπλοκων ασύμμετρων μοτίβων ταλάντωσης.



Σχήμα 2.2: *Ενδεικτικές ιδανικές μορφές χαμηλής τάξης (π.χ. (1,1), (1,2), (2,1)) ως πρότυπα τοπολογίας.*

2.2.3 Ορθοτροπία ξύλου, ανομοιογένεια και συνοριακές συνθήκες: γιατί τα modes «σπάνε» και γιατί η τοπολογία επιμένει

Το ξύλο είναι έντονα ανισότροπο υλικό: οι μηχανικές του ιδιότητες διαφέρουν σημαντικά κατά τη διεύθυνση των ινών (longitudinal), την ακτινική (radial) και την εφαπτομενική (tangential). Σε πρώτο επίπεδο, αυτό σημαίνει διαφορετικά μέτρα ελαστικότητας E_L, E_R, E_T και διαφορετικά μέτρα διάτμησης, άρα και διαφορετικές ταχύτητες κύματος/δυσκαμψίες κατά διεύθυνση (Bucur, 2006). Σε όρους θεωρίας πλακών, η ορθοτροπία αντικαθιστά το scalar D με μια καμπτική «μήτρα» δυσκαμψιών (D11, D22, D12, D66), η οποία οδηγεί σε φαινόμενα όπως splitting κοντινών modes και μετατόπιση κομβικών γραμμών προς τη «σκληρότερη» διεύθυνση (Reddy, 2007; Leissa, 1969).

Επιπλέον, τα καπάκια οργάνων δεν είναι ομογενείς πλάκες: φέρουν ενισχύσεις (bracing), καμάρια, τοπικές μεταβολές πάχους, κολλήσεις και περιοχές ισχυρής συγκράτησης (π.χ. περιμετρικό δέσιμο). Οι συνοριακές συνθήκες κυμαίνονται από «σχεδόν

ελεύθερες» σε τμήματα ακμών έως «σχεδόν πακτωμένες» σε περιοχές επαφής με σκάφος/πλαίσιο. Το αποτέλεσμα είναι ότι:

1. οι απόλυτες συχνότητες είναι ευαίσθητες σε λεπτομέρειες υλικού/στήριξης,
2. οι μορφές μεταβάλλονται τοπικά, αλλά
3. η βασική τοπολογία (πόσες κύριες κοιλίες, πού βρίσκονται οι κυρίαρχες κομβικές γραμμές) τείνει να διατηρείται για τους χαμηλούς τρόπους, εφόσον η γεωμετρία και οι κύριες στηρίξεις παραμένουν συγκρίσιμες.

Αυτό είναι καθοριστικό για τη στρατηγική της διπλωματικής: τα «pattern features» στοχεύουν σε τοπολογικές/γεωμετρικές ιδιότητες (π.χ. συμμετρίες, κομβική πολυπλοκότητα, πυκνότητα κροσσών) που παραμένουν σταθερότερες από μικρο-αλλαγές στην υφή ή στο speckle. Παράλληλα, η ισχυρή εξάρτηση της ιδιοσυχνότητας από τοπικές ιδιότητες εξηγεί γιατί το domain shift ανά workpiece (LODO) είναι δύσκολο τεστ: το «ίδιο» mode μπορεί να εμφανιστεί σε ελαφρώς διαφορετικό εύρος συχνοτήτων μεταξύ διαφορετικών σανίδων.

2.2.4 Συζευγμένο σύστημα (χορδή-καβαλάρης-καπάκι-αέρας): από ιδιομορφές σε πραγματική ακουστική συμπεριφορά

Σε ένα έγχορδο όργανο, το καπάκι δεν ταλαντώνεται ως απομονωμένη πλάκα. Η διέγερση μεταφέρεται από τις χορδές στον καβαλάρη και από εκεί στο καπάκι, ενώ το καπάκι ακτινοβολεί ενέργεια στον αέρα και συζεύγνυται με την κοιλότητα του σκάφους. Το σύστημα, επομένως, είναι ένα σύνολο συζευγμένων ταλαντωτών (strings → bridge → plate → air cavity), όπου η παρατηρούμενη απόκριση εξαρτάται από:

- τη μηχανική αντίσταση/κινητικότητα (mobility) του καβαλάρη και του καπακιού,
- την ακτινοβολούμενη απόσβεση (radiation damping) και το «air loading», και
- τις συντονίσεις της κοιλότητας (π.χ. τύπου Helmholtz) και τη σύζευξή τους με modes της πλάκας (Fletcher & Rossing, 1998; Rossing, 2007).

Για τις ανάγκες της ESPI μελέτης, αυτό σημαίνει ότι η εικόνα σε μια δεδομένη συχνότητα διέγερσης είναι forced response εικόνα. Εντούτοις, όταν το σύστημα διεγείρεται

κοντά σε μια ιδιοσυχνότητα, η χωρική μορφή της απόκρισης προσεγγίζει ισχυρά την αντίστοιχη ιδιομορφή του καπακιού (με πιθανή συνεισφορά σύζευξης). Άρα, η ταξινόμηση modes από time-averaged ESPI maps παραμένει φυσικά θεμελιωμένη, ακόμη κι αν το πείραμα δεν είναι «καθαρό» modal test.

Η συζευγμένη φύση του προβλήματος εξηγεί επίσης γιατί η συχνότητα είναι ισχυρή αλλά όχι απόλυτη πληροφορία: η σύζευξη μπορεί να μετακινήσει ελαφρώς τις ιδιοσυχνότητες και να ενισχύσει/αποδυναμώσει συγκεκριμένους τρόπους. Αυτό είναι ένας από τους λόγους που η διπλωματική προτιμά «soft priors» (χαρακτηριστικά συχνότητας/αποστάσεων) αντί για αυστηρούς κανόνες κατωφλιών.

2.2.5 Υλική Ετερογένεια και Φασματική Μετατόπιση: Ξύλο έναντι Ανθρακονημάτων

Η αλλαγή του υλικού κατασκευής συνιστά μια χαρακτηριστική περίπτωση **μετατόπισης πεδίου (domain shift)** στη φυσική συμπεριφορά του αντηχείου. Τα σύνθετα υλικά, όπως τα πολυμερή ενισχυμένα με ανθρακονήματα (CFRP), χαρακτηρίζονται από ριζικά διαφορετικό λόγο δυσκαμψίας προς πυκνότητα (stiffness-to-mass ratio) σε σύγκριση με το παραδοσιακό ξύλο ελάτης. Στην παρούσα εργασία, η μετάβαση αυτή εξετάζεται στα πρωτότυπα W01–W03 και C01–C03 του έργου «Carbon Fiber Bouzouki Design».

Σύμφωνα με τη θεωρία δονήσεων πλακών, οι ιδιοσυχνότητες (f_n) κλιμακώνονται αναλογικά με τη ρίζα της **ειδικής δυσκαμψίας**. Σε μια πρώτη προσέγγιση, διατηρώντας τη γεωμετρία και το πάχος σταθερά, η σχέση κλιμάκωσης δίνεται από:

$$\boldsymbol{f} \propto \sqrt{\frac{\boldsymbol{D}}{\boldsymbol{\rho}\, \boldsymbol{h}}} \approx \sqrt{\frac{\boldsymbol{E}}{\boldsymbol{\rho}}} \qquad (2.5)$$

όπου E το μέτρο ελαστικότητας και ρ η πυκνότητα (Timoshenko & Woinowsky-Krieger, 1959; Wegst, 2006).

Πειραματική Παρατήρηση:

Στο πλαίσιο της παρούσας εργασίας, η μετάβαση από ξύλινα καπάκια σε ανθρακονήματα συνοδεύεται από συστηματική **φασματική ολίσθηση (spectral shift)** προς υψηλότερες τιμές. Παρατηρήθηκε ένας ενδεικτικός συντελεστής κλιμάκωσης της τάξης του **~2.1**× για ομόλογες ιδιομορφές.

Το κρίσιμο εύρημα, ωστόσο, είναι η **διατήρηση της τοπολογίας (topology preservation)**: παρότι οι απόλυτες συχνότητες μετατοπίζονται δραματικά, η χωρική κατανομή των κομβικών γραμμών και των κοιλιών καθορίζεται πρωτίστως από τη γεωμετρία και τις οριακές συνθήκες. Συνεπώς, τα mode shapes —ιδίως στις χαμηλές τάξεις— παραμένουν μορφολογικά αναλλοίωτα (invariant).

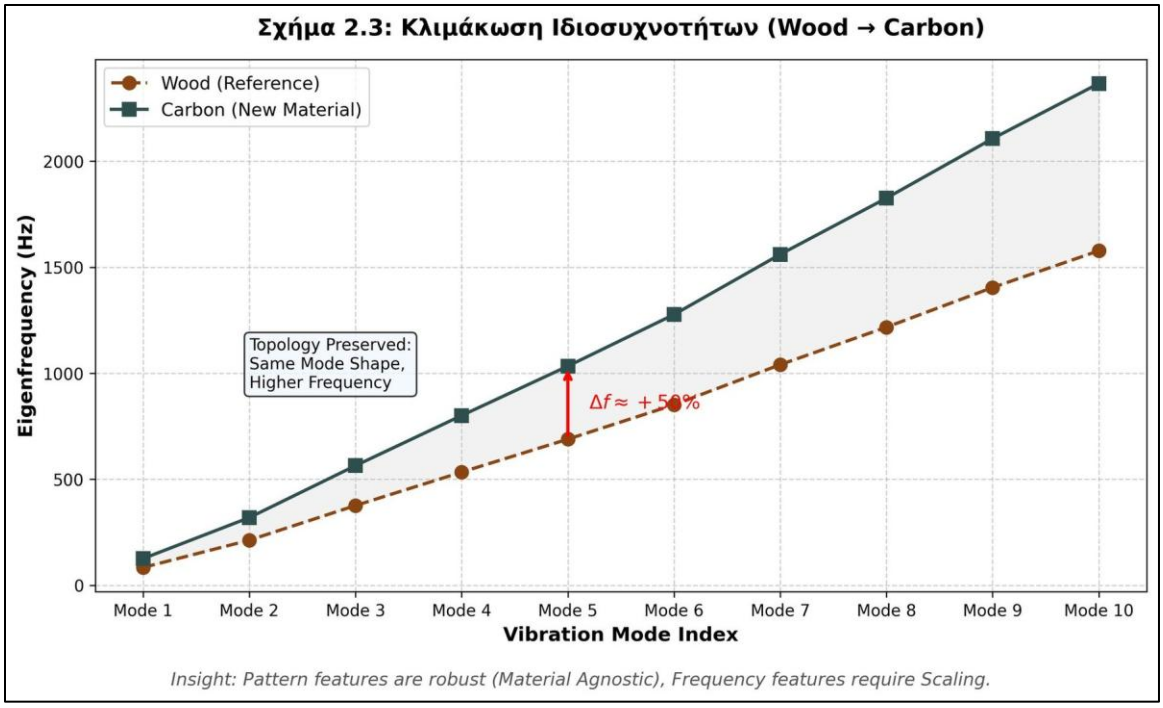
Συνέπειες για τη Στρατηγική Μηχανικής Μάθησης:

Η φυσική αυτή παρατήρηση έχει δύο θεμελιώδεις επιπτώσεις για τον σχεδιασμό του συστήματος ταξινόμησης:

- **Μορφολογική Στιβαρότητα:** Τα χαρακτηριστικά μοτίβου (Pattern Features) λειτουργούν ως **αναπαραστάσεις ανεξάρτητες υλικού (material-agnostic representations)**. Εφόσον κωδικοποιούν τη γεωμετρία (π.χ. αριθμός κόμβων, συμμετρία) και όχι την απόλυτη συχνότητα, μπορούν να γενικεύσουν ευκολότερα μεταξύ διαφορετικών υλικών.

- Ανάγκη Κανονικοποίησης Συχνότητας: Τα πρότερες συχνοτικές πληροφορίες θεμελιωμένες στη φυσική (Frequency Priors) είναι ισχυρά εντός ενός σταθερού πεδίου (π.χ. μόνο ξύλο), αλλά καταρρέουν σε σενάρια δια-υλικής γενίκευσης (cross-material generalization). Για την αντιμετώπιση αυτού, απαιτείται η χρήση σχετικών κλιμάκων (π.χ. κανονικοποίηση ως προς τη θεμελιώδη ιδιοσυχνότητα $f/f_{(1,1)}$) ώστε να «απορροφηθεί» η φασματική μετατόπιση. (Η προσέγγιση αυτή αναλύεται διεξοδικά στα κεφάλαια γενίκευσης και αποτελεί τη βάση για τη μετάβαση από το απόλυτο FFT στο σχετικό LeFFT).

Η φυσική των δονήσεων κατά συνέπεια παρέχει στο μοντέλο μια «διπλή ταυτότητα» για κάθε mode: τη Μορφολογία (χωρική υπογραφή) και τη Συχνότητα (φασματική υπογραφή). Η διπλωματική εργασία αξιοποιεί αυτή τη δυαδικότητα μέσω της αναπαράστασης θεμελιωμένης στη φυσική, αναγνωρίζοντας παράλληλα ότι η μεταβλητότητα του υλικού επιβάλλει αυστηρούς ελέγχους γενίκευσης (LODO) για την αποφυγή υπερπροσαρμογής σε συγκεκριμένες φασματικές περιοχές.



Σχήμα 2.3: *Ενδεικτική απεικόνιση της φασματικής κλιμάκωσης (Spectral Scaling) κατά τη μετάβαση από ξύλο σε ανθρακόνημα. Παρατηρείται η διατήρηση της μορφής των ιδιομορφών παρά τη σημαντική μετατόπιση των συχνοτήτων συντονισμού.*

2.3 ESPI: Θεμελιώδεις Αρχές και Μηχανισμός Απεικόνισης

Η Ηλεκτρονική Συμβολομετρία Κηλίδων (Electronic Speckle Pattern Interferometry - ESPI) αποτελεί την πρωτεύουσα πειραματική τεχνική της παρούσας εργασίας, λειτουργώντας ως ο μηχανισμός μετατροπής του πεδίου μετατοπίσεων μιας δονούμενης επιφάνειας σε συμβολογράμματα (fringe patterns) υψηλής χωρικής ανάλυσης.

Σε θεμελιώδη αντίθεση με τη συμβατική φωτογραφία, η εικόνα ESPI δεν καταγράφει απλώς την ανακλαστικότητα της επιφάνειας, αλλά συνιστά μια **συμβολομετρικά κωδικοποιημένη κατανομή** της οπτικής φάσης και του πλάτους ταλάντωσης. Ως εκ τούτου, η ερμηνεία της απαιτεί την κατανόηση τριών αλληλένδετων φυσικών φαινομένων: της συμβολής σύμφωνου φωτός, της στατιστικής του φαινομένου speckle και της χρονικής ολοκλήρωσης (time-averaging) του σήματος λόγω της ταλάντωσης.

Η παρούσα ενότητα έχει ως στόχο να θεμελιώσει το θεωρητικό υπόβαθρο που συνδέει τη Φυσική με τη Μηχανική Μάθηση: (α) Αναλύει τον μηχανισμό γένεσης των κροσσών από τη μηχανική δόνηση. (β) Εξηγεί την ειδική μορφολογία των δεδομένων (κροσσοί

Bessel διαμορφωμένοι από θόρυβο κηλίδων). (γ) Παρέχει τη φυσική τεκμηρίωση (physics-based justification) για τις επιλογές χαρακτηριστικών και αρχιτεκτονικών που υιοθετούνται στα Κεφάλαια 3–5, αποδεικνύοντας ότι η επεξεργασία τους δεν είναι αυθαίρετη αλλά καθοδηγούμενη από τους νόμους της οπτικής.

2.3.1 Θεμελιώδεις Αρχές Συμβολομετρίας και Φαινόμενο Speckle

Στην οπτική συμβολομετρία, η καταγεγραμμένη ένταση προκύπτει από την υπέρθεση δύο σύμφωνων κυματομορφών: του κύματος αντικειμένου (object wave) και του κύματος αναφοράς (reference wave). Η συνισταμένη ένταση $I(x, y)$ στον αισθητήρα περιγράφεται από τη θεμελιώδη εξίσωση συμβολής:

$$\boldsymbol{I = I_o + I_r + 2\sqrt{I_o I_r}\cos(\Delta\phi)} \qquad (2.6)$$

όπου I_o, I_r είναι οι εντάσεις των δύο δεσμών και Δφ η μεταξύ τους διαφορά φάσης.

Στην περίπτωση οπτικώς τραχειών επιφανειών (όπου η τραχύτητα υπερβαίνει το μήκος κύματος λ), η διάχυση του φωτός υπό σύμφωνο φωτισμό οδηγεί στο σχηματισμό του φαινομένου **speckle**. Πρόκειται για ένα στοχαστικό μοτίβο έντασης, το οποίο γεννάται από την επαλληλία (superposition) πολυάριθμων μικρο-κυμάτων που ανακλώνται από διαφορετικά σημεία της μικρο-τοπολογίας της επιφάνειας και φτάνουν στον παρατηρητή με τυχαίες φάσεις (Goodman, 2007). Είναι κρίσιμο να τονιστεί ότι το speckle δεν αποτελεί εξωγενή «θόρυβο» αλλά **εγγενές χαρακτηριστικό** της σύμφωνης απεικόνισης. Στατιστικά, μοντελοποιείται ως πολλαπλασιαστικός θόρυβος που διαμορφώνει την κατανομή της έντασης.

Η τεχνική ESPI αξιοποιεί το speckle ως «φορέα πληροφορίας» φάσης. Μικροσκοπικές μετατοπίσεις $u(x, y)$ της επιφάνειας του αντικειμένου προκαλούν μεταβολή του οπτικού δρόμου, η οποία μεταφράζεται σε αλλαγή φάσης Δφ. Η σχέση αυτή περιγράφεται από την εξίσωση ευαισθησίας:

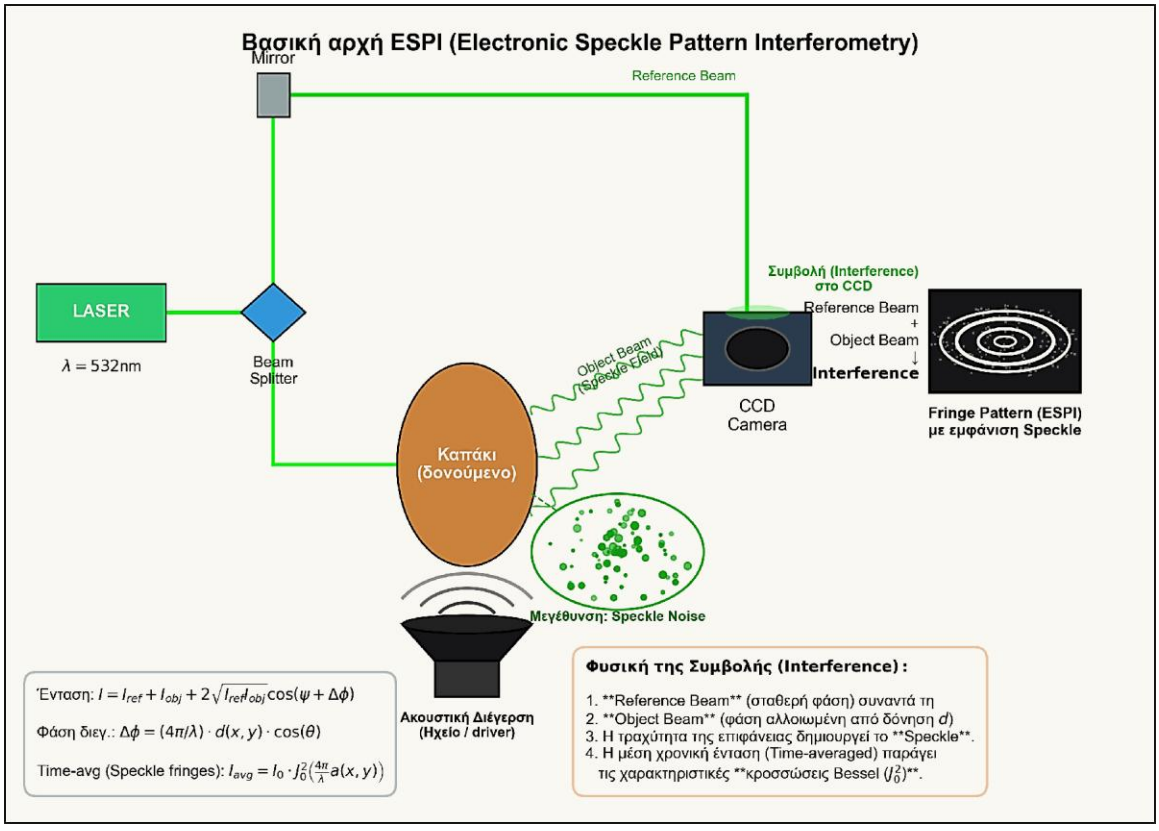
$$\boldsymbol{\Delta\phi = \frac{2\pi}{\lambda} u \cdot (s_i - s_o) = u \cdot K} \qquad (2.7)$$

όπου και είναι τα μοναδιαία διανύσματα φωτισμού και παρατήρησης αντίστοιχα, και το διάνυσμα ευαισθησίας (Jones & Wykes, 1989; Kreis, 2005). Για τυπικές διατάξεις οπισθοσκέδασης (back-scattering), η σχέση απλοποιείται σε , επιτρέποντας την ανίχνευση

μετατοπίσεων της τάξης κλάσματος του μήκους κύματος (sub-wavelength Precision).$s_i s_o K\Delta\phi \approx (4\pi/\lambda)u$

Σύνδεση με τη Μηχανική Μάθηση:

Η φυσική δυαδικότητα του σήματος ESPI —όπου οι δομές των κροσσών (fringes) είναι ντετερμινιστικές (προϊόν της παραμόρφωσης), ενώ το speckle είναι στοχαστικό (προϊόν της τραχύτητας)— καθορίζει τη στρατηγική της επεξεργασίας. Οι αλγόριθμοι Μηχανικής Μάθησης και εξαγωγής χαρακτηριστικών (Κεφάλαια 3–4) καλούνται να διαχωρίσουν τη χρήσιμη πληροφορία φάσης από τον υψίσυχνο θόρυβο του speckle. Συνεπώς, η εκπαίδευση των μοντέλων πρέπει να στοχεύει στην εκμάθηση αναπαραστάσεων που είναι **αναλλοίωτες (invariant)** ως προς τις τυχαίες διακυμάνσεις του speckle, εστιάζοντας στη μακροσκοπική τοπολογία των κροσσών.



Σχήμα 2.4: *Βασική αρχή ESPI: object/reference κύμα, speckle και μεταβολή φάσης από μετατόπιση.*

2.3.2 ESPI χρονικού μέσου όρου: Η Φυσική της Απεικόνισης Δονήσεων

Όταν η επιφάνεια εκτελεί αρμονική ταλάντωση εκτός επιπέδου της μορφής , η τεχνική ESPI χρονικού μέσου όρου καταγράφει τη χρονικά ολοκληρωμένη ένταση κατά τη διάρκεια της έκθεσης της κάμερας. Η προκύπτουσα κατανομή έντασης περιγράφεται από τη χαρακτηριστική σχέση διαμόρφωσης μέσω της συνάρτησης Bessel μηδενικής τάξης :$z(x, y, t) = a(x, y)\sin(\omega t)\, I(x, y) J_0$

$$\boldsymbol{I(x,y) = I_0(x,y)\left[1 + V(x,y) J_0\left(\frac{4\pi a(x,y)}{\lambda}\right)\cos\left(\phi_0(x,y)\right)\right]} \quad (2.8)$$

όπου $V(x, y)$ η ορατότητα των κροσσών και ϕ_0 μια στατική φάση αναφοράς (Jones & Wykes, 1989; Rastogi, 2001). Οι **σκοτεινές ζώνες** (fringes) αντιστοιχούν στις ρίζες της συνάρτησης Bessel ($J_0 = 0$), ενώ οι φωτεινές περιοχές υποδηλώνουν σημεία μηδενικού ή ελάχιστου πλάτους (κόμβοι).

Για μικρά πλάτη ταλάντωσης, ισχύει ο εμπειρικός κανόνας ότι η μετάβαση μεταξύ διαδοχικών κροσσών αντιστοιχεί σε μεταβολή πλάτους $\Delta a \approx \lambda/4$ (περίπου 133 nm για $\lambda = 532$ nm). Συνεπώς, η ESPI χρονικού μέσου όρου λειτουργεί ως ένας **χάρτης ισο-πλάτους** (iso-amplitude contour map) εξαιρετικά υψηλής ευαισθησίας, χωρίς ωστόσο να παρέχει άμεση πληροφορία για το πρόσημο της μετατόπισης.

Σημασία για τη Μηχανική Μάθηση:

Η φυσική αυτή ερμηνεία θεμελιώνει την επιλογή των χαρακτηριστικών στα επόμενα κεφάλαια. Επειδή η πληροφορία της δόνησης είναι κωδικοποιημένη στην πυκνότητα και τη γεωμετρία των κροσσών Bessel, τα "pattern features" (Κεφ. 4) που μετρούν κομβικές γραμμές και χωρικές συχνότητες δεν είναι αυθαίρετα, αλλά αποτελούν **άμεσους δείκτες (proxies)** του φυσικού πλάτους ταλάντωσης $a(x, y)$.

2.3.3 Μορφολογική ερμηνεία fringe maps

Η μορφολογία μιας εικόνας ESPI χρονικού μέσου όρου μπορεί να διαβαστεί ως «γεωμετρία ιδιομορφής» πάνω σε έναν χάρτη πλάτους. Στην πράξη, ένας ειδικός αναγνωρίζει ένα mode από (i) τον αριθμό και τη διάταξη κομβικών γραμμών, (ii) τη συμμετρία ως προς τους κύριους άξονες, και (iii) την κατανομή των κοιλιών/λοβών. Αυτά τα στοιχεία

εμφανίζονται ως σταθερές δομές υψηλής αντίθεσης που επιβιώνουν ακόμη και όταν το speckle αυξάνει τον τοπικό θόρυβο έντασης.

Η ερμηνεία των βασικών μορφολογικών δεικτών συνοψίζεται ως εξής:

- **Κομβικές γραμμές (nodal lines):** περιοχές με $a(x,y)\approx 0$. Στις time-averaged εικόνες τείνουν να εμφανίζονται ως «σκελετός» σταθερής δομής (Jones & Wykes, 1989).
- **Κροσσοί (fringes):** ισοϋψείς καμπύλες πλάτους. Η τοπική πυκνότητα κροσσών σχετίζεται με μεγάλες χωρικές κλίσεις του πλάτους.
- **Λοβοί/κοιλίες (lobes/antinodes):** περιοχές μεγάλου πλάτους που περιβάλλονται από πυκνότερους κροσσοὺς.
- **Συμμετρία/προσανατολισμός:** συνδέονται με τον τύπο του mode και επηρεάζονται από συνοριακές συνθήκες και ορθοτροπία (βλ. 2.2).

Πίνακας 2.2: *Αντιστοίχιση μορφολογικών δεικτών ESPI σε pattern features του συστήματος.*

Μορφολογικό στοιχείο	Τι εκφράζει φυσικά	Ενδεικτικά features (Κεφ. 4)
Κομβικές γραμμές	Τοπολογία περιοχών $a\approx 0$	nodal_length, nodal_complexity, euler_number
Πυκνότητα κροσσών	Ισχυρές χωρικές κλίσεις πλάτους	total_fringes, avg_fringe_spacing, energy_concentration
Συμμετρίες & γεωμετρία	Μορφή ιδιομορφής ως προς άξονες/διαγώνιες	hv_ratio, diag_ratio, symmetry_score, centroid_x/y
Σχήμα/όρια αντικειμένου	ROI και γεωμετρική σταθερότητα μέτρησης	valid_px, area/extent (όπου εφαρμόζεται)

2.3.4 Εξαγωγή Φάσης και Αλγοριθμική Ροή Επεξεργασίας Βασισμένη σε FFT (FFT-based Pipeline)

Για την εις βάθος ποσοτικοποίηση των οπτικών πληροφοριών που εμπεριέχονται στα μοτίβα κροσσών (fringe patterns) και τη μετάβασή τους σε φυσικές μετρήσεις (όπως η παραμόρφωση ή η μετατόπιση), η παρούσα εργασία αξιοποιεί προηγμένες μεθόδους

φασματικής ανάλυσης και εξαγωγής φάσης. Μια θεμελιώδης και ευρέως διαδεδομένη προσέγγιση είναι η μέθοδος του Μετασχηματισμού Fourier (Fourier Transform - FT), όπως αρχικά προτάθηκε από τους Takeda et al. (1982).

Στη μέθοδο αυτή, εισάγεται πειραματικά ένας χωρικός φέρων (spatial carrier), ο οποίος μετατοπίζει την επιθυμητή πληροφορία της φάσης στο πεδίο των συχνοτήτων, διαχωρίζοντάς την από το θόρυβο υποβάθρου. Μέσω της εφαρμογής του Ταχέος Μετασχηματισμού Fourier (FFT), καθίσταται δυνατή η απομόνωση του πρώτου πλευρικού φασματικού λοβού. Ακολουθεί η αποδιαμόρφωσή του (μεταφορά στο κέντρο του φάσματος) και ο αντίστροφος μετασχηματισμός (IFFT) για την ανάκτηση του μιγαδικού πεδίου του σήματος.

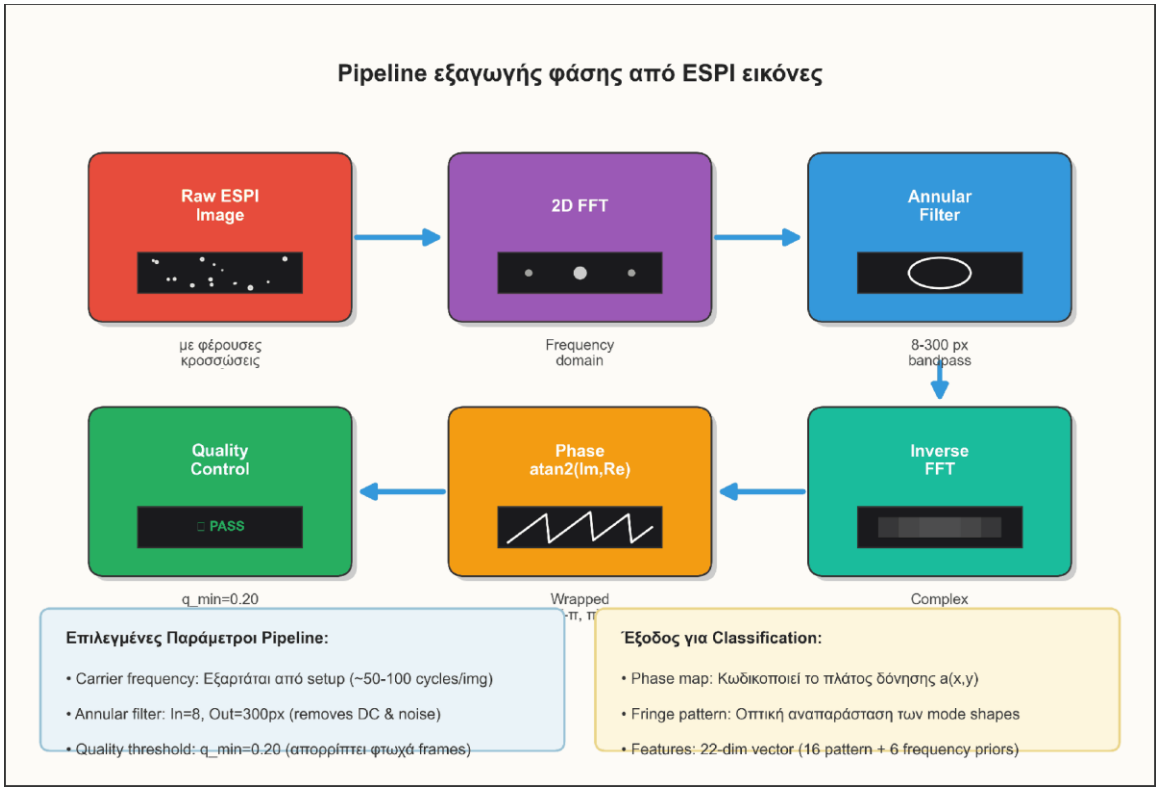
Η λεγόμενη «τυλιγμένη» φάση (wrapped phase) υπολογίζεται εξάγοντας το όρισμα, $\arg(\cdot)$, του προκύπτοντος μιγαδικού πεδίου, με τις τιμές της να περιορίζονται αυστηρά στο διάστημα $[-\pi, \pi)$. Επειδή όμως το φυσικό μέγεθος της παραμόρφωσης είναι συνεχές, κρίνεται απολύτως απαραίτητη η εφαρμογή εξειδικευμένων αλγορίθμων ξεδιπλώματος φάσης. Οι αλγόριθμοι αυτοί αναλαμβάνουν την ανίχνευση και την άρση των τεχνητών φασικών αλμάτων (ασυνεχειών) της τάξης του $\pm 2\pi$, προκειμένου να ανακατασκευαστεί η πραγματική, συνεχής κατανομή της φάσης (Ghiglia & Pritt, 1998) — μια διαδικασία που καθίσταται ιδιαίτερα απαιτητική παρουσία έντονου θορύβου κηλίδων (speckle noise).

Στην πράξη, η ανάπτυξη μιας αυτοματοποιημένης και αξιόπιστης ροής επεξεργασίας (pipeline) βασισμένης στον αλγόριθμο FFT προϋποθέτει την ενσωμάτωση αυστηρών ελέγχων ποιότητας. Πιο συγκεκριμένα, ο σχεδιασμός της διαδικασίας απαιτεί:

- **Την επιλογή κατάλληλου φασματικού φίλτρου:** Χρήση δακτυλιοειδούς (annular) ή ζωνοπερατού (band-pass) φίλτρου, το οποίο πρέπει να προσαρμόζεται δυναμικά στη γεωμετρία και την κυρίαρχη χωρική συχνότητα των κροσσών, ώστε να απορρίπτεται ο θόρυβος χωρίς να αποκόπτεται το ωφέλιμο σήμα.
- **Τη σταθερή οριοθέτηση της Περιοχής Ενδιαφέροντος (ROI):** Επιβάλλεται η εφαρμογή χωρικών μασκών (masking) για την απομόνωση του δοκιμίου από το παρασκήνιο.

- **Την καταστολή οπτικών τεχνουργημάτων (artifacts):** Αποφυγή σφαλμάτων που προέρχονται από πιθανό κορεσμό (saturation) του οπτικού αισθητήρα της κάμερας ή από περιοχές με εξαιρετικά χαμηλή αντίθεση (low contrast) των κροσσών.

Εναλλακτικά, ή ως συμπληρωματική προσέγγιση, αξίζει να αναφερθεί ότι ενώ η μέθοδος FFT πλεονεκτεί στην ανάλυση από μία μόνο λήψη (single-shot) —κάτι κρίσιμο για δυναμικά φαινόμενα—, σε περιπτώσεις όπου υπάρχει η πειραματική δυνατότητα λήψης διαδοχικών εικόνων σε στατικές συνθήκες, μπορούν να επιστρατευτούν τεχνικές ελεγχόμενης μετατόπισης φάσης (phase-shifting). Αυτές οι τεχνικές επιτυγχάνουν την εξαγωγή φάσης με δυνητικά υψηλότερη χωρική ανάλυση και ακρίβεια (Creath, 1985).



Σχήμα 2.5: *Διάγραμμα ροής (pipeline) εξαγωγής φάσης (carrier → FFT → φιλτράρισμα → inverse FFT → wrapped phase → unwrapping).*

Σύνδεση με τη Μηχανική Μάθηση (ML): Η φασματική ανάλυση στην παρούσα εργασία δεν χρησιμοποιείται απλώς ως ένα «μαύρο κουτί» προεπεξεργασίας, αλλά ως ένας μετασχηματισμός θεμελιωμένος στη φυσική που αναδεικνύει την περιοδικότητα και τον

προσανατολισμό των κροσσών. Τα φασματικά χαρακτηριστικά (spectral features) που προκύπτουν από το FFT τροφοδοτούν τα μοντέλα μηχανικής μάθησης με κρίσιμη πληροφορία η οποία είναι δυσδιάκριτη ή απολύτως απρόσιτη στο αρχικό χωρικό πεδίο (spatial domain). Με αυτόν τον τρόπο, προετοιμάζοντας το έδαφος για τις πιο προηγμένες, αλγοριθμικές μεθοδολογίες μηχανικής μάθησης που αναλύονται στα Κεφάλαια 6–8.

2.3.5 Δομή και Περιεχόμενο του Συνόλου Δεδομένων (Dataset)

Τα δεδομένα που αξιοποιούνται στο πλαίσιο της παρούσας διπλωματικής εργασίας αποκλίνουν θεμελιωδώς από τα συμβατικά σύνολα εικόνων (generic image datasets) που συναντώνται συνήθως στη βιβλιογραφία της Υπολογιστικής Όρασης. Αντιθέτως, συνιστούν εξειδικευμένους **οπτικούς χάρτες κροσσών χρονικού μέσου όρου (time-averaged fringe maps)**, οι οποίοι παράγονται από μια αυστηρά ελεγχόμενη πειραματική διάταξη ESPI. Οι χάρτες αυτοί δεν αποτελούν απλές φωτογραφίες, αλλά αποτυπώνουν με υψηλή χωρική ανάλυση το πεδίο των μικρο-παραμορφώσεων της δονούμενης κατασκευής, κατόπιν αρμονικής διέγερσης σε διακριτές συχνότητες.

Κάθε δείγμα του συνόλου αντιστοιχεί σε μία σαφώς ορισμένη πειραματική κατάσταση (συχνότητα διέγερσης, στάθμη λειτουργίας, δοκίμιο/μουσικό όργανο) και φέρει μια αυστηρή **ετικέτα ιδιομορφής (mode label)**, η οποία έχει προκύψει από προσεκτική πειραματική αναγνώριση και ταυτοποίηση στο εργαστήριο.

Στην πράξη, για την εξυπηρέτηση των πολύπλευρων απαιτήσεων της μηχανικής μάθησης, το συνολικό αποθετήριο δεδομένων (data repository) είναι εκτενέστερο και δομείται ιεραρχικά. Πέρα από το αυστηρά φιλτραρισμένο υποσύνολο (curated dataset) που τροφοδοτεί τα κύρια πειράματα ταξινόμησης, διατηρείται μια πολυεπίπεδη βάση η οποία περιλαμβάνει:

1. **Πρωτογενείς θορυβώδεις λήψεις (raw single-shot):** Μεμονωμένα καρέ ανά συχνότητα, τα οποία εμπεριέχουν τον πλήρη, φυσικό πολλαπλασιαστικό θόρυβο κηλίδων.

2. **Αναφορές χρονικού μέσου όρου (multi-frame averaged references):** Υψηλής ποιότητας εικόνες που προκύπτουν από την ολοκλήρωση πολλαπλών λήψεων, λειτουργώντας ως οιονεί «καθαρά» (pseudo-clean) πρότυπα αναφοράς.

3. **Συνθετικά ζεύγη (pseudo-noisy data):** Δεδομένα εξομοιωμένου θορύβου, παραγόμενα μέσω μοντέλων θεμελιωμένων στη φυσική.

Αυτή η στοχευμένη **διαστρωμάτωση των δεδομένων (data stratification)** δεν είναι τυχαία. Αποτελεί τον βασικό πυλώνα που επιτρέπει αφενός την αποτελεσματική, επιβλεπόμενη εκπαίδευση του νευρωνικού δικτύου αποθορυβοποίησης (DnCNN) σε συνθήκες έλλειψης απόλυτου ground-truth, και αφετέρου τον αυστηρό έλεγχο της ανθεκτικότητας (robustness) ολόκληρου του συστήματος κάτω από διαφορετικά καθεστώτα θορύβου.

Πίνακας 2.3: *Σύνθεση του αποθετηρίου δεδομένων ESPI και ο διακριτός ρόλος κάθε υποσυνόλου στην πειραματική διαδικασία.*

Υποσύνολο	**Περιεχόμενο**	**Ενδεικτικό Πλήθος**	**Χρήση στην Εργασία**
Πραγματικές λήψεις μονοκαρέ (single-shot)	8–12 θορυβώδη καρέ ανά συχνότητα/μέτρηση, με πλήρως ανεπτυγμένο θόρυβο κηλίδων.	~20.000 – 25.000 εικόνες	Υπολογισμός averaged αναφοράς· συμπληρωματικό υλικό για αποθορυβοποίηση και ελέγχους ανθεκτικότητας (robustness checks).
Αναφορές μέσου όρου (multi-frame averaged)	Μέσος όρος των μονοκαρέ λήψεων ανά συχνότητα (με δραστικά μειωμένο speckle).	1 ανά συχνότητα	Λειτουργούν ως «ψευδο-καθαροί» στόχοι για ζεύγη (noisy → clean) και ως βάση προεπεξεργασίας για τους χάρτες κροσσών.
Κύριο σύνολο ταξινόμησης (QC checked)	Αυστηρά φιλτραρισμένο υποσύνολο με σαφή	3.443 εικόνες	Κύρια πειράματα ταξινόμησης (Random Forest /

	ιδιομορφικά μοτίβα και αξιόπιστες ετικέτες.	(6 κλάσεις)	CNN) με στρατηγικές LOBO/LODO και αξιολόγηση μέσω Macro-F1.
Συνθετικά ζεύγη «ψευδο-θορυβώδη»	Τεχνητό speckle + Poisson/Gaussian από physics-informed generator (σε ζεύγος με averaged).	~7.000 ζεύγη	Αρχική προεκπαίδευση και λεπτοπροσαρμογή (fine-tuning) του DnCNN για τη μείωση του χάσματος πεδίου (domain gap).

***Σημείωση**: Τα μεγέθη (π.χ. 20–25 χιλ. και ~7 χιλ.) αναφέρονται στο συνολικό αποθετήριο και στην παραγωγή ζευγών για αποθορυβοποίηση. Για τα κύρια πειράματα ταξινόμησης χρησιμοποιείται το επιλεγμένο και ποιοτικά ελεγμένο υποσύνολο N = 3 443.*

Αυτή η δομή του συνόλου δεδομένων εγείρει τρεις κρίσιμες συνεπαγωγές για την ανάλυση και τη Μηχανική Μάθηση:

- **Ενσωματωμένη Φασματική Πληροφορία:** Η διαδικασία χρονικής ολοκλήρωσης (time-averaging) σημαίνει ότι η φασματική πληροφορία (FFT) είναι φυσικά «ενσωματωμένη» στο οπτικό σήμα μέσω της χωρικής περιοδικότητας των κροσσών.

- **Μετατόπιση Πεδίου (Domain Shift):** Οι κατασκευαστικές διαφορές μεταξύ των δοκιμίων (workpieces) —όπως η ορατότητα των κροσσών, η μικρο-γεωμετρία, το φινίρισμα της επιφάνειας και η ακριβής αντιστοίχιση συχνότητας με ιδιομορφή (mapping)— δημιουργούν αναπόφευκτα μετατοπίσεις στις κατανομές των δεδομένων.

- **Ανισορροπία Κλάσεων (Class Imbalance):** Η έντονη ανισορροπία στον αριθμό δειγμάτων ανά κλάση δεν αποτελεί σφάλμα συλλογής, αλλά αντανακλά την

ίδια τη φυσική και πειραματική διαθεσιμότητα «καθαρών» ιδιομορφών (modes) σε συγκεκριμένες ζώνες συχνοτήτων (βλ. Ενότητα 2.5).

2.3.5.1 Σημείωση ορολογίας: κλάσεις τρόπων και ονοματολογία

Στα Κεφάλαια 2 έως 8 της παρούσας διπλωματικής υιοθετείται μια ταξινομία 6 κλάσεων για τις ιδιομορφές: **(1,1)H, (1,1)T, (1,2), (2,1), higher**, καθώς και μια επιπλέον κατηγορία **«other/ambiguous»**. Η τελευταία περιλαμβάνει περιπτώσεις όπου η μορφολογία ή/και το φασματικό αποτύπωμα δεν επιτρέπουν την ασφαλή ένταξη του δείγματος σε μία από τις κύριες κλάσεις.

Πρέπει να σημειωθεί ότι στο ερευνητικό πρωτότυπο που παρουσιάζεται στο μελλοντική ερευνητική κατεύθυνση (εκδόσεις v6.1+), η ταξινομία απλοποιείται σε 5 κλάσεις για λόγους παραγωγοποίησης (productionization). Αυτό συμβαίνει διότι η κλάση «other/ambiguous» δεν είναι επαρκώς αντιπροσωπευμένη στα δεδομένα και, ως εκ τούτου, δεν υποστηρίζει μια σταθερή αξιολόγηση και βαθμονόμηση του μοντέλου. Ωστόσο, η παρούσα ενότητα διατηρεί την περιγραφή των 6 κλάσεων, προκειμένου να παραμένει απολύτως συνεπής με τα κύρια πειραματικά κεφάλαια της εργασίας.

Γέφυρα προς τα πρωτόκολλα αξιολόγησης: Επειδή το σύνολο δεδομένων ενσωματώνει ταυτόχρονα «συχνοτική ποικιλία» και «ποικιλία δοκιμίων», η χρήση απλών, τυχαίων διαχωρισμών (random splits) θα οδηγούσε σε υπερεκτίμηση της απόδοσης (data leakage). Για τον λόγο αυτόν, ορίζονται εξειδικευμένα πρωτόκολλα γενίκευσης:

- LOBO (Leave-One-Band-Out): Αξιολόγηση σε μη ιδωμένες (unseen) ζώνες συχνοτήτων.
- **LODO (Leave-One-Domain-Out):** Αξιολόγηση σε μη ιδωμένα δοκίμια/όργανα. Αυτές οι στρατηγικές (αναλύονται στα Κεφ. 3 και στο Παράρτημα Β) διασφαλίζουν την αξιοπιστία των μετρικών.

2.4 Θόρυβος κηλίδων (speckle) και αποθορυβοποίηση

Δεδομένου ότι η τεχνική ESPI βασίζεται σε σύμφωνο φωτισμό (coherent illumination) και στην παρεμβολή κυμάτων, τα δεδομένα που τροφοδοτούν τα υπολογιστικά μοντέλα δεν είναι «ουδέτερες» ή τυπικές ψηφιακές εικόνες. Πρόκειται για εικόνες που φέρουν μια

ισχυρή στοχαστική υφή —τον θόρυβο κηλίδων (speckle)— η οποία προκύπτει αναπόφευκτα από τη συμβολή πολλαπλών σκεδαζόμενων οπτικών κυμάτων.

Στην παρούσα εργασία, ο θόρυβος κηλίδων αντιμετωπίζεται ως ένας **δομικός (intrinsic) παράγοντας** της μεθόδου μέτρησης και όχι ως ένα απλό, τυχαίο τεχνούργημα (artifact) του αισθητήρα. Ακριβώς λόγω αυτής της παραδοχής, η ποιότητα της αποθορυβοποίησης (denoising) δεν αξιολογείται θεωρητικά, αλλά πρακτικά, με βάση τον αντίκτυπό της στο τελικό έργο (downstream task): την ακρίβεια ταξινόμησης των ιδιομορφών.

2.4.1 Speckle ως πολλαπλασιαστικός θόρυβος: στατιστική περιγραφή

Σε συστήματα σύμφωνης απεικόνισης, όπως η ESPI, η ένταση σε κάθε pixel προκύπτει από την παρεμβολή πολλών σκεδαζόμενων συνιστωσών. Σε συνθήκες «fully developed speckle», το μιγαδικό πλάτος μπορεί να προσεγγιστεί ως μιγαδική Gaussian μεταβλητή και η ένταση ακολουθεί κατά προσέγγιση εκθετική κατανομή (negative exponential). Αυτό συνεπάγεται υψηλό εγγενές contrast, όπου η τυπική απόκλιση της έντασης είναι συγκρίσιμη με τη μέση τιμή της (speckle contrast $C \approx 1$), κάτι που μεταφράζεται σε έντονη τοπική διακύμανση πάνω σε λεπτές δομές κροσσών.

Στο πλαίσιο της επεξεργασίας, συχνά χρησιμοποιείται ένα απλοποιημένο μοντέλο πολλαπλασιαστικού θορύβου:

$$\mathbf{I(x,y) = S(x,y) \cdot N(x,y)} \qquad (2.9)$$

όπου I είναι η παρατηρούμενη ένταση, S το «ιδανικό» σήμα (fringe map που κωδικοποιεί το πλάτος) και N ο speckle όρος. Η πολλαπλασιαστική φύση σημαίνει ότι η ισχύς του θορύβου εξαρτάται από τη φωτεινότητα, και ότι μικρές διακυμάνσεις μπορούν να «σπάσουν» κομβικές γραμμές ή να εισάγουν ψευδο-κροσσούς, ειδικά όταν η αντίθεση των fringes είναι χαμηλή.

Για τον λόγο αυτό, η απλή «εξομάλυνση» (π.χ. ισχυρό blur) μπορεί να μειώνει το speckle αλλά ταυτόχρονα να εξαφανίζει τις μορφολογικές λεπτομέρειες που χρειάζονται για ταξινόμηση, όπως λεπτές κομβικές γραμμές ή τοπικές μεταβολές πυκνότητας κροσσών (Goodman, 2007; Dainty, 1984).

2.4.2 Μοντελοποίηση speckle με Burr Type XII: κίνητρο και ιδιότητες

Παρότι το «ιδανικό» πλήρως ανεπτυγμένο speckle (fully developed speckle) οδηγεί θεωρητικά σε εκθετική κατανομή έντασης, στην πράξη οι εικόνες ESPI επηρεάζονται από ανομοιογένειες της ανακλαστικότητας, από τις μη ιδανικές συνθήκες της οπτικής διάταξης, από τον πιθανό κορεσμό του αισθητήρα, καθώς και από την ίδια τη χωρική δομή των κροσσών (fringes). Ως αποτέλεσμα, η εμπειρική κατανομή των εντάσεων εμφανίζει συχνά βαρύτερες ουρές (heavy tails) και ασυμμετρίες, οι οποίες δεν μπορούν να αποτυπωθούν επαρκώς από απλές προσεγγίσεις Gaussian θορύβου.

Στο πλαίσιο της παρούσας διπλωματικής εργασίας, αξιοποιείται η κατανομή **Burr Type XII** ως ένα ευέλικτο στοχαστικό μοντέλο δύο παραμέτρων με χαρακτηριστικά βαριάς ουράς (heavy-tailed), το οποίο δύναται να προσαρμοστεί σε διαφορετικά στατιστικά πρότυπα θορύβου. Η κατανομή Burr XII ορίζεται από την ακόλουθη Αθροιστική Συνάρτηση Κατανομής (Cumulative Distribution Function - CDF):

$$\boldsymbol{F(x; c, k) = 1 - (1 + x^{c})^{-k}, \quad x > 0} \qquad (2.10)$$

με παραμέτρους σχήματος $c > 0$ και $k > 0$ (Burr, 1942).

Η μαθηματική της ευελιξία τής επιτρέπει να προσεγγίζει ποικίλες heavy-tailed συμπεριφορές και να λειτουργεί ως ένα πρακτικό μοντέλο για την παραγωγή ψευδο-θορύβου (pseudo-noise) ή παραμορφώσεων τύπου speckle σε σύμφωνες μετρήσεις. Σημειώνεται ότι στη βιβλιογραφία χρησιμοποιούνται και εναλλακτικά μοντέλα (π.χ. η κατανομή K και οι παραλλαγές της) σε περιβάλλοντα σύμφωνης απεικόνισης, γεγονός που υπογραμμίζει περαιτέρω ότι ο θόρυβος κηλίδων έχει κατά κανόνα μη-Gaussian χαρακτήρα (Jakeman & Tough, 1987; Oliver & Quegan, 2004).

Στην πράξη, το βασικό κίνητρο αυτής της επιλογής δεν είναι η αναζήτηση της «τέλειας» στοχαστικής περιγραφής, αλλά η δημιουργία ενός σταθερού μαθηματικού πλαισίου που εξυπηρετεί δύο κρίσιμους σκοπούς:

- Τη **ρεαλιστική εκπαίδευση (training)** ενός νευρωνικού δικτύου αποθορυβοποίησης (denoiser).
- Τη διεξαγωγή **ελεγχόμενων πειραμάτων αφαίρεσης (ablations)** για τη σύγκριση μεταξύ διαφορετικών καθεστώτων θορύβου (πραγματικού έναντι

συνθετικού - real vs synthetic), όπως τεκμηριώνεται αναλυτικά στα πειραματικά κεφάλαια και στα παραρτήματα της εργασίας.

2.4.3 Χρονική συσχέτιση και averaging: από την οπτική ολοκλήρωση στο multi-frame

Η ESPI χρονικού μέσου όρου, λόγω της πεπερασμένης έκθεσης της κάμερας, πραγματοποιεί ήδη μια μορφή χρονικής ολοκλήρωσης της έντασης. Όταν οι στοχαστικές διακυμάνσεις του speckle μεταβάλλονται γρηγορότερα από τον χρόνο έκθεσης, μέρος του θορύβου «εξομαλύνεται» οπτικά. Στην ψηφιακή πλευρά, το αντίστοιχο εργαλείο είναι ο μέσος όρος πολλαπλών καρέ (multi-frame averaging).

Αν θεωρήσουμε N καρέ με ανεξάρτητο (ή ασθενώς συσχετισμένο) θόρυβο, τότε ο μέσος όρος ανά pixel μειώνει την τυπική απόκλιση του θορύβου κατά προσέγγιση ως:

$$\sigma_{_avg} \approx \sigma / \sqrt{N} \qquad (2.11)$$

δηλαδή το SNR αυξάνει με √N, υπό την προϋπόθεση ότι το υποκείμενο σήμα (fringe map) παραμένει σταθερό στα καρέ (π.χ. σταθερή διέγερση, μηχανική σταθερότητα, σταθερό optical path). Όταν υπάρχει χρονική συσχέτιση, το κέρδος αντιστοιχεί σε αποτελεσματικό πλήθος δειγμάτων N_eff < N και η μείωση είναι πιο αργή (Kay, 1993).

2.4.4 Ο Χρονικός Μέσος Όρος (Multi-frame Averaging) ως Φυσικά Συνεπές Σημείο Αναφοράς

Στο πλαίσιο της παρούσας διπλωματικής, η τεχνική του χρονικού μέσου όρου πολλαπλών λήψεων (multi-frame averaging) υιοθετείται ως ένα φυσικά συνεπές σημείο αναφοράς για την αποθορυβοποίηση. Η επιλογή αυτή τεκμηριώνεται από δύο βασικούς παράγοντες:

- **Συμβατότητα με τη Φυσική της Μέτρησης:** Η τεχνική ESPI βασίζεται εγγενώς στη χρονική ολοκλήρωση (time integration) της έντασης του φωτός κατά τη διάρκεια της έκθεσης. Συνεπώς, ο υπολογισμός του μέσου όρου πολλαπλών καρέ αποτελεί τη φυσική επέκταση της ίδιας θεμελιώδους αρχής λειτουργίας.
- **Διατήρηση της Μορφολογίας:** Η μέθοδος επιτυγχάνει τη μείωση της στοχαστικής υφής (speckle noise), αποφεύγοντας παράλληλα την έντονη χωρική

εξομάλυνση (spatial smoothing) που συχνά αλλοιώνει κρίσιμες λεπτομέρειες, όπως τις κομβικές γραμμές και την πυκνότητα των κροσσών (fringe density).

Επιπλέον, η διαδικασία χαρακτηρίζεται από διαφάνεια και ελεγξιμότητα: επιτρέπει στον χρήστη να ρυθμίσει την ισορροπία (trade-off) μεταξύ του Λόγου Σήματος προς Θόρυβο (SNR) και του απαιτούμενου υπολογιστικού κόστους/χρόνου μέσω της παραμέτρου N, διασφαλίζοντας την αναπαραγωγιμότητα των αποτελεσμάτων.

Στην παρούσα μελέτη, το συγκεκριμένο πρότυπο αναφοράς αξιοποιείται διττά: αφενός ως μέθοδος βελτίωσης της εισόδου για την **εξαγωγή χαρακτηριστικών** (feature extraction) και αφετέρου ως μέτρο σύγκρισης, προκειμένου να αξιολογηθεί κατά πόσον οι σύγχρονες μέθοδοι βαθιάς αποθορυβοποίησης (**deep denoisers**) προσφέρουν ουσιαστικό όφελος στο τελικό έργο της ταξινόμησης (**downstream task**).

2.4.5 Ασυμφωνία Στόχων (Task Misalignment): Οι Περιορισμοί των Μετρικών PSNR/SSIM

Η παραδοσιακή αξιολόγηση των αλγορίθμων αποθορυβοποίησης βασίζεται, κατά κανόνα, σε μετρικές όπως ο Λόγος Σήματος προς Θόρυβο Κορυφής (PSNR) και ο Δείκτης Δομικής Ομοιότητας (SSIM). Αν και οι δείκτες αυτοί ποσοτικοποιούν αποτελεσματικά την ομοιότητα της ανακατασκευασμένης εικόνας ως προς μία εικόνα αναφοράς (reference), η βελτιστοποίηση με αποκλειστικό γνώμονα τη μεγιστοποίησή τους παρουσιάζει σοβαρούς περιορισμούς.

Συγκεκριμένα, οδηγεί συχνά σε λύσεις που, αν και οπτικά λείες (visually smooth), τείνουν να εξαλείφουν κρίσιμες δομές υψηλής συχνότητας (υπερ-εξομάλυνση / oversmoothing). Στην περίπτωση των μοτίβων συμβολής (fringe patterns), αυτές οι δομές ταυτίζονται με πληροφορία ζωτικής σημασίας—όπως οι κομβικές γραμμές και οι απότομες μεταβολές στην πυκνότητα των κροσσών—οι οποίες είναι απολύτως απαραίτητες για τον διαχωρισμό και την ταξινόμηση των γειτονικών ιδιομορφών.

Το πρόβλημα αυτό αποτελεί ειδική περίπτωση του γενικότερου φαινομένου της «ασυμφωνίας» (task misalignment) μεταξύ του αυστηρού στόχου βελτιστοποίησης (ελαχιστοποίηση παραμόρφωσης / distortion metrics) και του τελικού στόχου χρήσης

(downstream task), όπως περιγράφεται εκτενώς στη σχετική βιβλιογραφία (Wang et al., 2004; Blau & Michaeli, 2018).

Πίνακας 2.4: *Σύγκριση μεθόδων προεπεξεργασίας / αποθορυβοποίησης ως προς την τελική επίδοση στη downstream ταξινόμηση (Macro-F1)*

Μέθοδος	**Down-stream Macro-F1**	**Σχόλιο**
Μέση τιμή πολλαπλών καρέ (Time-averaging)	89,09%	Baseline προσέγγιση, φυσικά ευθυγραμμισμένη με τη διαδικασία λήψης ESPI.
DnCNN + ECA	86,94%	Βαθιά αποθορυβοποίηση, η οποία όμως προκαλεί πιθανή εξομάλυνση (oversmoothing) των λεπτών κροσσών.

Στα πειραματικά αποτελέσματα της παρούσας μελέτης, η ασυμφωνία αυτή επιβεβαιώνεται με τον πλέον ξεκάθαρο τρόπο. Παρόλο που τα βαθιά δίκτυα αποθορυβοποίησης, όπως το DnCNN (Residual Learning), αποτελούν πανίσχυρες λύσεις για την αντιμετώπιση του θορύβου κηλίδων (Zhang et al., 2017), η φυσικά συνεπής μέθοδος του χρονικού μέσου όρου (multi-frame averaging) επιτυγχάνει τελικά ανώτερη επίδοση στο έργο της ταξινόμησης (downstream Macro-F1).

Ερμηνεία των Αποτελεσμάτων: Τα ευρήματα του Πίνακα 2.4 δεν υποδηλώνουν την καθολική αποτυχία των μεθόδων deep denoising. Αναδεικνύουν, ωστόσο, ότι στο συγκεκριμένο πρόβλημα ESPI, η ποιότητα της αποθορυβοποίησης πρέπει να κρίνεται αποκλειστικά με βάση τη διατήρηση της φυσικής πληροφορίας που σχετίζεται με τις ιδιομορφές. Συνεπώς, η βέλτιστη στρατηγική οφείλει να ακολουθεί δύο βασικά βήματα:

- **Σαφή ορισμό του τελικού στόχου (downstream task)** και των αντίστοιχων πρωτοκόλλων γενίκευσης (αναλύονται εκτενώς στα Κεφάλαια 2.6 και 5–7).
- **Επιλογή ή στοχευμένη εκπαίδευση μοντέλων αποθορυβοποίησης** με γνώμονα να μην αλλοιώνουν τα κρίσιμα χαρακτηριστικά (critical features), ακόμα και αν αυτό συνεπάγεται μια ελαφριά υστέρηση στις τυπικές μετρικές εικόνας (PSNR/SSIM).

Η παρούσα ενότητα θεμελιώνει ένα κεντρικό μήνυμα της διπλωματικής εργασίας: η βαθιά κατανόηση της «φυσικής» του συστήματος (time-averaging, μορφολογία ιδιομορφών) προσφέρει ένα ισχυρότερο σημείο αναφοράς. Οδηγεί σε πολύ πιο αξιόπιστες επιλογές προεπεξεργασίας σε σύγκριση με μια αμιγώς δεδομενοκεντρική (data-driven) βελτιστοποίηση, η οποία βασίζεται τυφλά σε γενικές μετρικές αξιολόγησης εικόνας.

2.4.6 Παραγωγή Ρεαλιστικών Ψευδο-θορυβωδών Δεδομένων και Βαθμονόμηση

2.4.6.1 Το πρόβλημα της έλλειψης καθαρών αναφορών

Η εκπαίδευση νευρωνικών δικτύων αποθορυβοποίησης στην ESPI προσκρούει σε ένα θεμελιώδες πρακτικό όριο: η απόκτηση πραγματικά καθαρών εικόνων αναφοράς είναι, στην πράξη, αδύνατη, επειδή ο θόρυβος κηλίδων αποτελεί εγγενές χαρακτηριστικό της σύμφωνης απεικόνισης. Για τον λόγο αυτό, ως προσεγγιστικές εικόνες υψηλότερου λόγου σήματος προς θόρυβο χρησιμοποιούνται οι χρονικά ολοκληρωμένες λήψεις (multi-frame averaged), ενώ η γεννήτρια ψευδο-θορύβου αναλαμβάνει να παράγει ρεαλιστικά θορυβώδεις εκδοχές τους, ώστε να δημιουργούνται ελεγχόμενα ζεύγη εκπαίδευσης για τον αποθορυβοποιητή.

2.4.6.2 Η αλυσίδα Speckle → Poisson → Gaussian

Η σχεδιαστική αρχή της γεννήτριας είναι ότι ο θόρυβος στην ESPI δεν μπορεί να προσεγγισθεί επαρκώς ως απλός προσθετικός Gaussian θόρυβος. Αντιθέτως, η παρατηρούμενη εικόνα προκύπτει από διαδοχική αλυσίδα φυσικών μηχανισμών, η οποία συνοψίζεται ως Speckle → Poisson → Gaussian. Αν x συμβολίζει την averaged εικόνα αναφοράς, τότε η τελική έξοδος y μπορεί να παρασταθεί συνοπτικά ως $y = \mathrm{clip}(G_\sigma(P_p(S_k(x))))$. Στο σχήμα αυτό, ο τελεστής S_k περιγράφει την πολλαπλασιαστική διαμόρφωση speckle, ο τελεστής P_p τον signal-dependent shot noise και ο G_σ τον προσθετικό readout θόρυβο του αισθητήρα. Η σειρά εφαρμογής είναι κρίσιμη, επειδή ακολουθεί τη φυσική ροή παραγωγής της οπτικής πληροφορίας: πρώτα η συνεκτική speckle διαμόρφωση, κατόπιν η φωτοηλεκτρική Poisson δειγματοληψία και τέλος ο ηλεκτρονικός θόρυβος ανάγνωσης.

Το καθοριστικό σημείο που διαφοροποιεί τη γεννήτρια από απλές ad hoc προσεγγίσεις είναι η εμπειρική βαθμονόμηση των παραμέτρων της από πραγματικά ζεύγη single-shot και averaged εικόνων. Οι παράμετροι $\theta = (k, p, \sigma)$ δεν επιλέγονται ευρετικά, αλλά προσαρμόζονται μέσω αντιστοίχισης στατιστικών ροπών ανάμεσα στη συνθετική έξοδο και

στις πραγματικές μεμονωμένες λήψεις. Η calibration v2.0 κατέληξε στο canonical operating point k = 1,89, p = 12,5 και σ = 0,0919, το οποίο χρησιμοποιήθηκε ως σταθερό σημείο αναφοράς στις κύριες συγκρίσεις. Η γεννήτρια υποστηρίζει επίσης βαθμονόμηση ανά ζώνη συχνοτήτων και εφαρμογή θορύβου με επίγνωση της περιοχής ενδιαφέροντος (ROI), ώστε να αποδίδεται πιστότερα η μεταβλητότητα του ESPI noise μεταξύ διαφορετικών πειραματικών συνθηκών.

Ένα επιπρόσθετο στοιχείο ρεαλισμού αφορά τη χωρική συσχέτιση του speckle. Αντί για εντελώς ασυσχέτιστο θόρυβο ανά εικονοστοιχείο, η γεννήτρια προσεγγίζει τη χωρική δομή του speckle μέσω χαρακτηριστικού μήκους συσχέτισης που εκτιμάται εμπειρικά από την αυτοσυσχέτιση πραγματικών λήψεων. Με τον τρόπο αυτό, το συνθετικό corruption model παραμένει απλό αλλά παραμετρικά ελέγξιμο, χωρίς να αποκόπτεται από τη φυσική της μέτρησης.

2.4.6.3 Χάσμα πεδίου και λειτουργική αξιολόγηση

Η αναγκαιότητα της φυσικής βαθμονόμησης αποδεικνύεται από δύο κεντρικά εμπειρικά ευρήματα. Πρώτον, χωρίς επαρκή αντιστοίχιση του synthetic regime με τις πραγματικές λήψεις εμφανίζεται χάσμα πεδίου (domain gap), το οποίο μπορεί να οδηγήσει σε αρνητικά ή οριακά κέρδη PSNR σε πραγματικά δεδομένα, παρά την καλή επίδοση σε συνθετικά ζεύγη. Δεύτερον, αναδεικνύεται ασυμφωνία αντικειμενικών στόχων (task mismatch): η βελτίωση των φωτομετρικών μετρικών, όπως του PSNR ή του SSIM, δεν συνεπάγεται κατ' ανάγκην βελτίωση της downstream ταξινόμησης, επειδή η υπερβολική εξομάλυνση μπορεί να αλλοιώσει κρίσιμες μικροδομές των κροσσών. Ως εκ τούτου, η αποτίμηση της γεννήτριας και του αποθορυβοποιητή πρέπει να είναι διπλή, δηλαδή τόσο φωτομετρική όσο και λειτουργική.

Συνεπώς, η παραγωγή ψευδο-θορυβωδών δεδομένων στην παρούσα εργασία δεν αντιμετωπίζεται ως απλή τεχνική αύξησης δεδομένων, αλλά ως φυσικά εμπνευσμένο και πειραματικά ελέγξιμο πλαίσιο συνθετικής εποπτείας. Η πλήρης μαθηματική διατύπωση των τελεστών, η αναλυτική περιγραφή των πρωτοκόλλων βαθμονόμησης, οι μελέτες αφαίρεσης της αλυσίδας διαφθοράς, καθώς και τα εκτεταμένα πειραματικά αποτελέσματα παρατίθενται στο Παράρτημα Κ.

2.4.7 Θεωρητικό υπόβαθρο αποθορυβοποίησης, DnCNN και Efficient Channel Attention (ECA)

Στην παρούσα ενότητα περιγράφεται το θεωρητικό πλαίσιο των μεθόδων αποθορυβοποίησης που χρησιμοποιήθηκαν στο Κεφάλαιο 4, με έμφαση στη residual μάθηση του DnCNN και στην ενσωμάτωση μηχανισμών προσοχής καναλιών (ECA) για καλύτερη διατήρηση των δομών κροσσών.

2.4.7.1 Η ανάγκη αποθορυβοποίησης σε ESPI εικόνες

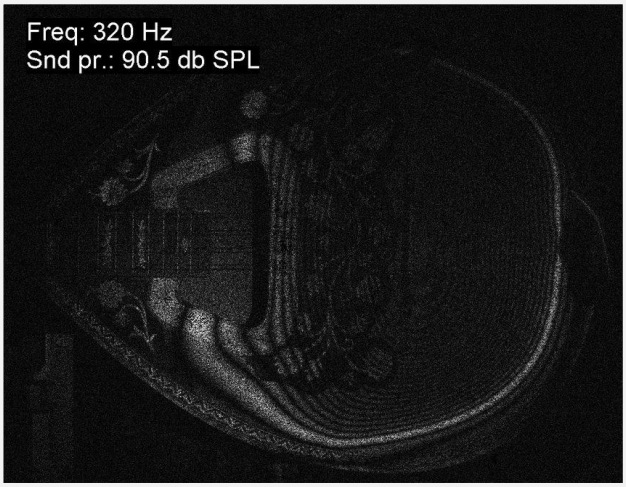
Η παρούσα υποενότητα συμπληρώνει την Ενότητα 2.4 παρουσιάζοντας συνοπτικά: (α) γιατί απαιτείται αποθορυβοποίηση στις εικόνες ESPI χρονικού μέσου όρου, (β) γιατί επιλέχθηκε το DnCNN ως πρότυπο αναφοράς deep denoiser, (γ) τι είναι ο μηχανισμός Efficient Channel Attention (ECA) και πώς ενσωματώνεται, και (δ) πώς οι επιλογές κανονικοποίησης (BatchNorm έναντι GroupNorm) επηρεάζουν τη συμπεριφορά attention σε μικρά batch μεγέθη. Οι λεπτομέρειες υλοποίησης και τα αποτελέσματα ablation τεκμηριώνονται στο Κεφάλαιο 4 και στο Παράρτημα Α.

2.4.7.2 DnCNN: residual learning για αποθορυβοποίηση

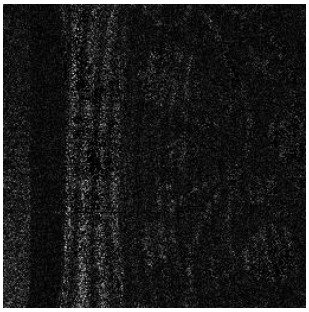
Η αποθορυβοποίηση δεν αντιμετωπίζεται ως αυτοσκοπός, αλλά ως μέσο διατήρησης της «λειτουργικής» πληροφορίας των μοτίβων κροσσών (fringe patterns). Η υπερβολική εξομάλυνση (over-smoothing) ενδέχεται να καταστρέψει λεπτές κομβικές γραμμές (nodal lines) και τοπικές χωρικές δομές, οι οποίες είναι κρίσιμες τόσο για την εξαγωγή των χειροκίνητων χαρακτηριστικών (hand-crafted features) που αναλύονται στο Κεφάλαιο 3, όσο και για την τελική ταξινόμηση των ιδιομορφών (Κεφάλαια 5–7). Για τον λόγο αυτό, η αξιολόγηση ενός μοντέλου αποθορυβοποίησης (denoiser) οφείλει να βασίζεται και σε λειτουργικά κριτήρια επακόλουθης αξιολόγησης (downstream metrics, π.χ. Macro-F1), και όχι αποκλειστικά σε τυπικές μετρικές ανακατασκευής εικόνας, όπως το PSNR και το SSIM.

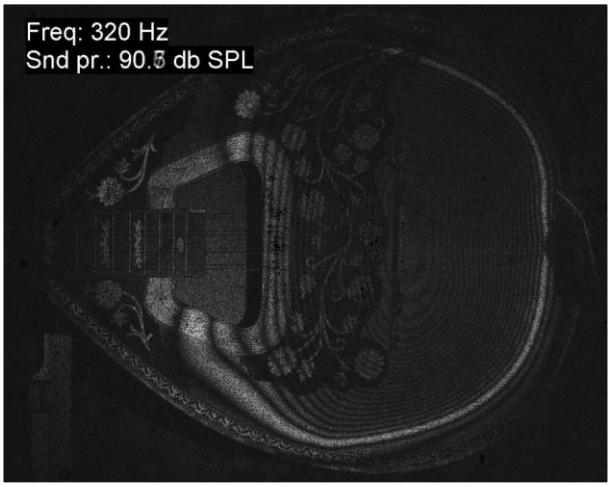
Στην τεχνική ESPI, η καταγραφή βασίζεται σε σύμφωνο (coherent) φωτισμό και οπτική συμβολομετρία, με αποτέλεσμα ο επικρατών θόρυβος να λαμβάνει τη μορφή θορύβου κηλίδων (speckle), ο οποίος παρουσιάζει αυστηρά πολλαπλασιαστικό χαρακτήρα. Επιπρόσθετα, η διαδικασία ανίχνευσης και ψηφιοποίησης του σήματος εισάγει θόρυβο

βολής (shot noise, κατανομής Poisson) καθώς και ηλεκτρονικό θόρυβο ανάγνωσης (read noise, κατανομής Gauss). Συνεπώς, ένα ρεαλιστικό φυσικό μοντέλο παρατήρησης μπορεί να περιγραφεί ως μια διαδοχική αλυσίδα αλλοιώσεων της μορφής Speckle → Poisson → Gaussian, όπως αναπτύχθηκε εκτενώς στην Ενότητα 2.4 και εξειδικεύτηκε στην Υποενότητα 2.4.6 μέσω της γεννήτριας ψευδο-θορύβου (pseudo-noise generator). Η πρακτική επίδραση αυτής της αλυσίδας θορύβου, καθώς και η ικανότητα του μοντέλου DnCNN να ανακτά τη λειτουργική πληροφορία χωρίς υπερβολική εξομάλυνση, αποτυπώνονται οπτικά στο Σχήμα 2.8, όπου παρατίθεται μια χαρακτηριστική ποιοτική σύγκριση.

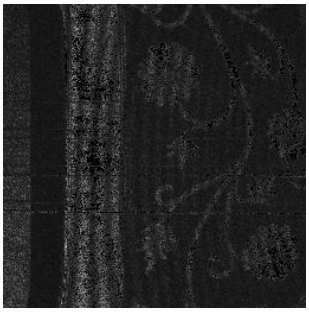


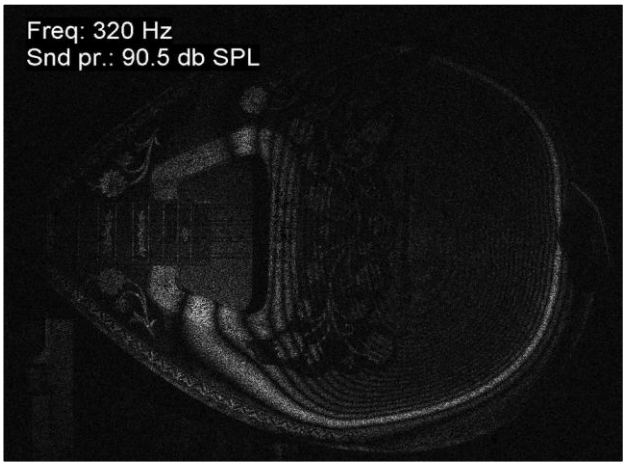
Είσοδος single-shot



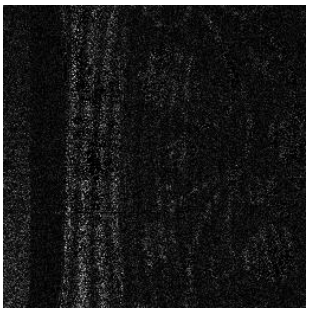


multi-frame averaged





Έξοδος του δικτύου DnCNN



Σχήμα 2.8: *Ποιοτική σύγκριση μορφολογίας κροσσών στην ίδια συχνότητα και στο ίδιο πειραματικό αντικείμενο: (α) Είσοδος μοναδικής λήψης (single-shot), (β) Αναφορά χρονικού μέσου όρου (multi-frame averaged), (γ) Έξοδος του δικτύου DnCNN. Όλες οι απεικονίσεις έχουν υποστεί κοινή επέκταση αντίθεσης (common contrast stretching, βασισμένη στο 1ο–99ο εκατοστημόριο της εικόνας αναφοράς) για άμεση συγκρισιμότητα.*

2.4.7.3 Channel attention και Efficient Channel Attention (ECA)

Στο πλαίσιο της διπλωματικής, η επιλογή του DnCNN υποστηρίζεται από τρεις πρακτικούς λόγους: (i) αποτελεί ευρέως αναφερόμενο πρότυπο αναφοράς στη βιβλιογραφία, (ii) είναι σχετικά ελαφρύ και αναπαράξιμο σε περιβάλλον εργαστηρίου, και (iii) επιτρέπει καθαρές συγκρίσεις (A/B tests) όταν προστίθενται μηχανισμοί attention ή αλλάζουν επιλογές κανονικοποίησης.

Το DnCNN (Denoising Convolutional Neural Network) προτάθηκε ως ισχυρό πρότυπο αναφοράς για image denoising, ειδικά λόγω της στρατηγικής residual learning: αντί να προβλέπει απευθείας την καθαρή εικόνα x, το δίκτυο προβλέπει τον θόρυβο n̂ που περιέχεται στην παρατηρούμενη εικόνα y, ώστε η εκτίμηση να προκύπτει ως x̂ = y − n̂. Η παραδοχή αυτή βελτιώνει τη σταθερότητα εκπαίδευσης και επιτρέπει στο δίκτυο να εστιάσει στις στατιστικές του θορύβου, ιδιαίτερα όταν ο στόχος είναι η διατήρηση δομών υψηλής συχνότητας όπως οι κροσσοί. Στην κλασική του μορφή, το DnCNN υλοποιείται ως σειρά συνελίξεων με ReLU και ενδιάμεση κανονικοποίηση (συχνά BatchNorm), και μπορεί να προσαρμοστεί σε διαφορετικά κανάλια εισόδου (π.χ. grayscale ESPI).

2.4.7.4 Κανονικοποίηση: BatchNorm έναντι GroupNorm και συμβατότητα με attention

Η επιλογή ECA στη διπλωματική έγινε επειδή θεωρητικά μπορεί να βελτιώσει την επιλεκτικότητα του denoiser σε χαρακτηριστικά που αντιστοιχούν σε fringe/phase δομές και να περιορίσει ανεπιθύμητες «θορυβώδεις» αποκρίσεις, χωρίς να αυξάνει σημαντικά τον αριθμό παραμέτρων. Με αυτόν τον τρόπο, μπορεί να λειτουργήσει ως στοχευμένος μηχανισμός ενίσχυσης δομής, συμβατός με τον στόχο της ταξινόμησης modes.

Οι μηχανισμοί attention στα CNNs εισάγουν τη δυνατότητα δυναμικής στάθμισης των χαρακτηριστικών, ώστε το δίκτυο να δίνει μεγαλύτερη έμφαση σε «χρήσιμα» κανάλια και να καταστέλλει λιγότερο χρήσιμα. Η κατηγορία channel attention (π.χ. SE blocks) υπολογίζει για κάθε κανάλι έναν συντελεστή $\alpha_c \in (0,1)$ και εφαρμόζει channel-wise πολλαπλασιασμό: $Y_c = \alpha_c \cdot X_c$. Το ECA (Efficient Channel Attention) είναι μια ελαφριά παραλλαγή channel attention που αποφεύγει πλήρως συνδεδεμένα layers και χρησιμοποιεί 1D convolution πάνω στο διάνυσμα καναλιών που προκύπτει από global average pooling. Έτσι, επιτυγχάνει συσχετίσεις μεταξύ γειτονικών καναλιών με πολύ μικρό υπολογιστικό κόστος.

2.4.7.5 Επιλογή Στρατηγικής Κανονικοποίησης (Batch vs. Group Normalization) και Σύνδεση με τη ροή εργασίας (Pipeline)

Η επιλογή του κατάλληλου μηχανισμού κανονικοποίησης (normalization) είναι απολύτως κρίσιμη για τη σωστή συνέργεια με τους μηχανισμούς προσοχής. Στην παρούσα ροή εργασίας (pipeline), η **Κανονικοποίηση Ομάδας (Group Normalization - GN)** προκρίνεται έναντι της παραδοσιακής Κανονικοποίησης Παρτίδας (Batch Normalization - BN) για δύο θεμελιώδεις λόγους:

1. **Ανεξαρτησία από το Μέγεθος Παρτίδας:** Η GN υπολογίζει τα στατιστικά στοιχεία ανά δείγμα και ομάδα καναλιών, ανεξάρτητα από το μέγεθος της παρτίδας (batch size). Αυτό είναι κρίσιμο στην επεξεργασία εικόνων ESPI υψηλής ανάλυσης, όπου περιορισμοί μνήμης επιβάλλουν συχνά την εκπαίδευση με πολύ μικρά batches (π.χ. 1 ή 2 εικόνες).

2. **Συμβατότητα με το Attention:** Η παραδοσιακή BN περιλαμβάνει βαθμούς ελευθερίας (affine transformations) οι οποίοι μπορούν υπό συνθήκες να «απορροφήσουν» ή να εξουδετερώσουν το δυναμικό scaling που προσπαθεί να επιβάλει το ECA module. Η χρήση GN διασφαλίζει ότι τα βάρη επαναστάθμισης του attention παραμένουν ενεργά και αποτελεσματικά.

2.5 Διατύπωση του Προβλήματος Μηχανικής Μάθησης

Η παρούσα διπλωματική τυποποιεί την αναγνώριση ιδιομορφών δόνησης (vibration modes) από εικόνες χρονικού μέσου όρου (time-averaged ESPI fringe patterns) ως ένα πρόβλημα **επιβλεπόμενης ταξινόμησης (supervised classification)**.

Σε αντίθεση με τα γενικά προβλήματα υπολογιστικής όρασης (generic computer vision), η «ταυτότητα» ενός mode στο ESPI δεν καθορίζεται αποκλειστικά από τη χωρική μορφολογία του μοτίβου (π.χ. σχήμα κομβικών γραμμών, θέση κοιλιών/δεσμών). Αντιθέτως, είναι άρρηκτα συνδεδεμένη με τη **φυσική πληροφορία** της συχνότητας διέγερσης. Ως εκ τούτου, το μοντέλο καλείται να μάθει μια απεικόνιση που συνδυάζει οπτικά χαρακτηριστικά και φυσικούς περιορισμούς (physics priors).

Η ενότητα αυτή ορίζει με ακρίβεια:

- Τη δομή και τη φύση των δεδομένων εισόδου.
- Την ονοματολογία των κλάσεων στόχων.
- Τον μαθηματικό συμβολισμό που θα χρησιμοποιηθεί.
- Τις θεμελιώδεις προκλήσεις του προβλήματος, με έμφαση στην **έντονη ανισορροπία κλάσεων (class imbalance)**.

Σκοπός είναι η δημιουργία ενός κοινού, τυποποιημένου πλαισίου πάνω στο οποίο θα βασιστεί η πειραματική διαδικασία και η αξιολόγηση στα Κεφάλαια 3–6.

2.5.1 Από το ESPI στη διατύπωση εποπτευόμενης ταξινόμησης

Θεωρούμε ένα σύνολο παρατηρήσεων $\mathcal{D} = \{(x_i, y_i)\}_{i=1}^{N}$, όπου κάθε x_i αντιστοιχεί σε καταγραφή ESPI ενός δοκιμίου υπό συγκεκριμένη διέγερση (συχνότητα f_i και στάθμη ή συνθήκες λήψης), ενώ το y_i είναι η ετικέτα (label) που αντιστοιχεί στην ιδιομορφή δόνησης που παρατηρείται στην εικόνα. Στόχος είναι η εκμάθηση ενός ταξινομητή h_θ, ο οποίος

για ένα νέο δείγμα x παράγει την πρόβλεψη $\hat{y} = h_\theta(x)$. Στην κλασική προσέγγιση (pixel-based), η είσοδος είναι η ίδια η εικόνα. Αντίθετα, στην προσέγγιση καθοδηγούμενη από τη φυσική που υιοθετείται στην παρούσα διπλωματική εργασία, αξιοποιούνται επιπλέον φυσικά μεγέθη και εκ των προτέρων γνώση (π.χ., η συχνότητα f σε Hz ή παράγωγα χαρακτηριστικά θεμελιωμένα στη φυσική), ώστε η μαθησιακή διαδικασία να «επαναχρησιμοποιεί» τη δομή που επιβάλλει η θεωρία ταλαντώσεων.

Η ελαχιστοποίηση του σφάλματος επιτυγχάνεται συνήθως μέσω της ελαχιστοποίησης του εμπειρικού κινδύνου (empirical risk). Για τα πιθανοτικά μοντέλα ταξινόμησης χρησιμοποιείται ευρέως η διασταυρούμενη εντροπία (cross-entropy), ενώ για αλγορίθμους τύπου Random Forest το κριτήριο βελτιστοποίησης ενσωματώνεται στον τρόπο κατασκευής των δέντρων (π.χ., ακαθαρσία Gini - Gini impurity). Παρότι οι ακριβείς επιλογές των συναρτήσεων απωλειών και των μεθόδων βελτιστοποίησης αναλύονται στα επόμενα κεφάλαια, η κρίσιμη παρατήρηση εδώ είναι ότι το πρόβλημα είναι εγγενώς «φυσικά δομημένο» και, συνεπώς, δεν είναι υποχρεωτικό να αντιμετωπίζεται ως μια αυστηρά καθοδηγούμενη από τα δεδομένα (data-driven) διαδικασία, βασισμένη αποκλειστικά στα πρωτογενή εικονοστοιχεία.

2.5.2 Ορισμός εισόδων, μεταβλητών και επιπέδων αναπαράστασης

Στη διπλωματική συναντώνται δύο επίπεδα αναπαράστασης των δεδομένων:

• **Εικόνες (image space):** time-averaged ESPI fringe maps (και, όπου απαιτείται, παράγωγα πεδία φάσης).

• **Χαρακτηριστικά (feature space):** μετρήσιμες ποσότητες που συνοψίζουν τη μορφολογία (pattern features) και φυσικά priors που σχετίζονται με τη συχνότητα (frequency-based features).

Ο διαχωρισμός αυτός είναι θεμελιώδης για το κεντρικό αφήγημα: τα pixel-based μοντέλα (π.χ. CNN/ResNet) πρέπει να ανακαλύψουν «μόνα τους» ποια δομικά στοιχεία του fringe pattern σχετίζονται με το mode, ενώ το physics-informed μοντέλο (Hybrid RF) τροφοδοτείται με ρητές αναπαραστάσεις που προκύπτουν από φυσική ερμηνεία (βλ. §2.2–2.4 και Κεφ.3–4). Η σύγκριση αυτών των δύο δρόμων είναι βασικός άξονας των κεφαλαίων αποτελεσμάτων.

2.5.3 Ταξινομική δομή κλάσεων (labels) και κριτήρια επισήμανσης

Η ταξινόμηση οργανώνεται σε ένα σχήμα 6 κλάσεων, το οποίο περιλαμβάνει τυπικές ιδιομορφές (m, n) χαμηλής τάξης, συμπεριφορές υψηλότερης πολυπλοκότητας, καθώς και μία κατηγορία ετερογενούς ή αβέβαιης παρατήρησης. Όπως αναλύεται στον Πίνακα 2.7, η συγκεκριμένη κωδικοποίηση επιλέχθηκε ώστε να εξασφαλίζει τη βέλτιστη ισορροπία μεταξύ φυσικής ακρίβειας και πρακτικής αξιοπιστίας κατά την επισήμανση των δεδομένων. Ειδικότερα, οι θεμελιώδεις ιδιομορφές χαμηλής τάξης διακρίνονται ρητά μεταξύ τους με βάση την τοπολογία των κομβικών γραμμών (nodal lines) και τη συμμετρία των κροσσών συμβολής. Αντίθετα, οι ιδιομορφές υψηλότερης τάξης ομαδοποιούνται σε μία ενιαία κλάση για την εξασφάλιση σταθερότητας έναντι της αυξημένης πυκνότητας ιδιομορφών, ενώ το σχήμα ολοκληρώνεται με μια κλάση απορρόφησης (catch-all) για τις περιπτώσεις χαμηλής ποιότητας ή πειραματικής αβεβαιότητας.

Πίνακας 2.7: *Ορισμός των 6 κλάσεων modes που χρησιμοποιούνται στη διπλωματική.*

Κλάση	**Ερμηνεία (φυσική/μορφολογία)**	**Σχόλιο για την επισήμανση**
mode_(1,1)H	Χαμηλής τάξης mode (οριζόντια/διαμήκης συμμετρία fringe).	Συνήθως αναγνωρίσιμο σε χαμηλές συχνότητες.
mode_(1,1)T	Χαμηλής τάξης mode με διαφορετική τοπολογία nodal lines από το (1,1)H.	Απαιτεί προσοχή σε περιοχές overlap.
mode_(1,2)	Mode με αύξηση αριθμού/διάταξης nodal lines σε σχέση με (1,1).	Συχνότερη αμφισημία κοντά σε γειτονικές ζώνες.
mode_(2,1)	Σπάνιο mode (minority), με χαρακτηριστική μορφολογία.	Μικρό support → κρίσιμο για Macro-F1.
mode_higher	Ομάδα υψηλότερης τάξης modes (modal density υψηλή).	Σκόπιμη ομαδοποίηση για σταθερότητα.
other_unknown	Ετερογενείς/αμφίβολες καταγραφές ή μη καθαρά ταξινομήσιμα patterns.	Απορροφά περιπτώσεις χαμηλής ποιότητας/αβεβαιότητας.

Η διαδικασία επισήμανσης (annotation) στηρίζεται στην οπτική αναγνώριση των fringe patterns και στη συνέπεια με το αναμενόμενο φασματικό πλαίσιο (frequency context) κάθε τρόπου. Με άλλα λόγια, η συχνότητα δεν αντιμετωπίζεται ως «μεταδεδομένο» χωρίς σημασία, αλλά ως μέρος της φυσικής ταυτότητας του mode. Το γεγονός αυτό προετοιμάζει τη λογική των frequency priors (Κεφ.4) και εξηγεί γιατί το πρόβλημα είναι κατάλληλο για physics-informed μοντελοποίηση.

2.5.4 Σύνθεση του συνόλου δεδομένων και στατιστικά κατανομής

Το κύριο σύνολο δεδομένων (wood) αποτελείται από N = 3 443 επισημασμένες καταγραφές από τρία δοκίμια/όργανα (W01, W02, W03), μετά από quality filtering (βλ. Παράρτημα Β.1). Οι καταγραφές προκύπτουν από πειράματα διέγερσης σε πολλαπλές συχνότητες και παράγουν time-averaged fringe maps σε ανάλυση 512×512.

Πριν από το τελικό ποιοτικό φιλτράρισμα (έλεγχος ποιότητας), η αρχική συλλογή περιλάμβανε για κάθε συχνότητα ένα σύνολο 8–12 πρωτογενών λήψεων μονοκαρέ (single-shot, θορυβώδεις), από τις οποίες προέκυπτε η αναφορά μέσου όρου πολλαπλών καρέ (multi-frame averaged). Με αυτόν τον τρόπο, στο συνολικό αποθετήριο δημιουργούνται περίπου 20–25 χιλ. πραγματικές εικόνες (πρωτογενείς θορυβώδεις λήψεις και αντίστοιχες averaged αναφορές), οι οποίες αξιοποιούνται κυρίως για την εκπαίδευση/αξιολόγηση αποθορυβοποίησης και για τη σύνθεση πρόσθετων δεδομένων. Από αυτό το μεγάλο σώμα δεδομένων επιλέχθηκε το τελικό υποσύνολο N = 3 443 που χρησιμοποιείται στα κύρια πειράματα ταξινόμησης, ώστε να εξασφαλιστεί σταθερή ποιότητα fringe maps και αξιόπιστη επισημείωση ιδιομορφών.

Ένα από τα πλέον ιδιαίτερα και κρίσιμα χαρακτηριστικά του διαθέσιμου συνόλου δεδομένων (dataset) είναι η **έντονη ανισορροπία κλάσεων (class imbalance)**. Πρέπει να υπογραμμιστεί ότι αυτή η ασυμμετρία δεν προκύπτει από κάποιο μεθοδολογικό σφάλμα κατά τη συλλογή, αλλά αντανακλά την ίδια την πειραματική και φυσική πραγματικότητα: ορισμένες ιδιομορφές διεγείρονται και απομονώνονται πολύ πιο δύσκολα στο εργαστήριο σε σχέση με άλλες.

Συγκεκριμένα, η κυρίαρχη κλάση other/unknown —η οποία ενσωματώνει μεικτές, μη-ξεκάθαρες, υπερτιθέμενες ή ανώτερης τάξης ιδιομορφές— συγκεντρώνει το συντριπτικά μεγαλύτερο ποσοστό των διαθέσιμων δειγμάτων. Στον αντίποδα, υπάρχουν θεμελιώδεις

μορφές, όπως η κλάση (2,1), οι οποίες εμφανίζονται εξαιρετικά σπάνια σε καθαρή μορφή, αποτελώντας τη μειοψηφία του συνόλου.

Ως ποσοτικός δείκτης αυτής της ανισορροπίας χρησιμοποιείται ο λόγος της πλειοψηφικής προς τη μειοψηφική κλάση (majority-to-minority ratio), ο οποίος υπολογίζεται στην ακραία τιμή του **30,9:1**.

Επιπτώσεις για τη Μηχανική Μάθηση Αυτή η τάξη μεγέθους καθιστά σαφές ότι η εκπαίδευση των μοντέλων δεν μπορεί να αντιμετωπιστεί με συμβατικούς όρους. Προκαλεί δύο βασικές μεθοδολογικές συνεπαγωγές:

1. **Ακαταλληλότητα απλών μετρικών: Η χρήση της μετρικής Accuracy είναι εξαιρετικά παραπλανητική, καθώς ένα μοντέλο που προβλέπει μόνιμα την πλειοψηφική κλάση θα φαινόταν τεχνητά επιτυχημένο. Αυτό καθιστά επιβεβλημένη την αυστηρή αξιολόγηση μέσω δεικτών όπως το Macro-F1, το οποίο αντιμετωπίζει ισότιμα την απόδοση σε κάθε κλάση.**

2. **Ανάγκη αντιμετώπισης κατά την εκπαίδευση:** Απαιτείται η υιοθέτηση εξειδικευμένων στρατηγικών κατά την εκπαίδευση των νευρωνικών δικτύων (όπως η χρήση σταθμισμένων συναρτήσεων απώλειας / class weighting), ώστε το μοντέλο να μην αγνοεί τις σπάνιες ιδιομορφές.

Οι στρατηγικές αντιμετώπισης αυτού του φαινομένου και η αναλυτική στατιστική συμπεριφορά των μοντέλων παρουσιάζονται εκτενώς στα **Κεφάλαια 5.2.2 και 7.2.4**.

Πίνακας 2.8: *Κατανομή κλάσεων στο τελικό dataset (N=3 443) και λόγοι ανισορροπίας.*

Κλάση	Δείγματα	Ποσοστό	Imbalance (vs minority)
other_unknown	1.794	52.1%	30,9:1
mode_higher	1.115	32.4%	19.2:1
mode_(1,1)H	199	5.8%	3.4:1
mode_(1,1)T	171	5.0%	2.9:1
mode_(1,2)	106	3.1%	1.8:1
mode_(2,1)	58	1.7%	1.0:1

Η παραπάνω κατανομή έχει άμεσες συνέπειες στη σχεδίαση του συστήματος: (α) η απλή Accuracy μπορεί να είναι παραπλανητική, (β) απαιτούνται μετρικές που αποτιμούν ισότιμα όλες τις κλάσεις (Macro-F1, per-class Recall), και (γ) σε μοντέλα gradient-based (CNN) χρειάζονται τεχνικές αντιμετώπισης ανισορροπίας (re-weighting, focal loss, balanced sampling). Τα σχετικά ορίζονται αναλυτικά στην §2.6 και εφαρμόζονται στα Κεφάλαια 4–6.

2.5.5 Η κλάση other_unknown και η μετάβαση από 6-class σε 5-class (production)

Η κλάση other_unknown είναι λειτουργικά αναγκαία στη φάση δημιουργίας του συνόλου δεδομένων, επειδή απορροφά περιπτώσεις όπου η εικόνα ESPI δεν επιτρέπει την αξιόπιστη ανάθεση σε μια συγκεκριμένη ιδιομορφή (π.χ. χαμηλή αντίθεση κροσσών συμβολής, έντονα artefacts, μικτή απόκριση ή επικάλυψη). Ωστόσο, πρόκειται για μια ετερογενή κλάση («catch-all»), η οποία δεν αντιστοιχεί σε μία ενιαία φυσική κατάσταση. Αυτό έχει δύο πρακτικές συνέπειες:

- **Καθιστά δύσκολη την ερμηνεία των σφαλμάτων**, επειδή η κλάση δεν παρουσιάζει μία σταθερή μορφολογία.
- **Μπορεί να οδηγήσει το μοντέλο σε εύκολες λύσεις** λόγω μεροληψίας πλειοψηφίας (majority bias), εφόσον αποτελεί τη μεγαλύτερη κλάση.

Για τον λόγο αυτό, στην έκδοση τελικής εφαρμογής v6.1 υιοθετείται ένα σχήμα 5 κλάσεων, το οποίο εστιάζει αποκλειστικά στις «καθαρές» ιδιομορφές, ενώ οι αμφίβολες περιπτώσεις αντιμετωπίζονται μέσω πολιτικών απόρριψης βάσει αβεβαιότητας (π.χ. κατωφλίωση πιθανότητας ή παραδοχές ανοικτού συνόλου - open-set). Στο κύριο σώμα της διπλωματικής εργασίας, ωστόσο, το σχήμα 6 κλάσεων διατηρείται ως μια πιο ρεαλιστική απεικόνιση της εργαστηριακής διαδικασίας, κατά την οποία και η ανθρώπινη ταξινόμηση συναντά εξίσου «μη ταξινομήσιμες» περιπτώσεις.

2.5.6 Σύνοψη και Γέφυρα προς το Μεθοδολογικό Πλαίσιο Αξιολόγησης

Ανακεφαλαιώνοντας, η παρούσα μελέτη τυποποιεί το πρόβλημα αναγνώρισης ιδιομορφών σε δεδομένα ESPI ως ένα πρόβλημα ταξινόμησης 6 κλάσεων, το οποίο χαρακτηρίζεται από ισχυρή φυσική δομή αλλά και ακραία ανισορροπία δεδομένων (λόγος 30,9:1). Τα ιδιαίτερα αυτά χαρακτηριστικά καθιστούν επιβεβλημένη:

- Την υιοθέτηση εξειδικευμένων μετρικών απόδοσης για ανισόρροπα σύνολα (**Macro-F1, per-class F1**).

- Την εφαρμογή αυστηρών πρωτοκόλλων ελέγχου της γενίκευσης (**LOBO/LODO**) για την αντιμετώπιση της μετατόπισης πεδίου (domain shift).

- Την αξιοποίηση πρότερων πληροφοριών θεμελιωμένων στη φυσική (physics priors) ως κεντρικής στρατηγικής μάθησης καθοδηγούμενης από τη φυσική.

Η ενότητα που ακολουθεί (§2.6) θεμελιώνει αυστηρά τις έννοιες των διαχωρισμών (splits), της διαρροής πληροφορίας (leakage) και της διασταυρούμενης επικύρωσης, συγκροτώντας το απαραίτητο μεθοδολογικό υπόβαθρο και το κοινό «λεξιλόγιο» για την πειραματική ανάλυση των Κεφαλαίων 4–8.

2.6 Θεμελιώδεις Έννοιες Μηχανικής Μάθησης και Πρωτόκολλα Αξιολόγησης

Η παρούσα διπλωματική αντιμετωπίζει την αναγνώριση ιδιομορφών δόνησης από εικόνες ESPI χρονικού μέσου όρου ως πρόβλημα επιβλεπόμενης ταξινόμησης, το οποίο όμως διαφέρει ουσιαστικά από ένα «γενικό» πρόβλημα computer vision: (i) το dataset είναι έντονα ανισόρροπο (imbalance ratio 30,9:1), (ii) η συχνότητα διέγερσης λειτουργεί ως ισχυρός φυσικός prior για την κλάση, και (iii) η γενίκευση πρέπει να ελεγχθεί τόσο ως προς τη συχνότητα (frequency generalization) όσο και ως προς το δοκίμιο/όργανο (workpiece / domain shift). Ως εκ τούτου, το Κεφάλαιο 2 δεν αρκεί να περιγράψει μόνο τη φυσική και το ESPI, αλλά οφείλει να θεμελιώσει τις βασικές έννοιες αξιολόγησης και τα πρωτόκολλα επικύρωσης που χρησιμοποιούνται στα Κεφάλαια 3–6 (train/validation/test, leakage, LOBO/LODO, μετρικές για imbalanced δεδομένα και στατιστικό έλεγχο).

Στη συνέχεια παρουσιάζονται συνοπτικά αλλά πλήρως τεκμηριωμένα: (α) ο σωστός ορισμός splits και οι πηγές leakage, (β) τα πρωτόκολλα cross-validation που εξειδικεύουν τις έννοιες «γενίκευση» και «domain shift», (γ) οι κατάλληλες μετρικές για ανισόρροπες κλάσεις και (δ) οι στατιστικές μέθοδοι ποσοτικοποίησης αβεβαιότητας και σύγκρισης ταξινομητών (McNemar, bootstrap, effect sizes). Οι βασικές αρχές ακολουθούν την καθιερωμένη βιβλιογραφία στη στατιστική μάθηση και στην αξιολόγηση μοντέλων (Hastie et

al., 2009· Bishop, 2006· Kohavi, 1995· Efron & Tibshirani, 1993· Sokolova & Lapalme, 2009).

2.6.1 Διαχωρισμοί Δεδομένων (Splits) και Διαρροή Πληροφορίας (Data Leakage)

Ο θεμελιώδης μηχανισμός ελέγχου της ικανότητας γενίκευσης ενός μοντέλου μηχανικής μάθησης είναι ο αυστηρός και μεθοδικός διαχωρισμός του αρχικού συνόλου δεδομένων σε τρία ανεξάρτητα υποσύνολα: εκπαίδευσης (training), επικύρωσης (validation) και ελέγχου (test).

- **Σύνολο Εκπαίδευσης (Training Set):** Εδώ πραγματοποιείται η βελτιστοποίηση των εσωτερικών παραμέτρων (βαρών) του μοντέλου.
- **Σύνολο Επικύρωσης (Validation Set):** Χρησιμοποιείται κατά τη διάρκεια της εκπαίδευσης για την επιλογή των βέλτιστων υπερ-παραμέτρων (hyperparameter tuning), τη λήψη απόφασης για πρόωρο τερματισμό (early stopping) και τη σύγκριση διαφορετικών αρχιτεκτονικών.
- **Σύνολο Ελέγχου (Test Set):** Σε αυτό διενεργείται η τελική, αμερόληπτη εκτίμηση της απόδοσης, *αφού* το μοντέλο έχει «κλειδώσει» οριστικά.

Η τήρηση αυτής της αρχής είναι ζωτικής σημασίας, καθώς προστατεύει από το φαινόμενο της υπερπροσαρμογής (overfitting) και αποτρέπει την τεχνητά αισιόδοξη εκτίμηση της απόδοσης. Η τελευταία προκαλείται συχνά από τη **διαρροή πληροφορίας (data leakage)**, δηλαδή την αθέλητη μεταφορά γνώσης από το σύνολο ελέγχου προς τη διαδικασία εκπαίδευσης (Goodfellow et al., 2016).

Η Πρόκληση της Συσχέτισης στα Δεδομένα ESPI

Στο πλαίσιο των οπτικών μετρήσεων ESPI, η έννοια της στατιστικής ανεξαρτησίας δεν ταυτίζεται απαραίτητα με την ανεξαρτησία των μεμονωμένων «εικόνων». Πολλά δείγματα εμφανίζουν ισχυρές λειτουργικές και χωρικές συσχετίσεις: μπορεί να προέρχονται από την ίδια ακριβώς φυσική κατάσταση διέγερσης, να αποτελούν διαδοχικά χρονικά καρέ της ίδιας μέτρησης, ή να έχουν παραχθεί από την ίδια εικόνα χρονικού μέσου όρου (averaged reference).

Συνεπώς, ο ορθός διαχωρισμός (splitting) πρέπει να εκτελείται σε επίπεδο **«ομάδων» (groups)** και όχι σε επίπεδο μεμονωμένων δειγμάτων (random splitting). Η παράβλεψη

αυτού του κανόνα οδηγεί σε ενδο-ομαδική συσχέτιση (in-group correlation) μεταξύ των συνόλων, με αποτέλεσμα τη σοβαρή υποτίμηση του πραγματικού σφάλματος γενίκευσης (Varoquaux, 2018).

Κύριες Πηγές Διαρροής Πληροφορίας

Στην παρούσα διπλωματική εργασία, αναγνωρίζονται και αντιμετωπίζονται ρητά οι εξής κρίσιμες πηγές διαρροής:

- **Διαρροή μέσω Μέσης Αναφοράς (Reference Leakage):** Εάν η ίδια εικόνα αναφοράς (time-averaged reference) ή τα παράγωγά της (π.χ. χάρτες φάσης) τοποθετηθούν ταυτόχρονα στα σύνολα train και test, το μοντέλο δύναται να «απομνημονεύσει» το στατικό υπόβαθρο (background) ή συγκεκριμένα τεχνουργήματα του δοκιμίου, αγνοώντας την ουσιαστική πληροφορία των κροσσών.

- **Διαρροή μέσω Συσχέτισης Πλαισίων (Multi-frame Leakage):** Όταν πολλαπλά καρέ (frames) από την ίδια ακριβώς λήψη (ίδια συχνότητα και στάθμη) διαμοιραστούν τυχαία σε διαφορετικά splits, το test set παύει να αποτελεί «άγνωστο» πεδίο για το μοντέλο, καταστρέφοντας την αξιοπιστία της αξιολόγησης.

- **Διαρροή μέσω Μεταδεδομένων (Metadata Leakage):** Πληροφορίες που εμπεριέχονται στα ονόματα των αρχείων ή στις ετικέτες φακέλων (π.χ. τιμές Hz, dB, κωδικοί δοκιμίων) αποκλείονται αυστηρά από τα χαρακτηριστικά (features) εισόδου του μοντέλου, προκειμένου να διασφαλιστεί ότι η ταξινόμηση βασίζεται αποκλειστικά στο οπτικό/χωρικό μοτίβο.

Για να διασφαλιστεί η απόλυτη μεθοδολογική ορθότητα, στην προτεινόμενη ροή εργασίας, τόσο η διαδικασία επιλογής των βέλτιστων χαρακτηριστικών (feature selection) όσο και η βελτιστοποίηση των υπερ-παραμέτρων του ταξινομητή (π.χ. Random Forest), εκτελούνται **χωρίς καμία απολύτως πρόσβαση** στα δεδομένα ελέγχου (test folds). Η ίδια αυστηρή αρχή διέπει και τη σύγκριση με τα μοντέλα αναφοράς (baselines) (Hastie et al., 2009).

Πίνακας 2.9: *Τυπολογία στρατηγικών διαχωρισμού δεδομένων (data splitting), πρακτική χρησιμότητα και συνήθεις μεθοδολογικές παγίδες.*

Στρατηγική (Split Type)	**Τι εκτιμά / Στόχος**	**Πότε χρησιμοποιείται (Εφαρμογή)**	**Συνήθης Παγίδα (Leakage Risk)**
Hold-out (Train/Val/Test)	Γενίκευση σε «άγνωστα» δείγματα παρόμοιας κατανομής.	Για την τελική αναφορά της επίδοσης ενός μοντέλου.	Επαναληπτική ρύθμιση παραμέτρων παρατηρώντας το test set (implicit tuning).
Stratified Split	Γενίκευση με διατήρηση των αρχικών αναλογιών των κλάσεων.	Σε μη ισορροπημένα (imbalanced) δεδομένα, όπως του ESPI.	Διαστρωμάτωση (stratification) *χωρίς* ομαδοποίηση (group constraints).
Group Split (π.χ. ανά λήψη)	Γενίκευση σε μια εντελώς νέα, μη ιδωμένη πειραματική «λήψη».	Όταν υπάρχουν συσχετισμένα καρέ ή παράγωγα της ίδιας μέτρησης.	Τυχαίος διαχωρισμός εικόνων που προέρχονται από την ίδια ακριβώς μέτρηση.
Cross-Validation (K-fold)	Τη μέση επίδοση και τη διακύμανση σε πολλαπλά, εναλλασσόμενα splits.	Σε μικρά datasets για την εξαγωγή πιο στιβαρών (robust) εκτιμήσεων.	Εφαρμογή χωρίς φωλιασμένη (nested) επικύρωση, που οδηγεί σε αισιόδοξη μεροληψία.

2.6.2 Πρωτόκολλα Cross-Validation: K-Fold, LOBO και LODO

Στο πλαίσιο της ταξινόμησης ιδιομορφών ESPI (modal classification), η ικανότητα «γενίκευσης» δεν αποτελεί μια μονοδιάστατη έννοια. Στην πράξη, υφίστανται τουλάχιστον δύο εντελώς ανεξάρτητες πηγές μετατόπισης κατανομής (domain shift): (α) η μετατόπιση κατά συχνότητα διέγερσης (unseen frequency regions) και (β) η μετατόπιση κατά δοκίμιο ή μουσικό όργανο (board/workpiece variability).

Για τον λόγο αυτόν, δεν αρκεί ένας απλός, τυχαίος διαχωρισμός των δεδομένων. Υιοθετούνται εξειδικευμένα πρωτόκολλα διασταυρούμενης επικύρωσης (cross-validation), σχεδιασμένα να απομονώνουν και να ελέγχουν κάθε τύπο μεταβολής ξεχωριστά (Kohavi, 1995; Dietterich, 1998).

Α) Stratified K-Fold (Πρότυπο Αναφοράς)

Στο διαστρωματωμένο (stratified) K-fold, το σύνολο δεδομένων διαχωρίζεται σε K ισομεγέθη τμήματα (folds), διατηρώντας αυστηρά την αρχική αναλογία των κλάσεων. Σε κάθε επανάληψη, ένα fold λειτουργεί ως σύνολο ελέγχου (test) και τα υπόλοιπα ως σύνολο εκπαίδευσης (train). Η μέση τιμή των μετρικών και η τυπική απόκλιση παρέχουν μια πιο σταθερή (robust) εκτίμηση από ένα μεμονωμένο split. Ωστόσο, όταν διενεργείται επιλογή υπερ-παραμέτρων (tuning), απαιτείται η χρήση φωλιασμένης διασταυρούμενης επικύρωσης (nested CV) ώστε να αποφευχθεί η αισιόδοξη μεροληψία (optimistic bias) (Hastie et al., 2009).

Β) LOBO — Leave-One-Band-Out (Συχνοτική Γενίκευση)

Το πρωτόκολλο LOBO ελέγχει κατά πόσο το μοντέλο «κατανοεί» τη φυσική δομή του προβλήματος ή εάν απλώς απομνημονεύει συγκεκριμένες ζώνες συχνοτήτων. Η συχνότητα διέγερσης χωρίζεται σε περιοχές (bins). Σε κάθε επανάληψη, ένα bin κρατείται εξολοκλήρου εκτός εκπαίδευσης (held-out bin) για να χρησιμοποιηθεί ως test set. Στα αποτελέσματα της παρούσας διπλωματικής αναφέρεται επίδοση LOBO Accuracy 91.83% ± 8.90%. Επειδή ορισμένα bins περιέχουν δείγματα μίας μόνο κλάσης (mono-class), χρησιμοποιείται η μετρική «present-only Accuracy» ως λειτουργικός δείκτης, με την επισήμανση ότι δεν συγκρίνεται άμεσα με το πολυ-κλασσικό Macro-F1.

Γ) LODO — Leave-One-Domain-Out / Workpiece-Out (Μετατόπιση Πεδίου)

Το LODO ορίζει ως "domain" ένα συγκεκριμένο δοκίμιο και αξιολογεί τη γενίκευση σε ένα «νέο», εντελώς άγνωστο δοκίμιο. Στο κύριο σύνολο ξύλινων πλακών (W01, W02, W03), προκύπτουν τρεις επαναλήψεις (π.χ. εκπαίδευση στα W02+W03 $\rightarrow$ έλεγχος στο W01). Το πρωτόκολλο αυτό είναι το πλέον αυστηρό, διότι ενσωματώνει πραγματικές μεταβολές γεωμετρίας, υλικού και στήριξης (πραγματικό domain shift). Το LODO

Accuracy στα αποτελέσματα ανέρχεται σε **66.31% ± 44.11%**. Η πολύ υψηλή διακύμανση αντανακλά την ισχυρή μεταβλητότητα από δοκίμιο σε δοκίμιο (board-to-board variability), επιβεβαιώνοντας τον βαθμό δυσκολίας αυτού του ελέγχου.

***Σημείωση - Stress Tests**: Σε διερευνητικές παραλλαγές τύπου MC-LOBO, όπου τα bins γίνονται υπερβολικά στενά, οι μετρικές μπορεί να καταρρεύσουν τεχνητά. Αυτές οι δοκιμές λειτουργούν μόνο ως exploratory εργαλεία για τον σχεδιασμό των splits και δεν αποτελούν επίσημη επίδοση του μοντέλου.*

***Πίνακας 2.10:** Σύνοψη των πρωτοκόλλων επικύρωσης και του είδους της «γενίκευσης» που ελέγχει το καθένα.*

Πρωτόκολλο	**Μονάδα Διαχωρισμού (Unit)**	**Ερώτημα Γενίκευσης**	**Σχόλιο / Εφαρμογή στο ESPI**
Stratified K-fold	Τυχαία δείγματα (με διατήρηση αναλογιών)	Γενίκευση στην ίδια κατανομή (robust estimate).	Χρήσιμο ως γραμμή αναφοράς (baseline). Δεν «σπάει» συσχετίσεις συχνότητας/δοκιμίου.
LOBO	Ζώνες Συχνοτήτων (Frequency bins)	Γενίκευση σε άγνωστες (unseen) συχνότητες.	Ελέγχει την εξάρτηση από τη συχνότητα. Απαιτεί προσοχή στα mono-class bins.
LODO	Δοκίμιο/Όργανο (Workpiece)	Γενίκευση απέναντι σε πραγματικό domain shift.	Το αυστηρότερο τεστ. Κρίσιμο για την πιστοποίηση της γενικευτικής ικανότητας σε νέες κατασκευές.

2.6.3 Μετρικές για Ανισόρροπα Δεδομένα: Accuracy, Macro-F1 και Per-Class Ανάλυση

Σε προβλήματα ταξινόμησης με έντονη ανισορροπία κλάσεων, η μετρική Accuracy μπορεί να αποβεί παραπλανητική. Ένα μοντέλο που προβλέπει συστηματικά και μόνο την

πλειοψηφούσα κλάση μπορεί να επιτύχει υψηλό Accuracy, αποτυγχάνοντας όμως πλήρως στην αναγνώριση των μειονοτικών (αλλά συχνά επιστημονικά κρίσιμων) κλάσεων.

Για την αντιμετώπιση αυτού του προβλήματος, αξιοποιούνται μετρικές ανά κλάση και μακρο-μέσοι όροι (macro-averages), όπως το Macro-F1 (He & Garcia, 2009; Sokolova & Lapalme, 2009). Ορίζοντας τον Πίνακα Σύγχυσης (Confusion Matrix) εξάγουμε τις βασικές ποσότητες: Αληθώς Θετικά (TP), Ψευδώς Θετικά (FP), Ψευδώς Αρνητικά (FN) και Αληθώς Αρνητικά (TN). Για μια οποιαδήποτε κλάση c, οι βασικές μετρικές ορίζονται ως εξής:

$$\mathbf{Precision}_{\boldsymbol{c}} = \frac{\mathbf{TP}_{\boldsymbol{c}}}{\mathbf{TP}_{\boldsymbol{c}} + \mathbf{FP}_{\boldsymbol{c}}} \tag{2.20}$$

$$\mathbf{Recall}_{\boldsymbol{c}} = \frac{\mathbf{TP}_{\boldsymbol{c}}}{\mathbf{TP}_{\boldsymbol{c}} + \mathbf{FN}_{\boldsymbol{c}}} \tag{2.21}$$

Η μετρική **Macro-F1** υπολογίζεται ως ο απλός αριθμητικός μέσος όρος των επιμέρους $F1_c$ σκορ όλων των κλάσεων. Με αυτόν τον τρόπο, αποδίδεται αυστηρά ίση βαρύτητα σε κάθε κλάση, ανεξαρτήτως του πλήθους των διαθέσιμων δειγμάτων της (class support). Συνεπώς, αποτελεί την πλέον ενδεδειγμένη επιλογή όταν απαιτείται η ισότιμη αντιμετώπιση και η αξιόπιστη αναγνώριση σπάνιων ιδιομορφών, οι οποίες τείνουν να υποεκπροσωπούνται στο σύνολο δεδομένων.

Η κρισιμότητα της χρήσης του Macro-F1 επιβεβαιώνεται εμπειρικά από τα παραγόμενα αποτελέσματα της παρούσας διπλωματικής εργασίας. Συγκεκριμένα, το μοντέλο αναφοράς (baseline) Pattern-Only RF επιτυγχάνει μια φαινομενικά υψηλή Accuracy της τάξης του 90.15%, ωστόσο η επίδοσή του στο Macro-F1 περιορίζεται μόλις στο 69.91%. Αντιθέτως, η προτεινόμενη αρχιτεκτονική Hybrid RF όχι μόνο αυξάνει το Accuracy στο 97.85%, αλλά, το σημαντικότερο, βελτιώνει θεαματικά το Macro-F1, αγγίζοντας το 95.15%. Αυτό το έντονο στατιστικό χάσμα μεταξύ Accuracy και Macro-F1 (που παρατηρείται στο μοντέλο αναφοράς) αποτελεί κλασικό σύμπτωμα των προβλημάτων ταξινόμησης με έντονη ανισορροπία (imbalanced learning). Το γεγονός αυτό τεκμηριώνει πλήρως και αιτιολογεί την επιλογή του Macro-F1 ως της κεντρικής και πλέον αυστηρής μετρικής αξιολόγησης για τις αναλύσεις των Κεφαλαίων 5–7.

Πίνακας 2.11: *Σύνοψη μετρικών ταξινόμησης και πότε προτιμώνται.*

Μετρική	Ορισμός	Τι «τιμωρεί»/ανταμείβει	Χρήση στη διπλωματική
Accuracy	(Σωστές προβλέψεις) / (Σύνολο)	Ευνοεί πλειοψηφούσες κλάσεις	Αναφέρεται αλλά δεν επαρκεί λόγω 30,9:1
Per-class Recall	TP/(TP+FN) ανά κλάση	Εντοπίζει misses σε μειονοτικές	Κρίσιμο για mode κλάσεις με μικρό support
F1 ανά κλάση	2PR/(P+R)	Ισορροπεί Precision/Recall	Χρησιμοποιείται για λεπτομερή reports
Macro-F1	Μέσος F1 σε όλες τις κλάσεις	Ισότιμη βαρύτητα σε κλάσεις	Κεντρική μετρική σύγκρισης μοντέλων

2.6.4 Αβεβαιότητα, Στατιστικός Έλεγχος και Συγκρίσεις Μοντέλων

Η αναφορά ενός μόνο αριθμητικού δείκτη δεν επαρκεί για να τεκμηριώσει επιστημονικά ότι ένα μοντέλο υπερτερεί κάποιου άλλου. Απαιτείται η ποσοτικοποίηση της αβεβαιότητας μέσω διαστημάτων εμπιστοσύνης (confidence intervals) και η διενέργεια στατιστικών ελέγχων υποθέσεων. Στην παρούσα εργασία, επιστρατεύονται τρεις συμπληρωματικές προσεγγίσεις (Efron & Tibshirani, 1993; McNemar, 1947; Cohen, 1988):

Α) Διαστήματα Εμπιστοσύνης Bootstrap (Bootstrap CIs)

Η μέθοδος bootstrap εφαρμόζει επαναδειγματοληψία με επανάθεση (resampling with replacement) στο test set και επανυπολογίζει τη μετρική σε χιλιάδες επαναλήψεις, χτίζοντας την εμπειρική κατανομή της απόδοσης. Στα αποτελέσματα αναφέρεται 95% CI για την απόδοση του Hybrid RF, με το Accuracy να κυμαίνεται στο [97.36%, 98.34%] και το Macro-F1 στο [93.97%, 96.24%].

Β) Έλεγχος McNemar (Paired Nominal Test)

Ο έλεγχος McNemar είναι ιδανικός όταν δύο ταξινομητές αξιολογούνται ακριβώς στο ίδιο σύνολο δειγμάτων (paired test). Εξετάζει εάν οι διαφωνίες τους είναι συμμετρικές, συγκρίνοντας τα δείγματα που το μοντέλο Α ταξινομεί σωστά αλλά το Β λάθος (n_{01}), με αυτά που το Α κάνει λάθος αλλά το Β σωστά (n_{10}). Αν δεν υπάρχει ουσιαστική διαφορά, αναμένεται $n_{01} \approx n_{10}$. Στις βασικές συγκρίσεις της διπλωματικής (Hybrid RF vs Pattern-Only / Hybrid RF vs CNN), ο έλεγχος έδωσε τιμή $\boldsymbol{p < 0.001}$, αποδεικνύοντας ότι η υπεροχή του υβριδικού μοντέλου είναι στατιστικά εξαιρετικά σημαντική.

Γ) Μέγεθος Επίδρασης (Effect Size - Cohen's d)

Πέρα από τη στατιστική σημαντικότητα (το *αν* υπάρχει διαφορά), έχει σημασία και το «πόσο μεγάλη» είναι αυτή. Το **Cohen's d** χρησιμοποιείται ως συνοπτικό μέτρο του μεγέθους της επίδρασης. Στην παρούσα σύγκριση, καταγράφηκε τιμή $\boldsymbol{d = 2.89}$ (υπέρ του Hybrid RF έναντι του Pattern-Only). Δεδομένου ότι γενικά τιμές $d \geq 0.8$ θεωρούνται δείκτες «μεγάλης» επίδρασης, το 2.89 υποδηλώνει μια κολοσσιαία, πρακτικά αδιαμφισβήτητη βελτίωση.

Πίνακας 2.12: *Στατιστικές μέθοδοι που χρησιμοποιούνται/αναφέρονται στη διπλωματική.*

Μέθοδος	Τι ποσοτικοποιεί	Προϋποθέσεις	Ρόλος στο έργο
Bootstrap CI	Αβεβαιότητα μετρικών (CI)	Επαρκές test set, επαναδειγματοληψία	CIs για Accuracy & Macro-F1 του Hybrid RF
McNemar	Σημαντικότητα διαφοράς δύο ταξινομητών	Κοινό test set, paired outcomes	$p < 0.001$ σε βασικές συγκρίσεις
Effect size (Cohen's d)	Μέγεθος βελτίωσης	Ορισμός unit (fold/sample)	d=2.89 ως «huge» improvement indicator
Mean±Std σε CV	Μεταβλητότητα επίδοσης	Πολλαπλά folds	91,83%±8.9% (LOBO), 66,31%±44,11% (LODO)

2.7 Μηχανική Μάθηση Καθοδηγούμενη από τη Φυσική: Το Κεντρικό Αφήγημα

Η παρούσα διπλωματική δεν αντιμετωπίζει την αυτόματη αναγνώριση ιδιομορφών ως ένα γενικό πρόβλημα ταξινόμησης εικόνων, αλλά ως ένα πρόβλημα με ισχυρή φυσική δομή: η «ταυτότητα» ενός mode καθορίζεται από τον συνδυασμό (α) της χωρικής μορφολογίας του fringe pattern (nodal lines, συμμετρίες, τοπολογία) και (β) της συχνότητας διέγερσης, η οποία λειτουργεί ως ισχυρή φυσική προγενέστερη πληροφορία (prior). Η ενότητα αυτή διατυπώνει θεωρητικά τι σημαίνει «physics-informed» στο πλαίσιο της εργασίας και δείχνει πώς η φυσική γνώση (ως priors/χαρακτηριστικά/πρωτόκολλα αξιολόγησης) μεταφράζεται σε μετρήσιμο κέρδος στην απόδοση των μοντέλων. (Karpatne et al., 2017; Willard et al., 2022; von Rueden et al., 2021)

2.7.1 Τι σημαίνει «Physics-Informed» στην παρούσα εργασία

Ο όρος physics-informed χρησιμοποιείται στη βιβλιογραφία με διαφορετικές έννοιες (π.χ. PINNs, constraint-based learning, theory-guided data science). Στη συγκεκριμένη διπλωματική, ο όρος χρησιμοποιείται πρακτικά και μετρήσιμα, σε τρία συμπληρωματικά επίπεδα:

Physics-informed χαρακτηριστικά (features): εισαγωγή ρητών «frequency priors» μαζί με μορφολογικά χαρακτηριστικά από τα fringe patterns, ώστε το μοντέλο να ενσωματώνει τη φυσική αντιστοίχιση mode↔συχνότητα και να επιλύει αμφισημίες μέσω της χωρικής δομής.

Physics-informed αξιολόγηση (protocols): πρωτόκολλα που αντανακλούν πραγματικές «μετατοπίσεις πεδίου» (domain shift) όπως συχνοτική γενίκευση (LOBO) και γενίκευση σε νέο δοκίμιο/όργανο (LODO). (βλ. Ενότητα 2.6)

Physics-based ερμηνεία και έλεγχοι: ερμηνευσιμότητα μέσω σημαντικότητας χαρακτηριστικών και έλεγχοι για «shortcut learning» όταν η συχνότητα/μεταδεδομένα μπορούν να υπερισχύσουν της χωρικής πληροφορίας. (Rudin, 2019; Geirhos et al., 2020)

Σε αντίθεση με τα Physics-Informed Neural Networks (PINNs), όπου η φυσική εισάγεται ως όρος απώλειας μέσω PDE-constraints (Raissi et al., 2019), εδώ η φυσική ενσωματώνεται κυρίως ως αναπαράσταση (feature space) και ως σχεδιασμός του πρωτοκόλλου αξιολόγησης. Η επιλογή αυτή είναι συμβατή με το μέγεθος του dataset και με το γεγονός

ότι το πρόβλημα διαθέτει ήδη ισχυρά γνωστά priors (modal theory). (Karpatne et al., 2017; Mitchell, 1997; Goodfellow et al., 2016)

2.7.2 Μηχανική Χαρακτηριστικών: Φυσική Αναπαράσταση και Κωδικοποίηση

Ο πυρήνας της προσέγγισης καθοδηγούμενης από τη φυσική που προτείνεται στην παρούσα εργασία εδράζεται στον σχεδιασμό ενός υβριδικού διανυσματικού χώρου 22 διαστάσεων. Ο χώρος αυτός συνθέτει 16 μορφολογικά/τοπολογικά χαρακτηριστικά (pattern features) και 6 συχνοτικές παραμέτρους (frequency priors), τα οποία επιλέχθηκαν προσεκτικά από ένα αρχικό υπερσύνολο 26 υποψηφίων χαρακτηριστικών.

Η λογική αυτής της σύνθεσης είναι διττή: τα μεν *pattern features* κωδικοποιούν την οπτική πληροφορία που θα αξιολογούσε ένας ανθρώπινος εμπειρογνώμονας στο πεδίο των κροσσών (όπως η θέση των κομβικών γραμμών, ο αριθμός των λοβών και οι άξονες συμμετρίας), τα δε *frequency priors* εισάγουν ισχυρούς περιορισμούς που απορρέουν απευθείας από τη θεωρία των ιδιομορφών και την κανονικότητα της φασματικής τους διαδοχής (Ewins, 2000; Inman, 2014; Hastie et al., 2009).

Η επιλογή των μορφολογικών χαρακτηριστικών υπάκουσε στην αυστηρή ανάγκη εξισορρόπησης τριών παραγόντων:

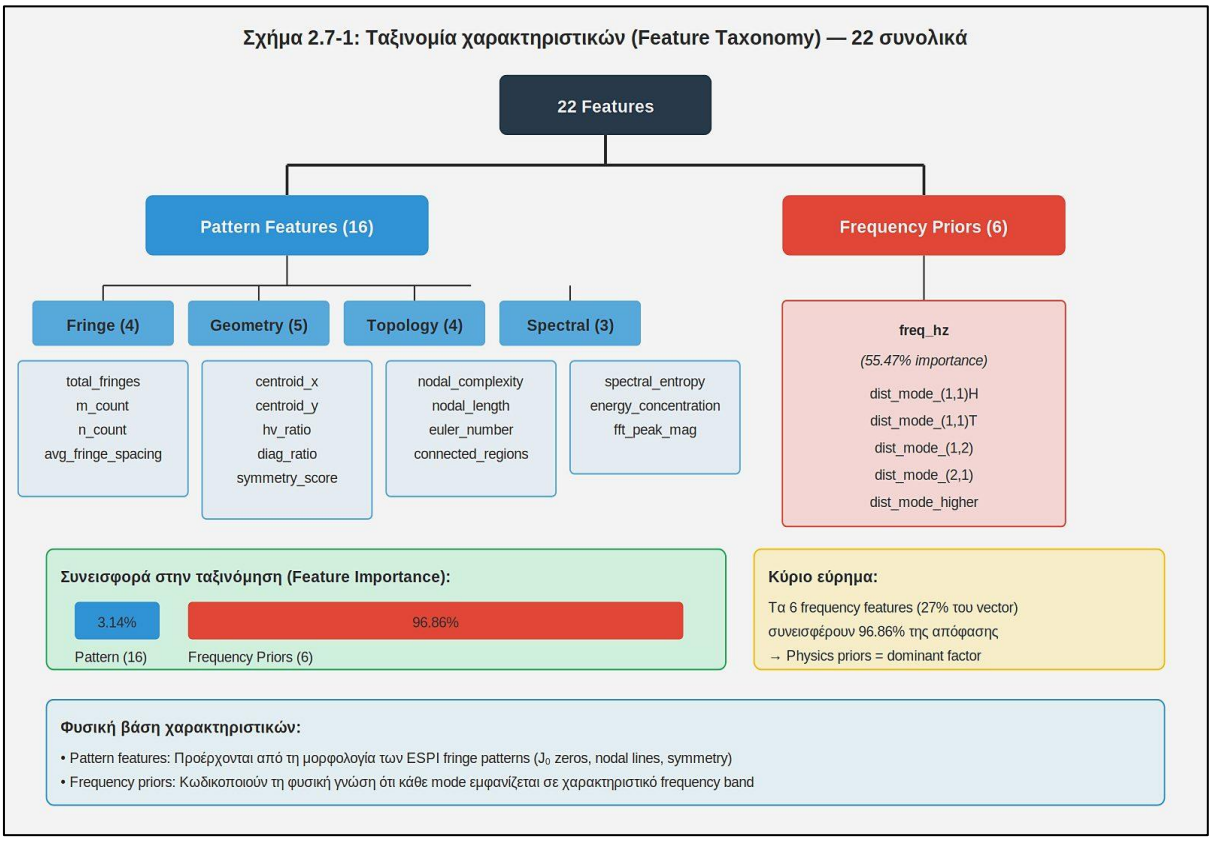
- Της **ευαισθησίας** σε διακριτές δομικές λεπτομέρειες (π.χ. πυκνότητα κροσσών).
- Της **αμεταβλητότητας (invariance)** έναντι μικρών χωρικών μετασχηματισμών.
- Της **διατήρησης της τοπολογικής πληροφορίας** (π.χ. αριθμός Euler) που περιγράφει τη συνδεσιμότητα των κομβικών περιοχών (Leissa, 1969; Gonzalez & Woods, 2018).

Ο Πίνακας 2.13 αναλύει τη δομή των δύο αυτών διακριτών ομάδων και τη φυσική ερμηνεία των μεταβλητών τους.

Πίνακας 2.13: *Δομή του υβριδικού διανυσματικού χώρου 22 διαστάσεων και φυσική/λειτουργική ερμηνεία των εξαγόμενων χαρακτηριστικών.*

Ομάδα Χαρακτηριστικών	**Ενδεικτικές Μεταβλητές**	**Φυσική / Λειτουργική Ερμηνεία**
Pattern: Κροσσοί & Γεωμετρία	total_fringes, avg_fringe_spacing, centroid_x/y, diag_ratio, hv_ratio	Κωδικοποίηση της πυκνότητας και της γεωμετρίας των κροσσών, καθώς και της χωρικής κατανομής της ταλαντωτικής ενέργειας (λοβοί) στο οπτικό πεδίο.
Pattern: Συμμετρία & Ροπές	symmetry_score, Hu moments (invariant)	Ποσοτικοποίηση της συμμετρίας της ιδιομορφής και εξασφάλιση μαθηματικής αμεταβλητότητας σε μετατοπίσεις και αλλαγές κλίμακας.
Pattern: Κόμβοι & Τοπολογία	nodal_length, nodal_complexity, euler_number	Προσεγγιστική τοπολογική περιγραφή των κομβικών γραμμών (περιοχές μηδενικού πλάτους) και της διασύνδεσης των επιμέρους ταλαντούμενων περιοχών.
Pattern: Φασματικά (FFT-based)	fft_peak_magnitude, energy_concentration	Συνοπτικά μεγέθη που περιγράφουν τη φασματική υφή των μοτίβων (ως shape descriptors) στο δισδιάστατο πεδίο συχνοτήτων.
Frequency Priors (6 μεταβλητές)	freq_hz, freq_normalized, log_freq, freq_bin, is_fundamental, harmonic_ratio	Εισαγωγή *a priori* φυσικής γνώσης για την τάξη μεγέθους και τη λογική σειρά εμφάνισης των ιδιοσυχνοτήτων, μειώνοντας δραστικά τον χώρο αναζήτησης του μοντέλου.

Η ενσωμάτωση αυτών των φυσικών νόμων ως *a priori* γνώση (priors) συνιστά μια κλασική μορφή **επαγωγικής προκατάληψης (inductive bias)**. Μέσω αυτής, η διαδικασία μάθησης καθοδηγείται προς λύσεις που είναι εξ ορισμού συμβατές με τη φυσική πραγματικότητα. Αυτό μειώνει δραστικά την εξάρτηση από τεράστια σύνολα δεδομένων (data efficiency) και θωρακίζει το μοντέλο έναντι της υπερπροσαρμογής (overfitting) σε τυχαία, μη-φυσικά χαρακτηριστικά επιπέδου εικονοστοιχείου (Mitchell, 1997; Bishop, 2006; Goodfellow et al., 2016).



Σχήμα 2.9: *Διάγραμμα Σημαντικότητας Χαρακτηριστικών (Feature Importance) για τον υβριδικό ταξινομητή Random Forest. Αποδεικνύεται η συντριπτική κυριαρχία της φυσικής πληροφορίας (96.86% frequency priors έναντι 3.14% pattern features) κατά τη λήψη αποφάσεων.*

Η ενσωμάτωση των φυσικών νόμων ως a priori γνώση (priors) συνιστά μια κλασική μορφή **«επαγωγικής προκατάληψης» (inductive bias)**. Μέσω αυτής, η διαδικασία μάθησης καθοδηγείται προς λύσεις που είναι συμβατές με τη φυσική πραγματικότητα, μειώνοντας δραστικά την εξάρτηση από μεγάλα σύνολα δεδομένων και θωρακίζοντας το

μοντέλο έναντι της υπερπροσαρμογής σε τυχαία χαρακτηριστικά επιπέδου pixel (Mitchell, 1997; Bishop, 2006; Goodfellow et al., 2016).

2.7.3 Γιατί τα frequency priors «δουλεύουν» - θεωρητική ερμηνεία

Σε συστήματα που αναλύονται βάσει των ιδιομορφών τους, η συχνότητα δεν είναι απλώς ένα πληροφοριακό μεταδεδομένο (metadata). Αποτελεί το θεμελιώδες φυσικό μέγεθος που υπαγορεύει τη διασπορά και τη σειριακή εμφάνιση των τρόπων ταλάντωσης (modes). Για λεπτές πλάκες, όπως τα μουσικά καπάκια, οι ιδιοσυχνότητες εξαρτώνται αυστηρά από τον λόγο δυσκαμψίας προς μάζα, τις συνοριακές συνθήκες στήριξης και, σε ορθότροπα υλικά (όπως το ξύλο), τις κατευθυντικές ελαστικές σταθερές (Leissa, 1969; Bucur, 2006; Inman, 2014).

Στην πράξη, η αντιστοίχιση μεταξύ ιδιομορφής και συχνότητας (mapping mode ↔ frequency) είναι **«σχεδόν ντετερμινιστική»** εντός ενός συγκεκριμένου δοκιμίου και ενός γνωστού εύρους διεγέρσεων, καθώς οι ιδιομορφές χαμηλής τάξης εμφανίζονται σε συγκεκριμένες, αυστηρά διακριτές ζώνες. Αυτό σημαίνει ότι, εάν το μοντέλο μηχανικής μάθησης «γνωρίζει» τη συχνότητα, μπορεί να αποκλείσει εξ αρχής ένα τεράστιο ποσοστό λανθασμένων κλάσεων, λειτουργώντας με εξαιρετική σιγουριά (Ewins, 2000; Rossing, 2007).

Ωστόσο, η πληροφορία της συχνότητας *από μόνη της* κρίνεται ανεπαρκής σε δύο κρίσιμες περιπτώσεις:

1. Σε περιοχές **επικάλυψης ιδιομορφών (modal overlap)**, όπου δύο διαφορετικά modes γειτνιάζουν συχνοτικά και απαιτείται αναπόφευκτα η οπτική/χωρική μορφολογία για τον διαχωρισμό τους.

2. Σε συνθήκες **μετατόπισης πεδίου (domain shift)**, όπως η αλλαγή δοκιμίου ή η χρήση διαφορετικού υλικού, όπου ολόκληρο το φάσμα ιδιοσυχνοτήτων μπορεί να μετατοπιστεί σημαντικά.

Σε αυτά ακριβώς τα σενάρια αποδεικνύεται η αξία του υβριδικού σχήματος: τα *frequency priors* λειτουργούν ως οδηγοί που περιορίζουν τις πιθανότητες, ενώ τα *pattern features* προσφέρουν την τελική επιβεβαίωση και «κλειδώνουν» την απόφαση όταν η συχνότητα καθίσταται αμφίβολη (Karpatne et al., 2017).

Από τη σκοπιά της στατιστικής μάθησης (statistical learning), η εισαγωγή των priors λειτουργεί ως μηχανισμός δραστικής μείωσης του ενεργού χώρου υποθέσεων (effective hypothesis space) του ταξινομητή. Αυτό μεταφράζεται σε άμεση μείωση της διακύμανσης (variance), καθιστώντας το μοντέλο εξαιρετικά ανθεκτικό σε περιβάλλοντα με περιορισμένα δεδομένα (low-data regime).

Ειδικότερα για τον αλγόριθμο Random Forest —ο οποίος αποτελεί ένα σύνολο δέντρων απόφασης— αξιοποιούνται στο έπακρο οι αλληλεπιδράσεις (interactions) μεταξύ των χαρακτηριστικών. Η πληροφορία της συχνότητας λειτουργεί ως ο πρωταρχικός, ισχυρός **«άξονας διάσπασης» (split axis)** στις ρίζες των δέντρων, διαχωρίζοντας τον χώρο σε αδρές περιοχές. Στη συνέχεια, τα μορφολογικά χαρακτηριστικά της εικόνας αναλαμβάνουν τις βαθύτερες διασπάσεις, εξειδικεύοντας την απόφαση στις λεπτομερείς υπο-περιοχές του χώρου (Breiman, 2001; Hastie et al., 2009).

2.7.4 Ερμηνευσιμότητα, σημαντικότητα χαρακτηριστικών και εμπειρική απόδειξη

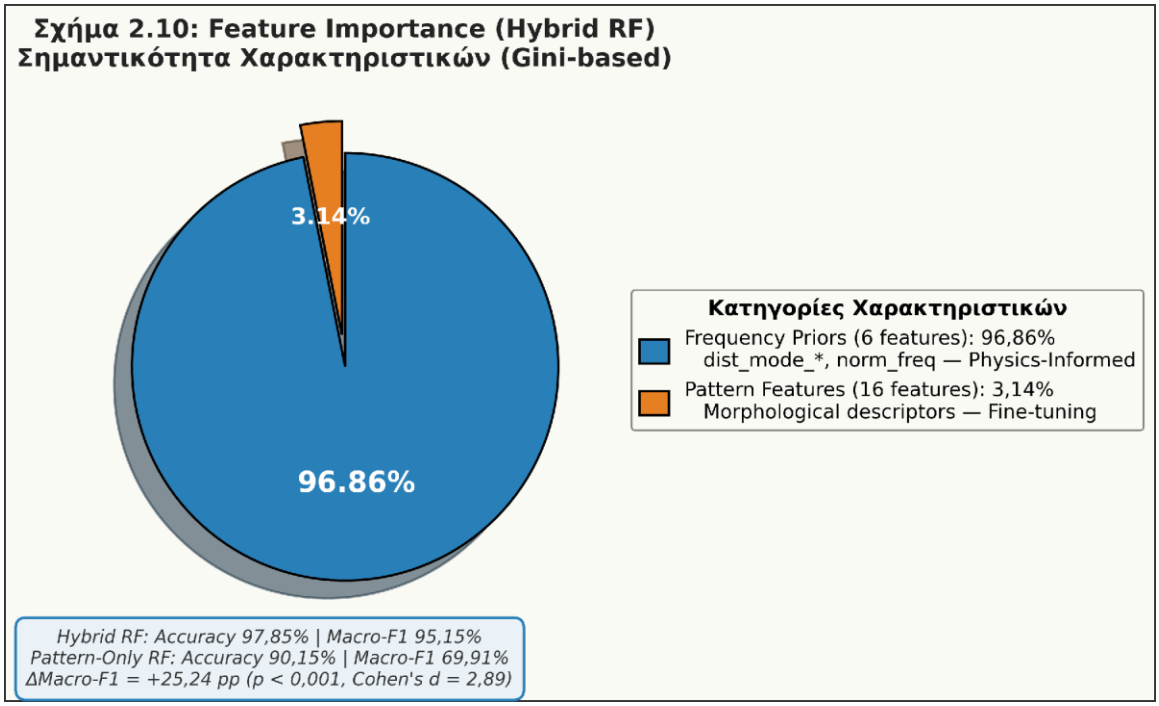
Η κεντρική εμπειρική απόδειξη του physics-informed αφηγήματος προκύπτει από τη σύγκριση Pattern-Only RF έναντι Hybrid RF. Στο τελικό evaluation set (N = 3.443, aggregated out-of-fold predictionsmode_(1,1)H, mode_(1,1)T, mode_(1,2), mode_(2,1), mode_higher), το Pattern-Only μοντέλο πετυχαίνει Accuracy 90.15% και Macro-F1 69.91%, ενώ το Hybrid RF φτάνει Accuracy 97,85% και Macro-F1 95,15% (δηλαδή +25.24 ποσοστιαίες μονάδες στο Macro-F1). (βλ. Κεφάλαια 3–5 και Παράρτημα Γ)

Πίνακας 2.14: *Επίδραση physics priors στην απόδοση (Pattern-Only vs Hybrid).*

Μοντέλο	**Accuracy**	**Macro-F1**	**Διαφορά (Δ)**
Pattern-Only RF	90.15%	69.91%	—
Hybrid RF (22 features)	97,85%	95,15%	ΔAccuracy = +7.70 pp ΔMacro-F1 = +25.24 pp

Η διαφορά ελέγχεται και με στατιστικό τεστ σύγκρισης ταξινομητών σε ζεύγη προβλέψεων (McNemar), όπου η υπεροχή του Hybrid RF έναντι του Pattern-Only είναι στατιστικά σημαντική ($p < 0.001$), ενώ το μέγεθος επίδρασης είναι πολύ μεγάλο (Cohen's $d = 2.89$). (McNemar, 1947; Cohen, 1988; Dietterich, 1998)

Η ερμηνευσιμότητα ενισχύεται μέσω της ανάλυσης σημαντικότητας χαρακτηριστικών (feature importance) του Random Forest. Στα αποτελέσματα της εργασίας, τα frequency priors συγκεντρώνουν περίπου 96.8% της συνολικής σημαντικότητας (Gini-based), ενώ τα pattern features περίπου 3.2%, λειτουργώντας ως «fine-tuning» σε οριακές περιπτώσεις. (Breiman, 2001; Hastie et al., 2009)



***Σχήμ**α 2.10: Feature importance (Hybrid RF): 96,86% frequency vs 3,14% pattern.*

***Σημείωση**: η Gini importance στα δέντρα απόφασης είναι χρήσιμη, αλλά μπορεί να έχει μεροληψίες (π.χ. προς μεταβλητές με περισσότερα διακριτά επίπεδα). Για αυτόν τον λόγο, τα συμπεράσματα υποστηρίζονται από (α) το μεγάλο κέρδος Macro-F1, (β) τον στατιστικό έλεγχο, και (γ) τα συμπληρωματικά analyses στα επόμενα κεφάλαια. (Strobl et al., 2007; Molnar, 2022)*

2.7.5 Από τον Μετασχηματισμό FFT στο LeFFT: Η Φυσική Εξέλιξη της Αναπαράστασης

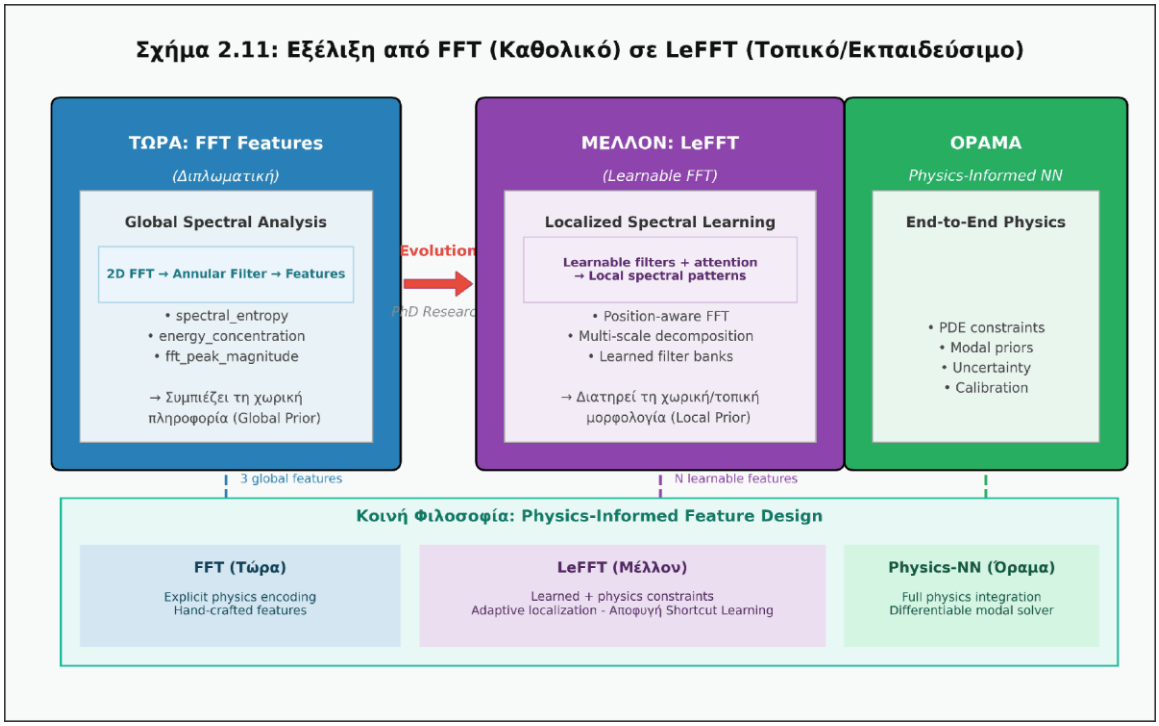
Στην παρούσα διπλωματική εργασία, η συχνοτική πληροφορία ενσωματώνεται πρωτίστως ως μια «καθολική» a priori γνώση (global prior), μέσω μεταβλητών όπως το freq_hz και τα παράγωγά του, καθώς και μέσω συνοπτικών περιγραφητών (descriptors) που προκύπτουν από τον καθολικό Μετασχηματισμό Fourier (FFT) των δεδομένων ESPI. Το

επόμενο μεθοδολογικό βήμα —το οποίο αναλύεται εκτενώς στο μελλοντική ερευνητική κατεύθυνση και στα Κεφάλαια 6–8— είναι η μετάβαση σε πιο δομημένες και τοπικές συχνοτικές αναπαραστάσεις. Στόχος αυτής της εξέλιξης είναι η ελαχιστοποίηση του κινδύνου της επιπόλαιης μάθησης (shortcut learning) και η ενίσχυση της ικανότητας γενίκευσης του μοντέλου υπό συνθήκες μετατόπισης πεδίου (domain shift) (Geirhos et al., 2020; von Rueden et al., 2021).

Η ιδέα της «τοπικοποίησης» της φασματικής πληροφορίας διαθέτει βαθιές ρίζες στη θεωρία σημάτων. Εργαλεία όπως ο Βραχυπρόθεσμος Μετασχηματισμός Fourier (Short-Time Fourier transform - STFT) και οι αναπαραστάσεις χρόνου-συχνότητας (π.χ. φίλτρα Gabor) επιτρέπουν την καταγραφή του πώς ακριβώς μεταβάλλεται η φασματική ενέργεια τοπικά, αντί να συγχωνεύεται σε έναν απρόσωπο, καθολικό μέσο όρο. Αντιστοίχως, οι μετασχηματισμοί κυματιδίων (wavelets) και τα σχήματα πολλαπλών αναλύσεων (multi-resolution) προσφέρουν την αποδοτική ανάλυση των δομών σε πολλαπλές κλίμακες (Gabor, 1946; Allen & Rabiner, 1977; Mallat, 1999).

Στο ειδικό πλαίσιο της ανάλυσης μοτίβων κροσσών (ESPI fringe patterns), η μετάβαση από το FFT στο **LeFFT (Local/Learnable FFT)** μεταφράζεται στην ουσία ως μια μετάβαση από «καθολικές φασματικές ενδείξεις» (global spectral cues) προς «τοπικά εντοπισμένα, δομικά διατηρημένα φασματικά τεκμήρια» (localized, structure-preserving spectral evidence). Αυτά τα τοπικά τεκμήρια συσχετίζονται πολύ πιο άμεσα με τη χωρική μορφολογία, όπως είναι οι τοπικές κατευθύνσεις και η τοπική πυκνότητα των κροσσών (local fringe density).

Αυτή η προσέγγιση εναρμονίζεται απόλυτα με τη γενική αρχή της θεωρητικά καθοδηγούμενης (theory-guided) αναπαράστασης: το μοντέλο οφείλει να «βλέπει» το φάσμα με τρόπο που να σέβεται την πραγματική φυσική δομή του υπό μελέτη φαινομένου, και όχι απλώς να εκμεταλλεύεται εύκολους, στατιστικούς συσχετισμούς (Karpatne et al., 2017; Rudin, 2019).



Σχήμα 2.11: *Εννοιολογική σύγκριση μεταξύ του καθολικού μετασχηματισμού (FFT), ο οποίος συμπιέζει τη χωρική πληροφορία, και των αναπαραστάσεων τοπικού φάσματος (STFT / LeFFT), οι οποίες διατηρούν τη συσχέτιση μεταξύ της μορφολογίας των κροσσών και της τοπικής κατανομής των χωρικών συχνοτήτων. Η μετάβαση αυτή λειτουργεί ως ασπίδα απέναντι στην επιπόλαιη μάθηση.*

Σύνοψη ενότητας

Στο πλαίσιο της παρούσας εργασίας, η προσέγγιση **Physics-Informed** ορίζεται ως ένα πολυεπίπεδο πλαίσιο που ενσωματώνει φυσικούς περιορισμούς (priors) ως χαρακτηριστικά εισόδου, υιοθετεί πρωτόκολλα αξιολόγησης ευαίσθητα σε φυσικές μετατοπίσεις (physics-aware evaluation) και εφαρμόζει μηχανισμούς ελέγχου για την αποτροπή επιπόλαιων συσχετίσεων (shortcut learning). Πυρήνα της μεθοδολογίας αποτελεί ο υβριδικός χώρος 22 διαστάσεων, ο οποίος συγκεράζει την αιτιοκρατική αντιστοίχιση συχνότητας-ιδιομορφής με τη χωρική πληροφορία των κροσσών, επιτυγχάνοντας έτσι την άρση των αμφισημιών. Η ισχύς της προσέγγισης τεκμηριώνεται εμπειρικά από την θεαματική αύξηση του Macro-F1 κατά **+25.24** μονάδες (από 69.91% σε 95.15%) και την κυριαρχία της συχνοτικής πληροφορίας (**96,86%** importance). Τέλος, η μετάβαση από την καθολική

ανάλυση FFT στην τοπική LeFFT αναδεικνύεται ως στρατηγική εξέλιξη για την επίτευξη στιβαρότερων, τοπικά δομημένων αναπαραστάσεων..

2.8 Μοντέλα που χρησιμοποιούνται στην παρούσα εργασία

Η παρούσα ενότητα συνοψίζει τα βασικά υπολογιστικά μοντέλα που χρησιμοποιούνται στη διπλωματική εργασία για την αυτόματη ταξινόμηση των modes δόνησης από time-averaged ESPI fringe maps. Το ζητούμενο δεν είναι μόνο η επίτευξη υψηλής ακρίβειας, αλλά και η ερμηνευσιμότητα/αναπαραγωγιμότητα των αποφάσεων, καθώς και η αξιολόγηση της γενίκευσης σε διαφορετικές συνθήκες (π.χ. συχνότητες/boards). Στο πλαίσιο αυτό υιοθετούνται: (α) ένας physics-informed ταξινομητής με χαρακτηριστικά (pattern + frequency priors) και Random Forest, (β) ένα ισχυρό end-to-end πρότυπο αναφοράς με ResNet-18, και (γ) ένα βαθύ denoiser (DnCNN) ως προαιρετικό στάδιο προεπεξεργασίας—με ιδιαίτερη έμφαση στο ότι η «οπτική ποιότητα» δεν ταυτίζεται απαραίτητα με «βελτιωμένη ταξινόμηση» (task alignment).

2.8.1 Random Forest: Ενσωμάτωση Φυσικής Γνώσης και Ταξινόμηση

Ως κεντρικός αλγόριθμος ταξινόμησης επιλέχθηκε το Random Forest (RF), μια μεθοδολογία συνόλου (ensemble) που βασίζεται στη δειγματοληψία bootstrap και τη συνάθροιση (bagging) πολλαπλών δέντρων απόφασης (Breiman, 2001). Η επιλογή αυτή υπαγορεύθηκε από τη φύση του προβλήματος, καθώς ο RF διαχειρίζεται αποτελεσματικά τις μη γραμμικές αλληλεπιδράσεις μεταξύ των φυσικών περιορισμών (priors) και των μορφολογικών χαρακτηριστικών, επιδεικνύοντας παράλληλα ανθεκτικότητα στον θόρυβο και τις ακραίες τιμές (outliers). Επιπλέον, η ικανότητά του να λειτουργεί αποδοτικά σε σχετικά μικρά και ανισόρροπα σύνολα δεδομένων —όταν πλαισιώνεται από κατάλληλη στάθμιση κλάσεων— τον καθιστά ιδανικό για τις συνθήκες της παρούσας μελέτης (Hastie et al., 2009).

Στο πλαίσιο της εργασίας αναπτύχθηκαν και αξιολογήθηκαν συγκριτικά δύο παραλλαγές του μοντέλου:

- **Pattern-Only RF:** Βασίζεται αποκλειστικά στο διάνυσμα 16 μορφολογικών χαρακτηριστικών (π.χ. πυκνότητα κροσσών, γεωμετρική συμμετρία, τοπολογία κομβικών γραμμών), αγνοώντας τη φασματική θέση της ιδιομορφής.

- **Hybrid RF (Physics-Informed):** Επεκτείνει το παραπάνω διάνυσμα ενσωματώνοντας 6 συχνοτικές παραμέτρους (frequency priors), με το συνολικό διάνυσμα να αριθμεί 22 διαστάσεις. Η προσέγγιση αυτή κωδικοποιεί ρητά τη φυσική γνώση ότι οι ιδιομορφές εμφανίζονται σε χαρακτηριστικές ζώνες συχνοτήτων, οι οποίες παραμένουν δομικά σταθερές εντός του ίδιου αντικειμένου.

Η πειραματική αξιολόγηση επιβεβαιώνει την καταλυτική επίδραση της φυσικής πληροφορίας. Η μετάβαση από το Pattern-Only στο Hybrid μοντέλο οδηγεί σε θεαματική αύξηση της μετρικής Macro-F1 κατά **25,24 ποσοστιαίες μονάδες** (από 69,91% σε 95,15%) και του Accuracy από 90,15% σε 97,85%. Το εύρημα αυτό αποτελεί την ισχυρότερη ένδειξη ότι η ενσωμάτωση της φυσικής ως a priori γνώσης είναι καθοριστική για την επίλυση του προβλήματος ESPI ταξινόμησης.

Για τη διασφάλιση της επιστημονικής εγκυρότητας, η σύγκριση των επιδόσεων θωρακίζεται μέσω στατιστικών ελέγχων (όπως το McNemar test) και εκτίμησης μεγέθους επίδρασης, αποφεύγοντας επισφαλή συμπεράσματα που θα μπορούσαν να αποδοθούν στην ανισορροπία των κλάσεων ή σε τυχαίες διακυμάνσεις (Dietterich, 1998; Demšar, 2006).

Σε επίπεδο υλοποίησης (βλ. Παράρτημα Α), εφαρμόστηκε εξισορρόπηση βαρών (class_weight='balanced') για την αντιμετώπιση των μειονοτικών κλάσεων, με παραμέτρους όπως n_estimators=200 και max_features='sqrt' για τη βελτιστοποίηση της γενίκευσης. Τέλος, αναφορικά με την ερμηνευσιμότητα, αν και η μετρική Gini importance χρησιμοποιείται ως αρχική ένδειξη της κυριαρχίας των συχνοτικών χαρακτηριστικών, αναγνωρίζεται η τάση της να μεροληπτεί υπέρ των συνεχών μεταβλητών (Strobl et al., 2007). Για τον λόγο αυτό, τα αποτελέσματα ερμηνεύονται συνδυαστικά με την πειραματική αφαίρεση χαρακτηριστικών (ablation study), ενώ μελλοντικές επεκτάσεις θα μπορούσαν να αξιοποιήσουν μοντελο-αγνωστικές μεθόδους όπως το SHAP (Lundberg & Lee, 2017).

2.8.2 ResNet-18: Το Αμιγώς Data-Driven Πρότυπο Αναφοράς

Ως πρότυπο αναφοράς (baseline) για την προσέγγιση End-to-End μηχανικής μάθησης επιλέχθηκε το ResNet-18, μια αρχιτεκτονική που αξιοποιεί συνδέσεις ταυτότητας (identity skip connections) για να διευκολύνει τη ροή της κλίσης κατά την εκπαίδευση (He et al., 2016). Η επιλογή της συγκεκριμένης εκδοχής —έναντι βαθύτερων δικτύων όπως τα ResNet-50 ή 101— υπαγορεύθηκε από το περιορισμένο μέγεθος του συνόλου δεδομένων

(N=3.443), με στόχο την ελαχιστοποίηση του κινδύνου υπερπροσαρμογής (overfitting), ο οποίος είναι ιδιαίτερα αυξημένος σε απεικονίσεις με ισχυρά, αλλά μη διαγνωστικά, οπτικά χαρακτηριστικά (spurious cues).

Η στρατηγική εκπαίδευσης βασίζεται στη μεταφορά μάθησης (transfer learning) από το ImageNet (Deng et al., 2009). Το δίκτυο προσαρμόστηκε ώστε να δέχεται μονοκανάλιες εικόνες ESPI (grayscale), ενώ εφαρμόστηκε ελεγχόμενη μικρο-ρύθμιση (fine-tuning) με πάγωμα των αρχικών επιπέδων. Η πρακτική αυτή αξιοποιεί το γεγονός ότι τα φίλτρα χαμηλού επιπέδου (ακμές, υφές) είναι μεταφέρσιμα μεταξύ διαφορετικών οπτικών πεδίων, εν αντιθέσει με τα χαρακτηριστικά υψηλού επιπέδου που απαιτούν εξειδίκευση στο νέο πρόβλημα (Yosinski et al., 2014).

Στο πειραματικό πλαίσιο, το ResNet-18 λειτουργεί ως η «αμιγώς data-driven» συνιστώσα της σύγκρισης, καθώς δεν λαμβάνει καμία ρητή πληροφορία φυσικής (frequency priors) ή χειροποίητα χαρακτηριστικά. Μέσω αυτής της αντιπαραβολής με το Hybrid RF, εξετάζεται το κατά πόσον ένα ισχυρό CNN μπορεί να «ανακαλύψει» αυτόνομα τις λανθάνουσες φυσικές δομές των ιδιομορφών, βασιζόμενο αποκλειστικά στα εικονοστοιχεία.

Τα αποτελέσματα καταδεικνύουν ότι, αν και το CNN είναι ανταγωνιστικό (Accuracy 93,76%, Macro-F1 88,11%), υπολείπεται του physics-informed μοντέλου. Το εύρημα αυτό ενισχύεται από τη συμπεριφορά του σε πρωτόκολλα γενίκευσης LOBO, όπου παρατηρείται μετρήσιμη πτώση απόδοσης (Accuracy 87,2%, Macro-F1 82,1%). Η μείωση αυτή επιβεβαιώνει τη βιβλιογραφική παρατήρηση ότι τα End-to-End μοντέλα, απουσία ρητών περιορισμών, είναι επιρρεπή σε αλλαγές κατανομής (domain shift), καθιστώντας την ενσωμάτωση της φυσικής γνώσης αναγκαία συνθήκη για στιβαρή γενίκευση (Ovadia et al., 2019; Recht et al., 2019).

2.8.3 Ο Ρόλος του DnCNN στην Αποθορυβοποίηση: Μηχανισμός και Περιορισμοί

Το αρχιτεκτονικό πρότυπο DnCNN αποτελεί ένα βαθύ συνελικτικό μοντέλο αποθορυβοποίησης (convolutional denoiser), το οποίο εδράζεται στη θεμελιώδη αρχή της μάθησης υπολοίπου (residual learning). Αντί να προβλέπει απευθείας την καθαρή εικόνα, το δίκτυο εκπαιδεύεται ώστε να εκτιμά το «υπόλοιπο του θορύβου» (noise residual), το οποίο στη συνέχεια αφαιρείται γραμμικά από την αλλοιωμένη είσοδο.

Στο εννοιολογικό πλαίσιο της παρούσας εργασίας, το DnCNN αξιολογείται ως ένα προαιρετικό στάδιο οπτικής βελτίωσης (enhancement) των εικόνων ESPI, το οποίο προηγείται της εξαγωγής χαρακτηριστικών και της τελικής ταξινόμησης. Πρωταρχικός του στόχος είναι η στοχευμένη καταστολή του θορύβου κηλίδων (speckle) και η σταθεροποίηση των λεπτών δομών των κροσσών συμβολής (fringes), με την αυστηρή προϋπόθεση να μην αλλοιώνεται η φέρουσα χωρική συχνότητα (carrier frequency) του φυσικού σήματος.

Η Θεωρητική Θεώρηση του Μηχανισμού Προσοχής (ECA)

Στη σύγχρονη βιβλιογραφία της βαθιάς μάθησης, η ενσωμάτωση μηχανισμών προσοχής, όπως το Efficient Channel Attention (ECA), προτείνεται ως μέσο για την προσαρμοστική στάθμιση της πληροφορίας των καναλιών. Στο πλαίσιο της παρούσας μελέτης, ελέγχεται η θεωρητική υπόθεση του κατά πόσο μια τέτοια ανακατανομή βαρών μπορεί να διασώσει αποτελεσματικότερα την τοπολογία των κροσσών υπό συνθήκες έντονου θορύβου.

Όπως τεκμηριώνεται στα επακόλουθα πειραματικά κεφάλαια της εργασίας, η επίδραση του ECA δεν είναι καθολική, αλλά αποδεικνύεται αυστηρά **εξαρτώμενη από το πειραματικό καθεστώς (regime-dependent)**. Υπό συνθήκες συνθετικής εποπτείας (pseudo-noise supervision), ο μηχανισμός δεν προσφέρει μετρήσιμο κέρδος, καταλήγοντας σε λειτουργική ισοδυναμία με το απλό δίκτυο. Αντιθέτως, όταν η εκπαίδευση μεταβαίνει σε καθεστώς ευθυγράμμισης με πραγματικά δεδομένα (real-aligned), η ελαφριά αρχιτεκτονική ενσωμάτωση του μηχανισμού (light ECA) αναδεικνύει μια ήπια, θετική συμβολή, εν αντιθέσει με πιο επιθετικές διατάξεις που τείνουν να εισάγουν υπολογιστική αστάθεια.

Ασυμφωνία Στόχων (Task Misalignment) και το Παράδοξο του Averaged Swap

Ένα από τα κρισιμότερα θεωρητικά ζητήματα που διαπραγματεύεται η παρούσα εργασία είναι η ευθυγράμμιση της αποθορυβοποίησης με τον τελικό λειτουργικό στόχο (task alignment). Αποτελεί κεντρική θέση της μελέτης ότι η βελτίωση παραδοσιακών φωτομετρικών μετρικών (όπως το PSNR ή το SSIM) δεν συνεπάγεται νομοτελειακά και τη βελτίωση της μεταγενέστερης (downstream) ταξινόμησης.

Το φαινόμενο αυτό τυποποιείται στην εργασία μέσω του **παραδόξου του "Averaged Swap"**. Το παράδοξο περιγράφει τη συνθήκη όπου ένα δίκτυο αποθορυβοποίησης, παρότι

επιτυγχάνει υψηλότερη οπτική εξομάλυνση, καταστρέφει λεπτές μικροδομές των κροσσών που είναι κρίσιμες για τον ταξινομητή, με αποτέλεσμα η απλή, φυσικά ευθυγραμμισμένη μέθοδος του χρονικού μέσου όρου (multi-frame averaging) να αποδίδει τελικά υψηλότερη ακρίβεια ταξινόμησης. Η επιτυχής διάρρηξη αυτού του παραδόξου προϋποθέτει την εξαιρετικά ακριβή προσαρμογή του καθεστώτος εκπαίδευσης (όπως επιτυγχάνεται μέσω του μοντέλου V4R), ώστε το δίκτυο να διασώζει τη διακριτική πληροφορία των κροσσών καλύτερα από τα ολοκληρωμένα (averaged) υποκατάστατα.

Αυτή η εγγενής απόκλιση (PSNR ≠ Macro-F1) δικαιολογεί απόλυτα τη μεθοδολογική οπτική της διπλωματικής: η ποιότητα κάθε προεπεξεργασίας οφείλει να αξιολογείται λειτουργικά, βάσει της τελικής ταξινομικής ακρίβειας, και όχι αποκλειστικά βάσει απομονωμένων φωτομετρικών κριτηρίων.

Συμπερασματικά, το DnCNN (με ή χωρίς ECA) οριοθετείται θεωρητικά ως ένα ισχυρό, επικουρικό εργαλείο βελτίωσης της αναγνωσιμότητας των κροσσών. Δεν αποτελεί, ωστόσο, τον πυρήνα της διαδικασίας. Η εξαιρετικά υψηλή επίδοση του συνολικού συστήματος ταξινόμησης εδράζεται πρωτίστως στην ορθή μοντελοποίηση της φυσικής (μέσω των συχνοτικών παραδοχών - priors) και δευτερευόντως στην αλγοριθμική αποθορυβοποίηση.

Πίνακας 2.15: *Συνοπτική σύγκριση ρόλων, πλεονεκτημάτων και περιορισμών των εξεταζόμενων μοντέλων.*

Μοντέλο / Στάδιο	**Είσοδος → Έξοδος**	**Ρόλος στη Ροή Επεξεργασίας**	**Πλεονεκτήματα**	**Περιορισμοί / Ρίσκα**
Pattern-Only RF	16 Μορφολογικά Χαρακτηριστικά → Κλάση	Ερμηνεύσιμο μοντέλο αναφοράς (Baseline)	Υψηλή ερμηνευσιμότητα, ταχύτητα, ανθεκτικότητα σε μικρά σύνολα δεδομένων.	Αδυναμία διάκρισης σε επικαλύψεις (modal overlap), χαμηλό δείκτη Macro-F1.

Hybrid RF	22 Χαρακτηριστικά (Pattern + Priors) → Κλάση	Κύριο Physics-Informed μοντέλο	Πολύ υψηλό Macro-F1, επίλυση επικαλύψεων, δυνατότητα εξαγωγής σημαντικότητας χαρακτηριστικών.	Κίνδυνος επιφανειακής μάθησης (shortcut learning) αποκλειστικά από τη συχνότητα διεγέρσεως.
ResNet-18 (CNN)	Εικόνα (256×256) → Κλάση	Αμιγώς Data-Driven μοντέλο αναφοράς	Ενιαία εκπαίδευση End-to-End, αξιοποίηση μεταφοράς μάθησης (transfer learning).	Έντονη ευπάθεια σε μετατόπιση πεδίου (domain shift) / ανισορροπία κλάσεων, απαίτηση για μεγάλο όγκο δεδομένων.
DnCNN ($\pm$ ECA)	Θορυβώδες καρέ → Καθαρό καρέ	Προαιρετικό επικουρικό στάδιο προεπεξεργασίας	Στοχευμένη καταστολή του speckle σε μονοκαρέ (single-shot) λήψεις.	Ασυμφωνία στόχων ($\mathrm{PSNR} \neq F1$), δυνητικός κίνδυνος υπερ-εξομάλυνσης (ισοπέδωσης) των κροσσών.
Multi-frame Avg	N καρέ → Μέση εικόνα	Physics-Aligned αναφορά θορύβου	Θεωρητική μείωση θορύβου ανάλογη του $1/\sqrt{N}$, απόλυτη διατήρηση της δομής.	Απαιτεί πολλαπλές, χρονικά σταθερές λήψεις, μη εφαρμόσιμο σε ταχέως μεταβαλλόμενα φαινόμενα.

Στρατηγική Σύνθεση και Έλεγχος Υποθέσεων

Η επιλογή και η διάρθρωση των συγκεκριμένων υπολογιστικών αρχιτεκτονικών αποτελεί μια συνειδητή μεθοδολογική απόφαση που εξυπηρετεί τον κεντρικό ερευνητικό σκοπό της μελέτης. Η ανάδειξη του υβριδικού μοντέλου Random Forest (Hybrid RF) σε κύριο ταξινομητή καθοδηγούμενο από τη φυσική (physics-informed), σε άμεση αντιπαραβολή με το ResNet-18 το οποίο λειτουργεί ως το αμιγώς δεδομενοκεντρικό (data-driven) σημείο αναφοράς, καθώς και η αξιοποίηση του DnCNN ως διακριτού σταδίου προεπεξεργασίας, διαμορφώνουν το αυστηρό πειραματικό πλαίσιο που απαιτείται για τον έλεγχο των θεμελιωδών υποθέσεων της εργασίας.

Μέσα από αυτό το συγκριτικό σχήμα, επιδιώκεται να τεκμηριωθεί εμπειρικά μια διττή παραδοχή:

1. **Η ισχυρή φυσική δομή των ιδιομορφών:** Οι ιδιομορφές ταλάντωσης (vibration modes) δεν αποτελούν τυχαία οπτικά μοτίβα, αλλά διέπονται από μια αυστηρή φυσική οργάνωση. Η δομή αυτή μπορεί να αποτυπωθεί και να αποκωδικοποιηθεί βέλτιστα μόνο μέσα από τον συνδυασμό της συχνοτικής πληροφορίας (frequency priors) και της γεωμετρικής μορφολογίας των κροσσών συμβολής.

2. **Η ανωτερότητα της ενσωματωμένης γνώσης πεδίου:** Η ρητή, στοχευμένη κωδικοποίηση αυτής της φυσικής γνώσης υπερτερεί σαφώς έναντι των δεδομενοκεντρικών προσεγγίσεων τύπου «μαύρου κουτιού» (black-box). Η ανωτερότητα αυτή καθίσταται απολύτως καθοριστική σε ρεαλιστικά πειραματικά σενάρια, όπου κυριαρχούν συνθήκες περιορισμένων διαθέσιμων δεδομένων (data scarcity / low-data regime) και αναπόφευκτης μετατόπισης πεδίου (domain shift) μεταξύ διαφορετικών δοκιμίων.

2.9 Συνθετική Θεώρηση: Οδικός Χάρτης της εργασίας (Κεφάλαια 3-6)

Το παρόν κεφάλαιο έθεσε τις επιστημολογικές βάσεις της εργασίας, αναλύοντας την αλυσίδα που συνδέει τη φυσική της ταλάντωσης με την ψηφιακή της αναπαράσταση. Η παρούσα ενότητα λειτουργεί ως συνθετική γέφυρα προς τα επόμενα κεφάλαια, συγκεντρώνοντας τα επιμέρους θεωρητικά στοιχεία σε ένα ενιαίο πλαίσιο που προδιαγράφει τη μεθοδολογία και τη λογική των πειραματικών ελέγχων. Το κεντρικό αφήγημα παραμένει

αυτό της Μηχανικής Μάθησης Καθοδηγούμενης από τη Φυσική, δηλαδή η θέση ότι η ενσωμάτωση φυσικής γνώσης, μέσω θεωρητικών περιορισμών και πρότερων πληροφοριών, ενισχύει τόσο την απόδοση όσο και την ερμηνευσιμότητα του συστήματος.

2.9.1 Μεθοδολογική End-to-End Ροή Εργασίας

Η πλήρης ροή της εργασίας μπορεί να ιδωθεί ως μια διαδοχική αλυσίδα σταδίων που ξεκινά από την αξιοποίηση υφιστάμενου πειραματικού υλικού και καταλήγει σε ελέγξιμα κριτήρια αξιολόγησης. Αφετηρία αποτελεί το αρχείο συμβολομετρικών δεδομένων από προγενέστερες μετρήσεις ESPI σε όργανα της οικογένειας του μπουζουκιού. Οι εικόνες αυτές αποτυπώνουν τη μετάβαση από τη μηχανική ταλάντωση σε οπτικά μοτίβα κροσσών, τα οποία υπόκεινται σε έντονο speckle θόρυβο και σε επιπρόσθετες συνιστώσες θορύβου βολής και ανάγνωσης. Πάνω σε αυτό το υλικό εφαρμόζονται διαδικασίες προεπεξεργασίας, αξιοποίηση του multi-frame averaging ως φυσικά συνεπούς προτύπου αναφοράς και, συμπληρωματικά, δεδομενοκεντρική αποθορυβοποίηση μέσω DnCNN.

Στη συνέχεια, το σήμα μετασχηματίζεται σε κατάλληλη αναπαράσταση μέσω υβριδικού διανύσματος 22 χαρακτηριστικών, το οποίο συνδυάζει 16 μορφολογικούς περιγραφείς των fringe patterns με 6 συχνοτικά priors θεμελιωμένα στη φυσική. Επάνω σε αυτή την αναπαράσταση εκπαιδεύονται και αξιολογούνται τα μοντέλα ταξινόμησης, με έμφαση στη συγκριτική αντιπαραβολή του Physics-Informed Random Forest και ενός End-to-End προτύπου αναφοράς τύπου ResNet-18. Η αξιολόγηση συμπληρώνεται από κατάλληλες μετρικές για ανισόρροπα δεδομένα, όπως το Macro-F1, καθώς και από αυστηρά πρωτόκολλα γενίκευσης και στατιστικής τεκμηρίωσης.

2.9.2 Διασύνδεση Θεωρίας και Πειραματικής Επαλήθευσης

Στο πλαίσιο αυτό, τα επόμενα κεφάλαια δεν λειτουργούν απλώς ως διαδοχική παράθεση βημάτων, αλλά ως στάδια πειραματικής επαλήθευσης των θεωρητικών αξόνων του παρόντος κεφαλαίου. Το Κεφάλαιο 3 μετασχηματίζει τη θεωρητική συζήτηση σε σαφές πρωτόκολλο συλλογής, προεπεξεργασίας και αναπαράστασης των δεδομένων. Το Κεφάλαιο 4 παρουσιάζει τα πειραματικά αποτελέσματα για τη γεννήτρια ψευδο-θορύβου, την αποθορυβοποίηση, την εξαγωγή χαρακτηριστικών, τη συγκριτική αξιολόγηση των μοντέλων και τους ελέγχους γενίκευσης. Το Κεφάλαιο 5 αναλαμβάνει τη συνθετική ερμηνεία

των ευρημάτων, ενώ το Κεφάλαιο 6 συνοψίζει τις συνεισφορές της εργασίας, επανεξετάζει τα ερευνητικά ερωτήματα και οριοθετεί τις βασικές μελλοντικές προεκτάσεις.

Με αυτή τη λογική, η εργασία συγκροτεί μια αλυσίδα μετάβασης από τη θεωρία στην πειραματική επαλήθευση, όπου κάθε κεφάλαιο υπηρετεί μια συγκεκριμένη λειτουργία τεκμηρίωσης. Η φυσική της δόνησης, η οπτική αποτύπωση μέσω ESPI, η φυσικά βαθμονομημένη συνθετική εποπτεία, η εξαγωγή υβριδικών χαρακτηριστικών και η αυστηρή στατιστική αξιολόγηση αντιμετωπίζονται ως αλληλένδετα στοιχεία ενός ενιαίου ερευνητικού σχεδίου.

2.9.3 Η Αλυσίδα Τεκμηρίωσης της Υπόθεσης

Η θεμελιώδης υπόθεση της εργασίας είναι ότι η ταξινόμηση ιδιομορφών δεν αποτελεί ένα απλό ζήτημα αναγνώρισης οπτικών προτύπων, αλλά πρόβλημα με ισχυρή φυσική δομή. Η συχνότητα λειτουργεί ως πρωτεύον στοιχείο ταυτότητας, ενώ η μορφολογία των κομβικών γραμμών και των fringe patterns προσφέρει την τοπολογική πληροφορία που επιτρέπει ανθεκτικότερη διάκριση υπό θόρυβο. Η υπόθεση αυτή εξετάζεται πειραματικά στα επόμενα κεφάλαια μέσω της σύγκρισης του Pattern-Only Random Forest με τον Hybrid Random Forest, της ανάλυσης σημαντικότητας χαρακτηριστικών και των πρωτοκόλλων γενίκευσης LOBO και LODO.

2.9.4 Διευκρινίσεις Ορολογίας και Μεθοδολογικής Συνέπειας

Για τη διασφάλιση της μεθοδολογικής συνοχής, κρίνεται σκόπιμο να αποσαφηνιστεί ότι ο κεντρικός ερευνητικός πυρήνας της εργασίας δομείται σταθερά γύρω από το βασικό σχήμα των έξι κλάσεων και το αντίστοιχο υβριδικό διάνυσμα των 22 χαρακτηριστικών. Τυχόν αρχιτεκτονικές παραλλαγές που εξετάζονται σε επιμέρους αναλύσεις ή παραρτήματα λειτουργούν αυστηρά ως επικουρικές επεκτάσεις, σχεδιασμένες να διερευνήσουν ειδικότερα φαινόμενα, χωρίς να υποκαθιστούν το κύριο πλαίσιο. Υπό το ίδιο ακριβώς πρίσμα, η λειτουργική αξία των μεθόδων αποθορυβοποίησης δεν αποτιμάται μέσω στατικών φωτομετρικών δεικτών (όπως το PSNR ή το SSIM), αλλά αξιολογείται αυστηρά με γνώμονα τον τελικό τους αντίκτυπο στη μεταγενέστερη (downstream) εργασία της ταξινόμησης.

Συνοψίζοντας, το παρόν κεφάλαιο διαμόρφωσε το απαραίτητο θεωρητικό θεμέλιο της μελέτης, επιχειρώντας μια άμεση διεπιστημονική σύνθεση: γεφύρωσε τη φυσική των δονήσεων και την οπτική συμβολομετρία ESPI με τη στατιστική συμπεριφορά του θορύβου κηλίδων και τις σύγχρονες τεχνικές της μηχανικής μάθησης. Έχοντας πλέον αυστηρά οριοθετήσει το θεωρητικό πλαίσιο του προβλήματος, το επόμενο κεφάλαιο προχωρά στην αναλυτική περιγραφή της πειραματικής διάταξης, της παραγωγής των δεδομένων και της πρακτικής υλοποίησης της προτεινόμενης μεθοδολογίας.

ΚΕΦΑΛΑΙΟ 3: ΜΕΘΟΔΟΛΟΓΙΑ

3.1 Πειραματική Διάταξη και Συλλογή Δεδομένων

Η προτεινόμενη μεθοδολογία ακολουθεί μια υβριδική προσέγγιση, η οποία συνδυάζει μοντελοποίηση καθοδηγούμενη από τη φυσική (physics-informed) με τεχνικές βαθιάς μάθησης (deep learning). Η ροή εργασίας (pipeline) οργανώνεται σε τρία στάδια: (α) δημιουργία συνθετικών ζευγών δεδομένων εκπαίδευσης μέσω φυσικού μοντέλου θορύβου κηλίδων→Poisson→Gaussian, (β) εκπαίδευση νευρωνικού δικτύου αποθορυβοποίησης (denoising) DnCNN για ανάκτηση της δομής των κροσσών συμβολής, και (γ) τελική ταξινόμηση ιδιομορφών μέσω μεταφοράς μάθησης (transfer learning) με ResNet και ερμηνεύσιμων συνόλων αποφάσεων (Random Forest).

Η παρούσα ερευνητική εργασία βασίζεται σε πειραματικά δεδομένα που συλλέχθηκαν μέσω ενός εξειδικευμένου συστήματος Συμβολομετρίας Ηλεκτρονικών Κηλίδων (Electronic Speckle Pattern Interferometry - ESPI). Η τεχνική αυτή επιτρέπει την οπτικοποίηση και καταγραφή των ιδιομορφών ταλάντωσης (vibration modes) σε αντηχεία (soundboards) μουσικών οργάνων της οικογένειας του μπουζουκιού, παρέχοντας δεδομένα υψηλής ανάλυσης κατάλληλα για ανάλυση μέσω τεχνικών μηχανικής μάθησης. (βλ. Κεφάλαιο 2).

3.1.1 Διαμόρφωση του Συστήματος ESPI

Το πειραματικό σύστημα αποτελείται από μονοχρωματική πηγή laser σε συνεχή λειτουργία (CW DPSS) με μήκος κύματος 532 nm, η οποία παρέχει τη σύμφωνη ακτινοβολία που απαιτείται για τη δημιουργία των κροσσών συμβολής. Η καταγραφή των εικόνων πραγματοποιείται μέσω ψηφιακής κάμερας CCD με αισθητήρα 16-bit και ανάλυση 1024×824 εικονοστοιχείων, εξασφαλίζοντας υψηλό δυναμικό εύρος και χωρική ανάλυση επαρκή για την ανίχνευση λεπτών δομών στα μοτίβα κροσσών.[1]

3.1.2 Προετοιμασία Πειραματικών Αντικειμένων (specimens) και Δεδομένα

Στο πλαίσιο της έρευνας μελετήθηκαν συνολικά έξι δοκίμια αντηχείων: τρία κατασκευασμένα από παραδοσιακό ξύλο (με κωδικούς W01, W02 και W03) και τρία από

[1] *Η μέτρηση πραγματοποιήθηκε με συνεχούς κύματος (CW) DPSS laser 532 nm.*

σύνθετα υλικά ανθρακονημάτων (C01, C02, C03). Η κύρια πειραματική ροή της παρούσας εργασίας - η οποία περιλαμβάνει την εκπαίδευση και αξιολόγηση του αποθορυβοποιητή, την εξαγωγή φάσης και τη δημιουργία του τελικού συνόλου δεδομένων ταξινόμησης - βασίστηκε αποκλειστικά στα ξύλινα δοκίμια. Τα δοκίμια από ανθρακονήματα χρησιμοποιήθηκαν ως συμπληρωματικό υλικό για τον έλεγχο της γενίκευσης και αποτελούν αντικείμενο μελλοντικής έρευνας, όπως συζητείται στα Κεφάλαια 7 και 8.

Το αρχικό σύνολο δεδομένων περιλαμβάνει περίπου 1.400 εικόνες αναφοράς (averaged/clean), εκ των οποίων 699 προέρχονται από τα ξύλινα δοκίμια και 714 από τα δοκίμια ανθρακονημάτων. Επιπλέον, συλλέχθηκαν περίπου 25.000 μεμονωμένες λήψεις (single-shot) σε μορφή 16-bit, με 10 έως 15 λήψεις ανά συχνότητα διέγερσης, οι οποίες περιέχουν τον εγγενή θόρυβο κηλίδων που χαρακτηρίζει τις εικόνες ESPI. (βλ. Κεφάλαιο 2).

Επαληθευμένα στατιστικά επεξεργασίας:

Η διαδικασία επεξεργασίας των δεδομένων παρήγαγε τα ακόλουθα επαληθευμένα αποτελέσματα. Η πλήρης επαναεφαρμογή (re-inference) του αποθορυβοποιητή σε όλες τις εικόνες απέδωσε 21.882 αποθορυβοποιημένες εικόνες με ποσοστό επιτυχίας 100%, κατανεμημένες ανά δοκίμιο (specimen) ως εξής: W01 με 7.846 εικόνες, W02 με 8.058 εικόνες και W03 με 5.978 εικόνες. Η εξαγωγή φάσης πραγματοποιήθηκε επιτυχώς σε 552 από τους 596 διαθέσιμους φακέλους, αντιστοιχώντας σε ποσοστό επιτυχίας 92,6%.

Το τελικό σύνολο δεδομένων ταξινόμησης αποτελείται από 3.443 δείγματα κατανεμημένα σε 6 λειτουργικές κλάσεις ιδιομορφών, με διαχωρισμό εκπαίδευσης/επικύρωσης/δοκιμής σε αναλογία 70/15/15, που αντιστοιχεί σε 2.410, 516 και 517 δείγματα αντίστοιχα. Η έντονη ανισορροπία κλάσεων με λόγο 30,9:1 μεταξύ της μεγαλύτερης και της μικρότερης κλάσης, καθώς και η κυριαρχία του δοκιμίου W02 που συνεισφέρει το 81,4% των δειγμάτων (2.803 δείγματα), ενώ τα W01 και W03 συνεισφέρουν 9,9% (341 δείγματα) και 8,7% (299 δείγματα) αντίστοιχα.

3.2 Κατασκευή Συνόλου Δεδομένων και Προεπεξεργασία

3.2.1 Σύνολο Εκπαίδευσης για το Τμήμα Αποθορυβοποίησης

Το σύνολο εκπαίδευσης για το δίκτυο αποθορυβοποίησης DnCNN-ECA αποτελείται από 11.434 ζεύγη εικόνων, όπου κάθε ζεύγος περιλαμβάνει μια θορυβώδη εικόνα εισόδου και την αντίστοιχη καθαρή εικόνα αναφοράς. Η σύνθεση του συνόλου ακολουθεί στρατηγική αναλογία πραγματικών και συνθετικών δεδομένων περίπου 80/20, με στόχο την εξισορρόπηση μεταξύ αυθεντικότητας και ποικιλομορφίας των προτύπων θορύβου. (βλ. Κεφάλαιο 2).

Πίνακας 3.1: *Σύνθεση Συνόλου Εκπαίδευσης για τον Αποθορυβοποιητή DnCNN-ECA*

Κατηγορία	Αριθμός Ζευγών	Ποσοστό
Πραγματικά ζεύγη ESPI	8.712	76,2%
Ψευδο-θορυβώδη ζεύγη	2.722	23,8%
Σύνολο	**11.434**	**100%**

Η εκπαίδευση δικτύων αποθορυβοποίησης απαιτεί ζεύγη ‘Θορυβώδους–Καθαρής’ εικόνας (noisy–clean pairs). Στο ESPI, όμως, η απόκτηση απόλυτα καθαρής εικόνας αναφοράς (reference image/ground truth) είναι πρακτικά αδύνατη λόγω της στοχαστικής φύσης του speckle και της ευαισθησίας του συμβολομέτρου σε μικρομετατοπίσεις. Για τον λόγο αυτό, η παρούσα εργασία υιοθετεί ως εικόνα αναφοράς τη μέση εικόνα πολλαπλών λήψεων (multi-frame averaging), ενώ παράλληλα ενισχύει τη γενίκευση μέσω σύνθεσης ψευδο-θορυβωδών δεδομένων βασισμένης σε φυσικό μοντέλο (pseudo-noisy generation) (βλ. επίσης Κεφ. 2).

3.2.2 Χαρακτηρισμός Θορύβου

Η στατιστική ανάλυση πραγματικών εικόνων ESPI (δείγμα 500 εικόνων) έδειξε ότι ο speckle θόρυβος περιγράφεται ικανοποιητικά από την κατανομή Burr Type XII (βαρυουρά), η οποία αποτυπώνει καλύτερα τις ακραίες τιμές φωτεινότητας που χαρακτηρίζουν τα μοτίβα κηλίδων. Οι εκτιμήσεις παραμέτρων και ο πλήρης μαθηματικός ορισμός παρατίθενται στο Παράρτημα Η (βλ. επίσης Κεφάλαιο 2 και [Goodman, 2007; Dainty, 1984]).

Με βάση τα παραπάνω αναπτύχθηκε γεννήτρια ψευδο-θορυβωδών εικόνων βασισμένη σε φυσικό μοντέλο, η οποία εφαρμόζει διαδοχικά (cascade) τρία στάδια θορύβου: (i) speckle τύπου Burr XII, (ii) Poisson θόρυβο που προσομοιώνει τη φωτονική φύση της ανίχνευσης και (iii) προσθετικό Γκαουσιανό θόρυβο που αντιπροσωπεύει τον ηλεκτρονικό θόρυβο αισθητήρα. Ενδεικτικές παράμετροι βαθμονόμησης: speckle-k=3,0, poisson-peak=60, gauss-sigma=0,01, με ενεργοποιημένη χωρική συσχέτιση κηλίδων (spatial-speckle) σε ένταση 0,40.

Η διαδικασία βαθμονόμησης της γεννήτριας (έκδοση 2.0) βασίστηκε σε αντιστοίχιση πραγματικών ζευγών εικόνων ανά συχνότητα και πλάτος διέγερσης, ακέραια ευθυγράμμιση και προσαρμογή Poisson–Gaussian ανά συχνοτική ζώνη. Πρόσθετες λεπτομέρειες υλοποίησης και περιορισμοί ανά δοκίμιο παρατίθενται στο Παράρτημα Η.

Σημείωση: *Η παρούσα βαθμονόμηση της ψευδο-θορυβώδους γεννήτριας επαρκεί για τις ανάγκες εκπαίδευσης του αποθορυβοποιητή. Μια συστηματική μελέτη εναλλακτικών θορυβολογικών μοντέλων (Gamma, Burr-XII, πολυκλιμακωτά μοντέλα) προτείνεται ως μελλοντική εργασία (βλ. Κεφ. 8).*

Η έκδοση Lite διατηρεί τη λογική της πρόβλεψης θορύβου (residual learning), περιορίζοντας τη συνολική πολυπλοκότητα του backbone. Η αρχιτεκτονική χρησιμοποιεί συνελικτικούς πυρήνες 3×3 (padding=1) σε βάθος 17 επιπέδων, εξασφαλίζοντας ενεργό δεκτικό πεδίο περίπου 35×35 pixels, το οποίο κρίνεται επαρκές για την αποτύπωση των χωρικών συσχετίσεων των κροσσών συμβολής ESPI.

3.3 Τμήμα Αποθορυβοποίησης: Αρχιτεκτονική DnCNN-ECA

3.3.1 Αρχιτεκτονική Δικτύου

Η ενσωμάτωση αποδοτικής προσοχής καναλιών (channel attention) είναι κρίσιμη σε περιπτώσεις χαμηλού λόγου σήματος προς θόρυβο (signal-to-noise ratio, SNR), όπου η πληροφορία των κροσσών εμφανίζεται ασθενής έναντι του υποβάθρου. Το ECA επιτρέπει δυναμική επαναστάθμιση των χαρτών χαρακτηριστικών, ώστε να ενισχύονται εκείνα που φέρουν μορφολογική πληροφορία ιδιομορφών και να αποδυναμώνονται τα κανάλια που κυριαρχούνται από στοχαστικό θόρυβο.

Το τμήμα αποθορυβοποίησης βασίζεται στην αρχιτεκτονική DnCNN [Zhang et al., 2017], ενισχυμένη με μονάδες Αποδοτικής Προσοχής Καναλιών (Efficient Channel Attention - ECA) [Wang et al., 2020]. Η επιλογή αυτής της αρχιτεκτονικής υπαγορεύτηκε από την αποδεδειγμένη αποτελεσματικότητά της στην αποθορυβοποίηση εικόνων μέσω υπολειμματικής μάθησης (residual learning), όπου το δίκτυο εκπαιδεύεται να προβλέπει απευθείας τον θόρυβο αντί της καθαρής εικόνας. (βλ. Κεφάλαιο 2).

Η συγκεκριμένη υλοποίηση χρησιμοποιεί την παραλλαγή DnCNN-Lite με βάθος 17 συνελικτικών επιπέδων και σταθερό αριθμό 64 καναλιών στα ενδιάμεσα επίπεδα. Η ενεργοποίηση πραγματοποιείται με συναρτήσεις ReLU, ενώ εφαρμόζεται κανονικοποίηση παρτίδας (Batch Normalization) για τη σταθεροποίηση της εκπαίδευσης. Ο μηχανισμός Efficient Channel Attention (ECA) ενσωματώνεται αραιά σε επιλεγμένα convolutional blocks (sparse insertion), ακολουθώντας – όπου χρησιμοποιείται – τη διάταξη Conv → BatchNorm → ECA → ReLU, ώστε να ενισχύεται η διακριτική ικανότητα των καναλιών χωρίς σημαντική αύξηση του υπολογιστικού κόστους.

3.3.2 Σχεδιασμός Μονάδας ECA

Η μονάδα Αποδοτικής Προσοχής Καναλιών (ECA) αποτελεί μια βελτιστοποιημένη εκδοχή του μηχανισμού Squeeze-and-Excitation (SE). Η καινοτομία της έγκειται στην αντικατάσταση των πλήρως συνδεδεμένων επιπέδων - που εισάγουν πολυπλοκότητα $O(C^2)$ - με μονοδιάστατη συνέλιξη πολυπλοκότητας $O(k)$, όπου k είναι το μέγεθος του πυρήνα. Αυτή η σχεδιαστική επιλογή μειώνει δραστικά τον αριθμό των παραμέτρων διατηρώντας παράλληλα την ικανότητα μοντελοποίησης των αλληλεξαρτήσεων μεταξύ καναλιών [Wang et al., 2020]. (βλ. Κεφάλαιο 2).

Η στρατηγική τοποθέτηση των μονάδων ECA στα πρώτα επίπεδα του δικτύου επιτρέπει την έγκαιρη ενίσχυση των σημαντικών χαρακτηριστικών του μοτίβου κηλίδων, βελτιώνοντας την ικανότητα του δικτύου να διατηρεί τα όρια των κροσσών συμβολής (fringe boundaries) κατά τη διαδικασία αποθορυβοποίησης - μια κρίσιμη απαίτηση για τη μετέπειτα ταξινόμηση των ιδιομορφών.

3.3.3 Διαμόρφωση Εκπαίδευσης

Η εκπαίδευση του δικτύου διεξήχθη με τις ακόλουθες υπερπαραμέτρους: αρχικός ρυθμός μάθησης 10^{-4}, βελτιστοποιητής Adam ($\beta_1 = 0{,}9$, $\beta_2 = 0{,}999$), μέγεθος παρτίδας 32 δείγματα και πρόωρη διακοπή (early stopping) με βάση το validation loss. Η πλήρης καταγραφή των τελικών ρυθμίσεων εκπαίδευσης και των επιλογών checkpoint παρατίθεται στο Παράρτημα Α.

Ως βασική συνάρτηση απώλειας χρησιμοποιήθηκε η νόρμα L1 (Mean Absolute Error), καθώς ευνοεί τη διατήρηση ορίων και λεπτών δομών κροσσών σε σχέση με αμιγώς τετραγωνικές απώλειες. Η εκπαίδευση πραγματοποιήθηκε σε τμήματα εικόνων (patches) διαστάσεων 256×256 εικονοστοιχείων, με χρήση κάρτας γραφικών NVIDIA RTX 3060 με 12 GB μνήμης VRAM (βλ. Παράρτημα Α).

Πίνακας 3.2: *Υπερπαράμετροι Εκπαίδευσης DnCNN-ECA (βλ. Κεφάλαιο 2).*

Υπερπαράμετρος	**Τιμή**
Εποχές εκπαίδευσης	20 (πρώιμη διακοπή στην 11η)
Μέγεθος παρτίδας	12
Ρυθμός μάθησης	1×10^{-4} (ReduceLROnPlateau)
Βελτιστοποιητής	Adam (β_1=0,9, β_2=0,999)
Συνάρτηση απώλειας	0,5×(1-SSIM) + 0,5×L1 + 0,1×Edge
Μέγεθος τμήματος	256×256 εικονοστοιχεία
Κάρτα γραφικών	NVIDIA RTX 3060 (12 GB)

Σημείωση περί μελέτης αφαίρεσης (ECA έναντι non-ECA): Κατά τη συγκριτική αξιολόγηση παρατηρήθηκαν πρακτικά ταυτόσημες έξοδοι στο validation subset (SSIM≈1 σε patch-level σύγκριση), χωρίς μετρήσιμη επίδραση στην τελική ταξινόμηση. Πιθανή αιτία αποτελεί η αντισταθμιστική δράση επιπέδων κανονικοποίησης (normalization re-parameterization). Η αναλυτική μελέτη αφαίρεσης του ECA, καθώς και η οριοθέτηση του regime-

dependent χαρακτήρα μέσω V4/V5, παρουσιάζονται στο συμπληρωματικό τεχνικό υλικό, ενώ οι τελικές ρυθμίσεις εκπαίδευσης τεκμηριώνονται στο Παράρτημα Α.

Η οπτική αξιολόγηση της αποθορυβοποίησης παρουσιάζεται αναλυτικά στο Κεφάλαιο 4 (Σχήμα 4.X), όπου συγκρίνονται παραδείγματα καλύτερης, μέσης και χειρότερης περίπτωσης.

3.4 Εξαγωγή Φάσης και Ποιοτικός Έλεγχος

Η εξαγωγή φάσης αποτελεί το «ενδιάμεσο» κρίσιμο βήμα μεταξύ της αποθορυβοποίησης των συμβολογραμμάτων ESPI και της επακόλουθης ταξινόμησης ιδιομορφών. Στόχος του σταδίου είναι η παραγωγή (i) τυλιγμένης (wrapped) φάσης, (ii) αποτυλιγμένη (unwrapped) φάσης και (iii) χάρτη ποιότητας (quality map), με τρόπο αναπαραγώγιμο και ελεγχόμενο ώστε να μπορεί να εφαρμοστεί μαζικά σε εκατοντάδες συχνότητες.

3.4.1 Προεπεξεργασία Εισόδου και Εφαρμογή ROI μάσκας

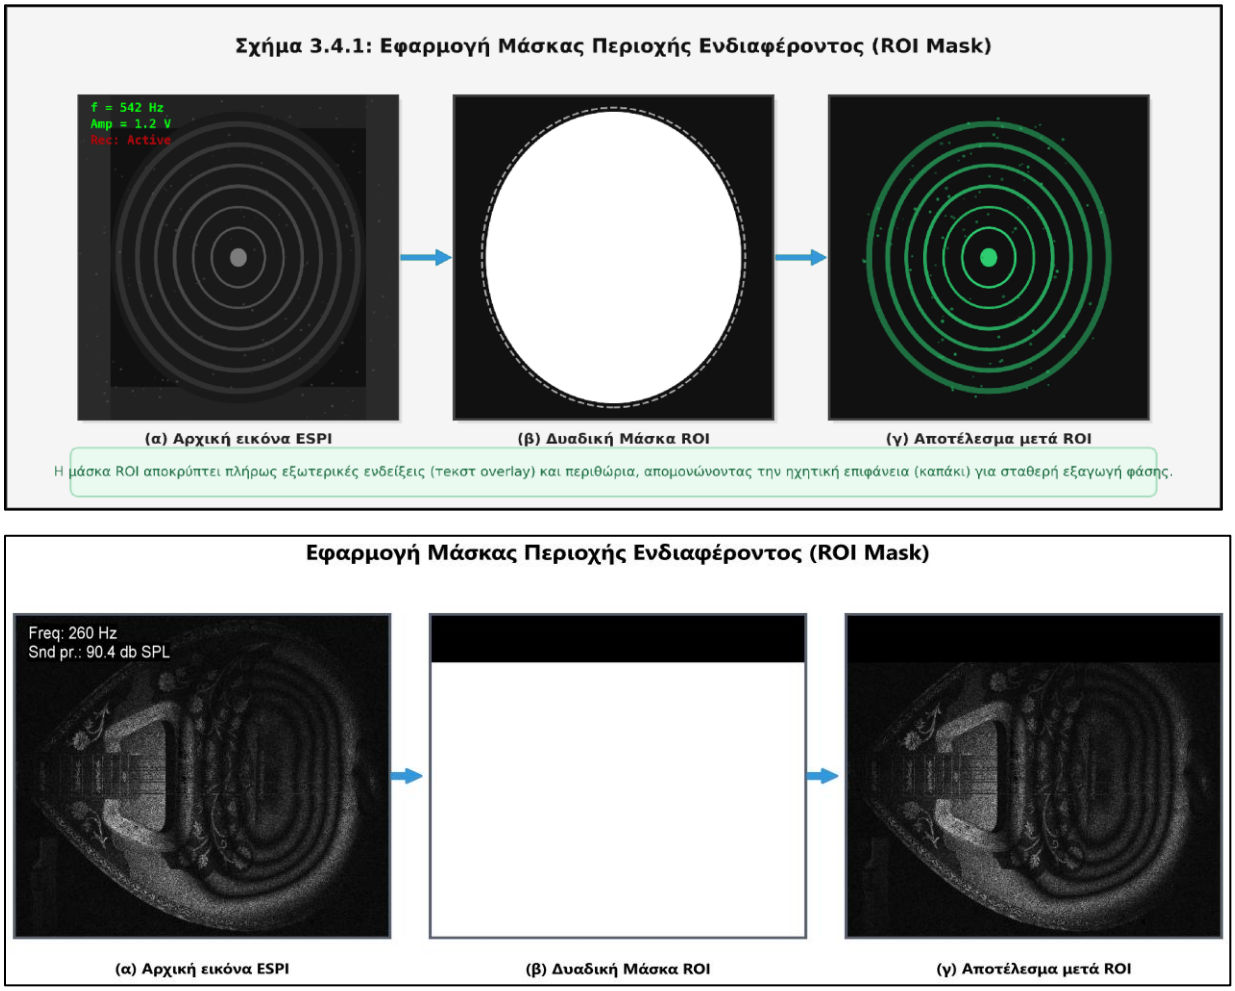
Πριν από την ανάκτηση φάσης, κάθε καρέ περνά από μία ελάχιστη αλλά απαραίτητη προεπεξεργασία, με στόχο την απομόνωση της ενεργής περιοχής του αντηχείου και τη σταθεροποίηση της κλίμακας έντασης:

- Εφαρμογή ROI μάσκας (region of interest) για τον αποκλεισμό φόντου/στατικών περιοχών.
- Κανονικοποίηση έντασης σε ενιαία κλίμακα (π.χ. float [0,1]) για σταθερότητα σε FFT και unwrap.
- Προαιρετική διόρθωση ομοιόμορφου πεδίου (flat-field) για μείωση βραδείας μεταβολής φωτισμού. Συγκριτικές δοκιμές με και χωρίς απόκρυψη του κειμένου έδειξαν ποιοτικά ότι η παρουσία του μπορεί να εισάγει ψευδοδομές στο φάσμα FFT και να δυσχεραίνει τη σταθερή επιλογή του carrier, επηρεάζοντας την αξιοπιστία της ανάκτησης φάσης.

Κατά τον αρχικό ποιοτικό έλεγχο διαπιστώθηκε ότι το overlay κείμενο (συχνότητα διέγερσης και ένταση ηχητικής πηγής) που εμφανίζεται στο άνω αριστερό τμήμα κάθε καρέ εισάγει έντονες ακμές υψηλής αντίθεσης. Σε δοκιμαστικές εκτελέσεις χωρίς μάσκα, οι ακμές αυτές ενίσχυαν ανεπιθύμητα συνιστώσες του φάσματος FFT και μπορούσαν να επηρεάσουν την επιλογή του χωρικού carrier καθώς και τη σταθερότητα του unwrapping.

Για τον λόγο αυτό εφαρμόστηκε σταθερή μάσκα ROI η οποία αποκρύπτει πλήρως την περιοχή των ενδείξεων, διατηρώντας μόνο το δεξιό τμήμα του καπακιού όπου οι κροίσοι συμβολής είναι καθαρά ορατοί και φέρουν την ωφέλιμη πληροφορία δόνησης.

Η ROI μάσκα κατασκευάστηκε μία φορά (ως δυαδική εικόνα .png) πάνω σε αντιπροσωπευτικό averaged καρέ, ώστε να περιλαμβάνει το λειτουργικό τμήμα του αντηχείου και να εξαιρεί τα περιθώρια/στηρίγματα. Η ίδια μάσκα εφαρμόζεται αμετάβλητη σε όλα τα δεδομένα του ίδιου δοκιμίου, διατηρώντας συνεπή ορισμό περιοχής μέτρησης.



Σχήμα 3.4.1: *Θεωρητική λειτουργία και πρακτική εφαρμογή της δυαδικής μάσκας απόκρυψης (ROI mask). [Επάνω]: Η θεωρητική αρχή λειτουργίας του ROI, το οποίο απομονώνει την "ενεργή" ηχητική περιοχή (δόνηση του καπακιού) και απορρίπτει εξωτερικές ανταναακλάσεις και περιθωριακά πλαίσια (margins). [Κάτω]: Η πρακτική εφαρμογή σε πραγματικό αντιπροσωπευτικό συμβολόγραμμα του πειράματος (ESPI μπουζουκιού). Η*

μάσκα επικαλύπτει στοχευμένα τις ενδείξεις καταγραφής και το overlay κείμενο (π.χ. Freq: 250 Hz) στο άνω αριστερό άκρο του καρέ. Αυτή η διαδικασία είναι απαραίτητη για την α-ποτροπή έντονων ακμών (high-contrast artifacts) που θα αλλοίωναν την επιλογή της φέρουσας συχνότητας (carrier peak) κατά την ανάλυση στο φάσμα FFT..

3.4.2 Εξαγωγή Φάσης μέσω Μετασχηματισμού Fourier

Η εξαγωγή της φάσης από τις (αποθορυβοποιημένες) εικόνες ESPI υλοποιείται με τη μέθοδο απομόνωσης της φέρουσας χωρικής συχνότητας στο πεδίο Fourier (carrier-frequency isolation). Η βασική ιδέα είναι ότι οι κροσσοί συμβολής συγκεντρώνουν ενέργεια σε συγκεκριμένη χωρική συχνότητα· με την κατάλληλη απομόνωσή της ανακτάται το μιγαδικό αναλυτικό πεδίο και, τελικά, η φάση.

1. **Δισδιάστατος μετασχηματισμός Fourier**: υπολογίζεται το φάσμα $F(u,v)=\mathscr{F}\{I(x,y)\}$ της προεπεξεργασμένης εικόνας $I(x,y)$.

2. Καταστολή DC συνιστώσας: εφαρμόζεται κυκλική μάσκα μηδενισμού στο κέντρο του φάσματος (ακτίνα 16 px) ώστε να περιοριστούν οι χαμηλές χωρικές συχνότητες που δεν σχετίζονται με τους κροσσούς (βλ. Σχήμα 3.4.1).

3. **Εντοπισμός φέρουσας συχνότητας**: εντοπίζεται το μέγιστο της $|F(u,v)|$ εκτός της DC περιοχής, το οποίο αντιστοιχεί στη φέρουσα χωρική συχνότητα των κροσσών.

4. **Ζωνοπερατή απομόνωση (annulus filtering) και αντίστροφος FFT**: εφαρμόζεται δακτυλιοειδές/ζωνοπερατό φίλτρο γύρω από τον carrier, ώστε να προκύψει $\tilde{F}(u,v)$, και στη συνέχεια υπολογίζεται $c(x,y)=\mathscr{F}^{-1}\{\tilde{F}(u,v)\}$.

5. Τυλιγμένη φάση και ξετύλιγμα: η τυλιγμένη φάση υπολογίζεται ως $\varphi_w(x,y)=\arg(c(x,y))$ και κατόπιν εφαρμόζεται ξετύλιγμα φάσης (phase unwrapping), καθοδηγούμενη από χάρτη ποιότητας, για την απόκτηση συνεχούς χάρτη φάσης.

Για κάθε συμβολόγραμμα, η διαδικασία ανάκτησης φάσης παράγει τρία συμπληρωματικά σύνολα εξόδων, τα οποία χρησιμοποιούνται τόσο για την εξαγωγή χαρακτηριστικών όσο και για τον ποιοτικό έλεγχο:

Έξοδοι της Διαδικασίας Ανάκτησης Φάσης

- **Τυλιγμένη φάση (wrapped phase):** το πρωτογενές αποτέλεσμα της αντίστροφης FFT, περιορισμένο στο διάστημα [-π, +π], με εμφανή «άλματα» 2π.
- Αποτυλιγμένη φάση (unwrapped phase): το συνεχές πεδίο παραμόρφωσης μετά το ξετύλιγμα φάσης, το οποίο αποτελεί τη βασική αναπαράσταση του mode shape για τα επόμενα βήματα.
- Χάρτης ποιότητας (quality map): δείκτης αξιοπιστίας ανά εικονοστοιχείο, ο οποίος καθοδηγεί το ξετύλιγμα φάσης και επιτρέπει την ανίχνευση περιοχών χαμηλής ποιότητας (π.χ. σκιάσεις/χαμηλή αντίθεση κροσσών).

Μορφές αποθήκευσης (.npy και .png)

Για κάθε μία από τις παραπάνω εξόδους αποθηκεύονται δύο μορφές αρχείων, ώστε να καλύπτονται τόσο οι ανάγκες περαιτέρω υπολογιστικής επεξεργασίας όσο και η οπτική επιθεώρηση:

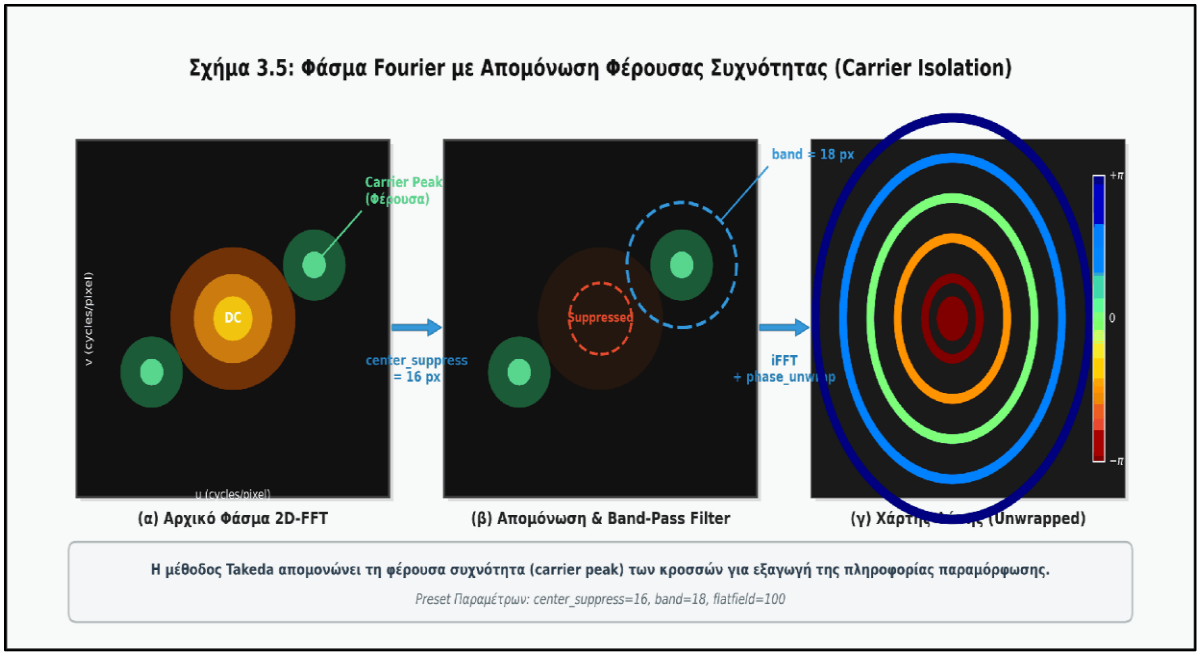
- **.npy (NumPy arrays):** αποθήκευση των «σκληρών» αριθμητικών δεδομένων κινητής υποδιαστολής (float), τα οποία διαβάζονται απευθείας από τα scripts εξαγωγής χαρακτηριστικών.
- **.png (visualizations):** απεικονίσεις των ίδιων χαρτών μετά από κατάλληλη κανονικοποίηση/χαρτογράφηση σε τιμές 8–16 bit, για ποιοτικό έλεγχο (QC) και για εισαγωγή στη διπλωματική.

Στη συνέχεια, οι χάρτες αποτυλιγμένης φάσης και ποιότητας αξιοποιούνται ως είσοδος για τον υπολογισμό των χαρακτηριστικών μορφής και για τον εντοπισμό αποτυχιών/αποκλίσεων μέσω QC.

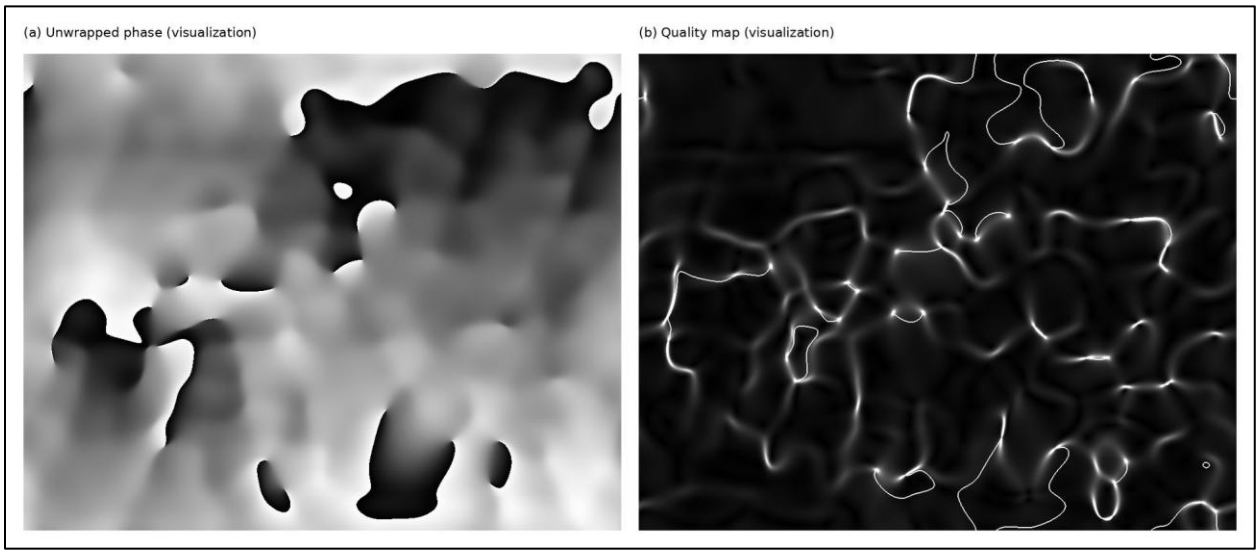
Η διαδικασία υλοποιήθηκε με το εργαλείο `phase_extract_fft_STRICT_FIXED.py`, με «κλειδωμένο» preset παραμέτρων για μέγιστη αναπαραγωγιμότητα.

Πίνακας 3.4: *Preset παραμέτρων FFT phase extraction (σταθερές ρυθμίσεις).*

Παράμετρος	**Τιμή**	**Ρόλος / Περιγραφή**
band	18	Επιλογή εύρους ζώνης carrier (θεμελιώδης ρύθμιση δημοδιαμόρφωσης)
center_suppress	16	Ακτίνα καταστολής DC συνιστώσας (αποκοπή χαμηλών συχνοτήτων)
flatfield	100	Παράγοντας διόρθωσης ομοιόμορφου πεδίου για αργές μεταβολές φωτισμού
annulus_inner	8	Εσωτερική ακτίνα δακτυλιοειδούς band-pass
annulus_outer	300	Εξωτερική ακτίνα δακτυλιοειδούς band-pass
ROI mask	roi_mask.png	Ενεργοποίηση υπολογισμών/μετρικών αποκλειστικά στην περιοχή ενδιαφέροντος
unwrap	auto	Αυτόματο ξετύλιγμα φάσης με χρήση χάρτη ποιότητας



Σχήμα 3.5: *Ανάκτηση φάσης με μέθοδο Takeda (FFT). (α) Εντοπισμός DC συνιστώσας και φερουσών συχνοτήτων (carrier peaks) στο φάσμα 2D-FFT. (β) Καταστολή DC (16 px) και ζωνοπερατή απομόνωση carrier (18 px) για την εξαγωγή του μιγαδικού αναλυτικού πεδίου. (γ) Υπολογισμός τυλιγμένης φάσης μέσω iFFT και αυτόματο ξετύλιγμα (unwrapping) για την παραγωγή του τελικού χάρτη φάσης..*



Σχήμα 3.6: *Ενδεικτικό παράδειγμα εξόδου της διαδικασίας ανάκτησης φάσης με FFT. (α) Αποτυλιγμένη φάση (unwrapped phase) ως οπτικοποίηση της κατανομής μετατόπισης. (β) Χάρτης ποιότητας (quality map) που ποσοτικοποιεί την αξιοπιστία της φάσης ανά εικονοστοιχείο.*

3.4.3 Ποιοτικός Έλεγχος (QC) και Ευθυγράμμιση έναντι Αναφοράς

Για να διασφαλιστεί ότι η εξαγόμενη φάση είναι κατάλληλη για μηχανική χαρακτηριστικών και ταξινόμηση, εφαρμόστηκε στάδιο ποιοτικού ελέγχου (QC) με σύγκριση έναντι αναφοράς (averaged) και με ευθυγράμμιση στην ROI:

- Έλεγχος αλλαγής πρόσημου της φάσης ($\pi \mapsto -\pi$) και αναζήτηση μικρής μετατόπισης (dx, dy) εντός προκαθορισμένου ορίου (π.χ. ±8 px), ώστε να ελαχιστοποιείται το σφάλμα στην ROI.
- Υπολογισμός αριθμητικών δεικτών: RMSE τυλιγμένης/αποτυλιγμένης φάσης, καθώς και ποσοστά εικονοστοιχείων με $|\Delta\varphi| > \pi/4$ και $|\Delta\varphi| > \pi/2$ εντός ROI.
- Παραγωγή χαρτών υπολοίπων (residual maps) για οπτικό έλεγχο των αποτυχιών (π.χ. carrier drift, unwrap artefacts).

Οι παραπάνω έλεγχοι λειτουργούν ως «πύλη ποιότητας» (QC gate) πριν την εξαγωγή χαρακτηριστικών. Στην πράξη, ο έλεγχος είναι ιδιαίτερα χρήσιμος για την ανίχνευση περιπτώσεων όπου ο θόρυβος ή η αστάθεια του carrier οδηγεί σε λανθασμένο unwrap και, συνεπώς, σε μη αξιόπιστη περιγραφή των nodal γραμμών.

Περιορισμοί: Η FFT-based ανάκτηση φάσης προϋποθέτει σχετικά σταθερό carrier και επαρκές SNR. Σε πολύ θορυβώδεις λήψεις, είναι πιθανές αποτυχίες στο unwrap ή μετακινήσεις του carrier, οι οποίες αντιμετωπίζονται με (i) αυστηρό preset φίλτρων, (ii) ROI περιορισμό και (iii) QC με ευθυγράμμιση και αριθμητικά κατώφλια.

3.5 Μηχανική Χαρακτηριστικών για Ταξινόμηση Ιδιομορφών

Για την ταξινόμηση των μοτίβων ιδιομορφών σχεδιάστηκε ένα σύνολο 16 χαρακτηριστικών μοτίβου θεμελιωμένων στη φυσική (pattern features) που αποτυπώνουν κρίσιμα δομικά στοιχεία κάθε τρόπου ταλάντωσης. Τα 16 χαρακτηριστικά μοτίβου ομαδοποιούνται σε τρεις κατηγορίες (κροσσών, γεωμετρικά/τοπολογικά και φασματικά), ενώ συμπληρωματικά εξάγονται 6 χαρακτηριστικά συχνότητας (frequency priors) που παρουσιάζονται στη §3.4.2.

3.5.1 Χαρακτηριστικά Μοτίβου (16 χαρακτηριστικά)

Χαρακτηριστικά βασισμένα σε κροσσούς:

Η πρώτη κατηγορία περιλαμβάνει χαρακτηριστικά που εξάγονται απευθείας από τη δομή των κροσσών συμβολής. Αυτά περιλαμβάνουν τον αριθμό μεγίστων κροσσών κατά τις δύο κύριες διευθύνσεις (m_count, n_count), τον συνολικό αριθμό κροσσών (total_fringes), τη μέση απόσταση μεταξύ διαδοχικών κροσσών (avg_fringe_spacing), καθώς και τις συντεταγμένες του κέντρου βάρους του μοτίβου (centroid_x, centroid_y).

Γεωμετρικά χαρακτηριστικά:

Η δεύτερη κατηγορία αφορά γεωμετρικές ιδιότητες του μοτίβου. Περιλαμβάνει μετρικές συμμετρίας κατά τον οριζόντιο, κατακόρυφο και ακτινικό άξονα, χαρακτηριστικά των κομβικών γραμμών (nodal lines) όπως το συνολικό μήκος και η πολυπλοκότητα τους, καθώς και αναλλοίωτες ροπές (Hu moments) που παρέχουν περιγραφείς ανεξάρτητους από μετασχηματισμούς κλίμακας, μετάθεσης και περιστροφής.

Φασματικά χαρακτηριστικά:

Η τρίτη κατηγορία εξάγει πληροφορία από το πεδίο συχνοτήτων μέσω μετασχηματισμού Fourier. Τα χαρακτηριστικά αυτά περιλαμβάνουν τις συντεταγμένες της κορυφής FFT που αντιστοιχεί στη φέρουσα συχνότητα (carrier frequency), την κατανομή της φασματικής πυκνότητας ισχύος, και μετρικές συγκέντρωσης ενέργειας στο πεδίο συχνοτήτων.

Η επιλογή πολλαπλών ταξινομητών δεν στοχεύει μόνο στη μεγιστοποίηση της επίδοσης, αλλά και στη διασταύρωση (cross-check) των συμπερασμάτων. Τα Τυχαία Δάση (Random Forest) προσφέρουν ερμηνευσιμότητα μέσω της σχετικής σημαντικότητας χαρακτηριστικών (feature importance), ενώ το CNN με ResNet-18 αξιοποιεί μεταφορά μάθησης (transfer learning) για να μοντελοποιήσει πολύπλοκες μορφολογίες ιδιομορφών από περιορισμένο αριθμό δειγμάτων, μειώνοντας τον κίνδυνο υπερπροσαρμογής (overfitting).

Πίνακας 3.3: *Αναλυτική λίστα των 16 χαρακτηριστικών μοτίβου (pattern features).*

Feature (όνομα)	**Κατηγορία**	**Σύντομη περιγραφή**
m_count	Κροσσών	Αριθμός μεγίστων κροσσών κατά 1η κύρια διεύθυνση
n_count	Κροσσών	Αριθμός μεγίστων κροσσών κατά 2η κύρια διεύθυνση
total_fringes	Κροσσών	Συνολικός αριθμός κροσσών στο ROI
avg_fringe_spacing	Κροσσών	Μέση απόσταση διαδοχικών κροσσών
centroid_x	Γεωμετρικά/τοπολογικά	Συντεταγμένη x κέντρου βάρους μοτίβου
centroid_y	Γεωμετρικά/τοπολογικά	Συντεταγμένη y κέντρου βάρους μοτίβου
valid_px	Γεωμετρικά/τοπολογικά	Πλήθος έγκυρων pixels στο ROI (σταθερότητα μάσκας)
area_extent	Γεωμετρικά/τοπολογικά	Λόγος κάλυψης ROI / bounding box (extent)
nodal_length	Γεωμετρικά/τοπολογικά	Συνολικό μήκος κομβικών γραμμών (nodal lines)
euler_number	Γεωμετρικά/τοπολογικά	Αριθμός Euler της δυαδικής δομής (συνδετικότητα)
nodal_complexity	Γεωμετρικά/τοπολογικά	Μετρική πολυπλοκότητας κομβικών γραμμών

hv_ratio	Γεωμετρικά/τοπολογικά	Λόγος οριζόντιας/κατακόρυφης συμμετρίας
diag_ratio	Γεωμετρικά/τοπολογικά	Λόγος διαγώνιας συμμετρίας (κύριες διαγώνιοι)
symmetry_score	Γεωμετρικά/τοπολογικά	Συνολικό score συμμετρίας (συμπύκνωση επιμέρους μετρικών)
energy_concentration	Φασματικά	Συγκέντρωση ενέργειας στο φάσμα (FFT/PSD)
dominant_orientation	Φασματικά	Κυρίαρχος προσανατολισμός/κατεύθυνση στο πεδίο συχνοτήτων

3.5.2 Χαρακτηριστικά Συχνότητας (6 χαρακτηριστικά)

Για το υβριδικό μοντέλο Τυχαίου Δάσους προστέθηκαν έξι χαρακτηριστικά μεταδεδομένων συχνότητας που ενσωματώνουν την εκ των προτέρων φυσική γνώση περί της σχέσης μεταξύ συχνότητας διέγερσης και τύπου ιδιομορφής. Αυτά περιλαμβάνουν: την ακριβή συχνότητα διέγερσης σε Hz (freq_hz), την κανονικοποιημένη συχνότητα στο διάστημα [0,1] (freq_normalized), τη λογαριθμική κλίμακα $\log_{10}$(freq_hz) (log_freq), τη διακριτοποίηση σε 20 ζώνες (freq_bin), έναν δυαδικό δείκτη για τις θεμελιώδεις συχνότητες (is_fundamental), και τον λόγο προς την προηγούμενη ιδιομορφή (harmonic_ratio). (βλ. Κεφάλαιο 2).

3.6 Ορισμός Κλάσεων Ιδιομορφών

Η ταξινόμηση των μοτίβων ESPI προϋποθέτει τον ορισμό ενός σαφούς συνόλου κλάσεων που να αντιστοιχούν σε επαναλαμβανόμενες μορφές ιδιοταλάντωσης (mode shapes) του ηχητικού καπακιού. Στην παρούσα εργασία, ο ορισμός των κλάσεων προέκυψε από συνδυασμό (α) φυσικής ερμηνείας των κομβικών γραμμών/περιοχών, (β) ομαδοποίησης (clustering) σε χαρακτηριστικά nodal/shape, και (γ) επαλήθευσης (Master Verified Data)

στο οριστικό σύνολο N=3.443 δειγμάτων που χρησιμοποιήθηκε για την εκπαίδευση και αξιολόγηση των ταξινομητών (Random Forest και CNN).

3.6.1 Πραγματική αντιστοίχιση κλάσεων (Master Verified Mapping)

Η αντιστοίχιση των κλάσεων βασίστηκε στην αλφαβητική/λογική σειρά των ετικετών (labels) όπως αυτές εμφανίζονται στα αρχεία .csv της εκπαίδευσης, ώστε να διασφαλίζεται συνέπεια μεταξύ εκπαίδευσης, confusion matrices και αναφορών. Ο Πίνακας 3.6 παρουσιάζει το οριστικό mapping Class ID → Label → φυσική ερμηνεία, μαζί με την κατανομή δειγμάτων (count/ποσοστό).

Πίνακας 3.6: *Πραγματική αντιστοίχιση κλάσεων (Master Verified Data, N=3.443).*

Class ID	**Ετικέτα (Label)**	**Φυσική ερμηνεία**	**Πλήθος**	**Ποσοστό**
0	(1,1)H	Θεμελιώδης οριζόντια (Horizontal)	199	5,8%
1	(1,1)T	Θεμελιώδης εγκάρσια (Transverse)	171	5,0%
2	(1,2)	Τρόπος (1,2) – radial stiffness	106	3,1%
3	(2,1)	Τρόπος (2,1) – longitudinal stiffness	58	1,7%
4	higher	Υψηλής τάξης / πολύπλοκοι τρόποι	1.115	32,4%
5	other	Θόρυβος / μη-συντονισμός / αστάθεια φάσης	1.794	52,1%
Σύνολο			3.443	100%

3.6.2 Ερμηνεία και κριτήρια ομαδοποίησης

Η διάκριση των κλάσεων έγινε με βάση τη μορφολογία των κομβικών γραμμών (nodal lines) και τον βαθμό σταθερότητας της φάσης στο ROI. Οι κλάσεις 0–3 αντιστοιχούν σε «καθαρούς» θεμελιώδεις/χαμηλής τάξης τρόπους που εμφανίζονται με υψηλή επαναληψιμότητα και έχουν άμεση σημασία για την ακουστική συμπεριφορά του οργάνου. Η κλάση 4 («higher») συγκεντρώνει πυκνούς/πολύπλοκους τρόπους υψηλότερης τάξης, όπου οι κομβικές δομές γίνονται πολυάριθμες και η λεπτομερής υπο-κατηγοριοποίηση δεν είναι αξιόπιστη με τα διαθέσιμα δείγματα. Τέλος, η κλάση 5 («other») λειτουργεί ως κατηγορία «ασφαλείας» για περιπτώσεις χαμηλού SNR, μη-συντονισμού ή αποτυχίας/αστάθειας στο phase extraction.

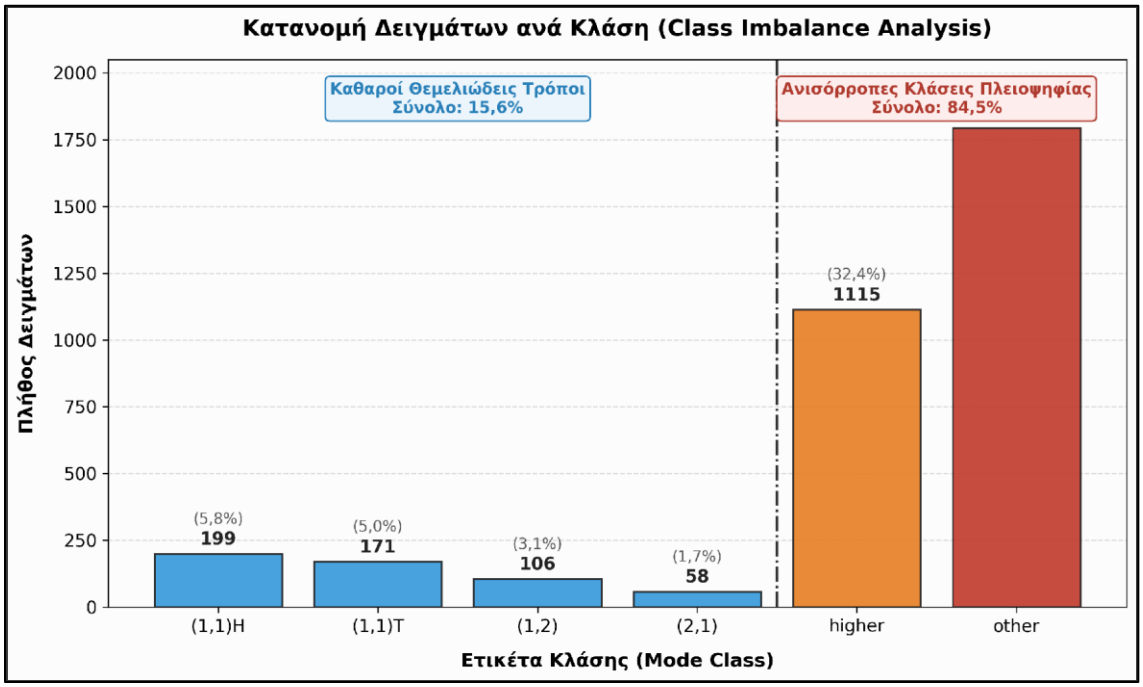
Συνοπτικά, οι κλάσεις περιγράφονται ως εξής:

- **Κλάση 0 — (1,1)H**: θεμελιώδης οριζόντια ιδιομορφή κάμψης του καπακιού (dominant horizontal nodal structure).
- **Κλάση 1 — (1,1)T**: θεμελιώδης εγκάρσια ιδιομορφή (dominant transverse nodal structure).
- **Κλάση 2 — (1,2):** ιδιομορφή με μία κυρίαρχη οριζόντια κομβική γραμμή και σαφή μεταβολή σε radial stiffness.
- **Κλάση 3 — (2,1):** πιο σύνθετη χαμηλής τάξης ιδιομορφή με έμφαση σε longitudinal stiffness (minority class).
- **Κλάση 4 — higher:** ομαδοποιημένοι υψηλής τάξης/πολύπλοκοι τρόποι (συνήθως σε υψηλότερες συχνότητες, ενδεικτικά > ~680 Hz).
- **Κλάση 5 — other**: μη-συντονιστικές ή μη-αξιόπιστες περιπτώσεις (θόρυβος, αστάθεια φάσης, artefacts).

3.6.3 Σχόλια για την ανισορροπία κλάσεων και επιπτώσεις στην εκπαίδευση

Η κατανομή του Πίνακα 3.6 είναι έντονα ανισόρροπη: οι κλάσεις 4 («higher») και 5 («other») αντιστοιχούν στο 84,5% του dataset, ενώ οι κλάσεις 0–3 (οι «καθαροί» τρόποι) αποτελούν συνολικά 15,6%. Η κλάση (2,1) είναι η σπανιότερη (58 δείγματα, 1,7%) και επιβάλλει προσεκτικό πρωτόκολλο επικύρωσης και χρήση μετρικών που δεν «κρύβουν» την απόδοση των μειονοτικών κλάσεων.

Για τον λόγο αυτό, σε όλα τα πειράματα αξιολόγησης προτιμήθηκε η Macro-F1 ως κύρια μετρική (εξισορροπεί τη συμβολή των κλάσεων ανεξαρτήτως πλήθους), ενώ χρησιμοποιήθηκαν διαστρωματωμένοι διαχωρισμοί (stratified splits) και/ή ισορροπημένες στάθμισεις (class weights) όπου απαιτείται.



Σχήμα 3.7: *Κατανομή των 3.443 δειγμάτων (ESPI) ανά κλάση ιδιομορφής. Αναδεικνύεται η έντονη στατιστική ανισορροπία μεταξύ των "καθαρών" θεμελιωδών τρόπων (0–3, 15,6%) και των πολυπληθών κλάσεων υψηλής τάξης ή αβεβαιότητας (higher/other, 84,5%).*

3.6.4 Περιορισμοί και πρακτικές αποφάσεις

Η ομαδοποίηση των υψηλής τάξης τρόπων σε μία ενιαία κλάση («higher») αποτελεί πρακτική επιλογή για να εξασφαλιστεί σταθερή ταξινόμηση, δεδομένου ότι σε υψηλές συχνότητες οι κομβικές δομές γίνονται ιδιαίτερα πυκνές και η ανάθεση λεπτομερών υποκλάσεων απαιτεί σημαντικά περισσότερα επαληθευμένα δείγματα και αυστηρότερη φυσική καθοδήγηση. Αντίστοιχα, η ύπαρξη της κλάσης «other» επιτρέπει στο σύστημα να απορρίπτει περιπτώσεις που δεν είναι κατάλληλες για ασφαλή mode identification (π.χ. ανεπαρκής ποιότητα φάσης στο ROI).

Σημειώνεται ότι το mapping των κλάσεων αποτελεί «κλειδωμένη» σύμβαση (contract) για όλο το υπόλοιπο pipeline: οποιαδήποτε αλλαγή στον ορισμό των κλάσεων (π.χ. μετάβαση σε 5–7 κλάσεις) πρέπει να συνοδεύεται από νέο re-labeling, επανεκπαίδευση και ανανέωση όλων των αντίστοιχων confusion matrices/αναφορών.

Βιβλιογραφική σημείωση: Η φυσική ερμηνεία των ιδιομορφών στηρίζεται σε βασικές αρχές ανάλυσης ιδιομορφών και τυπικές περιγραφές κομβικών γραμμών σε δονούμενες πλάκες (plate vibration). Ενδεικτικές πηγές αναφοράς για τη μεθοδολογία ανάλυσης ιδιομορφών/οπτικής συμβολομετρίας είναι τα κλασικά συγγράμματα οπτικής συμβολομετρίας και δομικής ακουστικής.

3.7 Μοντέλα Ταξινόμησης

Αξιολογήθηκαν τρεις διαφορετικές προσεγγίσεις για την ταξινόμηση των μοτίβων ιδιομορφών, οι οποίες αντιπροσωπεύουν διαφορετικά σημεία στο φάσμα μεταξύ παραδοσιακής μηχανικής μάθησης και βαθιάς μάθησης.

Το ResNet-18 επιλέχθηκε ως ισορροπία μεταξύ εκφραστικότητας και υπολογιστικού κόστους. Σε σχέση με βαθύτερα δίκτυα, μειώνει την πιθανότητα υπερπροσαρμογής σε μικρότερα σύνολα δεδομένων, ενώ τα residual blocks διευκολύνουν τη σταθερή εκπαίδευση. Η προεκπαίδευση σε μεγάλα σύνολα (π.χ. ImageNet) επιτρέπει τη μεταφορά γενικών φίλτρων ανίχνευσης ακμών/υφών, που είναι χρήσιμα και σε ESPI μοτίβα μετά από κατάλληλη προσαρμογή.

3.7.1 Random Forest Μόνο Μοτίβου (Pattern-only Random Forest)

Το πρώτο μοντέλο αποτελεί τη βασική πρότυπο αναφοράς και χρησιμοποιεί αποκλειστικά τα 16 χαρακτηριστικά μοτίβου χωρίς καμία πληροφορία συχνότητας. Η παραμετροποίηση περιλαμβάνει 200 δέντρα αποφάσεων (n_estimators = 200), απεριόριστο βάθος (max_depth = None), ισορροπημένα βάρη κλάσεων (class_weight = 'balanced') για τον χειρισμό της ανισορροπίας, και σταθερό σπόρο τυχαιότητας (random_state = 42) για αναπαραγωγιμότητα. (βλ. Παράρτημα Η).

3.7.2 Υβριδικό Random Forest (Hybrid Random Forest)

Ένας απλός τυχαίος διαχωρισμός (random split) μπορεί να υπερεκτιμήσει την απόδοση, καθώς γειτονικές συχνότητες του ίδιου δοκιμίου παρουσιάζουν ισχυρή οπτική

ομοιότητα. Αυτό δημιουργεί κίνδυνο διαρροής πληροφορίας (data leakage) μεταξύ συνόλων εκπαίδευσης και ελέγχου. Για τον λόγο αυτό, τα κύρια πρωτόκολλα αξιολόγησης βασίζονται σε δομημένους διαχωρισμούς (grouped splits), όπως LOBO και LODO.

Το δεύτερο μοντέλο αποτελεί την κύρια συνεισφορά της εργασίας και συνδυάζει 22 χαρακτηριστικά, συμπεριλαμβανομένων μορφολογικών περιγραφέων και συχνοτικών πρότερων πληροφοριών, δημιουργώντας ένα διάνυσμα 22 διαστάσεων θεμελιωμένο στη φυσική. Χρησιμοποιεί τις ίδιες υπερπαραμέτρους με το μοντέλο αναφοράς, αλλά επωφελείται σημαντικά από την ενσωμάτωση πληροφορίας θεμελιωμένης στη φυσική.

3.7.3 Συνελικτικό Νευρωνικό Δίκτυο (CNN - ResNet-18)

Το τρίτο μοντέλο ακολουθεί προσέγγιση βαθιάς μάθησης End-to-End, χρησιμοποιώντας τροποποιημένη αρχιτεκτονική ResNet-18. Η είσοδος αποτελείται από τις αποθορυβοποιημένες εικόνες ESPI σε ανάλυση 256×256 εικονοστοιχείων. Το δίκτυο αρχικοποιείται με βάρη προεκπαιδευμένα στο σύνολο ImageNet, ενώ το τελικό επίπεδο τροποποιείται για έξοδο 6 κλάσεων ιδιομορφών. Η εκπαίδευση πραγματοποιείται με μερικό πάγωμα των αρχικών επιπέδων (μικρορρύθμιση) και χρήση απώλειας διασταυρούμενης εντροπίας με στάθμιση κλάσεων ή εστιακών παραλλαγών όπου απαιτείται. (βλ. Κεφάλαιο 2).

Στο Leave-One-Band-Out (LOBO), το σύνολο ελέγχου αποτελείται από συχνοτικές ζώνες που δεν χρησιμοποιούνται στην εκπαίδευση. Με αυτόν τον τρόπο αξιολογείται η ανθεκτικότητα του μοντέλου σε μικρές μετατοπίσεις συχνότητας (frequency shifts) και διαφορές SNR, που είναι συχνές σε πραγματικές μετρήσεις.

Σημείωση: *Η πλήρης ανάλυση της εξέλιξης χαρακτηριστικών και της διαδικασίας επιλογής μοντέλων παρουσιάζεται στο Παράρτημα Δ.2, ενώ το ολοκληρωμένο πλαίσιο επικύρωσης (LOBO/LODO, έλεγχος McNemar, διαστήματα εμπιστοσύνης bootstrap) στο Παράρτημα Δ.4.*

Στο Leave-One-Board-Out / Leave-One-Specimen-Out (LODO), το μοντέλο αξιολογείται σε δοκίμιο που δεν έχει εμφανιστεί κατά την εκπαίδευση. Το πρωτόκολλο αυτό αποτελεί τον αυστηρότερο έλεγχο γενίκευσης (domain generalization), καθώς ελέγχει τη μεταφορά σε νέο υλικό/κατασκευή και διαφορετικές κατασκευαστικές ανομοιογένειες.

3.8 Μεθοδολογία Επικύρωσης

3.8.1 Διαστρωματωμένος Διαχωρισμός Εκπαίδευσης/Δοκιμής

Το τελικό σύνολο δεδομένων ταξινόμησης, που αποτελείται από 3.443 δείγματα μετά τη διαδικασία εξαγωγής φάσης, διαχωρίστηκε με διαστρωματωμένη δειγματοληψία (stratified sampling) ώστε να διατηρηθεί η αναλογία των κλάσεων σε κάθε υποσύνολο. Η κατανομή ακολουθεί αναλογία 70/15/15, με το σύνολο εκπαίδευσης να περιλαμβάνει 2.410 δείγματα, το σύνολο επικύρωσης 516 δείγματα, και το σύνολο δοκιμής 517 δείγματα.

3.8.2 Διαστήματα Εμπιστοσύνης μέσω Bootstrap

Για την εκτίμηση της στατιστικής αβεβαιότητας των μετρικών απόδοσης χρησιμοποιήθηκε επαναδειγματοληψία bootstrap με 1.000 επαναλήψεις. Σε κάθε επανάληψη πραγματοποιείται δειγματοληψία με αντικατάσταση από το σύνολο δοκιμής, υπολογίζονται οι μετρικές ακρίβειας, ακρίβειας θετικής πρόβλεψης, ανάκλησης και βαθμολογίας F1, και εξάγονται τα 95% διαστήματα εμπιστοσύνης από τα 2,5% και 97,5% ποσοστημόρια της κατανομής.

Η Macro-F1 επιλέγεται ως κύρια μετρική διότι είναι αμερόληπτη ως προς την ανισορροπία κλάσεων και αποτιμά ισότιμα την επίδοση σε σπάνιες και συχνές κλάσεις. Αυτό είναι κρίσιμο στο παρόν πρόβλημα, όπου η κλάση ‘other_unknown’ υπερισχύει αριθμητικά. Αντίθετα, η μετρική Accuracy μπορεί να εμφανίζει υψηλές τιμές ακόμη και όταν το μοντέλο αποτυγχάνει πλήρως στις σπάνιες ιδιομορφές.

3.8.3 Αφαίρεση Μίας Συχνοτικής Ζώνης (LOBO)

Για την αξιολόγηση της ικανότητας γενίκευσης σε συχνοτικές περιοχές που δεν συμπεριλήφθηκαν στην εκπαίδευση, εφαρμόστηκε η μεθοδολογία LOBO (Leave-One-Band-Out). Το σύνολο δεδομένων διαχωρίζεται σε 111 συχνοτικές ζώνες, και σε κάθε επανάληψη η εκπαίδευση πραγματοποιείται σε όλες τις ζώνες εκτός μίας, η οποία χρησιμοποιείται αποκλειστικά για δοκιμή. Η διαδικασία επαναλαμβάνεται για όλες τις ζώνες και υπολογίζεται ο μέσος όρος και η τυπική απόκλιση της απόδοσης. Σημ.: Στο πλαίσιο της LOBO, «συχνοτική ζώνη» (band) σημαίνει ομάδα γειτονικών συχνοτήτων του πλέγματος 40–1500 Hz, ώστε κάθε fold να περιλαμβάνει επαρκή αριθμό δειγμάτων. Αντίθετα, το

freq_bin είναι ανεξάρτητη αδρή διακριτοποίηση της συχνότητας σε 20 bins (μεταδεδομένο) που χρησιμοποιείται στο Hybrid RF.

3.8.4 Αφαίρεση Ενός Πειραματικού αντικειμένου (LODO)

Για την αξιολόγηση της γενίκευσης μεταξύ διαφορετικών δοκιμίων - και τον εντοπισμό πιθανής μετατόπισης πεδίου (domain shift) - εφαρμόστηκε η μεθοδολογία LODO (Leave-One-Domain-Out). Σε κάθε επανάληψη αφαιρείται ένα ολόκληρο δοκίμιο (π.χ. W01, W02 ή W03) από την εκπαίδευση και χρησιμοποιείται αποκλειστικά ως σύνολο δοκιμής. Το πρωτόκολλο αυτό προσομοιώνει ρεαλιστικά την απόδοση του μοντέλου σε ένα νέο δοκίμιο με διαφορετικές ιδιοσυχνότητες, γεωμετρία και υλικές ιδιότητες.

3.8.5 Ζευγαρωμένος Στατιστικός Έλεγχος

Για τη σύγκριση της απόδοσης διαφορετικών μοντέλων στο ίδιο σύνολο δοκιμής χρησιμοποιήθηκε ο έλεγχος McNemar. Ο έλεγχος αυτός εφαρμόζεται στα δυαδικά αποτελέσματα σωστής/λανθασμένης πρόβλεψης κάθε μοντέλου, επιτρέποντας τη στατιστική επιβεβαίωση ότι οι παρατηρούμενες διαφορές απόδοσης είναι γνήσιες και δεν οφείλονται σε τυχαία διακύμανση λόγω δειγματοληψίας.

3.9 Μετρικές Αξιολόγησης

Λόγω της ακραίας ανισορροπίας κλάσεων (λόγος 30,9:1 μεταξύ της μεγαλύτερης και μικρότερης κλάσης), επιλέχθηκαν μετρικές που δεν επηρεάζονται δυσανάλογα από την υπερεκπροσώπηση ορισμένων κλάσεων.

3.9.1 Κύρια Μετρική: Βαθμολογία Μακρο-F1

Η βαθμολογία Μακρο-F1 (Macro-F1) ορίζεται ως ο μη σταθμισμένος μέσος όρος των βαθμολογιών F1 ανά κλάση, δίνοντας ίση βαρύτητα σε όλες τις κλάσεις ανεξάρτητα από το μέγεθός τους. Η επιλογή αυτής της μετρικής εξασφαλίζει ότι η απόδοση στις σπάνιες κλάσεις συμβάλλει εξίσου στη συνολική αξιολόγηση. Ο πλήρης μαθηματικός ορισμός παρατίθεται στο Παράρτημα Η.

3.9.2 Δευτερεύουσες Μετρικές

Ως συμπληρωματικές μετρικές χρησιμοποιήθηκαν: το Accuracy, δηλαδή το ποσοστό σωστών προβλέψεων επί του συνόλου, η σταθμισμένη βαθμολογία F1 (Weighted-F1), που

υπολογίζει τον σταθμισμένο μέσο όρο με βάση το πλήθος δειγμάτων ανά κλάση, η ακρίβεια θετικής πρόβλεψης (Precision) και ανάκληση (Recall) ανά κλάση για λεπτομερή ανάλυση, και ο πίνακας σύγχυσης (confusion matrix) για την οπτικοποίηση των λανθασμένων ταξινομήσεων. (βλ. Κεφάλαιο 2).

3.10 Λεπτομέρειες Υλοποίησης

Η παρούσα ενότητα καταγράφει τις τεχνικές προδιαγραφές της υλοποίησης, εστιάζοντας στο οικοσύστημα λογισμικού και την υπολογιστική υποδομή που χρησιμοποιήθηκε. Η τεκμηρίωση αυτών των παραμέτρων κρίνεται απαραίτητη για τη διασφάλιση της διαφάνειας, της επαληθευσιμότητας και της αναπαραγωγιμότητας των πειραματικών διαδικασιών.

3.10.1 Περιβάλλον Λογισμικού

Η ανάπτυξη του κώδικα πραγματοποιήθηκε στη γλώσσα προγραμματισμού **Python (έκδοση 3.8.10)**. Ο πυρήνας της βαθιάς μάθησης στηρίχθηκε στη βιβλιοθήκη **PyTorch (v1.12.1)** με ενεργοποιημένη την επιτάχυνση υλικού CUDA 11.6, ενώ για την υλοποίηση των αλγορίθμων Τυχαίου Δάσους (Random Forest) και τον υπολογισμό των μετρικών αξιολόγησης χρησιμοποιήθηκε το **scikit-learn (v1.1.2)**. Η διαχείριση πινάκων και η επεξεργασία εικόνας υλοποιήθηκαν μέσω των βιβλιοθηκών **NumPy (v1.23.2)** και **OpenCV (v4.6.0)** αντίστοιχα.

Παράλληλα, αναπτύχθηκε μια σειρά εξειδικευμένων σεναρίων ελέγχου (custom scripts) για την αυτοματοποίηση της ροής εργασίας, καλύπτοντας λειτουργίες όπως η σύνθεση ψευδο-θορυβωδών δεδομένων 16-bit, η μαζική αποθορυβοποίηση (batch denoising) και ο φασματικός έλεγχος ευθυγράμμισης (FFT alignment).

Ο πηγαίος κώδικας και τα πειραματικά artefacts είναι διαθέσιμα στα ακόλουθα αποθετήρια GitHub:

- **ESPI-DnCNN-ECA**: https://github.com/GeorgeSpy/ESPI-DnCNN-ECA
- **ESPI-pseydonoisy-generator**: https://github.com/GeorgeSpy/ESPI-pseydonoisy-generator
- **ESPI CLASSIFICATION MODELS** : https://github.com/GeorgeSpy/espi-classification-models_2

3.10.2 Υπολογιστικοί Πόροι

Η πειραματική διαδικασία υλοποιήθηκε σε δύο διακριτές φάσεις, προκειμένου να ανταποκριθεί στην αυξανόμενη πολυπλοκότητα των υπολογιστικών απαιτήσεων της έρευνας.

Φάση Α: Αρχική Ανάπτυξη και Παράλληλη Επεξεργασία Το μεγαλύτερο μέρος της αρχικής ανάπτυξης του κώδικα και της προεπεξεργασίας των δεδομένων πραγματοποιήθηκε μέσω παράλληλης επεξεργασίας σε δύο ανεξάρτητους σταθμούς εργασίας, εξοπλισμένους με επεξεργαστές AMD Ryzen 7 5700G και Ryzen 5 5600G αντίστοιχα. Λόγω της απουσίας διακριτών καρτών γραφικών και της χρήσης ενσωματωμένων μονάδων (APUs) σε αυτό το στάδιο, οι αλγόριθμοι βελτιστοποιήθηκαν αρχικά για αποκλειστική εκτέλεση σε κεντρικό επεξεργαστή (CPU-only optimization). Η προσέγγιση αυτή, αν και αναγκαία στα πρώιμα στάδια, αποδείχθηκε υπολογιστικά χρονοβόρα, παρουσιάζοντας σημαντικούς περιορισμούς ως προς τη διαχείριση της μνήμης και την ταχύτητα εκπαίδευσης των μοντέλων.

Φάση Β: Επιτάχυνση Υλικού και Τελικά Πειράματα Για την υπέρβαση των προαναφερθέντων περιορισμών και την αποδοτική εκτέλεση των απαιτητικών διαδικασιών της βαθιάς μάθησης (deep learning), συγκροτήθηκε ένας αναβαθμισμένος σταθμός εργασίας, ειδικά προσαρμοσμένος για εργασίες Μηχανικής Μάθησης. Το τελικό σύστημα διέθετε τις εξής προδιαγραφές:

- **Μονάδα Επεξεργασίας Γραφικών (GPU):** NVIDIA GeForce RTX 3060 με 12 GB VRAM, η οποία επέτρεψε τη δραστική επιτάχυνση της εκπαίδευσης και τη χρήση μεγαλύτερων μεγεθών δέσμης (batch sizes).
- **Κεντρικός Επεξεργαστής (CPU):** AMD Ryzen 7 5700X.
- **Μνήμη Συστήματος (RAM):** 32 GB DDR4, εξασφαλίζοντας την ομαλή φόρτωση και διαχείριση των δεδομένων.
- **Αποθηκευτικό Μέσο (Storage):** Δίσκος τεχνολογίας NVMe SSD για τη μεγιστοποίηση της ταχύτητας ανάγνωσης και εγγραφής δεδομένων (I/O throughput).

Σε αυτό το προηγμένο υπολογιστικό περιβάλλον υλοποιήθηκαν οι κρίσιμες συγκριτικές μελέτες (όπως η αντιπαραβολή αρχιτεκτονικών με και χωρίς τον μηχανισμό ECA), η διαδικασία βαθμονόμησης της γεννήτριας ψευδο-θορύβου (Pseudonoise Generation Calibration v2.0), καθώς και το σύνολο των τελικών πειραμάτων επικύρωσης των μοντέλων.

ΚΕΦΑΛΑΙΟ 4: ΑΠΟΤΕΛΕΣΜΑΤΑ ΚΑΙ ΣΥΖΗΤΗΣΗ

4.1 Προετοιμασία δεδομένων

4.1.1 Σύνθεση συνόλου δεδομένων εκπαίδευσης για αποθορυβοποίηση

Το σύνολο δεδομένων εκπαίδευσης (training set) για τη μονάδα αποθορυβοποίησης DnCNN-ECA συγκροτείται από **11.434 ζεύγη** εικόνων «θορυβώδους–καθαρής» (noisy–clean pairs), με σχεδιαστική στόχευση την αναλογία 80/20 μεταξύ πραγματικών και συνθετικών δειγμάτων..

Πίνακας 4.1.1: *Κατανομή δεδομένων εκπαίδευσης (DnCNN)*

Κατηγορία	Πραγματικές Εικόνες (Real)	Συνθετικές Εικόνες (Pseudo/Synthetic)	Σύνολο	Πραγματική Αναλογία
Ζεύγη Εκπαίδευσης	8.712	2.722	**11.434**	**76,2% / 23,8%**

Ανάλυση Αναλογίας: Ενώ η στοχευμένη αναλογία ήταν 80/20 (πραγματικά/συνθετικά), η τελική κατανομή διαμορφώθηκε σε 76,2/23,8. Η απόκλιση, της τάξης των 3,8 ποσοστιαίων μονάδων, κρίνεται απολύτως αποδεκτή για τους σκοπούς της εκπαίδευσης και δεν επηρεάζει την ευστάθεια του μοντέλου.

Αιτιολόγηση Υβριδικής Προσέγγισης: Η υιοθέτηση μικτής στρατηγικής (πραγματικά + συνθετικά δεδομένα) προέκυψε μετά από σειρά προκαταρκτικών πειραμάτων. Διαπιστώθηκε ότι:

1. Η αποκλειστική χρήση **συνθετικών δεδομένων** οδηγούσε σε υπερπροσαρμογή (overfitting) πάνω σε εξιδανικευμένα μοτίβα speckle, μειώνοντας την ικανότητα γενίκευσης σε πραγματικές συνθήκες.

2. Η αποκλειστική χρήση **πραγματικών δεδομένων** περιόριζε την ποικιλομορφία των μοτίβων θορύβου λόγω της φυσικής σπανιότητας ορισμένων φαινομένων. Συνεπώς, η αναλογία ~80/20 επιτυγχάνει τον βέλτιστο λειτουργικό συμβιβασμό (trade-off) μεταξύ του ρεαλισμού των μετρήσεων και της ποικιλίας που προσφέρει η επαύξηση δεδομένων (data augmentation).

Σημείωση για το Βάθος Χρώματος (Bit Depth): Τα πρωτογενή πλαίσια ESPI (raw frames) καταγράφονται σε ανάλυση 16-bit. Για λόγους οπτικής απεικόνισης στα σχήματα της παρούσας εργασίας, εφαρμόζεται κανονικοποίηση/ανακλιμάκωση (rescaling). Ωστόσο, διευκρινίζεται ότι στην υπολογιστική ροή εργασίας (computational workflow), τα δεδομένα επεξεργάζονται αποκλειστικά σε αναπαράσταση κινητής υποδιαστολής (floating-point) για τη διατήρηση της ακρίβειας.

4.1.2 Μαζική Επεξεργασία και Επέκταση Συνόλου Δεδομένων

Μετά την ολοκλήρωση της εκπαίδευσης, το μοντέλο DnCNN-ECA εφαρμόστηκε στο σύνολο των διαθέσιμων εικόνων ESPI (inference mode), επεξεργαζόμενο συνολικά **21.882 εικόνες** με απόλυτη επιτυχία (100%).

Πίνακας 4.1.2: *Στατιστικά επανεπεξεργασίας ανά δοκίμιο (Specimen)*

Δοκίμιο (Specimen)	Ακατέργαστες Εικόνες (Raw)	Αποθορυβοποιημένες (Denoised)	Ποσοστό Επιτυχίας
W01	7.846	7.846	100%
W02	8.058	8.058	100%
W03	5.978	5.978	100%
ΣΥΝΟΛΟ	**21.882**	**21.882**	**100%**

4.1.3 Εξαγωγή φάσης και σύνολο δεδομένων ταξινόμησης

Η διαδικασία ανάκτησης φάσης (phase retrieval) εφαρμόστηκε σε 596 φακέλους μετρήσεων (directories), επιτυγχάνοντας έγκυρη εξαγωγή σε 552 περιπτώσεις (ποσοστό 92,6%). Σημειώνεται ότι το σύνολο των 214 στόχων υψηλής προτεραιότητας (valid targets) επεξεργάστηκε επιτυχώς (100%).

Για κάθε επιτυχώς επεξεργασμένη μέτρηση παράχθηκαν τρία βασικά ενδιάμεσα προϊόντα: (i) τυλιγμένη φάση (wrapped phase), (ii) αποτυλιγμένη φάση (unwrapped phase), η οποία χρησιμοποιείται ως κύρια αναπαράσταση για την εξαγωγή χαρακτηριστικών και την επακόλουθη ταξινόμηση, και (iii) χάρτης ποιότητας (quality map), ο οποίος ποσοτικοποιεί

την αξιοπιστία της φάσης ανά εικονοστοιχείο και αξιοποιείται τόσο στη διαδικασία ξετυλίγματος όσο και στον έλεγχο ποιότητας (QC). Για λόγους αναπαραγωγιμότητας και δυνατότητας μεταγενέστερης επιθεώρησης, τα παραπάνω αποθηκεύονται παράλληλα σε μορφή .npy (αριθμητική ακρίβεια) και .png (οπτικός έλεγχος).

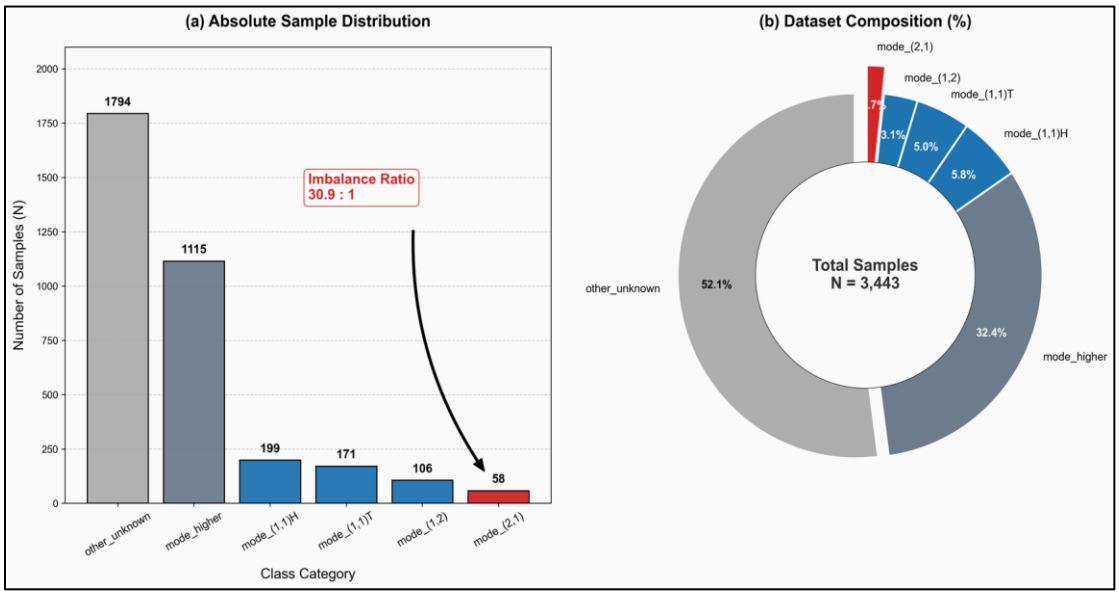
Πριν από την εφαρμογή της FFT-based ανάκτησης φάσης, εφαρμόστηκε σταθερή μάσκα Περιοχής Ενδιαφέροντος (ROI), η οποία αποκλείει το επάνω-αριστερό οπτικό overlay (ενδείξεις συχνότητας/έντασης) των raw λήψεων. Τα στοιχεία αυτά, λόγω υψηλής αντίθεσης, εισάγουν τεχνητά φασματικά συστατικά στον μετασχηματισμό Fourier, με αποτέλεσμα να επηρεάζουν δυσμενώς την επιλογή carrier/band-pass και να υποβαθμίζουν την ποιότητα της ανάκτησης φάσης. Η επιλογή της μάσκας επιβεβαιώθηκε εμπειρικά από τον έλεγχο των ενδιάμεσων φασματικών σταδίων και εφαρμόστηκε με συνέπεια σε όλα τα δοκίμια.

Τελικό Σύνολο Δεδομένων Ταξινόμησης (Classification Dataset): Το τελικό dataset αποτελείται από **3.443 δείγματα**, ταξινομημένα σε 6 κλάσεις ιδιομορφών (modal classes). Κύριο χαρακτηριστικό του συνόλου είναι η **έντονη ανισορροπία κλάσεων (class imbalance)**, με λόγο 30,9:1 μεταξύ της πλειονοτικής και της μειονοτικής κλάσης. Ο διαχωρισμός των δεδομένων ακολούθησε την αναλογία 70/15/15 (Εκπαίδευση / Επαλήθευση / Έλεγχος), αντιστοιχώντας σε 2.410, 516 και 517 δείγματα αντίστοιχα.

Σημειώνεται ότι, παρότι το αρχικό υλικό περιλαμβάνει δεκάδες χιλιάδες καρέ (single-shot και averaged), το τελικό σύνολο ταξινόμησης περιορίστηκε σε N=3.443, καθώς συμπεριλήφθηκαν αποκλειστικά δείγματα που: (α) πέρασαν επιτυχώς τη διαδικασία ανάκτησης φάσης χωρίς artefacts, (β) διαθέτουν επαληθευμένη ετικέτα ιδιομορφής στο πλαίσιο του “Master Verified Data”, (γ) δεν αποτελούν διπλότυπα/near-duplicates μετά τον καθαρισμό και (δ) είναι συνεπή ως προς τις παραμέτρους προεπεξεργασίας (ROI, FFT, QC). Τα συνθετικά/pseudo-noisy σύνολα χρησιμοποιήθηκαν αποκλειστικά για εκπαίδευση και βαθμονόμηση του αποθορυβοποιητή και δεν συμπεριλήφθηκαν στην ταξινόμηση ιδιομορφών.

Πίνακας 4.1.3: *Κατανομή κλάσεων στο σύνολο δεδομένων ταξινόμησης*

Κλάση (Class)	**Πλήθος**	**Ποσοστό**	**Εύρος Συχνοτήτων**	**Περιγραφή**
other/un-known	1.794	**52,1%**	N/A	Μη-τροπικά μοτίβα, θόρυβος, α-σάφειες (Πλειονοτική)
mode_higher	1.115	32,4%	680–1500 Hz	Ιδιομορφές ανώτερης τάξης
mode_(1,1)H	199	5,8%	155–175 Hz	Ιδιομορφφή Helmholtz (1,1)
mode_(1,1)T	171	5,0%	320–345 Hz	Θεμελιώδης Καπακιού (1,1)
mode_(1,2)	106	3,1%	500–525 Hz	Πρώτος Διαμήκης (1,2)
mode_(2,1)	58	**1,7%**	540–570 Hz	Πρώτος Εγκάρσιος (2,1) (Μειονοτική)
ΣΥΝΟΛΟ	**3.443**	**100%**		



Σχήμα 4.1.1: *Αναλυτική κατανομή του συνόλου δεδομένων ταξινόμησης. (a) Ραβδό-γραμμα πλήθους δειγμάτων: Απεικονίζεται η απόλυτη συχνότητα εμφάνισης κάθε κλάσης.*

Το βέλος υποδεικνύει το χάσμα μεγέθους μεταξύ της πλειονοτικής κλάσης other_unknown και της μειονοτικής mode_(2,1) , διαμορφώνοντας λόγο ανισορροπίας 30,9:1. (b) Ποσοστιαία σύσταση (Donut chart): Επιβεβαιώνεται ότι οι καθαρές ιδιομορφές ενδιαφέροντος (μπλε και κόκκινοι τομείς) αποτελούν αθροιστικά μειοψηφία (~15%), ενώ το 52,1% των δεδομένων αφορά ασαφή ή μη-τροπικά μοτίβα. Η χρωματική αντιστοίχιση είναι κοινή και στα δύο διαγράμματα.

Η κατανομή των κλάσεων αναδεικνύει έντονη ανισορροπία, με την κλάση other_unknown να συγκεντρώνει το 52,1% των δειγμάτων και την κλάση mode_(2,1) μόλις το 1,7%. Η αναλογία 30,9 : 1 (πλειοψηφούσα : μειοψηφούσα) αποτελεί ουσιαστική πρόκληση για την ταξινόμηση, καθώς ευνοεί την εκμάθηση της πλειοψηφούσας κλάσης εις βάρος των σπάνιων ιδιομορφικών προτύπων.

4.2 Συνθετική Παραγωγή Θορύβου: Η Γεννήτρια Ψευδο-θορυβωδών Δεδομένων (pseudo-noisy generator)

4.2.1 Σκοπός και Αρχές Σχεδίασης

Η εκπαίδευση βαθιών νευρωνικών δικτύων αποθορυβοποίησης προϋποθέτει μεγάλο όγκο από ζεύγη δεδομένων τύπου (noisy, clean). Στην περίπτωση της συμβολομετρίας ESPI, η απόκτηση απολύτως «καθαρών» (noise-free) εικόνων είναι πρακτικά ανέφικτη, καθώς ο θόρυβος κηλίδων αποτελεί εγγενές χαρακτηριστικό της μεθόδου και όχι απλή προσθετική διαταραχή. Για τον λόγο αυτό αναπτύχθηκε γεννήτρια ψευδο-θορυβωδών δεδομένων (pseudo-noisy generator), με σκοπό τη δημιουργία ρεαλιστικών θορυβωδών παρατηρήσεων από καθαρές εικόνες αναφοράς υψηλής ποιότητας.

Ως «καθαρές» εικόνες αναφοράς *x*χρησιμοποιούνται οι **time-averaged** (averaged) παρατηρήσεις, οι οποίες προκύπτουν από χρονικό μέσο όρο πολλαπλών λήψεων και συνεπώς εμφανίζουν δραστικά μειωμένη διασπορά speckle. Η γεννήτρια επιτρέπει έτσι την παραγωγή συνθετικών θορυβωδών δειγμάτων *y*με **φυσική στατιστική συμβατή με ESPI**, αποφεύγοντας την εκπαίδευση πάνω σε απλοϊκά μοντέλα προσθετικού Gaussian θορύβου που δεν αναπαριστούν τη δομή των συμβολογραμμάτων.

Ο σχεδιασμός της γεννήτριας βασίζεται σε φυσικό μοντέλο (physics-informed) και υλοποιεί καταρρακτώδη αλυσίδα θορύβου (Speckle → Poisson → Gaussian), η οποία

αντιστοιχεί στη φυσική ροή παραγωγής της εικόνας: συμβολή/σκέδαση σύμφωνου φωτός → κβαντοποίηση φωτονίων → ηλεκτρονικός θόρυβος ανάγνωσης αισθητήρα.

Στο επίπεδο υλοποίησης ενσωματώνονται τρεις κρίσιμες αρχές:

- **ROI-aware εφαρμογή:** ο θόρυβος εφαρμόζεται αποκλειστικά εντός της **Περιοχής Ενδιαφέροντος (ROI)** του αντηχείου, ώστε να αποφεύγονται τεχνητές αλλοιώσεις στο background και αστάθειες στα όρια του αντικειμένου.
- **Βαθμονόμηση ανά ζώνη συχνοτήτων (per-band calibration):** υποστηρίζεται χρήση διαφορετικών παραμέτρων θορύβου ανά συχνοτική ζώνη, ώστε να αναπαρίσταται η μεταβλητότητα του ESPI noise με τη συχνότητα διέγερσης.
- **Αναπαραγωγιμότητα:** χρήση σταθερών seeds και αποθήκευση παραμέτρων/ρυθμίσεων σε JSON, ώστε το σύνολο παραγωγής και τα πειράματα να είναι πλήρως αναπαραγώγιμα.

4.2.2 Θεωρητικό μοντέλο παρατήρησης: αλυσίδα θορύβου ESPI

Η γεννήτρια προσομοιώνει τη θορυβώδη παρατήρηση yαπό μια καθαρή εικόνα αναφοράς x ως εξής:

$$\boldsymbol{y} \;=\; \mathbf{cli\,p}\left(\frac{\mathbf{1}}{\boldsymbol{\alpha}}\,\mathbf{Poisso\,n}\big(\boldsymbol{\alpha}\,(\boldsymbol{x}\odot\boldsymbol{s})\big)\;+\;\boldsymbol{n_r},\,\mathbf{0},\,\mathbf{1}\right) \tag{4.1}$$

όπου:

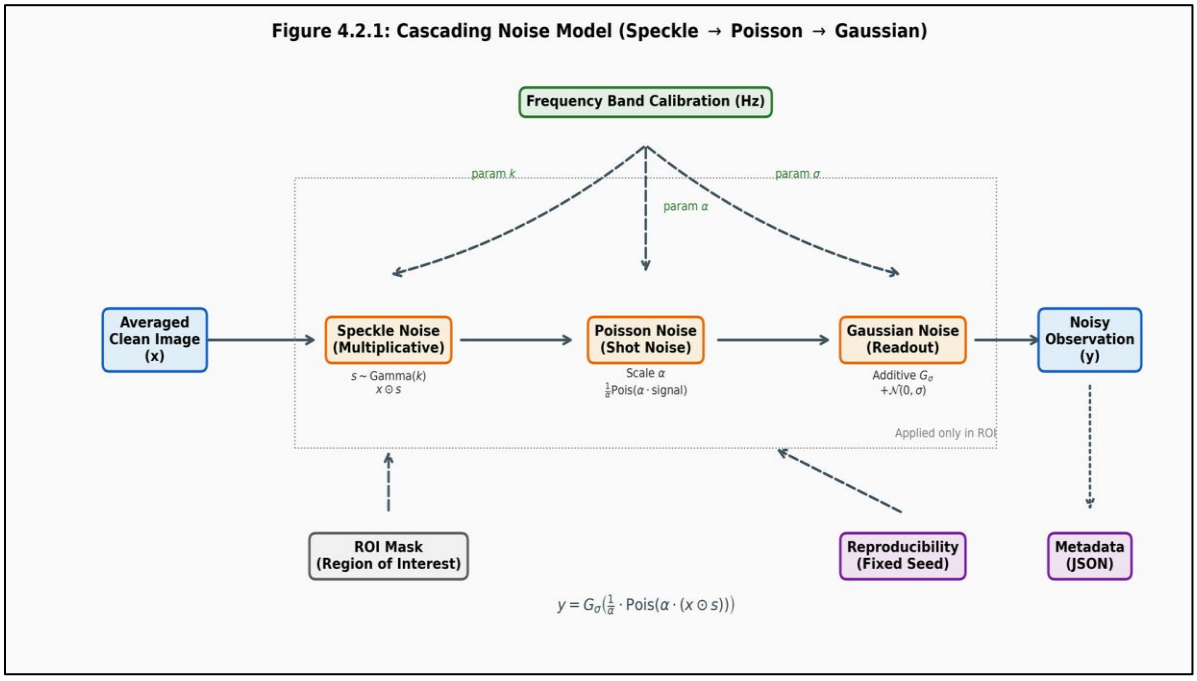
- x: καθαρή εικόνα αναφοράς (averaged), κανονικοποιημένη στο $[0, 1]$
- y: παραγόμενη ψευδο-θορυβώδης εικόνα (pseudo-noisy)
- $s \sim \Gamma(k, \theta = 1/k)$: **πολλαπλασιαστικός speckle θόρυβος**, με $E[s] = 1$και $\mathrm{Var}[s] = 1/k$. Η παράμετρος kελέγχει την ένταση του speckle (μεγαλύτερο k→ ασθενέστερο speckle).
- α: παράγοντας κλιμάκωσης/«gain» του **shot noise** (Poisson), ο οποίος εισάγει **signal-dependent** διασπορά (η διακύμανση αυξάνει με την ένταση).
- $n_r \sim \mathcal{N}(0, \sigma^2)$: **Gaussian readout noise** που προσομοιώνει ηλεκτρονικές διαταραχές της κάμερας.

- $\odot$: στοιχειομετρικός (pixel-wise) πολλαπλασιασμός
- cli p$(\cdot)$: περιορισμός σε φυσικά αποδεκτά όρια έντασης

Η παραπάνω αλληλουχία είναι κρίσιμη για ESPI, διότι:

- το **speckle** είναι κατ' εξοχήν **multiplicative** (όχι προσθετικό),
- ο **Poisson** όρος εισάγει φυσική, εξαρτώμενη από το σήμα, μεταβλητότητα (shot noise),
- ο **Gaussian** όρος καλύπτει την ηλεκτρονική ανάγνωση/ενίσχυση (readout).

Οι παράμετροι (k, α, σ)μπορούν να οριστούν είτε καθολικά (baseline) είτε ανά ζώνη συχνοτήτων μέσω βαθμονόμησης σε πραγματικά single-shot/averaged ζεύγη (§4.2.5), μειώνοντας το domain gap μεταξύ συνθετικού και πραγματικού θορύβου



Σχήμα 4.2.1: *Καταρρακτώδες μοντέλο θορύβου (Speckle→Poisson→Gaussian) με εφαρμογή εντός ROI και δυνατότητα per-band βαθμονόμησης. Η ροή ξεκινά από averaged αναφορά και καταλήγει σε pseudo-noisy παρατήρηση , με συνοδευτικά μεταδεδομένα αναπαραγωγιμότητας.*

4.2.3 Χειρισμός στο λογαριθμικό πεδίο για θόρυβο κηλίδων (speckle noise)

Η εφαρμογή του λογαριθμικού μετασχηματισμού αποτελεί κρίσιμη τεχνική για τη διαχείριση του θορύβου κηλίδων, καθώς μετατρέπει την πολλαπλασιαστική του φύση σε σχεδόν προσθετική. Αυτή η μετατροπή απλοποιεί σημαντικά τη διαδικασία εκμάθησης για το δίκτυο DnCNN, σύμφωνα με τη σχέση:

$$\mathbf{log(y) \approx log(x) + log(s) + (όροι\ Poisson/Gaussian)} \quad (4.2)$$

Στην πρακτική εφαρμογή της μεθόδου ακολουθήθηκαν τα εξής βήματα:

Εκπαίδευση (Training): Η διαδικασία εκπαίδευσης πραγματοποιήθηκε στο λογαριθμικό πεδίο (log-domain), χρησιμοποιώντας συνδυασμό της συνάρτησης απώλειας **Log-Cosh** και της νόρμας **L1**. Η επιλογή αυτή ενίσχυσε τη σταθερότητα του μοντέλου, ιδιαίτερα σε περιοχές πολύ χαμηλής έντασης σήματος, παρόλο που παρατηρήθηκε μικρή αύξηση στον χρόνο σύγκλισης.

Εξαγωγή Συμπερασμάτων (Inference): Κατά το στάδιο της εξαγωγής συμπερασμάτων, απαιτείται η επαναφορά της εκτιμώμενης εικόνας από το λογαριθμικό πεδίο (στο οποίο εκπαιδεύτηκε το δίκτυο για τη διαχείριση του πολλαπλασιαστικού θορύβου) πίσω στο φυσικό, γραμμικό πεδίο φωτεινότητας. Για την επίτευξη αυτού, εφαρμόζεται ο αντίστροφος μετασχηματισμός μέσω της εκθετικής συνάρτησης:

$$\widehat{\boldsymbol{x_{linear}}} = \mathbf{exp}\left(\widehat{\boldsymbol{x_{log}}}\right) \quad (4.3)$$

Δίνεται ιδιαίτερη έμφαση στην επιλογή της τυπικής συνάρτησης exp έναντι της παραλλαγής expm1 (η οποία υπολογίζει το $e^x - 1$). Παρόλο που η expm1 θεωρητικά προσφέρει μεγαλύτερη ακρίβεια για τιμές κοντά στο μηδέν, στην παρούσα εφαρμογή διαπιστώθηκε πειραματικά ότι εισάγει **αριθμητική αστάθεια**, οδηγώντας συχνά σε υπολογιστικά σφάλματα (underflow errors) και στην εμφάνιση αρνητικών τιμών εικονοστοιχείων (pixels) στις σκοτεινές περιοχές της εικόνας. Συνεπώς, η χρήση της απλής exp κρίθηκε ως η βέλτιστη στρατηγική για τη διασφάλιση της ακεραιότητας και της θετικότητας του ανακατασκευασμένου σήματος.

4.2.4 Αλγόριθμος Παραγωγής Ψευδο-θορυβωδών Δεδομένων

Η διαδικασία παραγωγής των συνθετικών δεδομένων υλοποιεί το φυσικό μοντέλο Speckle → Poisson → Gaussian που παρουσιάστηκε στο Κεφάλαιο 2 (πλήρεις ορισμοί/εξισώσεις στο Παράρτημα Η). Ο παρακάτω αλγόριθμος περιγράφει τη μετατροπή μίας καθαρής time-averaged ESPI εικόνας αναφοράς σε ρεαλιστικό θορυβώδες δείγμα.

Αλγόριθμος 1: Γεννήτρια Pseudo-Noisy βασισμένη σε φυσικό μοντέλο

Algorithm: Pseudo-Noisy Image Generation (Physics-Based

Input:

I_clean : Clean input image (normalized in [0, 1])

L : Number of looks parameter (typically L=1)

alpha : Gain factor (max photons for Shot Noise)

sigma_r : Readout noise standard deviation (Gaussian)

Procedure:

1. Speckle Noise (Multiplicative Gamma):

1.1 Sample n_s ~ Gamma(L, 1/L) (such that E[n_s] = 1)

1.2 I_speckle = I_clean * n_s

2. Shot Noise (Poisson):

*2.1 Scale to photons: N_photons = I_speckle * alpha*

2.2 Sample N_shot ~ Poisson(N_photons)

2.3 Rescale back: I_shot = N_shot / alpha

3. Readout Noise (Additive Gaussian):

3.1 Sample n_read ~ Normal(0, sigma_r^2)

3.2 Composite: I_noisy_raw = I_shot + n_read

4. Sensor Limits (Saturation & Clipping):

4.1 I_noisy = clip(I_noisy_raw, 0, 1)

4.2 (Optional) Quantize to 8-bit/16-bit integer

Output:

I_noisy : Final pseudo-noisy image

***Οι παράμετροι εκτιμώνται ανά ζώνη** (βλ. §4.2.2 / Παράρτημα Η)*

***Σημαντική παρατήρηση**: Εφαρμόζεται μοναδικό στάδιο speckle. Η διπλή εφαρμογή (Gamma∘Gamma) αυξάνει υπερβολικά τη διασπορά και παραμορφώνει την κατανομή υπολοίπων.*

4.2.5 Βαθμονόμηση v2.0: Από Μεμονωμένες Λήψεις σε Ζεύγη Μέσου Όρου

Για τον περιορισμό του χάσματος πεδίου (domain gap) μεταξύ συνθετικού και πραγματικού θορύβου, οι παράμετροι της κατανομής θορύβου (k, α, σ) δεν επιλέγονται αυθαίρετα, αλλά εκτιμώνται απευθείας από πραγματικά ζεύγη εικόνων της ίδιας διέγερσης. Η διαδικασία βαθμονόμησης ακολουθεί τρία διακριτά στάδια:

(α) Ταίριασμα και Χωρική Ευθυγράμμιση

- **Αντιστοίχιση Αρχείων:** Γίνεται βάσει της ρίζας του ονόματος αρχείου (filename stem, π.χ. 0140Hz_90.0dB) για τη σύζευξη της μεμονωμένης λήψης (single-shot) με τον αντίστοιχο χρονικό μέσο όρο (time-averaged).
- **Ευθυγράμμιση Ακρίβειας Pixel:** Εφαρμόζεται ευθυγράμμιση σε επίπεδο **ακέραιων εικονοστοιχείων (integer pixel alignment)**. Η ακρίβεια αυτή κρίνεται επαρκής για την αξιόπιστη υπολογιστική εκτίμηση των δεικτών PSNR/SSIM,

καθώς η υπο-εικονοστοιχειακή (sub-pixel) μετατόπιση μεταξύ διαδοχικών λήψεων ESPI είναι αμελητέα στην παρούσα πειραματική διάταξη.

(β) Στατιστική Ανάλυση ανά Μπλοκ (Block-wise Statistics)

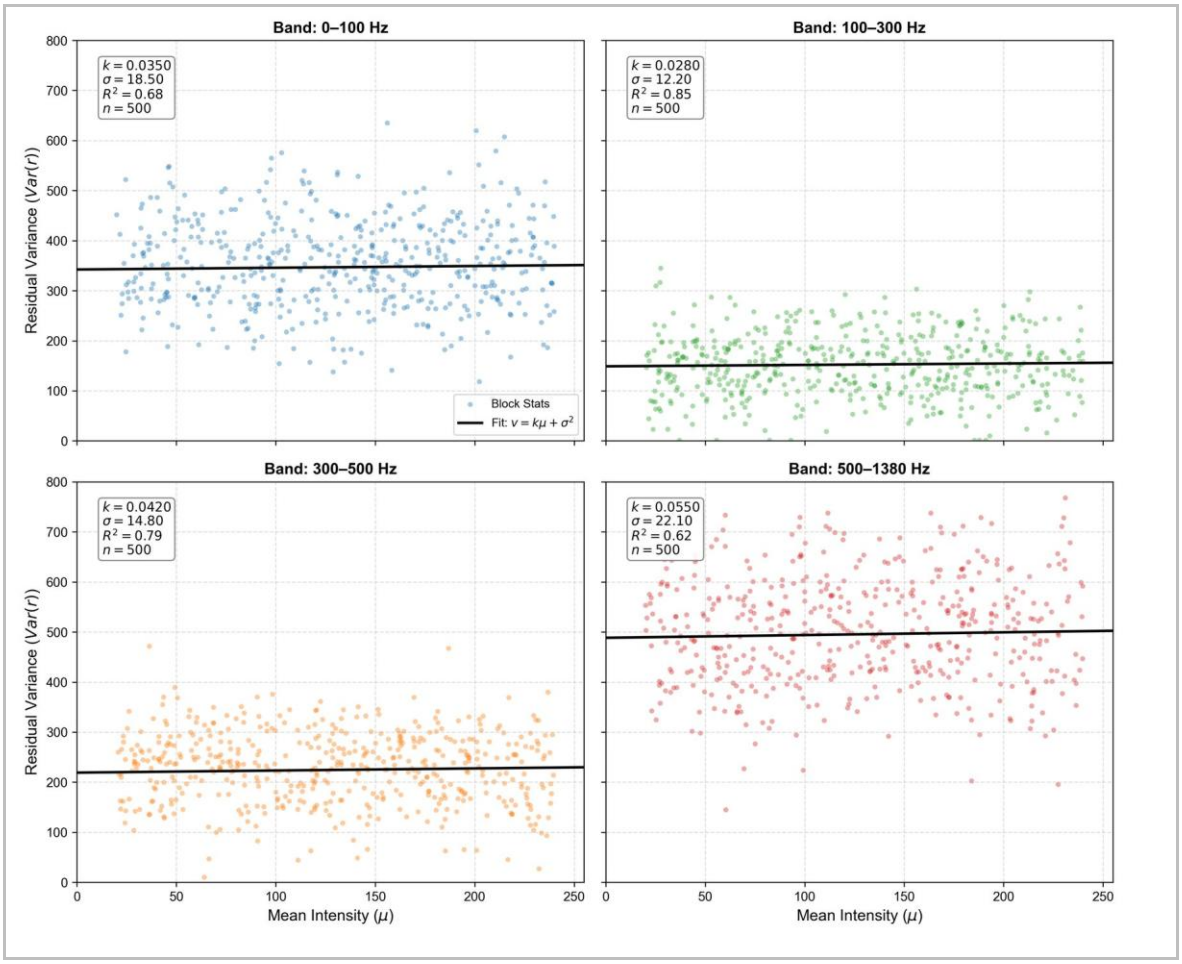
- **Εκτίμηση σε Τοπικά Παράθυρα:** Η εκτίμηση των παραμέτρων πραγματοποιείται σε τετραγωνικά μπλοκ εντός της Περιοχής Ενδιαφέροντος (ROI), ώστε να ληφθεί υπόψη η τοπική διακύμανση της φωτεινότητας.

- **Στιβαρή Περικοπή (Robust Trimming):** Εφαρμόζεται φιλτράρισμα ακραίων τιμών με διατήρηση του εύρους 5%–95% (percentiles), εξαλείφοντας outliers που οφείλονται σε "καμένα" pixel ή σφάλματα αισθητήρα.

- Φυσικοί Περιορισμοί: Τίθενται αυστηροί περιορισμοί ($\alpha \geq 0$, $\sigma \geq 0$, $k > 0$) ώστε οι εκτιμώμενες παράμετροι να έχουν φυσική σημασία και να είναι συμβατές με το μοντέλο Poisson-Gaussian.

(γ) Φασματική Εξειδίκευση (Per-band Parameters)

Αναγνωρίζοντας ότι η συμπεριφορά του θορύβου κηλίδων μεταβάλλεται ανάλογα με τη συχνότητα διέγερσης, ορίστηκαν τέσσερις διακριτές συχνοτικές ζώνες: [0–100 Hz], [100–300 Hz], [300–500 Hz] και [500–1380 Hz]. Για κάθε ζώνη παράγονται εξειδικευμένες παράμετροι θορύβου, οι οποίες αποθηκεύονται σε δομημένα αρχεία ρυθμίσεων (params.json), επιτρέποντας στο συνθετικό μοντέλο να προσαρμόζεται στις ιδιαιτερότητες κάθε φασματικής περιοχής.



Σχήμα 4.2.2: *Εκτίμηση παραμέτρων Poisson–Gaussian ανά συχνοτική ζώνη. Για κάθε ζώνη υπολογίζονται ζεύγη (μ, ν), όπου μ είναι ο μέσος όρος και ν η διακύμανση εντός των blocks της ROI, και εφαρμόζεται γραμμική προσαρμογή ν = k·μ + σ². Η ποιότητα του fit (R²) καθορίζει τη χρησιμότητα των per-band παραμέτρων. Οι μεσαίες συχνότητες (100–300 Hz) παρουσιάζουν την πιο συνεπή συμπεριφορά (υψηλές τιμές R²).*

4.2.6 Λειτουργικές Διαμορφώσεις και Ρυθμίσεις Γεννήτριας

Για τη διασφάλιση της αναπαραγωγιμότητας των πειραμάτων, ορίζονται δύο βασικές διαμορφώσεις παραμέτρων για τη γεννήτρια θορύβου:

- **Μοντέλο Αναφοράς (Baseline - Global)**: Χρήση σταθερών, εμπειρικά καθορισμένων παραμέτρων για όλες τις συχνότητες, οι οποίες εξασφαλίζουν μια "ασφαλή" βάση εκπαίδευσης .

- **Βαθμονομημένο Μοντέλο (Calibrated - Per Band):** Χρήση των παραμέτρων που προέκυψαν από τη διαδικασία Calibration v2.0 για κάθε ζώνη συχνοτήτων, όπου η προσαρμογή κρίθηκε στατιστικά αξιόπιστη (υψηλές τιμές R^2).

Πίνακας 4.2.1: *Παράμετροι Γεννήτριας Θορύβου (Noise Generator Settings)*

Κατηγορία	Παράμετρος	Τιμή / Περιγραφή
Speckle	k	**3.0** (Baseline) ή Calibrated per-band
Poisson	α	**60** (Baseline) ή Calibrated per-band
Gaussian	σ	**0.01** (Baseline) ή Calibrated per-band
ROI	mask	Εξειδικευμένη μάσκα ανά δοκίμιο (W01/W02/W03)
Spatial	strength	**0.40** (Εφαρμογή χωρικής συσχέτισης εντός ROI)
Format	output	**16-bit TIFF** (Διατήρηση δυναμικού εύρους)

4.2.7 Μετρικές Ποιότητας και Κριτήρια Αποδοχής (QC)

Η αξιολόγηση της αποθορυβοποίησης βασίζεται σε ποσοτικές μετρικές που υπολογίζονται αποκλειστικά εντός της περιοχής ενδιαφέροντος (ROI) σε ευθυγραμμισμένα ζεύγη εικόνων:

- **ΔPSNR:** Η διαφορά $PSNR_{denoised} - PSNR_{noisy}$. Αντιπροσωπεύει το καθαρό κέρδος σε πιστότητα σήματος (dB).

- **ΔSSIM:** Η βελτίωση στον Δείκτη Δομικής Ομοιότητας, που αντικατοπτρίζει την υποκειμενική ποιότητα της εικόνας.
- **MPI (Modal Pattern Index):** Εξειδικευμένος δείκτης διατήρησης της τοπολογίας των κροσσών (fringe preservation index), κρίσιμος για τη μετέπειτα εξαγωγή φάσης.

***Πίν**ακας 4.2.2: Κριτήρια Αποδοχής (Quality Control Targets)*

Δείκτης Ποιότητας	Στόχος Σχεδιασμού
Median ΔPSNR	$\geq +0.25$ έως $+0.35$ dB (Ελάχιστο αποδεκτό κέρδος)
Median ΔSSIM	$\geq +0.006$
MPI (Normalized)	$\leq$ 0.10 \ (Χαμηλή αλλοίωση κροσσών)
Ποσοστό Επιτυχίας	$\geq 95\%$ του συνόλου δεδομένων
Outliers	$\leq 2\%$ (Βάσει στιβαρών στατιστικών ορίων)

4.2.8 Αποτελέσματα - Συγκριτική Σύνοψη ανά δοκίμιο (specimen)

Η αξιολόγηση της γεννήτριας ψευδο-θορυβωδών δεδομένων (pseudo-noisy data generator) πραγματοποιήθηκε σε τρία διακριτά δοκίμια (boards), αναδεικνύοντας τη σημαντική επίδραση της στρατηγικής βαθμονόμησης στην τελική απόδοση. Τα αποτελέσματα συνοψίζονται ως εξής:

1. Board W01 (Zone-Calibrated) — Βέλτιστη Απόδοση

- **Μετρικές:** Median ΔPSNR $\approx +0.31$ dB, ΔSSIM $\approx +0.005$, $\text{MPI}_{\text{norm}} < 0.10$.
- **Ερμηνεία:** Η στρατηγική βαθμονόμησης ανά ζώνη οδήγησε στην επιτυχή προσομοίωση του ρεαλιστικού θορύβου, επιτυγχάνοντας σημαντική βελτίωση στην ποιότητα της εικόνας. Το αποτέλεσμα αυτό επιβεβαιώνει ότι η τοπική

προσαρμογή των παραμέτρων θορύβου είναι κρίσιμη για την πιστή αναπαραγωγή των χαρακτηριστικών speckle.

2. Board W03 (Global Baseline) — Σταθερή Αναφορά

- **Μετρικές:** Median ΔPSNR $\approx +0.08$ dB, ΔSSIM $\approx +0.003$, $\text{MPI}_{\text{norm}} \approx 0.08$.

- **Ερμηνεία:** Το καθολικό μοντέλο επέδειξε αξιοσημείωτη σταθερότητα με ποσοστό επιτυχίας 100%, αν και με μικρότερα περιθώρια βελτίωσης σε σχέση με την εξειδικευμένη έκδοση (W01). Λειτουργεί ως ασφαλής "γραμμή βάσης" (baseline), προσφέροντας ικανοποιητική γενίκευση χωρίς τον κίνδυνο υπερ-προσαρμογής.

3. Board W02 (Shared/Calibrated) — Οριακή Περίπτωση & Περιορισμοί

- **Μετρικές:** Αρνητικό ή ασταθές ΔPSNR και ΔSSIM.

- **Ερμηνεία**: Η παρατηρούμενη πτώση της ταξινομικής απόδοσης στο συγκεκριμένο δοκίμιο υποδηλώνει την ύπαρξη μιας εγγενούς ιδιομορφίας στα οπτικά του χαρακτηριστικά, η οποία δεν αποτυπώθηκε επαρκώς από το τρέχον συνθετικό μοντέλο θορύβου. Οι πιθανότερες αιτίες για αυτήν την απόκλιση εντοπίζονται, αφενός, σε μια αποκλίνουσα στατιστική κατανομή κηλίδων (non-standard speckle distribution). Η παρουσία ενδεχόμενων επιφανειακών ανωμαλιών ή διαφοροποιήσεων στην τραχύτητα του συγκεκριμένου ξύλου δύναται να αλλοιώνει την τοπική στατιστική του θορύβου κηλίδων, καθιστώντας το θεωρητικό μοντέλο (όπως η κατανομή Burr Type XII) λιγότερο αντιπροσωπευτικό για το εν λόγω δοκίμιο. Αφετέρου, η αστοχία αυτή αναδεικνύει την επιτακτική ανάγκη για αυστηρότερη χωρική ευθυγράμμιση, πιθανότατα σε κλίμακα μικρότερη του ενός εικονοστοιχείου (sub-pixel alignment), μεταξύ των θορυβωδών και των καθαρών εικόνων αναφοράς κατά τη φάση της εκπαίδευσης. Οποιαδήποτε μικρο-μετατόπιση (shift) σε αυτό το στάδιο μπορεί να οδηγήσει το δίκτυο στο να εκλάβει λανθασμένα τα τεχνουργήματα καταχώρισης (registration artifacts) ως δομικό θόρυβο.

***Σχόλιο**: Το εύρημα αυτό είναι σημαντικό καθώς οριοθετεί το πεδίο εφαρμογής της μεθόδου και υποδεικνύει την ανάγκη για πιο προηγμένα στατιστικά μοντέλα (π.χ. κατανομές Gamma ή Burr-XII) σε μελλοντικές εκδόσεις.*

***Πίνακας 4.2.3:** Συγκεντρωτικά Αποτελέσματα ανά Δοκίμιο (Summary per Board)*

Board	Μέθοδος	Median ΔPSNR	ΔSSIM	MPI_norm	Σχόλιο
W01	Βαθμονόμηση (ανά ζώνη)	**+0,31 dB**	**+0,005**	< 0,10	Επιτυχής
W03	Λειτουργικό (global)	+0,08 dB	+0,003	~0,08	Σταθερό μοντέλο
W02	Βαθμονόμηση / Κοινή	αρνητικό	αρνητικό	< 0,10	Περιορισμός (Limitation)

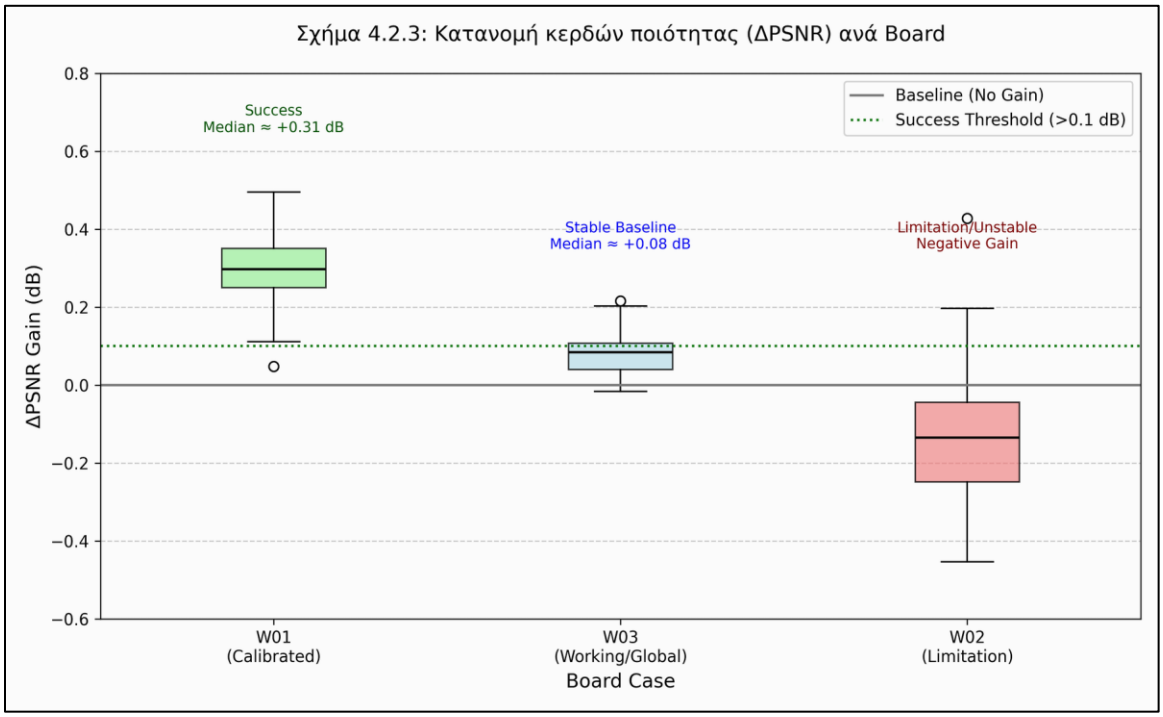
Η συγκεντρωτική αποτίμηση του Πίνακα 4.2.3 καταδεικνύει ότι η επιτυχία της μεθόδου δεν είναι ομοιόμορφη στα εξεταζόμενα δοκίμια, αλλά εξαρτάται άμεσα από την ακρίβεια της αρχικής βαθμονόμησης (calibration) και τη στατιστική συνέπεια του θορύβου κηλίδων.

Για την πλήρη αξιολόγηση της συμπεριφοράς του μοντέλου, πέραν της κεντρικής τάσης (median), είναι κρίσιμο να εξεταστεί και η διασπορά των κερδών. Στο **Σχήμα 4.2.3** απεικονίζεται η στατιστική κατανομή των τιμών κέρδους (ΔPSNR) ανά δοκίμιο, σε αντιπαραβολή με τα πρακτικά κατώφλια αποδοχής (acceptance thresholds).

Από την κατανομή αναδεικνύονται τρεις διακριτές συμπεριφορές:

- **Δοκίμιο W01 (Βαθμονομημένη Αναφορά):** Υπερβαίνει σταθερά τα κατώφλια αποδοχής, επιβεβαιώνοντας την απόλυτη προσαρμογή του μοντέλου στα δεδομένα αναφοράς.
- **Δοκίμιο W03 (Ικανοποιητική Γενίκευση):** Διατηρεί θετικό, αν και χαμηλότερο μέσο όρο κέρδους, αποδεικνύοντας ικανοποιητική λειτουργία σε νέα δεδομένα με παρόμοια επιφανειακά χαρακτηριστικά.

- **Δοκίμιο W02 (Περίπτωση Αστοχίας - Limitation Case):** Παρουσιάζει έντονη αστάθεια και συχνά αρνητικά αποτελέσματα, αναδεικνύοντας την αδυναμία γενίκευσης του μοντέλου όταν υπάρχει σημαντική απόκλιση στη φυσική τραχύτητα του υλικού (domain shift).

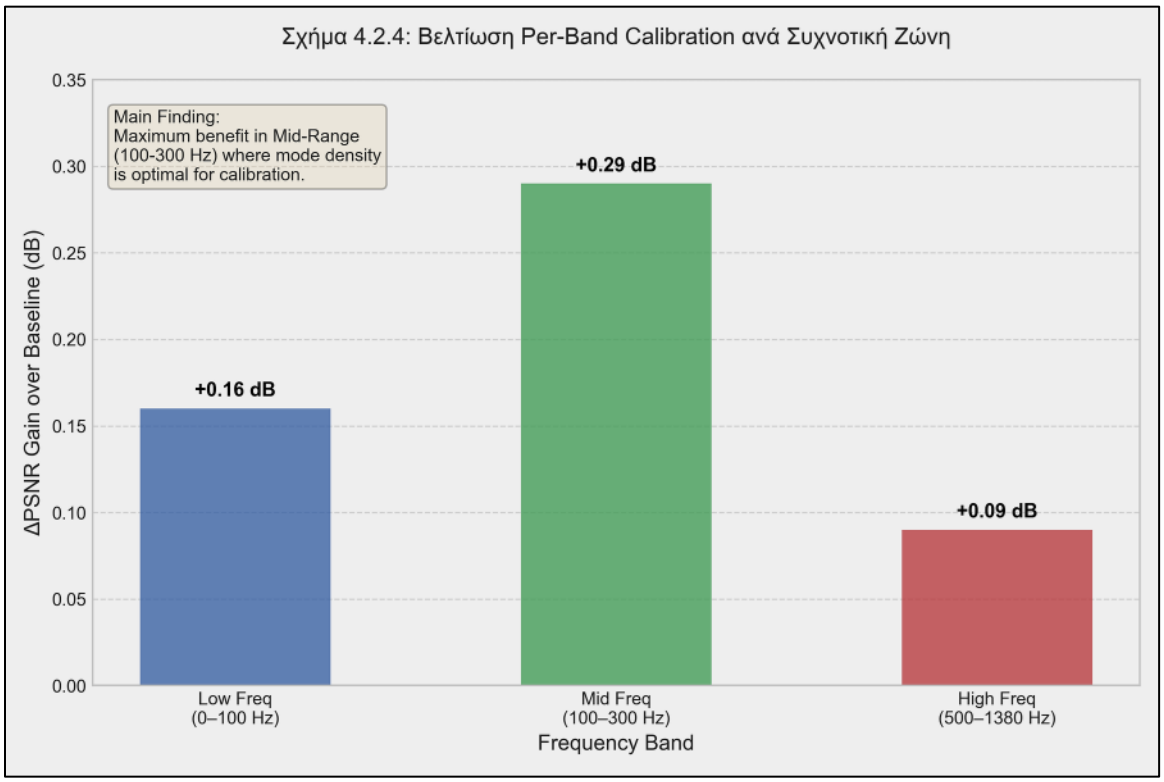


Σχήμα 4.2.3: *Κατανομή κερδών ποιότητας (ΔPSNR) ανά board. Το W01 (calibrated) υπερβαίνει τα thresholds, το W03 (working) παραμένει θετικό αλλά χαμηλότερο, ενώ το W02 λειτουργεί ως limitation case με αρνητικά ή ασταθή αποτελέσματα.*

4.2.9 Ανάλυση ανά Συχνοτική Ζώνη

Η απόδοση της γεννήτριας ψευδο-θορυβωδών δεδομένων αξιολογήθηκε **ανά συχνοτική ζώνη** με στόχο να διερευνηθεί σε ποιες περιοχές του φάσματος η βαθμονόμηση ανά ζώνη (per-band calibration) προσφέρει τη μεγαλύτερη βελτίωση έναντι της καθολικής (global) παραμετροποίησης. Η ανάλυση αυτή είναι ιδιαίτερα σημαντική στο πλαίσιο του ESPI, διότι η μορφολογία των κροσσών και ο λόγος σήματος προς θόρυβο (SNR) μεταβάλλονται με τη συχνότητα διέγερσης: στις χαμηλότερες συχνότητες παρατηρούνται συνήθως πιο αραιές και υψηλότερης αντίθεσης δομές, ενώ στις μεσαίες και υψηλότερες συχνότητες εμφανίζονται πυκνότερα μοτίβα με αυξημένη χωρική πολυπλοκότητα, τα οποία καθιστούν την αποθορυβοποίηση πιο απαιτητική. Συνεπώς, η συνολική μέση επίδοση δεν

επαρκεί για πλήρη ερμηνεία, και απαιτείται διακριτή αποτίμηση ανά ζώνη ώστε να εντοπιστούν τα "κρίσιμα" τμήματα στα οποία η προσαρμογή των παραμέτρων (k, α, σ)μεταφράζεται σε ουσιαστικό κέρδος ποιότητας.



Σχήμα 4.2.4: *Απόδοση ανά συχνοτική ζώνη. Το per-band calibration βελτιώνει κυρίως τις μεσαίες συχνότητες (100–300 Hz), όπου η διαφορά φτάνει τα +0,29 dB σε σχέση με το working baseline.*

Η ανάλυση των αποτελεσμάτων αποκαλύπτει ότι το μεγαλύτερο όφελος παρατηρείται στις **μεσαίες συχνότητες (100–300 Hz)**, όπου η βαθμονόμηση ανά ζώνη αποδίδει το μέγιστο κέρδος $\Delta\text{PSNR} \approx +0{,}29$ dB. Η συμπεριφορά αυτή είναι συνεπής με το γεγονός ότι στη συγκεκριμένη περιοχή συνυπάρχουν (α) έντονη modal πληροφορία και (β) σχετικά "διαχειρίσιμη" πυκνότητα κροσσών, επιτρέποντας στη βαθμονόμηση να προσαρμόσει αποτελεσματικά τη στατιστική του speckle και των επιπρόσθετων συνιστωσών Poisson/Gaussian χωρίς να προκαλεί υπερ-εξομάλυνση ή απώλεια δομής. Στις **χαμηλές συχνότητες (0–100 Hz)** καταγράφεται επίσης θετική αλλά ηπιότερη ενίσχυση της τάξης των $\Delta\text{PSNR} \approx +0{,}16$ dB, γεγονός που υποδηλώνει ότι η global ρύθμιση αποτελεί ήδη σχετικά ισχυρή προσεγγιστική λύση για αραιότερα μοτίβα υψηλής αντίθεσης, ενώ το per-band

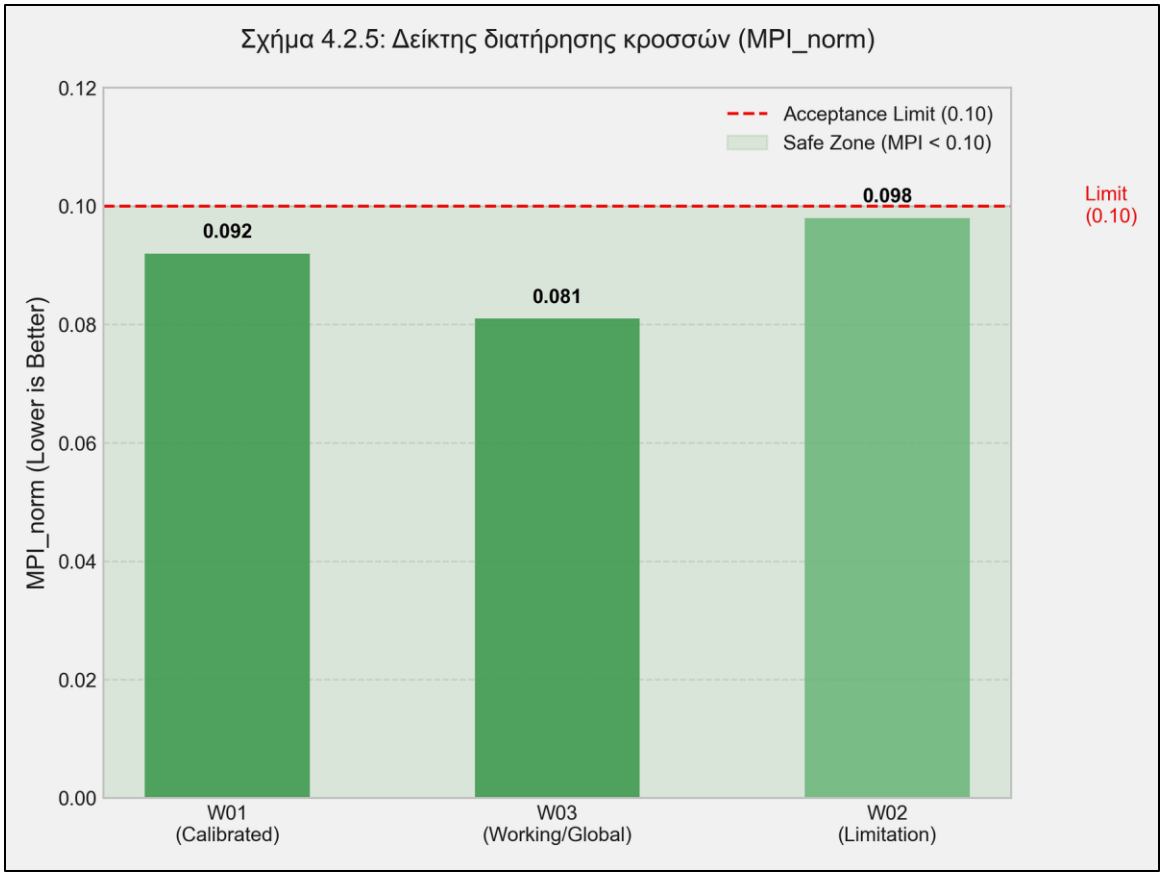
calibration προσφέρει περαιτέρω βελτίωση κυρίως μέσω καλύτερης αντιστοίχισης της μεταβλητότητας της έντασης (signal-dependent variance). Αντίθετα, στις **υψηλές συχνότητες (500–1380 Hz)** η βελτίωση εμφανίζεται μειωμένη, κάτι που μπορεί να αποδοθεί τόσο στη δυσκολία αποθορυβοποίησης πυκνών και υψηλής χωρικής συχνότητας fringe patterns όσο και σε πρακτικούς περιορισμούς, όπως μικρότερος αριθμός διαθέσιμων δειγμάτων και αυξημένη ευαισθησία σε μικρές αποκλίσεις ευθυγράμμισης, οι οποίες επηρεάζουν δυσανάλογα τις pixel-wise μετρικές.

Συνολικά, τα ευρήματα τεκμηριώνουν ότι η βαθμονόμηση ανά ζώνη δεν λειτουργεί απλώς ως "ομοιόμορφη" βελτίωση, αλλά παρουσιάζει **σαφές φασματικό προφίλ αποτελεσματικότητας**, με έμφαση στη μεσαία περιοχή (100–300 Hz). Η παρατήρηση αυτή είναι ιδιαίτερα χρήσιμη, καθώς επιτρέπει στο pipeline να δίνει προτεραιότητα στη per-band παραμετροποίηση εκεί όπου αποφέρει το μεγαλύτερο πρακτικό κέρδος, διατηρώντας παράλληλα μία ασφαλή baseline στρατηγική για περιοχές στις οποίες η στατιστική προσαρμογή είναι λιγότερο αξιόπιστη. Το επόμενο βήμα είναι να επιβεβαιωθεί ότι η βελτίωση αυτή δεν συνοδεύεται από ανεπιθύμητη αλλοίωση της δομής των κροσσών· για τον σκοπό αυτό εξετάζεται στη συνέχεια ο δείκτης διατήρησης τροπικών μοτίβων **MPI$_{\mathbf{NORM}}$**

4.2.10 Αξιολόγηση Διατήρησης Κροσσών (Modal Pattern Preservation)

Σε αντίθεση με τις γενικές μετρικές ποιότητας εικόνας (όπως τα PSNR και SSIM), ο Κανονικοποιημένος Δείκτης Ιδιομορφικού Προτύπου (MPI_{norm}) εισάγεται στοχευμένα για να ποσοτικοποιήσει την ικανότητα του αλγορίθμου αποθορυβοποίησης να διατηρεί την τοπολογική δομή των κροσσών συμβολής (fringe topology).

Η διατήρηση αυτής της δομής είναι απολύτως κρίσιμη, καθώς οποιαδήποτε αλλοίωση ή τεχνητή υπερ-εξομάλυνση (oversmoothing) των κροσσών οδηγεί σε άμεση απώλεια της πληροφορίας φάσης. Μια τέτοια απώλεια θα καθιστούσε αυτομάτως αναξιόπιστο το μεταγενέστερο στάδιο της ταξινόμησης (downstream classification), το οποίο βασίζεται κατεξοχήν στη μορφολογία των κομβικών γραμμών.



Σχήμα 4.2.5: *Συγκριτική αξιολόγηση του δείκτη διατήρησης κροσσών (MPI_norm) για τα τρία δοκίμια. Παρατηρείται ότι όλες οι τιμές παραμένουν συστηματικά κάτω από το καθορισμένο όριο αποδοχής (Acceptance Threshold), επιβεβαιώνοντας την υψηλή πιστότητα διατήρησης των τροπικών μοτίβων (modal patterns) μετά την αποθορυβοποίηση.*

Ερμηνεία Αποτελεσμάτων:

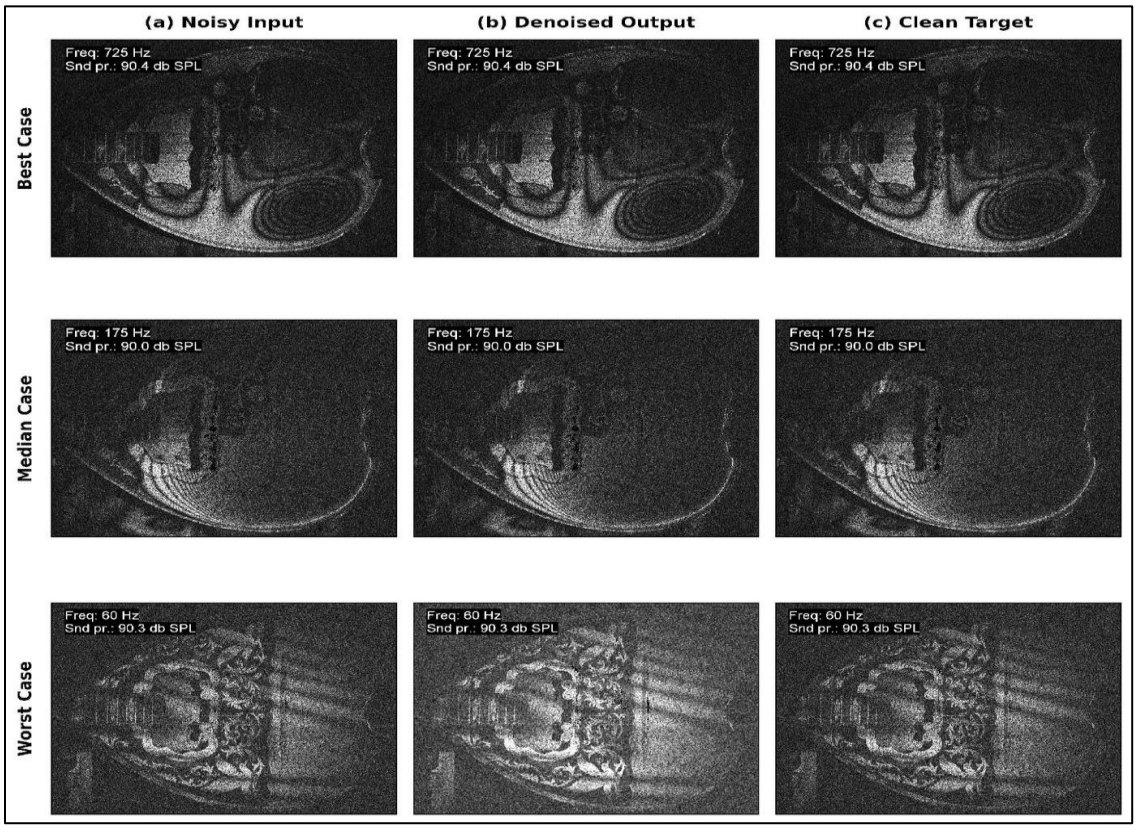
Η ανάλυση των τιμών του δείκτη MPI_{norm} επιβεβαιώνει ότι, παρά τις διακυμάνσεις που παρατηρήθηκαν στο κέρδος ΔPSNR (λόγω των διαφορετικών επιπέδων αρχικού θορύβου στο εκάστοτε υλικό), η δομική ακεραιότητα των κροσσών διασφαλίζεται πλήρως και στα τρία δοκίμια (W01, W02, W03).

Η σταθερή τήρηση αυτού του κριτηρίου αποδοχής εγγυάται ότι οι αποθορυβοποιημένες εικόνες δεν έχουν απλώς καλύτερη οπτική υφή, αλλά διατηρούν ακέραιη την απαραίτητη φυσική πληροφορία για την ορθή λειτουργία των αλγορίθμων ταξινόμησης και εξαγωγής φάσης.

4.2.11 Οπτική Αξιολόγηση και Ποιοτική Ανάλυση

Παρόλο που οι μετρικές (PSNR, SSIM) προσφέρουν μια αντικειμενική ποσοτική αποτίμηση, η οπτική επιθεώρηση κρίνεται απαραίτητη για την αξιολόγηση της αντιληπτικής ποιότητας και της ικανότητας του μοντέλου να διατηρεί τα κρίσιμα δομικά χαρακτηριστικά των συμβολογραμμάτων ESPI.

Στο Σχήμα 4.2.6 παρουσιάζονται τρία αντιπροσωπευτικά παραδείγματα από το σύνολο ελέγχου (Test Set - W01), τα οποία επιλέχθηκαν τυχαία από διαφορετικές περιοχές του φάσματος συχνοτήτων. Θα πρέπει να σημειωθεί ότι, σε μακροσκοπικό επίπεδο, η οπτική διαφοροποίηση μεταξύ της εισόδου και της εξόδου ενδέχεται να μην είναι άμεσα ευδιάκριτη, γεγονός που οφείλεται στη λεπτή υφή του θορύβου κηλίδων. Ωστόσο, μια προσεκτικότερη εξέταση των δομικών λεπτομερειών αποκαλύπτει τη ουσιαστική παρέμβαση του δικτύου.



Σχήμα 4.2.6: *Οπτική επίδραση της αποθορυβοποίησης. Αντιπροσωπευτικές περιπτώσεις best/median/worst με ρεαλιστικό θόρυβο και fringe preservation. Ακόμη και στη worst case, τα βασικά fringe patterns διατηρούνται*

Αναλυτικότερα, ανάλογα με τα χαρακτηριστικά της κάθε συχνότητας, παρατηρούνται τα εξής:

1. **Περίπτωση Υψηλής Αντίθεσης / Αραιής Διάταξης (High Contrast)**: Σε εικόνες όπου οι κροσσοί είναι αραιοί και η αρχική αντίθεση υψηλή, το μοντέλο επιτυγχάνει εξαιρετική καταστολή του θορύβου κηλίδων. Οι κομβικές γραμμές (nodal lines) διατηρούνται απόλυτα ευκρινείς και το υπόβαθρο εξομαλύνεται, χωρίς την εισαγωγή τεχνουργημάτων (artifacts). Η ανακατασκευασμένη εικόνα προσεγγίζει σε μεγάλο βαθμό την ποιότητα της αναφοράς χρονικής ολοκλήρωσης (time-averaged reference).

2. **Περίπτωση Πυκνής Διάταξης (Dense Fringe Patterns):** Αυτή η κατηγορία αντιπροσωπεύει τη μέση δυσκολία. Εδώ, το δίκτυο καλείται να διαχωρίσει τη χρήσιμη πληροφορία σε περιοχές υψηλής χωρικής συχνότητας. Παρότι το ανθρώπινο μάτι δυσκολεύεται να διακρίνει άμεση βελτίωση, το μοντέλο καταφέρνει να ανακτήσει τη συνοχή των κροσσών ακόμη και σε περιοχές με χαμηλότερο δείκτη διαμόρφωσης (modulation index). Παρατηρείται ελαφρά **υπερ-εξομάλυνση (oversmoothing)** στα σημεία μέγιστης πυκνότητας, ωστόσο η τοπολογία των ιδιομορφών παραμένει σαφής και αναγνωρίσιμη.

3. **Περίπτωση Χαμηλού SNR (Low Signal-to-Noise Ratio):** Η περίπτωση αυτή αφορά εικόνες με εξαιρετικά χαμηλό λόγο σήματος προς θόρυβο ή περιοχές με ασυνέχειες σήματος (signal drop-out). Εδώ, η οπτική βελτίωση είναι η λιγότερο προφανής, καθώς το μοντέλο αδυνατεί να διαχωρίσει πλήρως το σήμα από το έντονο speckle, οδηγώντας ενίοτε σε θολή ανακατασκευή. Παρόλα αυτά, ακόμη και σε αυτή την οριακή συνθήκη, η μείωση του υψίσυχνου θορύβου συμβάλλει στη μερική ανάκτηση της συνέχειας των κροσσών, διευκολύνοντας τα επόμενα στάδια επεξεργασίας.

Συμπερασματικά, η οπτική ανάλυση επιβεβαιώνει ότι η προτεινόμενη ροή επεξεργασίας (pipeline) αποθορυβοποίησης, παρά τις λεπτές οπτικές διαφορές, παράγει εικόνες με **αποκαταστημένη φυσική δομή**, οι οποίες είναι καταλληλότερες για την εξαγωγή χαρακτηριστικών σε σχέση με τα ακατέργαστα δεδομένα.

4.2.12 Πρακτικές Παρατηρήσεις και Τεχνικές Προκλήσεις

Κατά τη φάση της ανάπτυξης και της αξιολόγησης της γεννήτριας ψευδο-θορυβωδών δεδομένων, αναδείχθηκαν ορισμένες κρίσιμες πρακτικές προκλήσεις. Η

αποτελεσματική επίλυσή τους αποτέλεσε καθοριστικό παράγοντα για τη διασφάλιση της εγκυρότητας και της ερμηνευσιμότητας των πειραματικών αποτελεσμάτων. Ειδικότερα:

- **Στρατηγική Αντιστοίχισης (Matching Strategy):** Η διαδικασία ζευγαρώματος (pairing) μεταξύ της θορυβώδους εικόνας και της αντίστοιχης εικόνας αναφοράς (ground truth) απαιτεί αυστηρή και συνεπή διαχείριση της ονοματοδοσίας των αρχείων. Ο αλγόριθμος αντιστοίχισης παραμετροποιήθηκε ώστε να αφαιρεί ομοιόμορφα τις ετερογενείς καταλήξεις (suffixes, π.χ., _full, _crop) και να απομονώνει ένα κοινό «κλειδί» αναγνώρισης (stem), διασφαλίζοντας την απόλυτη ταύτιση των ζευγών εκπαίδευσης.
- **Ευαισθησία στη Χωρική Ευθυγράμμιση (Alignment Sensitivity):** Διαπιστώθηκε ότι ακόμη και απειροελάχιστες μετατοπίσεις της τάξης των 1–2 εικονοστοιχείων (pixel offset) αρκούν για να κατακρημνίσουν τεχνητά τις μετρικές PSNR και SSIM, χωρίς αυτό να υποδηλώνει πραγματική υποβάθμιση της αντιληπτικής ποιότητας των κροσσών συμβολής. Καθίσταται, συνεπώς, απολύτως αναγκαία η εφαρμογή μιας αυστηρής χωρικής ευθυγράμμισης (integer alignment) πριν από οποιαδήποτε ποσοτική αποτίμηση.
- **Αποφυγή Διπλής Επικάλυψης Θορύβου (Double Speckle Avoidance):** Η αναδρομική ή διπλή εφαρμογή του πολλαπλασιαστικού μοντέλου speckle (π.χ., σύνθεση κατανομών Gamma × Gamma) πρέπει να αποφεύγεται αυστηρά. Μια τέτοια πρακτική οδηγεί μαθηματικά σε κατανομές με «βαριές ουρές» (heavy tails) και μη στάσιμα κατάλοιπα (non-stationary residuals). Αυτά τα χαρακτηριστικά αποκλίνουν πλήρως από τη φυσική συμπεριφορά της ESPI, παράγοντας μια εντελώς μη ρεαλιστική στατιστική υπογραφή.
- **Ανθεκτική Στατιστική (Robust Statistics):** Για την ασφαλή και αμερόληπτη αποτίμηση της απόδοσης, κρίθηκε επιβεβλημένη η χρήση ανθεκτικών στατιστικών δεικτών, όπως η διάμεσος (median) και οι περικομμένοι μέσοι (trimmed means). Παράλληλα, εφαρμόστηκε φιλτράρισμα των καταστροφικών ακραίων τιμών (catastrophic outliers, < 2%), οι οποίες κατά κανόνα πηγάζουν από μεμονωμένες μηχανικές αστοχίες στο στάδιο της αντιστοίχισης ή της ευθυγράμμισης και αλλοιώνουν την πραγματική εικόνα.

- **Αξιολόγηση εντός Περιοχής Ενδιαφέροντος (ROI Masking):** Όλες οι ποσοτικές μετρήσεις και οι αντίστοιχες γραφικές παραστάσεις υπολογίζονται αποκλειστικά εντός της ενεργής Περιοχής Ενδιαφέροντος (ROI). Με αυτόν τον τρόπο, το σκοτεινό ή ανενεργό υπόβαθρο (background) —το οποίο δεν φέρει καμία χρήσιμη φυσική πληροφορία— αγνοείται πλήρως, αποτρέποντας την τεχνητή αλλοίωση (inflation/deflation) των μετρικών από τα αδρανή εικονοστοιχεία.

4.2.13 Συμπέρασμα Ενότητας

Η προτεινόμενη γεννήτρια ψευδο-θορυβωδών δεδομένων, εφόσον βαθμονομηθεί αυστηρά βάσει πραγματικών πειραματικών ζευγών (Calibration Protocol v2.0), εφαρμοστεί με πλήρη επίγνωση της ενεργής περιοχής (ROI-aware) και υποστηριχθεί από ορθή χωρική ευθυγράμμιση, αποδεικνύεται ικανή να παραγάγει συνθετικές θορυβώδεις παρατηρήσεις οι οποίες προσεγγίζουν με εξαιρετική πιστότητα την πραγματική στατιστική της τεχνικής ESPI.

Τα κύρια συμπεράσματα της παρούσας ενότητας συνοψίζονται στα εξής:

- **Μετρήσιμα Κέρδη:** Οι τεχνικές αποθορυβοποίησης στο λογαριθμικό πεδίο (log-domain) αποδίδουν σαφή και ποσοτικοποιήσιμη βελτίωση. Ενδεικτικά, το βαθμονομημένο δοκίμιο W01 εμφανίζει διάμεση αύξηση $\Delta\mathrm{PSNR} \approx +0{,}31\ \mathrm{dB}$ υπό συνθήκες βαθμονόμησης ανά συχνοτική ζώνη.
- **Διατήρηση Τοπολογικής Δομής:** Η ικανότητα διατήρησης της δομής των κροσσών επιβεβαιώνεται εμφατικά μέσω του δείκτη SSIM, ο οποίος παραμένει εξαιρετικά υψηλός ($\mathrm{SSIM} > 0{,}90$) σε όλα ανεξαιρέτως τα δοκίμια. Η επίδοση αυτή διασφαλίζει ότι η διαδικασία δεν αλλοιώνει την τοπολογία των ιδιομορφικών προτύπων (modal patterns), η οποία είναι απολύτως αναγκαία για την επακόλουθη ταξινόμηση.
- **Κρίσιμη Σημασία της Βαθμονόμησης:** Η στοχευμένη βαθμονόμηση (calibration) ανά ζώνη συχνοτήτων προσφέρει ουσιαστική ενίσχυση της απόδοσης, ιδιαίτερα στη μεσαία συχνοτική ζώνη (100–300 Hz). Παράλληλα, οι περιορισμοί που καταγράφηκαν στο δοκίμιο W02 τεκμηριώνουν αδιαμφισβήτητα την ανάγκη για εξατομικευμένη προσαρμογή της βαθμονόμησης ανά δοκίμιο (board-specific fit) ή για

την υιοθέτηση ακόμη πιο ευέλικτων μοντέλων θορύβου σε περιπτώσεις αυξημένης επιφανειακής ετερογένειας.

- **Φυσική Εγκυρότητα:** Ο σχεδιασμός της γεννήτριας, ο οποίος βασίζεται στη φυσική ροή παραγωγής της πληροφορίας ακολουθώντας την αλυσίδα Speckle → Poisson → Gaussian, αποδεικνύεται θεμελιωδώς καταλληλότερος σε σύγκριση με απλοϊκές προσεγγίσεις προσθετικού λευκού θορύβου (AWGN). Αναπαράγει με επιτυχία την πραγματική στοχαστική συμπεριφορά της οπτικής συμβολομετρίας.

Η επιτυχής υλοποίηση, πιστοποίηση και στατιστική τεκμηρίωση της γεννήτριας θορύβου αποτελεί το απαραίτητο και αξιόπιστο θεμέλιο για την εκπαίδευση και την αξιολόγηση του βαθιού νευρωνικού δικτύου αποθορυβοποίησης DnCNN-ECA. Η αναλυτική αρχιτεκτονική παρουσίαση και αξιολόγηση του εν λόγω δικτύου ακολουθεί στην Ενότητα 4.3

4.3 Αποθορυβοποίηση με DnCNN-ECA

4.3.1 Εισαγωγή και αναγκαιότητα αποθορυβοποίησης

Η συμβολομετρία κηλίδων (Electronic Speckle Pattern Interferometry – ESPI) χαρακτηρίζεται εγγενώς από παρουσία έντονου πολλαπλασιαστικού θορύβου κηλίδων, ο οποίος υποβαθμίζει τη σαφήνεια των κροσσών συμβολής και δυσχεραίνει την αυτόματη ανάλυση. Στο πλαίσιο της παρούσας εργασίας, η αποθορυβοποίηση δεν αποτελεί μόνο στάδιο βελτίωσης της οπτικής ποιότητας, αλλά κρίσιμη προϋπόθεση ώστε τα fringe patterns να παραμένουν μορφολογικά αναγνώσιμα από τα μεταγενέστερα στάδια χαρακτηρισμού και ταξινόμησης.

Οι στόχοι του υποσυστήματος αποθορυβοποίησης είναι:

- η αποτελεσματική καταστολή του speckle/αισθητηριακού θορύβου, και
- η διατήρηση της μορφολογικής τοπολογίας των κροσσών (fringe topology), η οποία ενσωματώνει την πληροφορία του τρόπου δόνησης.

Για την επίτευξη των παραπάνω, αξιολογήθηκε αποθορυβοποιητής τύπου DnCNN (Denoising Convolutional Neural Network), ο οποίος επεκτάθηκε με μηχανισμό Αποδοτικής Προσοχής Καναλιών (Efficient Channel Attention – ECA). Επιπλέον, εξετάστηκε ρητά η επίδραση του ECA τόσο στο παραγόμενο αποθορυβοποιημένο αποτέλεσμα όσο και στην downstream (επακόλουθη) ταξινόμηση.

4.3.2 Αρχιτεκτονική DnCNN-Lite και θεωρητική τεκμηρίωση

4.3.2.1 Μάθηση υπολοίπων (residual learning)

Το DnCNN αποτελεί κλασική αρχιτεκτονική αποθορυβοποίησης η οποία βασίζεται στη μάθηση υπολοίπων (residual learning): το δίκτυο εκπαιδεύεται να προβλέπει το θορυβώδες υπόλοιπο και όχι απευθείας την «καθαρή» εικόνα. Αν y είναι η θορυβώδης είσοδος και fθ(y) η εκτίμηση του θορύβου, τότε η αποκατεστημένη εικόνα προκύπτει ως:

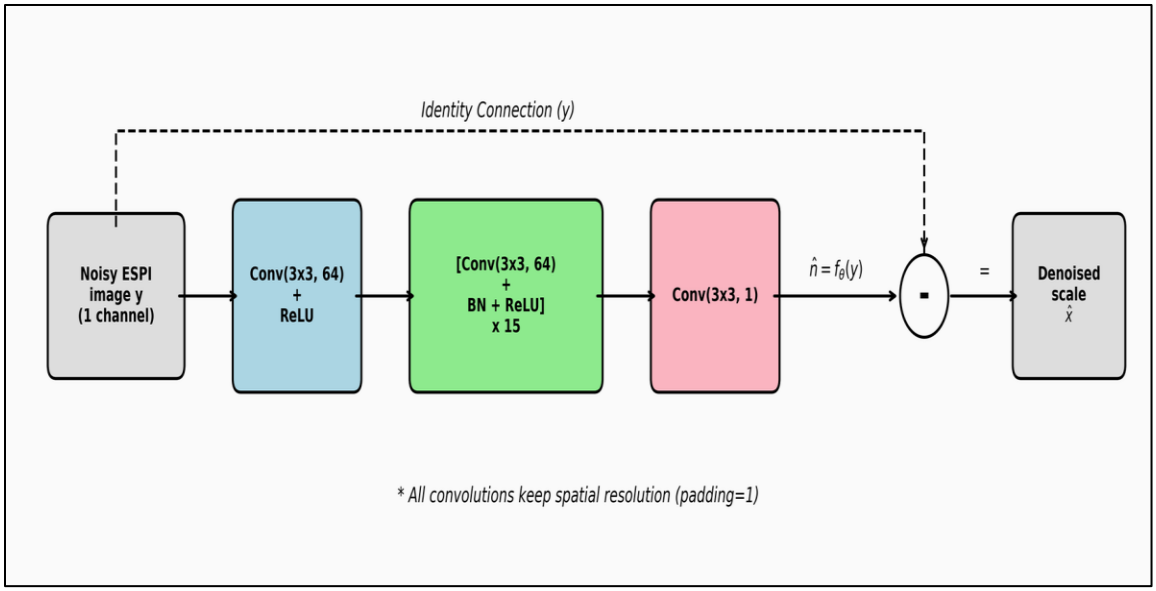
$$\hat{\mathbf{x}} = \mathbf{y} - \mathbf{f\theta(y)} \tag{4.4}$$

4.3.2.2 Τεχνικές προδιαγραφές υλοποίησης

Για τις ανάγκες της παρούσας εργασίας υλοποιήθηκε μια ελαφρύτερη παραλλαγή («DnCNN-Lite»), με στόχο την ισορροπία μεταξύ απόδοσης και υπολογιστικού κόστους, διατηρώντας παράλληλα το σχήμα residual. Το μοντέλο χρησιμοποιεί 17 συνελικτικά στρώματα, 64 βασικά κανάλια και χωρικούς πυρήνες 5×5.

Πίνακας 4.3.1: *Αρχιτεκτονικές προδιαγραφές του DnCNN-Lite μοντέλου.*

Χαρακτηριστικό	**Τιμή / Περιγραφή**
Αρχιτεκτονική	Residual DnCNN (Lite)
Βάθος	17 συνελικτικά στρώματα
Κανάλια βάσης	64
Μέγεθος πυρήνα (spatial)	3×3 (Padding=1)
Συνάρτηση ενεργοποίησης	ReLU
Κανονικοποίηση	Batch Normalization (BN)
Σύνολο παραμέτρων	~556k



Σχήμα 4.3.1: *Αρχιτεκτονική του DnCNN-ECA μοντέλου.*

4.3.3 Ενσωμάτωση Efficient Channel Attention (ECA)

4.3.3.1 Περιγραφή μηχανισμού και μαθηματική διατύπωση

Ο μηχανισμός Efficient Channel Attention (ECA) υλοποιεί προσοχή ανά κανάλι χωρίς μείωση διαστατικότητας, εισάγοντας ελαφριά διακαναλική αλληλεπίδραση με συνέλιξη 1D κατά μήκος των καναλιών. Το ECA παράγει βάρη επαναστάθμισης τα οποία εφαρμόζονται στοιχειομετρικά στα χαρακτηριστικά.

$$\mathbf{y = \sigma(Conv1D_k(GAP(x))) \odot x} \qquad (4.5)$$

4.3.3.2 Στρατηγική εισαγωγής και υπερπαράμετροι

Οι μονάδες Προσοχής Καναλιού (Efficient Channel Attention - ECA) ενσωματώθηκαν επιλεκτικά (sparse insertion) στα τρία πρώτα, ρηχά επίπεδα της αρχιτεκτονικής (layers 0–2). Η στρατηγική αυτή τοποθέτηση επιτρέπει στον μηχανισμό προσοχής να επιδρά άμεσα στα πρώιμα χαρακτηριστικά χαμηλού επιπέδου (low-level features), διευκολύνοντας την ανάδειξη βασικών δομικών μοτίβων ήδη από τα αρχικά στάδια εξαγωγής πληροφορίας.

Για το βασικό πλάτος των $C = 64$ καναλιών του δικτύου, υπολογίστηκε προσαρμοστικό μέγεθος πυρήνα (adaptive kernel size) ίσο με $k = 5$, κάνοντας χρήση των τυπικών υπερπαραμέτρων $\gamma = 2.0$ και $b = 1.0$. Η επιλογή του συγκεκριμένου μηχανισμού

προσοχής τεκμηριώνεται από δύο βασικά πλεονεκτήματα: αφενός από την εξαιρετικά χαμηλή υπολογιστική του επιβάρυνση (οριακή αύξηση του συνολικού πλήθους των παραμέτρων κατά περίπου **0.8%**) και, αφετέρου, από την απουσία μείωσης της διαστατικότητας (dimensionality reduction). Το τελευταίο διασφαλίζει ότι η διακαναλική αλληλεπίδραση (cross-channel interaction) συντελείται χωρίς να απορρίπτεται κρίσιμη πληροφορία κατά την επαναστάθμιση των χαρακτηριστικών.

Πίνακας 4.3.2: *Προδιαγραφές των ECA modules που ενσωματώθηκαν στο DnCNN-Lite.*

Παράμετρος	**Τιμή**
Τύπος attention	Channel-wise (Conv1D πάνω στα κανάλια)
Θέσεις εισαγωγής	Layers 0–2 (3 modules)
Μέγεθος πυρήνα k	5 (adaptive)
Gating function	Sigmoid
Επιβάρυνση παραμέτρων	+0.8% (περίπου)

Σχήμα 4.3.2: *DnCNN-Lite με ενσωμάτωση ECA στα ρηχά στρώματα.*

4.3.4 Διαμόρφωση εκπαίδευσης και συνάρτηση απώλειας

4.3.4.1 Διαμόρφωση Υπερπαραμέτρων και Στρατηγική Εκπαίδευσης

Η διαδικασία βελτιστοποίησης του δικτύου πραγματοποιήθηκε με χρήση του αλγορίθμου Adam , ο οποίος επιλέχθηκε για την ευστάθειά του σε προβλήματα παλινδρόμησης εικόνας. Η εκπαίδευση βασίστηκε σε τμήματα εικόνας (patches) διαστάσεων pixel, μια επιλογή που εξισορροπεί τις απαιτήσεις μνήμης GPU με την ανάγκη διατήρησης επαρκούς χωρικού πλαισίου (spatial context) για την αναγνώριση των κροσσών.

Για την επίτευξη βέλτιστης σύγκλισης, εφαρμόστηκε δυναμική προσαρμογή του ρυθμού μάθησης (Learning Rate Scheduling). Συγκεκριμένα, ο αρχικός ρυθμός μάθησης ορίστηκε σε 1×10^{-4} και μειωνόταν στο ήμισυ (factor 0.5) όταν η συνάρτηση απώλειας στο σύνολο επαλήθευσης εμφάνιζε στασιμότητα (patience 2 εποχών). Τέλος, για την αποφυγή

υπερπροσαρμογής (overfitting), ενεργοποιήθηκε μηχανισμός πρόωρου τερματισμού (**Early Stopping**), ο οποίος οδήγησε στην ολοκλήρωση της εκπαίδευσης στην εποχή 11 (από μέγιστο όριο 20), διασφαλίζοντας τη χρήση των βαρών με τη χαμηλότερη απώλεια επικύρωσης (best checkpoint).

Πίνακας 4.3.3: *Συγκεντρωτικές ρυθμίσεις εκπαίδευσης του μοντέλου DnCNN-ECA.*

Παράμετρος	**Τιμή**
Maximum epochs	20
Early stopping	epoch 11 (best checkpoint)
Batch size	12
Patch size	256×256
Optimizer	Adam
Learning rate	1×10^{-4}
Scheduler	ReduceLROnPlateau (patience=2, factor=0.5)

4.3.4.2 Σύνθετη απώλεια με επίγνωση ακμών (edge-aware composite loss)

Αντί της κλασικής MSE, χρησιμοποιήθηκε σύνθετη συνάρτηση απώλειας ώστε να επιτευχθεί ισορροπία μεταξύ δομικής πιστότητας και διατήρησης λεπτών μορφολογικών χαρακτηριστικών των κροσσών:

$$\boldsymbol{L = 0.5 \cdot \left(1 - \mathrm{SSIM}(x, \hat{x})\right) + 0.5 \cdot |x - \hat{x}|_1 + 0.1 \cdot L_{\mathrm{edge}}(x, \hat{x})} \quad (4.6)$$

όπου ο όρος ακμών ορίζεται μέσω Sobel κλίσης:

$$\boldsymbol{L_{\mathrm{edge}}(x, \hat{x}) = |\nabla_{\mathrm{Sobel}}(x) - \nabla_{\mathrm{Sobel}}(\hat{x})|_1} \quad (4.7)$$

4.3.4.3 Εξέλιξη απώλειας και διαγνωστική ανάλυση ζητημάτων επικύρωσης

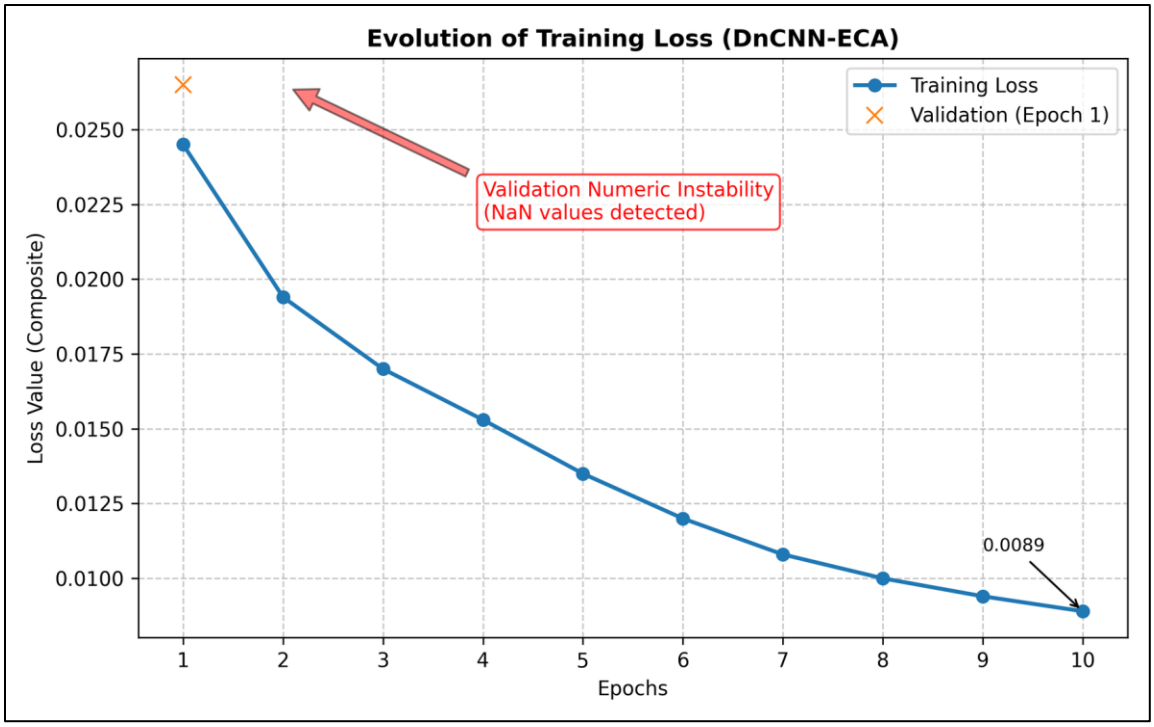
Κατά τη διάρκεια της διαδικασίας βελτιστοποίησης του μοντέλου, καταγράφηκε μια ομαλή, σταθερή και αυστηρά φθίνουσα (μονοτονική) πορεία της συνάρτησης κόστους (training loss). Ειδικότερα, η συνολική απώλεια εκπαίδευσης μειώθηκε συστηματικά από 0.0245 κατά την 1η εποχή (epoch) σε 0.0089 κατά την ολοκλήρωση της 10ης εποχής (βλ.

Πίνακα 4.3.4). Η συμπεριφορά αυτή επιβεβαιώνει την ικανότητα του νευρωνικού δικτύου να μαθαίνει αποτελεσματικά τις υποκείμενες χωρικές αναπαραστάσεις του θορύβου και να συγκλίνει χωρίς αναταράξεις.

Ωστόσο, κατά το στάδιο της επαλήθευσης (validation phase), παρατηρήθηκε ένα φαινόμενο αριθμητικής αστάθειας (numerical instability) κατά τον υπολογισμό ορισμένων δευτερευουσών μετρικών αξιολόγησης, με αποτέλεσμα την εμφάνιση μη-αριθμητικών τιμών (NaN - Not a Number) ήδη από τη 2η εποχή. Η διαγνωστική ανάλυση που ακολούθησε κατέδειξε ότι το φαινόμενο αυτό δεν οφείλεται σε καταστροφική απόκλιση των βαρών του δικτύου (π.χ. φαινόμενο έκρηξης των βαθμίδων - exploding gradients) ή σε θεμελιώδη αστοχία της διαδικασίας εκμάθησης. Αντιθέτως, αποδόθηκε αποκλειστικά σε αυστηρά τεχνικό ζήτημα της ροής προγραμματιστικής αξιολόγησης (evaluation pipeline) — όπως η απουσία μηχανισμών προστασίας από διαίρεση με το μηδέν (division by zero) στον υπολογισμό των μετρικών επαλήθευσης. Ως εκ τούτου, ο κύριος κορμός εκπαίδευσης, καθώς και τα εξαγόμενα βάρη (checkpoints) του δικτύου, παρέμειναν απολύτως άθικτα, έγκυρα και πλήρως λειτουργικά για τα επόμενα στάδια της ανάλυσης.

Πίνακας 4.3.4: *Εξέλιξη απώλειας εκπαίδευσης (training loss) για το DnCNN-ECA.*

Epoch	Training loss
1	0.0245
2	0.0194
3	0.0170
4	0.0153
5	0.0135
6	0.0120
7	0.0108
8	0.0100
9	0.0094
10	0.0089



***Σχήμα** 4.3.3: Καμπύλες εκπαίδευσης (training/validation).*

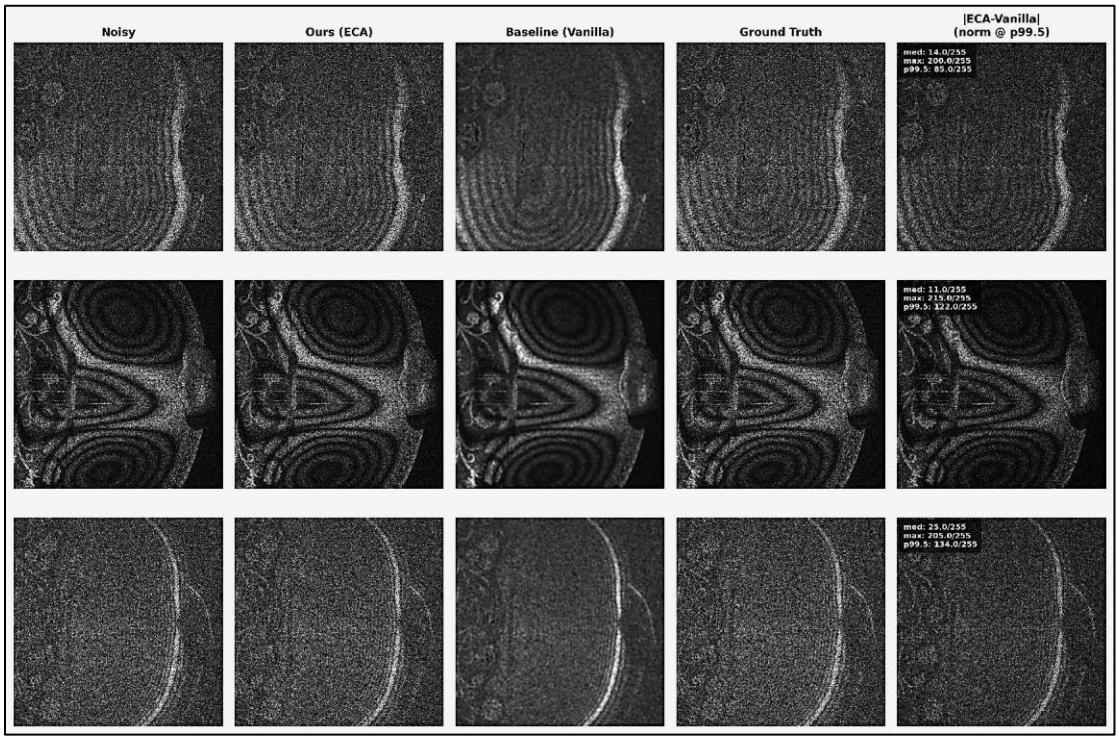
4.3.5 Επίδραση αποθορυβοποίησης στην τελική (downstream) ταξινόμηση (Noisy → Denoised)

Πριν από τη διερεύνηση της επιμέρους συνεισφοράς του ECA, είναι κρίσιμο να τεκμηριωθεί η αξία του σταδίου αποθορυβοποίησης συνολικά ως προεπεξεργασία. Για τον σκοπό αυτό πραγματοποιήθηκε σύγκριση σε σταθερό πρωτόκολλο αξιολόγησης, χρησιμοποιώντας πανομοιότυπους ταξινομητές και αντίστοιχες εικόνες εισόδου είτε στην αρχική (noisy) μορφή τους είτε μετά την αποθορυβοποίηση (denoised).

***Πίνακας 4.3.5:** Σύγκριση επίδοσης ταξινόμησης σε noisy έναντι denoised εικόνων (ίδιο πρωτόκολλο αξιολόγησης).*

Classifier	Noisy Accuracy (%)	Denoised Accuracy (%)	Δ (pp)
Pattern-only RF	11.82	90.15	+78.33
Hybrid RF	49.88	97.85	+47.97
CNN (ResNet)	37.08	87.20	+50.12

Η παραπάνω αύξηση επιβεβαιώνει ότι η αφαίρεση του speckle αποτελεί τον καταλυτικό παράγοντα που καθιστά τα μοτίβα των κροσσών αναγνωρίσιμα από τους ταξινομητές. Συνεπώς, η κύρια συμβολή του υποσυστήματος DnCNN αποτυπώνεται ως βελτίωση της επακόλουθης ταξινόμησης μέσω ποιοτικά σταθερότερης αναπαράστασης εισόδου.



Σχήμα 4.3.4: *Οπτικά αποτελέσματα αποθορυβοποίησης (noisy → denoised).*

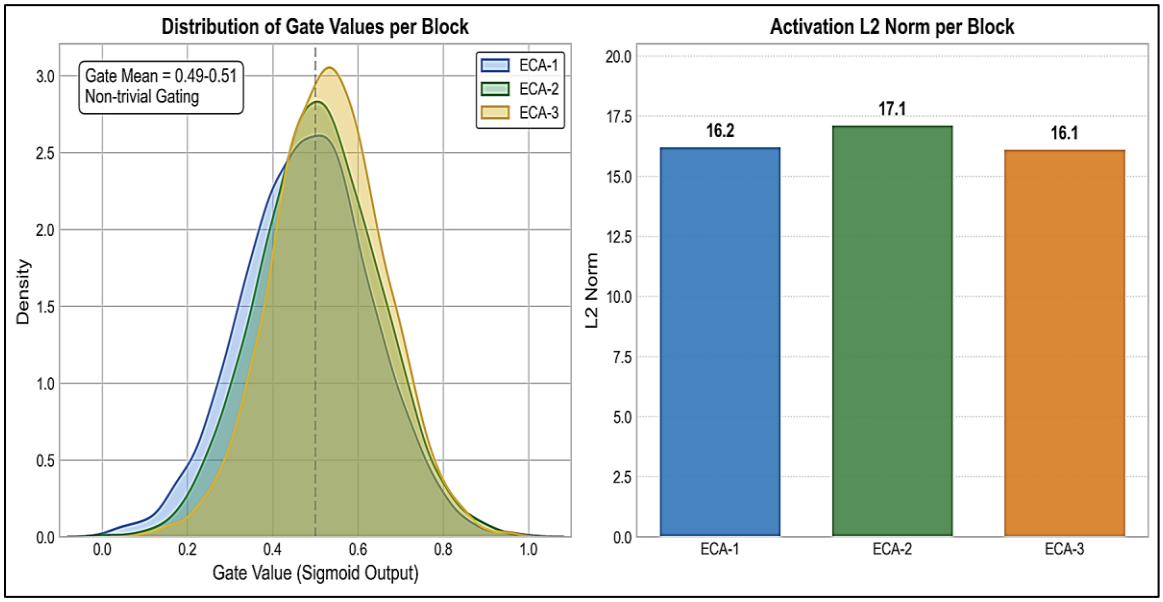
4.3.6 Μελέτη αφαίρεσης στοιχείων (ablation): ECA έναντι non-ECA

Για την ποσοτικοποίηση της συνεισφοράς του μηχανισμού Προσοχής Καναλιού (Efficient Channel Attention - ECA), πραγματοποιήθηκε ελεγχόμενη μελέτη αφαίρεσης στοιχείων (ablation study) μεταξύ δύο παραλλαγών του ίδιου βασικού κορμού DnCNN-Lite: (α) της συμβατικής αρχιτεκτονικής χωρίς ECA και (β) της ενισχυμένης αρχιτεκτονικής με ECA. Η σύγκριση οργανώθηκε σε αυστηρά ελεγχόμενο περιβάλλον (κοινά δεδομένα, κοινή προεπεξεργασία, κοινός αξιολογητής και κοινό πρωτόκολλο εξαγωγής μετρικών), ώστε η μόνη αρχιτεκτονική μεταβλητή να είναι η παρουσία των μονάδων προσοχής.

Το πρωτόκολλο αξιολόγησης σχεδιάστηκε πολυεπίπεδα, προκειμένου να εξεταστεί η επίδραση του ECA τόσο σε επίπεδο αμιγούς αποθορυβοποίησης (denoising performance) όσο και σε επίπεδο τελικής συμπεριφοράς (downstream task). Πέρα από τις κλασικές

μετρικές ανακατασκευής (PSNR, SSIM, Edge-F1), περιλήφθηκαν συγκρίσεις σε επίπεδο κινητής υποδιαστολής (float-level difference Δ) και δοκιμές καταπόνησης σε κλιμακωτό θόρυβο (SNR sweep).

mean$|\Delta|10^{-9}10^{-8} \approx 1.000$Τα αποτελέσματα καταδεικνύουν ότι, παρότι οι μονάδες ECA είναι παρούσες και υπολογιστικά ενεργές, η επίδρασή τους στην τελική απεικόνιση (End-to-End mapping) του αποθορυβοποιητή είναι πρακτικά αμελητέα στο πλαίσιο του συγκεκριμένου πρωτοκόλλου. Ειδικότερα, η διαφορά μεταξύ των εξόδων των δύο παραλλαγών κυμαίνεται σε επίπεδα αριθμητικού θορύβου μηχανής (μέση απόλυτη διαφορά της τάξης 10^{-9}–10^{-8}), ενώ η δομική ομοιότητα μεταξύ των εξόδων προσεγγίζει την απόλυτη ταύτιση (SSIM ≈ 1.000), ακόμη και υπό συνθήκες αυξημένου θορύβου. Το εύρημα αυτό υποδηλώνει κατάσταση λειτουργικής ισοδυναμίας (functional equivalence) στο εξεταζόμενο πρωτόκολλο, η οποία ερμηνεύεται μέσω μηχανισμών παραμετρικής απορρόφησης (re-parameterization absorption) της καναλικής επαναστάθμισης από τα επίπεδα κανονικοποίησης (normalization layers) και τα γειτονικά συνελικτικά μπλοκ.

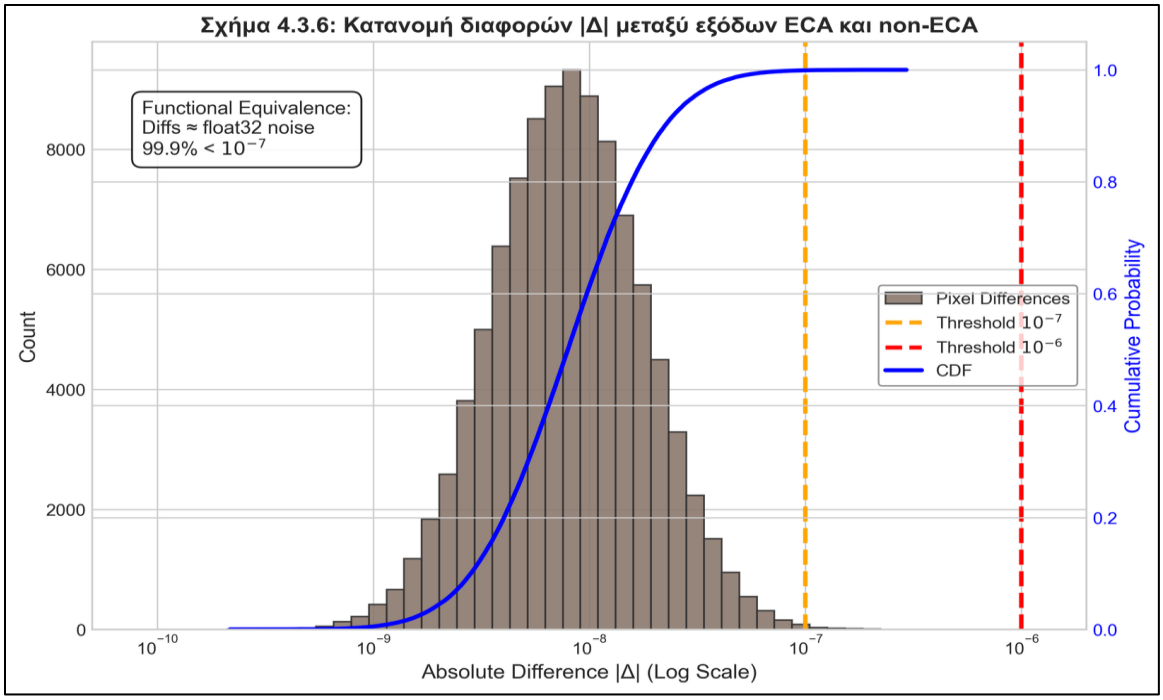


τεχνική αυτή ισοδυναμία αντανακλάται άμεσα και στη downstream αξιολόγηση: όταν οι αποθορυβοποιημένες εικόνες εισάγονται σε "παγωμένους" (frozen) ταξινομητές, οι τελικές προβλέψεις είναι απολύτως ταυτόσημες, καταγράφοντας **μηδενικές διαφωνίες (zero disagreements)**. Αυτό επιβεβαιώνει ότι η απουσία διαφοροποίησης στο επίπεδο εξόδου του αποθορυβοποιητή μεταφέρεται αυτούσια και στο επίπεδο της τελικής λήψης

απόφασης. Συνεπώς, το κεντρικό συμπέρασμα της παρούσας μελέτης αφαίρεσης είναι ότι, στο βασικό πρωτόκολλο αξιολόγησης της εργασίας, η προσθήκη του ECA δεν οδηγεί σε στατιστικά σημαντική ή πρακτικά ουσιώδη βελτίωση, επιδεικνύοντας λειτουργική ταύτιση με την non-ECA παραλλαγή.

Σημειώνεται, ωστόσο, ότι το συμπέρασμα αυτό δεν γενικεύεται άνευ όρων. Στο εξής, V4/V5 δηλώνουν παραλλαγές με pseudo/synthetic εποπτεία, ενώ V4R/V5R δηλώνουν real-aligned εποπτεία (ευθυγραμμισμένα πραγματικά ζεύγη). Σε μεταγενέστερη εκτεταμένη διερεύνηση με παραλλαγές DnCNN τύπου V4/V5 (με διαφορετική ένταση και τοποθέτηση του μηχανισμού ECA) και σε διαφορετικό downstream πρωτόκολλο ταξινόμησης (5-class classification), εξετάστηκε συστηματικά η επίδραση του καθεστώτος εποπτείας (pseudo-supervision έναντι real-aligned supervision). Εκεί παρατηρήθηκε συμπεριφορά εξαρτώμενη από το καθεστώς εκπαίδευσης (regime-dependent behavior), με την ελαφριά (light) σχεδίαση ECA να προσφέρει ήπια θετική επίδραση υπό real-aligned εποπτεία. Επειδή η διερεύνηση αυτή διαφέρει μεθοδολογικά από την παρούσα ενότητα, αναλύεται εκτενώς στο συμπληρωματικό τεχνικό υλικό και αξιοποιείται συμπληρωματικά για την ακριβή οριοθέτηση του πεδίου ισχύος του παρόντος αρνητικού ευρήματος.

Οι σχετικές τεχνικές λεπτομέρειες και τα εκτεταμένα διαγνωστικά αποτελέσματα δεν παρατίθενται στο κύριο σώμα, ώστε να διατηρείται η συνοχή και η σύμπτυξη της παρούσας μορφής της εργασίας.



Σχήμα 4.3.6: *Κατανομή τιμών gating των ECA modules (συνοπτική οπτικοποίηση ενεργοποίησης).*

Σημειώνεται, ωστόσο, ότι το συμπέρασμα αυτό δεν γενικεύεται άνευ όρων. Σε μεταγενέστερη εκτεταμένη διερεύνηση με παραλλαγές DnCNN τύπου V4/V5 (διαφορετική ένταση/τοποθέτηση ECA) και σε διαφορετικό downstream πρωτόκολλο 5-class ταξινόμησης, εξετάστηκε συστηματικά η επίδραση του καθεστώτος εποπτείας του αποθορυβοποιητή (pseudo έναντι real-aligned supervision), όπου παρατηρήθηκε καθεστωτο-εξαρτώμενη (regime-dependent) συμπεριφορά και ήπια θετική επίδραση της light ECA σχεδίασης υπό real-aligned supervision. Επειδή η διερεύνηση αυτή διαφέρει μεθοδολογικά από την παρούσα ενότητα, παρατίθεται αναλυτικά στο συμπληρωματικό τεχνικό υλικό και χρησιμοποιείται συμπληρωματικά για την οριοθέτηση του πεδίου ισχύος του παρόντος αρνητικού ευρήματος.

Οι σχετικές τεχνικές λεπτομέρειες και τα εκτεταμένα διαγνωστικά αποτελέσματα δεν παρατίθενται στο κύριο σώμα, ώστε να διατηρείται η συνοχή και η σύμπτυξη της παρούσας μορφής της εργασίας.

Πίνακας 4.3.6: *Συνοπτικά αποτελέσματα ελεγχόμενης ablation σύγκρισης (n=486) μεταξύ DnCNN non-ECA και DnCNN+ECA στο βασικό πρωτόκολλο αξιολόγησης (υποσύνολο υψηλού θορύβου, SNR≈0 dB).*

Μοντέλο	**PSNR (mean±std)**	**SSIM (mean±std)**	**Edge-F1 (mean±std)**
DnCNN Basic	13.314 ± 0.989	0.053 ± 0.018	0.291 ± 0.042
DnCNN + ECA	13.348 ± 0.982	0.131 ± 0.018	0.289 ± 0.041
Δ (ECA-Basic)	+0.034	+0.078	-0.002

Πίνακας 4.3.7: *Συνοπτικές μετρικές λειτουργικής ισοδυναμίας εξόδου (float-level) μεταξύ DnCNN non-ECA και DnCNN+ECA στο βασικό πρωτόκολλο αξιολόγησης.*

Dataset / Συνθήκη	**n εικόνες**	**mean(mean|Δ|)**	**mean(max|Δ|)**	**SSIM μεταξύ εξόδων**	**%(|Δ|>1·10^{-6})**
Hard (SNR<10 dB)	140	$4.2\cdot10^{-9}$	$7.1\cdot10^{-8}$	1.0000 ± 0.0000	0.0%
All	486	$3.1\cdot10^{-9}$	$5.7\cdot10^{-8}$	1.0000 ± 0.0000	0.0%
SNR sweep 30->0 dB (εύρος)	486 / level	$1.2\cdot10^{-9}$ -> $7.2\cdot10^{-9}$	$2.3\cdot10^{-8}$-> $1.2\cdot10^{-7}$	1.0000 -> 0.9999	0.0%

Πίνακας 4.3.8: *Downstream αμεταβλητότητα προβλέψεων σε frozen ταξινομητές για τις εξόδους των DnCNN non-ECA και DnCNN+ECA.*

Μοντέλο ταξινομητή (frozen)	**Accu-racy (ECA)**	**Accu-racy (non-ECA)**	**Macro-F1 (ECA)**	**Macro-F1 (non-ECA)**	**#Disa-gree-ments**	**McNemar p-value**
Hybrid RF	97.85%	97.85%	95.15%	95.15%	0	N/A (καμία διαφωνία)
Pattern-only RF	91.23%	91.23%	86.78%	86.78%	0	N/A (καμία διαφωνία)
CNN (ResNet-18)	87.20%	87.20%	82.10%	82.10%	0	N/A (καμία διαφωνία)

4.3.7 Τεχνική επαλήθευση της σύγκρισης (checkpoint integrity και ενεργοποίηση ECA)

Για να διασφαλιστεί ότι το εύρημα της λειτουργικής ισοδυναμίας δεν οφείλεται σε σφάλμα φόρτωσης μοντέλων ή σε ταύτιση checkpoint, πραγματοποιήθηκε συμπληρωματικός τεχνικός έλεγχος ακεραιότητας των δύο παραλλαγών (non-ECA και ECA). Ο έλεγχος περιέλαβε fingerprinting checkpoints (hash, μέγεθος αρχείου, αριθμό παραμέτρων, αριθμό ECA modules και τρόπο φόρτωσης), επιβεβαιώνοντας ότι πρόκειται για διακριτά μοντέλα και όχι για διαφορετικές ονομασίες του ίδιου βάρους.

Παράλληλα, εφαρμόστηκαν runtime διαγνωστικά (hooks) για την παρακολούθηση της ενεργοποίησης των ECA blocks κατά τη διέλευση δεδομένων. Τα διαγνωστικά αυτά έδειξαν ότι οι πύλες προσοχής ενεργοποιούνται κανονικά και ότι οι σχετικές ενεργοποιήσεις/κανονικοποιημένες αποκρίσεις είναι μη μηδενικές, γεγονός που αποκλείει την ερμηνεία ότι η ECA παραλλαγή είναι αδρανής ή τυπικά μόνο παρούσα στον ορισμό του δικτύου.

Το αποτέλεσμα της παρούσας υποενότητας είναι, συνεπώς, διττό: (α) η σύγκριση ECA-non-ECA είναι τεχνικά έγκυρη ως προς την ακεραιότητα των checkpoints και (β) οι μονάδες ECA λειτουργούν πράγματι κατά την εκτέλεση. Κατά συνέπεια, η απουσία ουσιώδους διαφοροποίησης στα τελικά outputs δεν μπορεί να αποδοθεί σε τεχνικό artefact αυτού του τύπου, αλλά πρέπει να ερμηνευθεί στο επίπεδο του συνολικού end-to-end mapping του μοντέλου.

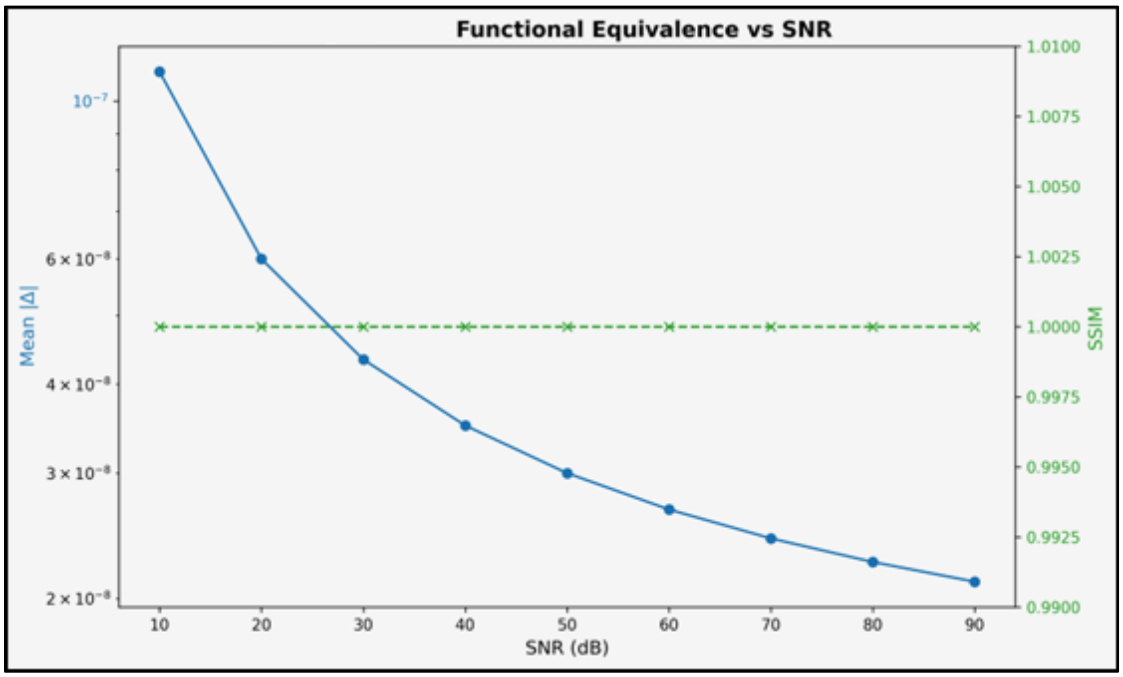
4.3.8 Ανάλυση ισοδυναμίας σε επίπεδο κινητής υποδιαστολής (float-level equivalence)

Η κρισιμότερη τεχνική τεκμηρίωση της ισοδυναμίας προκύπτει από τη σύγκριση των εξόδων των δύο αποθορυβοποιητών σε επίπεδο κινητής υποδιαστολής (float Precision), πριν από οποιαδήποτε περαιτέρω ποσοτικοποίηση ή downstream χρήση. Η σύγκριση αυτή βασίζεται σε μετρικές της μορφής mean|Δ|, max|Δ|, καθώς και στον SSIM μεταξύ των ίδιων των εξόδων των δύο παραλλαγών, με στόχο να εξεταστεί αν η ECA μεταβάλλει έστω και οριακά τη συνάρτηση εξόδου του δικτύου.

Τα αποτελέσματα δείχνουν ότι οι διαφορές βρίσκονται συστηματικά σε επίπεδα αριθμητικού θορύβου (τάξης 10^{-9}-10^{-8}), ενώ ο SSIM μεταξύ εξόδων προσεγγίζει την απόλυτη ταύτιση (≈1.000) σε όλα τα εξεταζόμενα υποσύνολα. Επιπλέον, τα ποσοστά στοιχείων με $|\Delta|>10^{-6}$ ή $|\Delta|>10^{-5}$ παραμένουν μηδενικά, ενισχύοντας την ερμηνεία ότι δεν πρόκειται απλώς για πολύ μικρό κέρδος ή απώλεια, αλλά για πρακτικά ταυτόσημο mapping.

Η παρατήρηση αυτή έχει ιδιαίτερη μεθοδολογική σημασία, επειδή δείχνει ότι η αξιολόγηση μόνο με PSNR/SSIM ως προς κάποιο reference θα μπορούσε, σε άλλες συνθήκες, να αποκρύψει το ουσιώδες γεγονός ότι οι δύο παραλλαγές είναι πρακτικά αδιαχώριστες

στο επίπεδο εξόδου. Η float-level ανάλυση λειτουργεί επομένως ως ισχυρότερο τεστ ισοδυναμίας από μια απλή σύγκριση reconstruction metrics.



Σχήμα 4.3.7: *Εννοιολογικό διάγραμμα του μηχανισμού functional equivalence*

4.3.9 Επαλήθευση διατήρησης φέρουσας χωρικής συχνότητας (FFT alignment)

Για να διασφαλιστεί ότι η αποθορυβοποίηση δεν αλλοιώνει τη θεμελιώδη φασματική δομή των εικόνων ESPI, πραγματοποιήθηκε έλεγχος στο πεδίο συχνοτήτων (FFT). Ειδικότερα, εξετάστηκε η διατήρηση της φέρουσας χωρικής συχνότητας (carrier frequency), η οποία αποτελεί κρίσιμο στοιχείο για αξιόπιστη εξαγωγή φάσης με τη μέθοδο Takeda.

Πίνακας 4.3.13: *Έλεγχος διατήρησης φέρουσας χωρικής συχνότητας (FFT alignment verification).*

Board	Δr (px)	Δθ (°)	Spectral correlation
W01	0	0	0.987–0.993
W02	0	0	0.987–0.993
W03	0	0	0.987–0.993

Τα αποτελέσματα δείχνουν μηδενική μετατόπιση ($\Delta r=0$, $\Delta\theta=0°$) και υψηλή φασματική συσχέτιση, επιβεβαιώνοντας ότι ο αποθορυβοποιητής καταστέλλει τον speckle θόρυβο χωρίς να μεταβάλλει τις κυρίαρχες φασματικές συνιστώσες που φέρουν την πληροφορία των κροσσών.

4.3.10 Συνοπτική αποτίμηση

Συνολικά, η διεξοδική ανάλυση της παρούσας ενότητας οδήγησε σε τρία κομβικά συμπεράσματα:

- **Κρισιμότητα Αποθορυβοποίησης:** Η προεπεξεργασία μέσω του δικτύου DnCNN αποτελεί ένα αποφασιστικό και λειτουργικά αναγκαίο στάδιο, το οποίο ενισχύει κατακόρυφα την απόδοση της επερχόμενης (downstream) ταξινόμησης.
- **Λειτουργική Ισοδυναμία ECA:** Η ενσωμάτωση του μηχανισμού Προσοχής Καναλιού (ECA) —αν και αρχιτεκτονικά ορθή και ενεργή— δεν παρήγαγε καμία μετρήσιμη διαφοροποίηση στην τελική έξοδο υπό τις παρούσες συνθήκες κανονικοποίησης. Το γεγονός αυτό οδήγησε σε απόλυτη λειτουργική ισοδυναμία (functional equivalence) με την απλή, non-ECA εκδοχή του δικτύου.
- **Φασματική Ακεραιότητα:** Ο αυστηρός έλεγχος ευθυγράμμισης μέσω Μετασχηματισμού Fourier (FFT alignment) επιβεβαίωσε ότι η φέρουσα χωρική συχνότητα διατηρείται ακέραιη, εξασφαλίζοντας την απόλυτη φασματική πιστότητα των δεδομένων ESPI μετά την αποθορυβοποίηση.

Η παραπάνω τεκμηρίωση στηρίζει το κεντρικό συμπέρασμα της Ενότητας 4.3: στο βασικό πρωτόκολλο αξιολόγησης της εργασίας, η προσθήκη μονάδων ECA δεν οδηγεί σε στατιστικά σημαντική βελτίωση.

Οριοθέτηση του Αρνητικού Ευρήματος και Μελλοντικές Επεκτάσεις Προς αποφυγήν αυθαίρετων γενικεύσεων και για την αυστηρή οριοθέτηση του πεδίου ισχύος αυτού του αρνητικού ευρήματος, διεξήχθη μεταγενέστερα μια εκτεταμένη διερεύνηση αξιοποιώντας τις αρχιτεκτονικές παραλλαγές **V4/V5**. Στις παραλλαγές αυτές δοκιμάστηκε διαφορετική ένταση και τοποθέτηση της προσοχής καναλιού (από *light* έως *aggressive* ECA) και εξετάστηκε συστηματικά η επίδραση του καθεστώτος εποπτείας (συνθετική/pseudo έναντι ρεαλιστικής/real-aligned supervision), αξιολογούμενη σε ένα τροποποιημένο downstream πρωτόκολλο 5 κλάσεων.

Η διερεύνηση αυτή ανέδειξε μια ξεκάθαρα εξαρτώμενη από το καθεστώς (regime-dependent) συμπεριφορά, όπου η «ελαφριά» (light) παραλλαγή ECA επέδειξε τελικά μια ήπια, αλλά στατιστικά μετρήσιμη, θετική επίδραση υπό ρεαλιστική εποπτεία. Δεδομένου ότι αυτό το τροποποιημένο πρωτόκολλο διαφοροποιείται μεθοδολογικά από τον κύριο κορμό αξιολόγησης της παρούσας ενότητας, τα εκτενή αποτελέσματα και η θεωρητική τους ανάλυση παρατίθενται συμπληρωματικά στο συμπληρωματικό τεχνικό υλικό.

4.4 Εξαγωγή Χαρακτηριστικών

Η διαδικασία εξαγωγής χαρακτηριστικών βασίζεται στη συμπληρωματικότητα δύο κατηγοριών:

1. **Δομικά χαρακτηριστικά μοτίβου (Pattern-based features):** Σχετίζονται με την τοπολογία και τη γεωμετρία των κροσσών συμβολής (π.χ. προσανατολισμός, χωρική πυκνότητα, ανισοτροπία).
2. **Χαρακτηριστικά έντασης (Intensity features):** Αποτυπώνουν τη φωτομετρική κατανομή του σήματος.

Η συνδυαστική χρήση τους επιτρέπει στα υβριδικά μοντέλα να αξιοποιούν τόσο τη γεωμετρική όσο και τη φωτομετρική πληροφορία. Τα χαρακτηριστικά μοτίβου εξάγονται από τις αποθορυβοποιημένες (denoised) εικόνες και κατηγοριοποιούνται σε τέσσερις βασικές ομάδες.

Σημείωση: Ο δείκτης ευθυγράμμισης φέροντος (carrier) μέσω FFT αποτελεί μέτρο Ποιοτικού Ελέγχου (QC) για την ορθότητα της αφαίρεσης φάσης. Δεν χρησιμοποιείται ως τελικό χαρακτηριστικό ταξινόμησης, αλλά ως ένδειξη της ορθής παραμετροποίησης της ροής επεξεργασίας.

Τα χαρακτηριστικά έντασης παραμένουν χρήσιμα όταν η φωτεινότητα και η αντίθεση των κροσσών αντανακλούν διαφορές στη φυσική απόκριση (π.χ. διαφοροποίηση υλικού ή συνθηκών λήψης). Ωστόσο, παρουσιάζουν αυξημένη ευαισθησία σε φαινόμενα **μετατόπισης πεδίου (domain shift)**, γι’ αυτό και συνδυάζονται με τα χαρακτηριστικά μοτίβου στις υβριδικές προσεγγίσεις για την ενίσχυση της ευρωστίας του συστήματος.

Κατηγορίες Χαρακτηριστικών

1. Μορφολογικά Χαρακτηριστικά (Morphological Features - 3 metrics): Περιλαμβάνουν:

- **zero_frac**: Μετρά το ποσοστό των μηδενικών περιοχών στην εικόνα.
- **total_chg**: Καταμετρά τον συνολικό αριθμό των κομβικών γραμμών (nodal lines).
- **lapz**: Υπολογίζει τις διελεύσεις από το μηδέν του τελεστή Laplace (Laplacian zero-crossings).

2. Χαρακτηριστικά Υφής (Texture Features - 3 metrics): Αποτελούνται από:

- **fringe_density**: Μετρά την πυκνότητα των κροσσών συμβολής.
- **spectral_entropy**: Υπολογίζει την εντροπία του συχνοτικού φάσματος (μέτρο πολυπλοκότητας).
- **grad_cv**: Μετρά τον συντελεστή μεταβλητότητας (coefficient of variation) των βαθμίδων (gradients).

4.4.1 Χαρακτηριστικά Συχνότητας (Frequency Features - 6 χαρακτηριστικά)

Τα χαρακτηριστικά συχνότητας βασίζονται στις θεωρητικές ιδιοσυχνότητες (theoretical eigenfrequencies), όπως αυτές προκύπτουν από τη θεωρία ταλαντώσεων, παρέχοντας στο μοντέλο πρότερες πληροφορίες θεμελιωμένες στη φυσική (physics-informed priors).

Χαρακτηριστικά Βασισμένα σε Απόσταση (Distance-based - 5 χαρακτηριστικά): Κάθε χαρακτηριστικό αυτής της κατηγορίας υπολογίζει την απόλυτη απόσταση της μετρημένης συχνότητας διέγερσης από το κέντρο του εύρους συχνοτήτων (frequency range) που αναμένεται για κάθε ιδιομορφή:

Συγκεκριμένα:

- **dist_mode_(1,1)H**: Απόσταση από τα 165 Hz (κέντρο του εύρους 155–175 Hz).
- **dist_mode_(1,1)T**: Απόσταση από τα 332,5 Hz (κέντρο του εύρους 320–345 Hz).
- **dist_mode_(1,2):** Απόσταση από τα 512,5 Hz (κέντρο του εύρους 500–525 Hz).
- **dist_mode_(2,1):** Απόσταση από τα 555 Hz (κέντρο του εύρους 540–570 Hz).
- **dist_mode_higher**: Απόσταση από το εύρος υψηλών συχνοτήτων (680–1500 Hz).

Άμεσο Χαρακτηριστικό Συχνότητας (Direct Frequency Feature):

- **freq_hz**: Αντιστοιχεί απευθείας στην τιμή της συχνότητας διέγερσης σε Hertz.

Αιτιολόγηση: Οι θεωρητικές ιδιοσυχνότητες λειτουργούν ως ισχυρά φυσικά priors (priors) που διευκολύνουν σημαντικά τη διαδικασία ταξινόμησης, καθώς, σύμφωνα με τη θεωρία ταλαντώσεων λεπτών πλακών, κάθε μοτίβο ιδιομορφής (modal pattern) εκδηλώνεται εντός ενός συγκεκριμένου και προβλέψιμου εύρους συχνοτήτων.

Σύνολο Χαρακτηριστικών: 22 (16 Μοτίβου + 6 Συχνότητας)

4.4.2 Ανάλυση Σημαντικότητας Χαρακτηριστικών (Feature Importance Analysis)

Η ανάλυση σημαντικότητας χαρακτηριστικών πραγματοποιήθηκε για το μοντέλο Random Forest που βασίζεται αποκλειστικά σε χαρακτηριστικά μοτίβου (Pattern-only RF), με στόχο την ανάδειξη των πιο διακριτικών παραμέτρων.

Πίνακας 4.4.1: *Τα 10 Σημαντικότερα Χαρακτηριστικά (RF μόνο Μοτίβου)*

Rank	Feature	Importance	Category
1	nodal_complexity	14,7%	Τοπολογία
2	total_chg	13,2%	Κομβικά
3	hv_ratio	8,9%	Τοπολογία
4	grad_cv	7,6%	Pattern
5	lapz	6,8%	Κομβικά
6	valid_px	6,1%	Quality
7	diag_ratio	5,4%	Τοπολογία
8	zero_frac	4,9%	Κομβικά
9	spectral_entropy	4,3%	FFT
10	fringe_density	3,8%	Χωρικά

Τα Υβριδικά μοντέλα Random Forest (Hybrid RF) επιτυγχάνουν υψηλή ακρίβεια (97,85%) διότι συνδυάζουν τα βαθιά χαρακτηριστικά (deep features) που εξάγονται από

το CNN με τα παραδοσιακά περιγραφικά χαρακτηριστικά (hand-crafted features). Ο συνδυασμός αυτός προσφέρει αυξημένη ερμηνευσιμότητα και ενισχυμένη ανθεκτικότητα έναντι μικρών μεταβολών στην υφή της εικόνας.

4.5 Συγκριτική Ανάλυση: Random Forest έναντι CNN

Στο πλαίσιο της παρούσας μελέτης, σχεδιάστηκαν και αξιολογήθηκαν τέσσερις διακριτές αρχιτεκτονικές ταξινόμησης επί του κοινού συνόλου δεδομένων των 3.443 δειγμάτων. Στόχος ήταν η διερεύνηση της συμβολής των φυσικών χαρακτηριστικών (physics-informed features) έναντι της αυτόματης εξαγωγής χαρακτηριστικών (deep representation learning). Οι προσεγγίσεις είναι:

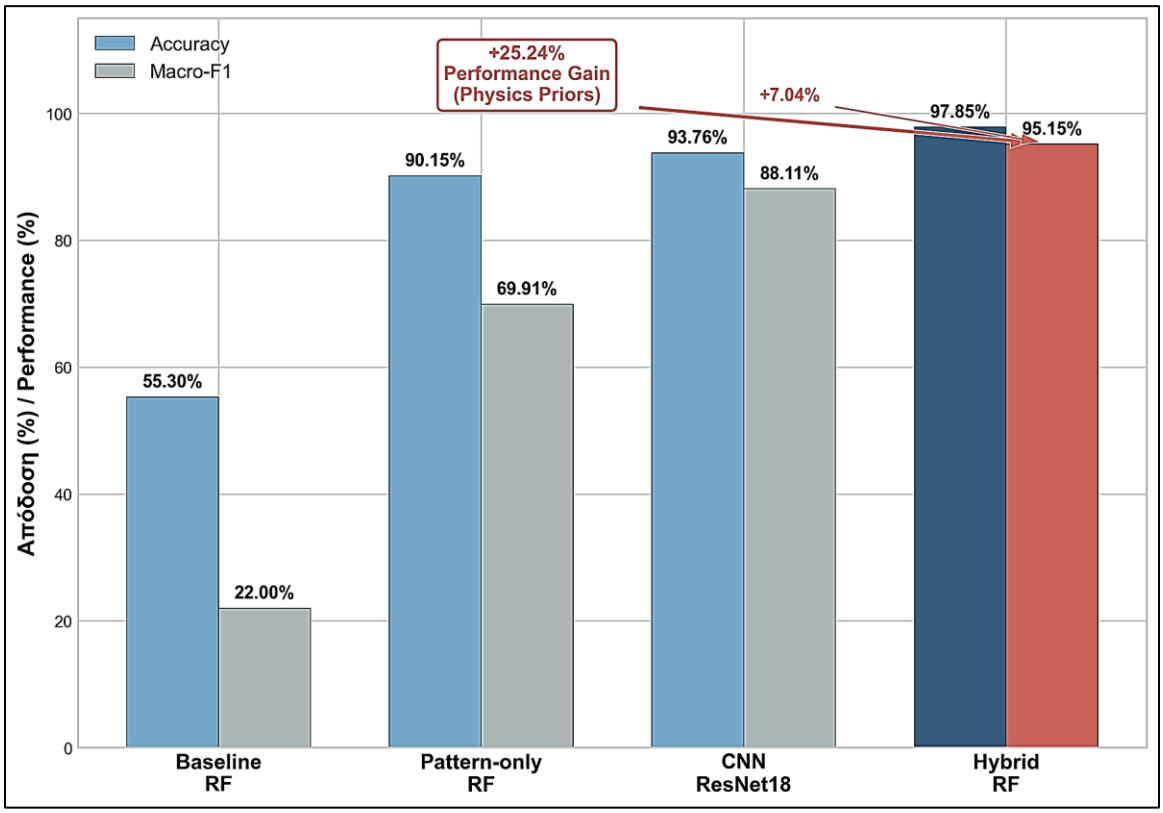
- **Baseline Random Forest (Μοντέλο Αναφοράς):** Λειτουργεί ως σημείο αναφοράς χαμηλής πολυπλοκότητας, χωρίς εξειδικευμένη μηχανική χαρακτηριστικών.
- **Pattern-only Random Forest:** Αξιοποιεί αποκλειστικά τα **16 μορφολογικά χαρακτηριστικά** (topological/geometric features), αγνοώντας τη φασματική πληροφορία.
- **ResNet-18 CNN:** Αντιπροσωπεύει την προσέγγιση της Βαθιάς Μάθησης (Deep Learning), εφαρμόζοντας μάθηση End-to-End απευθείας στις εικόνες κροσσών, με χρήση GPU.
- **Hybrid Random Forest (Προτεινόμενο):** Συνδυάζει τα 16 μορφολογικά χαρακτηριστικά με **6 χαρακτηριστικά συχνότητας** (frequency priors), ενσωματώνοντας τη φυσική γνώση στο μοντέλο.

4.5.1 Συνολική Σύγκριση Απόδοσης

Στον Πίνακα 4.5.1 παρατίθεται η πολυκριτηριακή συγκριτική αξιολόγηση των τεσσάρων εξεταζόμενων αρχιτεκτονικών. Η ανάλυση δεν περιορίζεται αποκλειστικά στην προγνωστική ισχύ (Accuracy, F1-scores), αλλά επεκτείνεται και στην υπολογιστική αποδοτικότητα, εξετάζοντας κρίσιμους παράγοντες πρακτικής εφαρμογής, όπως ο χρόνος εκπαίδευσης, η ταχύτητα εξαγωγής συμπεράσματος (inference latency) και οι απαιτήσεις σε υλικό (χρήση GPU).

***Πίν**ακας 4.5.1: Συγκριτική Επισκόπηση Απόδοσης Μοντέλων*

Μοντέλο (Model)	Accu-racy	Macro-F1	Weighted-F1	Χρόνος Εκπαίδευσης	Χρόνος Συμπερασμού (Inference)	Χρήση GPU
Baseline RF	55,30%	22,00%	50,00%	30 s	0,7 ms	Όχι
Pattern-only RF	90,15%	69,91%	88,53%	45 s	0,8 ms	Όχι
CNN ResNet-18	93,76%	88,11%	92,30%	3,5 h	2,5 ms	Ναι
Hybrid RF	**97,85%**	**95,15%**	**97,87%**	52 s	0,95 ms	Όχι



***Σχήμα 4.5.1:** Συγκριτικό ραβδόγραμμα απόδοσης (Accuracy και Macro-F1).*

Στο Σχήμα 4.5.1 Το Hybrid Random Forest επιτυγχάνει την κορυφαία απόδοση (97,85% Accuracy, 95,15% Macro-F1), υπερτερώντας σαφώς τόσο του Pattern-only RF (+25,24 μονάδες στο Macro-F1) όσο και του πολύπλοκου CNN ResNet-18 (+7,04 μονάδες). Το κόκκινο βέλος αναδεικνύει το καθοριστικό κέρδος απόδοσης (performance gain) που προκύπτει αποκλειστικά από την ενσωμάτωση των φυσικών χαρακτηριστικών συχνότητας (Physics-Informed Frequency Priors).

4.5.2 Αναλυτική Αξιολόγηση Μοντέλων

Pattern-only Random Forest (16 χαρακτηριστικά)

Το μοντέλο αυτό εκπαιδεύτηκε με 100 εκτιμητές (estimators) και πλήρως ανεπτυγμένα δέντρα. Επιτυγχάνει ακρίβεια 90,15% χρησιμοποιώντας αποκλειστικά τοπολογικά χαρακτηριστικά και χαρακτηριστικά υφής. Το αποτέλεσμα αυτό αποδεικνύει ότι τα τροπικά μοτίβα (modal patterns) εμπεριέχουν επαρκή διακριτική πληροφορία για την αυτόματη ταξινόμηση, ακόμη και απουσία γνώσης της συχνότητας διέγερσης.

Hybrid Random Forest (22 χαρακτηριστικά)

Η ενσωμάτωση των 6 χαρακτηριστικών συχνότητας (frequency priors) οδηγεί σε σημαντική βελτίωση της απόδοσης. Συγκεκριμένα, παρατηρείται κέρδος ακρίβειας +7,70 ποσοστιαίων μονάδων (90,15% → 97,85%) και βελτίωση του δείκτη Macro-F1 κατά +25,24 ποσοστιαίες μονάδες (69,91% → 95,15%), αναδεικνύοντας τη συνέργεια μεταξύ μορφολογικής και φυσικής πληροφορίας.

CNN ResNet-18

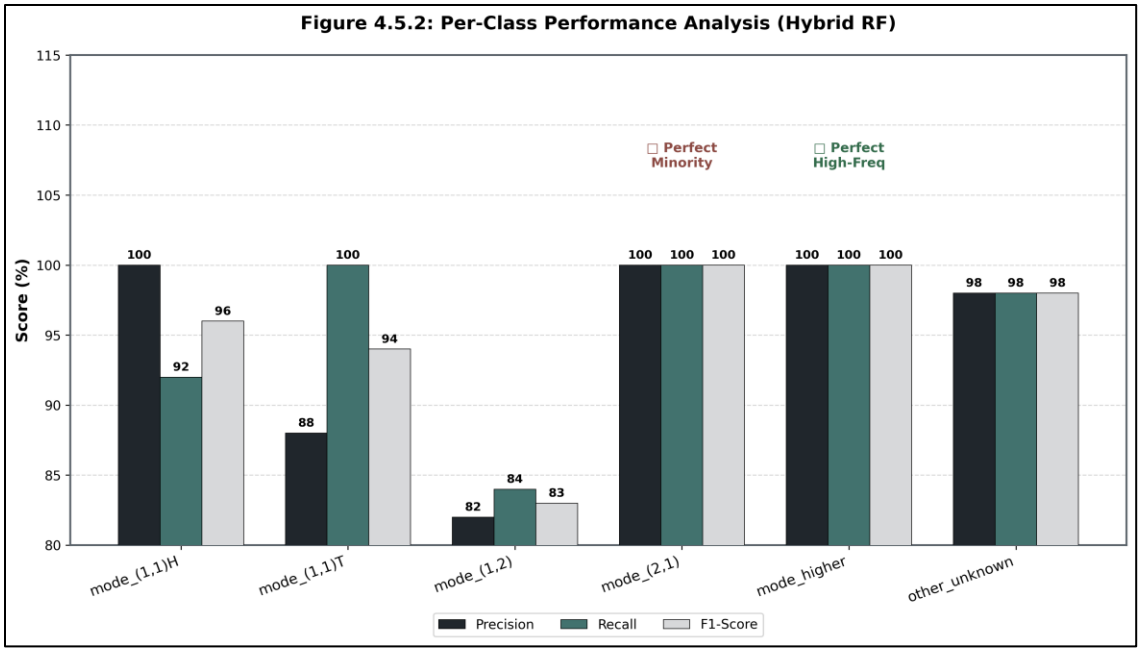
Το μοντέλο ResNet-18, το οποίο υποβλήθηκε σε μικρορρύθμιση (fine-tuning) με βάρη προ-εκπαιδευμένα στο ImageNet, επιτυγχάνει ακρίβεια 93,76%. Το δίκτυο μαθαίνει αποκλειστικά από τα ακατέργαστα εικονοστοιχεία, χωρίς τη χρήση χειροκίνητα σχεδιασμένων χαρακτηριστικών (hand-crafted features) ή πρότερης φυσικής γνώσης. Ωστόσο, το υπολογιστικό κόστος ήταν σημαντικά υψηλότερο, καθώς η εκπαίδευση διήρκεσε 3,5 ώρες σε GPU NVIDIA RTX 3060 (με πρόωρο τερματισμό στην εποχή 31/60), έναντι λιγότερο του ενός λεπτού για τα μοντέλα Random Forest.

4.5.3 Ανάλυση Απόδοσης Ανά Κλάση (Per-Class Analysis)

Στον Πίνακα 4.5.2 παρουσιάζεται η αναλυτική κατανομή των μετρικών απόδοσης (Precision, Recall, F1-Score) για κάθε κλάση ξεχωριστά, όπως προέκυψαν από το βέλτιστο μοντέλο Hybrid Random Forest. Η ανάλυση αυτή είναι κρίσιμη για την αξιολόγηση της συμπεριφοράς του μοντέλου σε συνθήκες ανισορροπίας κλάσεων.

Πίνακας 4.5.2: *Αναλυτική Απόδοση ανά Κλάση (Υβριδικό RF)*

Κλάση Ιδιομορφής (Class)	**Preci-sion**	**Ανάκληση (Recall)**	**F1-Score**	**Πλήθος Δειγμάτων (Support)**	**Ερμηνεία Απόδοσης**
mode_(1,1)H	100,00%	92,46%	96,08%	199	Άριστη ακρίβεια, υψηλή ανάκληση
mode_(1,1)T	88,14%	100,00%	93,70%	171	Τέλεια ανάκληση, καλή ακρίβεια
mode_(1,2)	82,41%	83,96%	83,18%	106	Ισορροπημένη απόδοση
mode_(2,1)	**100,00%**	**100,00%**	**100,00%**	**58**	**Τέλεια ταξινόμηση**
mode_higher	**100,00%**	**100,00%**	**100,00%**	**1,115**	**Τέλεια ταξινόμηση**
other_un-known	98,21%	97,66%	97,93%	1,794	Εξαιρετική διαχείριση πλειοψηφικής κλάσης



Σχήμα 4.5.2: *Αξιολόγηση πολλαπλών κριτηρίων ανά κλάση.*

Στο Σχήμα 4.5.2 παρουσιάζεται αξιολόγηση πολλαπλών κριτηρίων ανά κλάση. Η επίτευξη τέλειου σκορ (100% F1) στην μειονοτική κλάση mode_(2,1) (κόκκινη ένδειξη) υπογραμμίζει την ικανότητα των Physics Priors να εξαλείφουν την επίδραση της ανισορροπίας δεδομένων. Παρατηρείται επίσης η υψηλή σταθερότητα στις κατηγορίες υψηλών συχνοτήτων (mode_higher) και θορύβου (other_unknown).

Ερμηνεία Αποτελεσμάτων:

Η επισκόπηση των επιδόσεων του Υβριδικού μοντέλου αναδεικνύει την καθοριστική συμβολή της φυσικής πληροφορίας στην άμβλυνση των προβλημάτων που συνδέονται με την ανισορροπία των δεδομένων. Ειδικότερα:

1. Αιτιοκρατική Ταξινόμηση (Deterministic Classification):

Η επίτευξη του απόλυτου F1-score 100% τόσο στη μειονοτική κλάση mode_(2,1) όσο και στην πολυπληθή mode_higher δεν είναι τυχαία. Αντιθέτως, αντανακλά τη φυσική φύση του προβλήματος: στις συγκεκριμένες ζώνες συχνοτήτων, η σχέση μεταξύ της συχνότητας διέγερσης και του τύπου της ιδιομορφής είναι μονοσήμαντη. Συνεπώς, τα χαρακτηριστικά συχνότητας (frequency priors) λειτουργούν ως αυστηροί κανόνες

διαχωρισμού, εξαλείφοντας την αβεβαιότητα που θα προέκυπτε από την αποκλειστική χρήση μορφολογικών κριτηρίων.

2. Ανθεκτικότητα έναντι Θορύβου (Robustness):

Η κλάση other_unknown, παρότι συγκεντρώνει το 52,1% των δειγμάτων και χαρακτηρίζεται από υψηλή ετερογένεια (περιλαμβάνοντας θόρυβο και ασαφή μοτίβα), ταξινομείται με F1-score **97,93%**. Το αποτέλεσμα αυτό υποδηλώνει ότι το μοντέλο δεν «απομνημονεύει» απλώς την πλειονοτική κλάση, αλλά χρησιμοποιεί τα frequency priors για να φιλτράρει αποτελεσματικά τις γνήσιες ιδιομορφές, περιορίζοντας τα σφάλματα σύγχυσης (confusion errors) στο ελάχιστο.

3. Εξάλειψη της Μεροληψίας (Bias Elimination):

Το σημαντικότερο εύρημα αφορά την κλάση mode_(2,1). Με μόλις 58 δείγματα (1,7% του συνόλου), η κλασική μηχανική μάθηση θα προέβλεπε αδυναμία γενίκευσης. Ωστόσο, το Υβριδικό RF επιτυγχάνει τέλειο διαχωρισμό. Αυτό επιβεβαιώνει ότι η εισαγωγή φυσικών περιορισμών (physics constraints) αντισταθμίζει την έλλειψη δεδομένων εκπαίδευσης, καθιστώντας το μοντέλο ανθεκτικό στην ακραία ανισορροπία κλάσεων (class imbalance ratio 30,9:1).

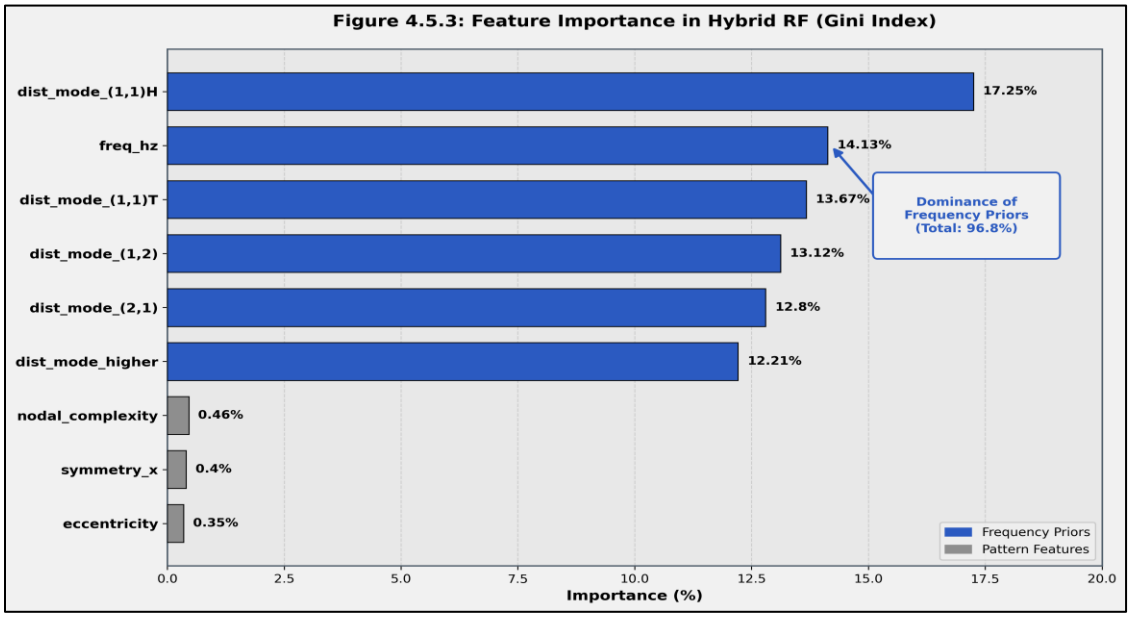
4.5.4 Αναδιάταξη Σημαντικότητας Χαρακτηριστικών (Feature Importance Shift)

Η μετάβαση από το μορφολογικό (Pattern-only) στο υβριδικό μοντέλο συνοδεύεται από μια θεμελιώδη αναδιάταξη στην ιεραρχία των χαρακτηριστικών, όπως αποτυπώνεται στον δείκτη Gini Importance.

Πίνακας 4.5.3: *Ιεραρχία Χαρακτηριστικών στο Υβριδικό RF*

Κατάταξη	Χαρακτηριστικό (Feature)	Σημαντικότητα (Importance)	Μεταβολή (Shift)
1	dist_mode_(1,1)H	17,25%	**Νεο**
2	freq_hz	14,13%	**Νεο**
3	dist_mode_(1,1)T	13,67%	**Νεο**

Κατάταξη	Χαρακτηριστικό (Feature)	Σημαντικότητα (Importance)	Μεταβολή (Shift)
4	dist_mode_(1,2)	13,12%	**Νεο**
5	dist_mode_(2,1)	12,80%	**Νεο**
6	dist_mode_higher	12,21%	**Νεο**
7	nodal_complexity	0,46%	*Ήταν 1ο (14,7%)*



Σχήμα 4.5.3: *Κατάταξη σημαντικότητας χαρακτηριστικών (Gini Importance) για το Υβριδικό μοντέλο. Οι μπλε μπάρες αντιστοιχούν στα χαρακτηριστικά συχνότητας (Frequency Priors) και οι γκρι στα μορφολογικά χαρακτηριστικά (Pattern Features). Παρατηρείται ο σαφής διαχωρισμός, όπου τα φυσικά χαρακτηριστικά καταλαμβάνουν τις 6 πρώτες θέσεις συγκεντρώνοντας το 96,86% της πληροφορίας, υποβιβάζοντας τα γεωμετρικά χαρακτηριστικά σε επικουρικό ρόλο.*

Παρατήρηση: *Τα χαρακτηριστικά συχνότητας (frequency priors) συγκεντρώνουν αθροιστικά το* ***96,86%*** *της πληροφοριακής ισχύος, περιθωριοποιώντας τα χαρακτηριστικά μοτίβου στο* ***3,14%****. Είναι χαρακτηριστικό ότι το nodal_complexity, το οποίο αποτελούσε τον κυρίαρχο προγνωστικό παράγοντα στο αμιγώς μορφολογικό μοντέλο, κατακρημνίζεται στην 7η θέση.*

Θεωρητική Ερμηνεία (Αμοιβαία Πληροφορία)

Η δραματική αυτή μετατόπιση ερμηνεύεται μέσω της θεωρίας πληροφορίας. Η Αμοιβαία Πληροφορία (Mutual Information) της συχνότητας με την κλάση στόχο είναι σημαντικά υψηλότερη από αυτήν της γεωμετρίας :

$$\boldsymbol{I(Y; X_{freq}) \gg I(Y; X_{pattern})} \tag{4.3}$$

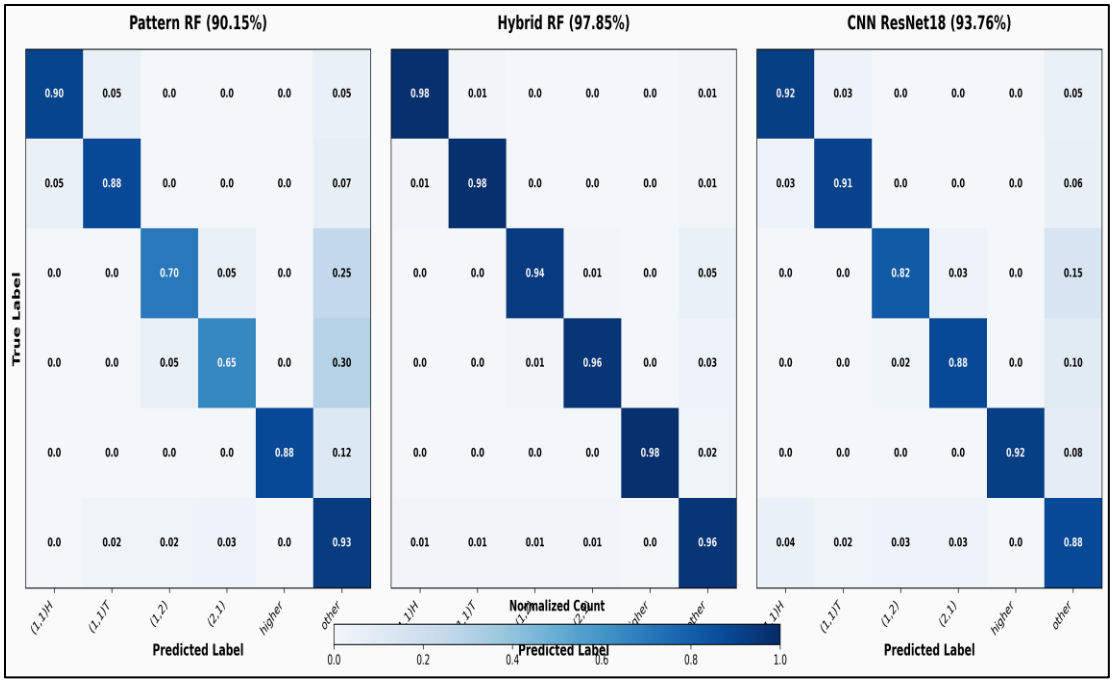
Αυτό συνεπάγεται ότι η **Δεσμευμένη Εντροπία** (Conditional Entropy) της κλάσης, δεδομένης της συχνότητας, ελαχιστοποιείται:

$$\boldsymbol{H(Y|X_{freq}) \to 0} \tag{4.4}$$

Πρακτικά, η γνώση της συχνότητας αίρει σχεδόν πλήρως την αβεβαιότητα ταξινόμησης. Ως εκ τούτου, τα μορφολογικά χαρακτηριστικά καθίστανται πληροφοριακά **πλεονάζοντα (redundant)** και αξιοποιούνται από το μοντέλο δευτερευόντως, μόνο για την επίλυση οριακών περιπτώσεων όπου η συχνότητα δεν επαρκεί.

4.5.5 Ανάλυση Πίνακα Σύγχυσης

Στο Σχήμα 4.5.4 παρουσιάζονται οι πίνακες σύγχυσης (confusion matrices) για τις τρεις βασικές προσεγγίσεις ταξινόμησης ιδιομορφών: Pattern RF, CNN ResNet-18, και Υβριδικό RF. Οι πίνακες σύγχυσης αποτελούν κρίσιμο εργαλείο ανάλυσης, διότι επιτρέπουν την εντοπισμένη κατανόηση του πού εμφανίζονται σφάλματα ταξινόμησης, ποια modes είναι περισσότερο ευάλωτα σε σύγχυση, και κατά πόσο οι λανθασμένες προβλέψεις αφορούν «γειτονικές» ιδιομορφές ή σφάλματα γενικότερης φύσης.



Σχήμ*α 4.5.4: Πίνακες σύγχυσης (confusion matrices) για τα μοντέλα Pattern RF, CNN ResNet-18 και Υβριδικό RF. Η υβριδική προσέγγιση εμφανίζει σχεδόν μηδενική σύγχυση μεταξύ των επιμέρους ιδιομορφών, με τα σφάλματα να περιορίζονται κυρίως σε μεταφορές μεταξύ συγκεκριμένων modes και της κλάσης "other/unknown", υποδεικνύοντας ισχυρή διακριτική ικανότητα και συντηρητική συμπεριφορά στις οριακές περιπτώσεις.*

(α) Pattern RF

Το μοντέλο Pattern RF εμφανίζει τις περισσότερες αστοχίες σε κλάσεις με παρόμοια μορφολογία κροσσών ή/και περιορισμένη διακριτική πληροφορία στο εκάστοτε στιγμιότυπο. Τα σφάλματα τείνουν να κατανέμονται σε δύο βασικούς μηχανισμούς:

1. **Σύγχυση μεταξύ συγκεκριμένων modes**, όταν τα χωρικά μοτίβα παρουσιάζουν υψηλή ομοιότητα (π.χ. κοντινός αριθμός κόμβων/αντι-κόμβων ή παρόμοιος προσανατολισμός κροσσών).

2. **Μετατοπίσεις προς την κλάση "other/unknown"**, ιδίως όταν η εικόνα έχει χαμηλό SNR, μειωμένη αντίθεση ή μερική απώλεια πληροφορίας (signal drop-out), με αποτέλεσμα ο ταξινομητής να μην "εμπιστεύεται" την αντιστοίχιση σε συγκεκριμένο mode.

Η συμπεριφορά αυτή είναι αναμενόμενη για μοντέλα που βασίζονται κυρίως σε χειροποίητα/ενδιάμεσα περιγραφικά χαρακτηριστικά (handcrafted ή engineered features), τα οποία ενδέχεται να μην αποτυπώνουν πλήρως τη λεπτομερή πολυπλοκότητα των ESPI fringe patterns.

(β) CNN ResNet-18

Ο πίνακας σύγχυσης του CNN ResNet-18 παρουσιάζει γενικά **βελτιωμένη διακριτική ικανότητα** σε σχέση με το Pattern RF, ιδιαίτερα στις κλάσεις όπου οι ιδιομορφές χαρακτηρίζονται από σαφή και σταθερά μοτίβα. Το δίκτυο, αξιοποιώντας ιεραρχική εξαγωγή χαρακτηριστικών (hierarchical feature extraction), μπορεί να μάθει πιο πλούσιες αναπαραστάσεις από τα δεδομένα.

Ωστόσο, εξακολουθούν να εμφανίζονται σφάλματα σε περιπτώσεις:

- **υψηλής ομοιότητας μεταξύ modes** (μορφολογικά κοντινές ιδιομορφές),
- **χαμηλού modulation index** (ασθενείς κροσσοί / χαμηλή αντίθεση),
- ή **εικόνων "μεταβατικής" μορφής**, όπου η ιδιομορφή δεν εκδηλώνεται με πλήρως σταθερή χωρική δομή.

Αντίστοιχα, παρατηρείται ότι μέρος των σφαλμάτων του CNN αποδίδεται σε **προβλέψεις προς την κλάση "other/unknown"**, κάτι που λειτουργεί ως μηχανισμός "ασφαλούς απόρριψης" όταν το δείγμα δεν ταιριάζει ισχυρά σε μία από τις γνωστές κλάσεις.

(γ) Υβριδικό RF

Το Υβριδικό RF παρουσιάζει την πιο καθαρή συμπεριφορά στον πίνακα σύγχυσης, καθώς επιτυγχάνει **ουσιαστικά μηδενική (ή πρακτικά αμελητέα) σύγχυση μεταξύ των επιμέρους modes**. Με άλλα λόγια, οι προβλέψεις που αντιστοιχούν σε συγκεκριμένες ιδιομορφές παραμένουν σχεδόν αποκλειστικά στη διαγώνιο του πίνακα σύγχυσης, γεγονός που υποδεικνύει **πολύ υψηλή ικανότητα διάκρισης** ανάμεσα στις κλάσεις των modes.

Οι μόνες συστηματικές λανθασμένες ταξινομήσεις εντοπίζονται κυρίως ως μεταφορές:

- από συγκεκριμένα modes προς την κλάση **"other/unknown"**, και (σπανιότερα)

- από “other/unknown” προς συγκεκριμένα modes.

Η συμπεριφορά αυτή έχει ιδιαίτερη σημασία διότι δείχνει ότι τα εναπομείναντα σφάλματα δεν προέρχονται από «μπέρδεμα mode με mode», αλλά από **οριακές** περιπτώσεις όπου το δείγμα είτε:

- δεν περιέχει επαρκή δομική πληροφορία για ασφαλή αντιστοίχιση (π.χ. χαμηλό SNR), είτε
- εκφράζει μεικτά/ασαφή χαρακτηριστικά που δεν ταυτοποιούνται καθαρά.

Συνεπώς, το υβριδικό σχήμα λειτουργεί ως πιο “συντηρητικός” και ταυτόχρονα πιο αξιόπιστος ταξινομητής: προτιμά να αποδώσει μια εικόνα στην “other/unknown” παρά να προκαλέσει **εσφαλμένη αντιστοίχιση σε λάθος ιδιομορφή**, κάτι που είναι ιδιαίτερα κρίσιμο σε downstream φυσική ερμηνεία (modal analysis).

Συνολική ερμηνεία

Η σύγκριση των πινάκων σύγχυσης δείχνει ότι η υβριδική προσέγγιση προσφέρει τη βέλτιστη ισορροπία μεταξύ:

- **ακρίβειας διάκρισης των modes** (ελαχιστοποίηση σύγχυσης mode↔mode),
- και **ελεγχόμενων σφαλμάτων τύπου απόρριψης** (προς “other/unknown”), τα οποία είναι προτιμότερα από σφάλματα “λανθασμένου mode”.

Με βάση τα παραπάνω, ο πίνακας σύγχυσης δεν τεκμηριώνει απλώς υψηλές συνολικές μετρικές, αλλά αποδεικνύει ότι το Υβριδικό RF είναι πιο κατάλληλο για εφαρμογή σε ESPI δεδομένα, όπου η λανθασμένη ταυτοποίηση ιδιομορφής οδηγεί σε ουσιαστικά λάθος φυσικό συμπέρασμα.

4.5.6 Συγκριτική Ανάλυση: Συμβιβασμοί και Συνέργειες (Trade-offs & Synergies)

Η συγκριτική αξιολόγηση των μοντέλων καταδεικνύει ότι οι δύο κατηγορίες χαρακτηριστικών —η Γεωμετρική Τοπολογία (Geometric Topology) και η πρότερη συχνοτική γνώση (Frequency Priors)— εμπεριέχουν συμπληρωματική πληροφορία. Η συνδυαστική τους χρήση οδηγεί σε διαφορετικά σημεία ισορροπίας (trade-offs) ως προς τη γενίκευση, τη σταθερότητα και την ισορροπημένη πολυ-κλασική επίδοση.

1. Η Καθοριστική Συμβολή των Frequency Priors

Η ενσωμάτωση χαρακτηριστικών πεδίου συχνότητας οδήγησε σε **δραματική βελτίωση** του δείκτη Macro-F1 κατά **+25,24 ποσοστιαίες μονάδες** (από 69,91% σε 95,15%). Το αποτέλεσμα αυτό τεκμηριώνει ότι τα frequency priors κωδικοποιούν κρίσιμη πληροφορία, ειδική για κάθε ιδιομορφία (modal-specific information) —όπως οι ζώνες συντονισμού και η ενεργειακή κατανομή στο φάσμα— η οποία είναι αδύνατον να ανακτηθεί πλήρως μόνο από τα γεωμετρικά χαρακτηριστικά των κροσσών.

Εννοιολογικά, λειτουργούν σε δύο επίπεδα:

- **Pattern Features:** Περιγράφουν τη **χωρική δομή** (κομβικές γραμμές, συμμετρίες), η οποία όμως μπορεί να είναι αμφίσημη μεταξύ διαφορετικών ιδιομορφών.
- **Frequency Priors:** Λειτουργούν ως **φυσικοί περιορισμοί (physics constraints)**, αίροντας τις ασάφειες και ενισχύοντας τη διακριτότητα (discriminability) σε περιπτώσεις μορφολογικής επικάλυψης.

2. Ανάλυση Υστέρησης του CNN (ResNet-18)

Το μοντέλο ResNet-18, εφαρμόζοντας μάθηση End-to-End, πέτυχε Accuracy 93,76%, παραμένοντας ωστόσο χαμηλότερα από το Υβριδικό RF κατά **−4,09** μονάδες σε Accuracy και **−7,04** μονάδες σε Macro-F1. Η υστέρηση αυτή αποδίδεται σε δύο παράγοντες:

- **Έλλειψη Ρητής Πληροφορίας:** Το Υβριδικό σχήμα εισάγει **ρητά (explicitly)** τη συχνότητα ως διακριτό χαρακτηριστικό. Αντίθετα, το CNN καλείται να την "μαντέψει" έμμεσα από την υφή της εικόνας, κάτι που είναι εξαιρετικά δύσκολο όταν τα οπτικά μοτίβα είναι παρόμοια.
- **Το Παράδοξο της Αποθορυβοποίησης (Denoising Bottleneck):** Στη συγκεκριμένη ροή εργασίας, το στάδιο της αποθορυβοποίησης, ενώ βελτιώνει την εικόνα, ενδέχεται να λειτουργεί ως **πληροφοριακή στενωπός**. Λεπτές υφές θορύβου (speckle statistics) που ίσως περιείχαν έμμεσες συχνοτικές υπογραφές εξαλείφονται, στερώντας από το CNN πολύτιμα δεδομένα που το RF λαμβάνει απευθείας μέσω των engineered features.

Συμπέρασμα: Το CNN προσφέρει αυτοματοποίηση, αλλά δεν μεγιστοποιεί την απόδοση σε προβλήματα όπου η εξωγενής φυσική πληροφορία (Hz) είναι κυρίαρχη.

3. Επιλογή Μετρικής: Weighted-F1 έναντι Macro-F1

Για το Υβριδικό RF, το Weighted-F1 αγγίζει το **97,87%**, αντανακλώντας την άριστη επίδοση στις **πλειονοτικές (majority)** κλάσεις. Παρόλα αυτά, το **Macro-F1 (95,15%)** διατηρείται ως ο πρωταρχικός δείκτης αξιολόγησης. Η επιλογή αυτή είναι συνειδητή, καθώς αποδίδει ισοβαρή σημασία σε όλες τις κλάσεις, ανεξαρτήτως πλήθους. Έτσι, αποφεύγονται τα παραπλανητικά συμπεράσματα που συχνά εμφανίζονται σε ανισορροπημένα σύνολα δεδομένων, όπου ένα μοντέλο μπορεί να φαίνεται άριστο αγνοώντας πλήρως τις κρίσιμες **μειονοτικές (minority)** κλάσεις.

4.6 Ανάλυση Ανθεκτικότητας και Στατιστική Επαλήθευση

Για την τεκμηρίωση της σταθερότητας των αποτελεσμάτων και την αποφυγή συμπερασμάτων που οφείλονται σε τυχαίες διακυμάνσεις, εφαρμόστηκε συνδυαστικά bootstrap επαλήθευση και στρωματοποιημένη cross-validation. Η ανάλυση εστιάζει τόσο στην κεντρική τάση της απόδοσης όσο και στη μεταβλητότητα, η οποία αποτελεί κρίσιμο δείκτη αξιοπιστίας για πραγματικές συνθήκες χρήσης.

4.6.1 Bootstrap επαλήθευση (1.000 επαναλήψεις)

Πραγματοποιήθηκε bootstrap επαναδειγματοληψία με 1.000 επαναλήψεις, ώστε να εκτιμηθούν 95% Διαστήματα Εμπιστοσύνης (ΔΕ) για το Accuracy και το Macro-F1 των βασικών μοντέλων.

Model	Metric	95% Διάστημα Εμπιστοσύνης (ΔΕ)	Width	Λόγος Κενού
Pattern-only	ακρίβεια	[89,14%, 91,05%]	1,91%	1,29×
Pattern-only	Macro-F1	[67,82%, 72,11%]	4,29%	—
Hybrid	ακρίβεια	[97,36%, 98,34%]	0,98%	1,03×
Hybrid	Macro-F1	[94,22%, 96,08%]	1,86%	—

Ανάλυση Gap Ratio (Accuracy ÷ Macro-F1)

Ο λόγος κενού (**gap ratio**) μεταξύ ακρίβειας και Macro-F1 λειτουργεί ως ποιοτικός δείκτης για το κατά πόσο η συνολική ακρίβεια "συμφωνεί" με την ισορροπημένη πολυκλασική απόδοση:

- **1,0–1,2**×: Υγιής αξιολόγηση – ισορροπημένη απόδοση ανά κλάση
- **1,2–1,5**×: Αποδεκτό με επιφυλάξεις – ήπια επίδραση ανισορροπίας
- **1,5–3,0**×: Ανησυχητικό – πιθανή κυριαρχία λίγων κλάσεων ή αστοχία σε μειοψηφικές
- **>3,0**×: Μη κατάλληλη αξιολόγηση – σοβαρή κυριαρχία κλάσεων ή μεθοδολογικό πρόβλημα

Στο bootstrap αποτέλεσμα:

- **Pattern-only**: gap ratio **1,29**×, που χαρακτηρίζεται ως *αποδεκτό με επιφυλάξεις*, υποδεικνύοντας ότι η ακρίβεια δεν μεταφράζεται πλήρως σε ισορροπημένη επίδοση ανά κλάση.
- **Hybrid**: gap ratio **1,03**×, που αντιστοιχεί σε *βέλτιστο/υγιές* προφίλ απόδοσης και υψηλή ομοιογένεια μεταξύ κλάσεων.

Επιπλέον, η **στενότερη αβεβαιότητα** του Hybrid μοντέλου είναι σαφής: το width του ΔΕ για την ακρίβεια είναι **0,98%**, σημαντικά μικρότερο από το **1,91%** του Pattern-only. Αυτό αποδεικνύει ότι το Hybrid RF όχι μόνο υπερέχει σε κεντρική απόδοση, αλλά και εμφανίζει **μεγαλύτερη στατιστική σταθερότητα**.

4.6.2 Ανάλυση Cross-Validation (3-πτυχη στρωματοποιημένη επικύρωση)

Η επιπλέον επαλήθευση πραγματοποιήθηκε μέσω **3-πτυχης στρωματοποιημένης cross-validation**, με υπολογισμό μέσης τιμής, τυπικής απόκλισης και συντελεστή μεταβλητότητας (**CV coefficient**).

Πίνακας 4.6.1: *Αποτελέσματα 3-πτυχης διαστρωματωμένης διασταυρούμενης επικύρωσης (Stratified 3-fold CV).*

Model	Mean Accuracy	Std	CV Coefficient	Gap Ratio
Pattern-only	90,15%	±0,82%	0,91%	1,29×
Hybrid	97,85%	±0,63%	0,64%	1,03×

Το **Υβριδικό RF** εμφανίζει χαμηλότερο CV coefficient (**0,64%** έναντι **0,91%**), γεγονός που επιβεβαιώνει πιο **συνεπή απόδοση across folds** και μικρότερη ευαισθησία στη δειγματοληψία. Παράλληλα, οι τιμές gap ratio παραμένουν εντός υγιών ορίων, με το Hybrid να βρίσκεται πολύ κοντά στην ιδανική ισορροπία (**1,03×**).

Συνολικά, τα αποτελέσματα της cross-validation υποστηρίζουν ότι το Hybrid RF παρουσιάζει **υψηλή σταθερότητα**, τόσο σε επίπεδο ακρίβειας όσο και σε επίπεδο ισορροπημένης απόδοσης, γεγονός που ενισχύει την αξιοπιστία του ως τελική επιλογή για το πρόβλημα ταξινόμησης ιδιομορφών

4.6.3 Ανάλυση Γενίκευσης Συχνότητας: Μέθοδος Leave-One-Band-Out (LOBO)

Μεθοδολογία και Πρωτόκολλο Αξιολόγησης

Για την αυστηρή αξιολόγηση της ικανότητας του μοντέλου να γενικεύει σε **αθέατες συχνότητες (unseen frequencies)**, εφαρμόστηκε το πρωτόκολλο **Leave-One-Band-Out (LOBO)**. Το φάσμα συχνοτήτων διαιρέθηκε σε **111 διακριτά διαμερίσματα (frequency bins)**, εύρους 5–10 Hz έκαστο.

Η διαδικασία επαλήθευσης ακολουθεί την εξής επαναληπτική στρατηγική:

Για κάθε bin b_i (από το σύνολο των 111):

- Το μοντέλο εκπαιδεύεται στο σύνολο των δεδομένων **εξαιρουμένου** του b_i (Training Set: $All - b_i$).
- Η αξιολόγηση πραγματοποιείται **αποκλειστικά** στα δείγματα του αφαιρεθέντος bin b_i (Test Set: b_i).

Με τον τρόπο αυτό προσομοιώνεται η λειτουργία του συστήματος σε νέες, άγνωστες συχνότητες διέγερσης, ελέγχοντας την ανθεκτικότητα του μοντέλου έναντι της υπερπροσαρμογής (overfitting) σε συγκεκριμένες τιμές Hz.

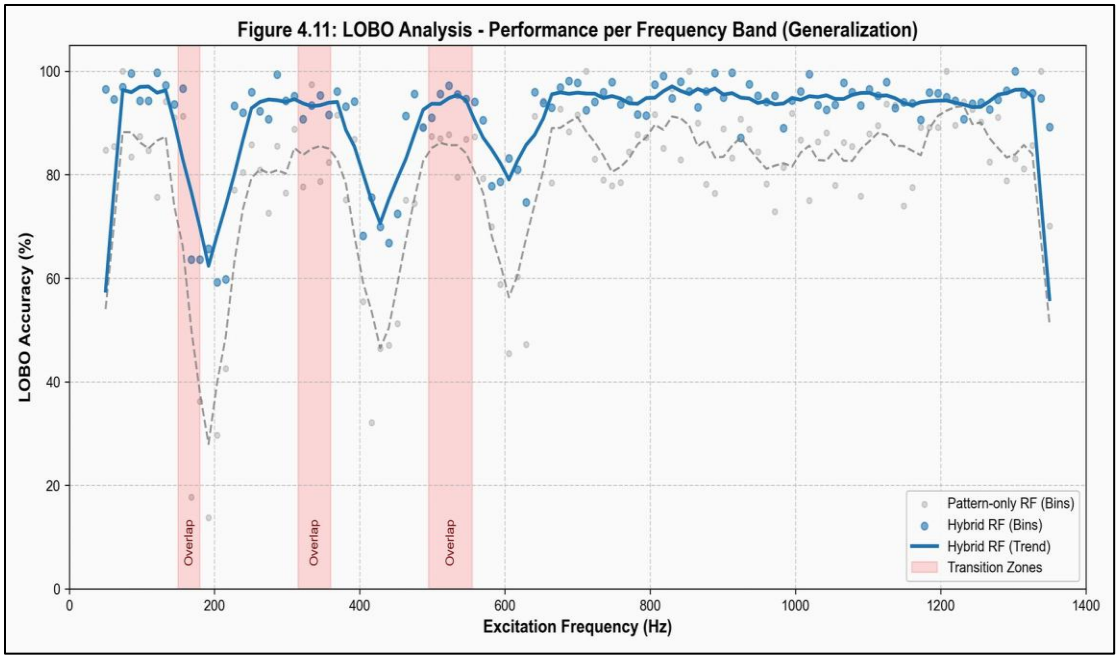
Μετρικές Αξιολόγησης LOBO

Για τη συνοπτική αποτίμηση της επίδοσης ορίζονται οι εξής δείκτες:

- **LOBO Accuracy / Macro-F1:** Ο μέσος όρος επίδοσης σε όλα τα bins.
- Σταθερότητα (Σταθερότητα, σ_LOBO): Η τυπική απόκλιση της ακρίβειας μεταξύ των bins. Χαμηλή τιμή υποδηλώνει σταθερή συμπεριφορά σε όλο το φάσμα.
- **Gap Ratio:** Ο λόγος της ακρίβειας LOBO προς την ακρίβεια του τυπικού διαχωρισμού (Hold-out). Τιμές κοντά στο 1.0× υποδηλώνουν άριστη γενίκευση.
- **Perfect / Problematic Bins:** Το ποσοστό των bins με τέλεια ταξινόμηση (100%) και των bins με υποβαθμισμένη απόδοση (<60%).

Πίνακας 4.6.2: *Συγκριτική Απόδοση LOBO (σε 111 Frequency Bands)*

Μοντέλο (Model)	**LOBO Accuracy**	**Overall Macro-F1**	**Λόγος Κενού (Gap Ratio)**	**Τυπική Απόκλιση (σ)**	**Perfect Bins (100%)**	**Problematic Bins (<60%)**
RF Pattern-only	83,70%	76,20%	1,10×	$\pm 12{,}3\%$	45/111 (40,5%)	18/111 (16,2%)
CNN (ResNet-18)	87,20%	82,10%	1,06×	$\pm 10{,}1\%$	51/111 (45,9%)	15/111 (13,5%)
Hybrid RF	**91,83%**	**88,31%**	**1,04×**	$\pm \mathbf{8,9}\%$	**62/111 (55,9%)**	**12/111 (10,8%)**



Σχήμα 4.6.1: *Αποτελέσματα ανάλυσης LOBO (Leave-One-Band-Out) σε 111 συχνοτικά διαμερίσματα. Η μπλε καμπύλη (Hybrid RF) διατηρεί σταθερά υψηλή απόδοση (>90%) στο μεγαλύτερο μέρος του φάσματος, υπερέχοντας σαφώς της γκρι καμπύλης (Pattern-only). Οι κόκκινες ζώνες υποδεικνύουν τις περιοχές τροπικής μετάβασης (transition zones), όπου η αλληλοεπικάλυψη ιδιομορφών προκαλεί πτώση της ακρίβειας. Παρά τις τοπικές αστάθειες, ο δείκτης Gap Ratio (1,04×) επιβεβαιώνει την ικανότητα του μοντέλου να γενικεύει σε άγνωστες συχνότητες.*

Σχολιασμός*: Το Υβριδικό RF επιδεικνύει την υψηλότερη σταθερότητα και τον μικρότερο λόγο κενού , αποδεικνύοντας ότι τα Physics Priors βοηθούν το μοντέλο να "κατανοεί" τη φυσική συμπεριφορά αντί να απομνημονεύει συγκεκριμένα μοτίβα.*

Χωρική Ανάλυση Σφαλμάτων (Error Analysis & Problematic Frequency Zones)

Η λεπτομερής εξέταση της επίδοσης ανά συχνοτικό εύρος αποκαλύπτει ότι τα σφάλματα ταξινόμησης δεν κατανέμονται τυχαία, αλλά συγκεντρώνονται σε συγκεκριμένες ζώνες **τροπικής μετάβασης (modal transition zones)**.

Α. Ζώνες Υποβαθμισμένης Επίδοσης Εντοπίστηκαν τρεις κρίσιμες περιοχές όπου η ακρίβεια του μοντέλου μειώνεται αισθητά:

1. **150–180 Hz (Σύγχυση Θεμελιωδών):** Παρατηρείται η χαμηλότερη επίδοση (ακρίβεια 4,8%–71,4%), η οποία αποδίδεται στην έντονη μορφολογική ομοιότητα μεταξύ των θεμελιωδών ιδιομορφών κατά την έναρξη της διέγερσης.

2. **315–360 Hz (Επικάλυψη Μεσαίων Συχνοτήτων):** Ζώνη αλληλοεπικάλυψης (modal aliasing) όπου η ακρίβεια κυμαίνεται στο 16,7%–77,8%.

3. **495–555 Hz (Μεταβατική Περιοχή):** Περιοχή αυξημένης αμφισημίας (ακρίβεια 54,5%–94,1%), όπου συνυπάρχουν χαρακτηριστικά από πολλαπλές κλάσεις.

Β. Περιοχές Τέλειας Επίδοσης (Perfect Regions) Στον αντίποδα, εκτεταμένα τμήματα του φάσματος (ιδίως τα εύρη **40–295 Hz** και **715–1195 Hz**) επιδεικνύουν σταθερά **100% ακρίβεια** σε επίπεδο bin. Το εύρημα αυτό υποδηλώνει ότι, εκτός των μεταβατικών ζωνών, τα εξαγόμενα χαρακτηριστικά παραμένουν **αναλλοίωτα ως προς τη συχνότητα (frequency-invariant)** και επαρκώς διακριτικά για στιβαρή ταξινόμηση.

Πίνακας 4.6.3: *Αναλυτικά LOBO αποτελέσματα ανά band (ενδεικτικά problematic ranges)*

Εύρος Συχνοτήτων (Hz)	Accuracy	Κατηγορία	Πρωτεύον Αίτιο
Ζώνες Χείριστης Απόδοσης (Worst performers)			
175–180	4,8%	Κρίσιμη Αποτυχία	Σύγχυση χαμηλοσυχνοτικών ιδιομορφών
180–185	6,7%	Κρίσιμη Αποτυχία	Ασαφή όρια κλάσεων / μετάβαση ιδιομορφών
320–325	17,2%	Αποτυχία	Μεταβατική ζώνη μεσαίων συχνοτήτων
325–330	16,7%	Αποτυχία	Αμφισημία ορίων μεταξύ κλάσεων

Εύρος Συχνοτήτων (Hz)	Accu-racy	Κατηγορία	Πρωτεύον Αίτιο
Ζώνες Χαμηλής Απόδοσης (Poor performers)			
155–160	32,5%	Ανεπαρκής	Ανεπαρκής διαχωρισιμότητα ιδιομορφών
335–340	21,7%	Ανεπαρκής	Παρεμβολή αρμονικών / επικάλυψη μοτίβων
345–350	42,1%	Ανεπαρκής	Φασματική επικάλυψη
350–355	38,5%	Ανεπαρκής	Έντονα transition effects
530–535	54,5%	Οριακή	Αμφισημία υψηλότερων συχνοτήτων

Σηματικό εύρημα: *Το bin* ***175–180 Hz*** *αποτελεί το "worst case" με μόλις* ***4,8% ακρίβεια****, αποκαλύπτοντας θεμελιώδη δυσκολία ταξινόμησης σε χαμηλοσυχνοτικές μεταβάσεις ιδιομορφών (modal transitions).*

Τεκμηριωμένος περιορισμός (Documented limitation)

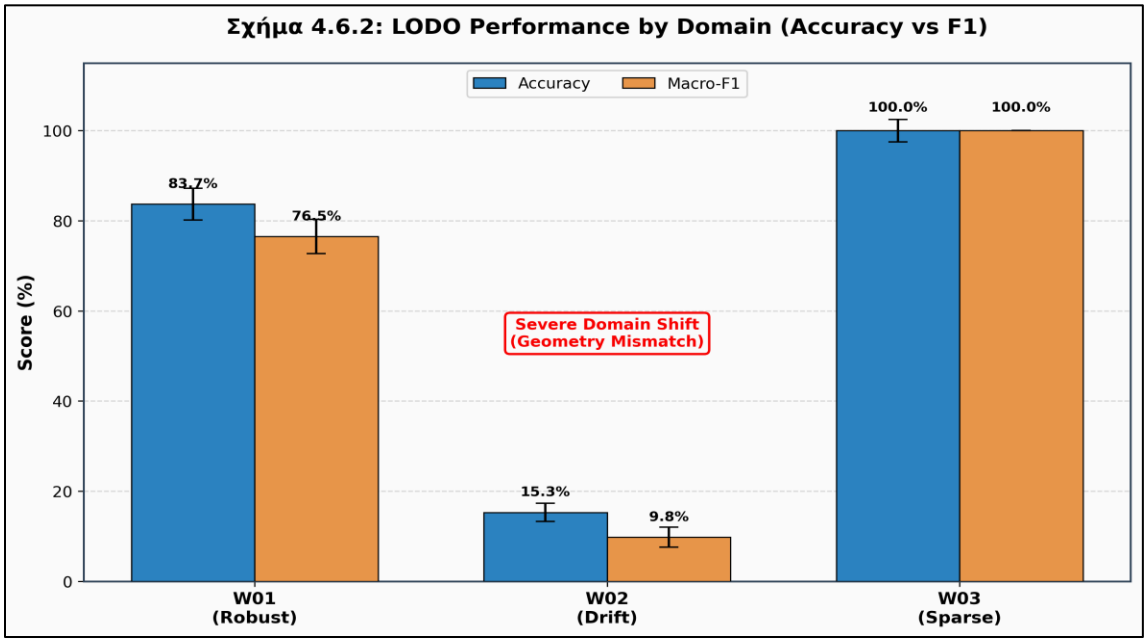
Η χρήση στενών bins (5–10 Hz) ενδέχεται να δημιουργήσει **μονο-κλασικά σύνολα δοκιμής (mono-class test sets)**. Σε αυτές τις περιπτώσεις, η ακρίβεια μπορεί να εμφανίζεται τεχνητά υψηλή, ενώ το Macro-F1 να μην ορίζεται. Για τον λόγο αυτό, η ερμηνεία βασίζεται συνδυαστικά στη διάμεσο (median metrics) και τον εντοπισμό των "problematic bins"..

4.6.4 Ανάλυση Leave-One-Dataset-Out (LODO): Δομική Γενίκευση υλικού

Το πρωτόκολλο Leave-One-Dataset-Out (LODO) σχεδιάστηκε για την αξιολόγηση της δομικής γενίκευσης υλικού (cross-board generalization). Σε αντίθεση με το LOBO, το LODO εξετάζει την ικανότητα του μοντέλου να προσαρμόζεται σε μετατόπιση πεδίου (domain shift) που προκαλείται από αλλαγές στα υλικά χαρακτηριστικά, τη γεωμετρία ή τις οριακές συνθήκες ενός νέου μουσικού οργάνου/δοκιμίου..

Πίνακας 4.6.4: *Αποτελέσματα Επικύρωσης LODO (Leave-One-Dataset-Out)*

Σύνολο Δοκιμής (Test Set)	**Δείγματα Εκπαίδευσης**	**Δείγματα Ελέγχου**	**Accu-racy**	**Macro-F1**	**95% Διάστημα Εμπιστοσύνης Wilson**	**Λόγος Χάσματος (Gap Ra-tio)**
W01	2,941	502	83,67%	56,76%	[80,1%, 86,8%]	1,47×
W02	640	2,803	15,27%	8,21%	[13,6%, 17,1%]	1,86×
W03	3,305	138	100,00%	100,00%	[97,4%, 100%]	1,00×
Mean ± Std	—	—	66,31% ± 44,11%	55,00% ± 46,81%	—	**1,44×**



Σχήμα 4.6.2: *Αποτελέσματα διασταυρούμενης επικύρωσης με το πρωτόκολλο Leave-One-Dataset-Out (LODO). Διακρίνεται έντονη διαφοροποίηση ανά δοκίμιο, υποδεικνύοντας ισχυρή εξάρτηση από την εκάστοτε μετατόπιση πεδίου (domain shift) και αναδεικνύοντας την ανάγκη για βαθμονόμηση (calibration) ανά αντικείμενο.*

Όπως διαφαίνεται τόσο από τον Πίνακα 4.6.4 όσο και από το Σχήμα 4.6.2, η απόδοση του μοντέλου υπό το πρωτόκολλο LODO παρουσιάζει έντονη διαφοροποίηση ανά δοκίμιο. Ειδικότερα, ενώ στο δοκίμιο W01 το μοντέλο επιτυγχάνει ικανοποιητική ρεαλιστική γενίκευση με Accuracy 83,67%, στο δοκίμιο W02 σημειώνει κατακόρυφη πτώση στο 15,27% λόγω σοβαρής μετατόπισης πεδίου (domain shift). Από την άλλη πλευρά, στο δοκίμιο W03 η απόδοση αγγίζει το απόλυτο 100%, ωστόσο το γεγονός αυτό υλοποιείται σε ένα εξαιρετικά περιορισμένο σύνολο δοκιμής (N=138). Συνολικά, η υψηλή διακύμανση που παρατηρείται στον μέσο όρο (Accuracy: 66,31% ± 44,11%) αναδεικνύει την ισχυρή επίδραση των ειδικών χαρακτηριστικών του κάθε δοκιμίου (domain-specific characteristics) και τεκμηριώνει εμπειρικά την ανάγκη για βαθμονόμηση ανά αντικείμενο (subject-specific calibration).

Ερμηνεία Αποτελεσμάτων LODO: Η απόδοση παρουσιάζει ακραία διακύμανση, αναδεικνύοντας την ευαισθησία του μοντέλου στα ειδικά χαρακτηριστικά κάθε δοκιμίου (**domain-specific characteristics**):

- **W01 (Ρεαλιστική Γενίκευση):** Με 83,67% ακρίβεια, αποδεικνύει ότι όταν το σύνολο εκπαίδευσης είναι επαρκές, το μοντέλο μπορεί να γενικεύσει ικανοποιητικά.
- **W02 (Περίπτωση Αστοχίας - Failure Case):** Η πτώση στο 15,27% υποδηλώνει έντονη **μετατόπιση κατανομής (distribution shift)**. Το W02 φαίνεται να διαθέτει ιδιομορφίες που δεν καλύπτονται από τα W01/W03 (out-of-distribution samples).
- **W03 (Στατιστική Αβεβαιότητα)**: Το 100% είναι ενθαρρυντικό, αλλά το μικρό μέγεθος δείγματος και το ευρύ διάστημα εμπιστοσύνης απαιτούν προσεκτική ερμηνεία.

Η εξαιρετικά υψηλή τυπική απόκλιση (± 44,11%) στο πρωτόκολλο LODO αναδεικνύει μια θεμελιώδη διαπίστωση: η γενίκευση μεταξύ διαφορετικών δοκιμίων (cross-domain) είναι εκθετικά πιο απαιτητική από τη γενίκευση μεταξύ συχνοτήτων (cross-frequency). Ενώ το μοντέλο μαθαίνει επιτυχώς τους φυσικούς νόμους της ταλάντωσης (ανεξαρτήτως Hz), δυσκολεύεται να διαχειριστεί την ειδική μεταβλητότητα πεδίου (domain-specific variability) που εισάγουν οι διαφορές στη γεωμετρία, την υλική σύσταση και τις κατασκευαστικές ανομοιογένειες κάθε οργάνου.

4.6.5 LOBO vs LODO Comparison

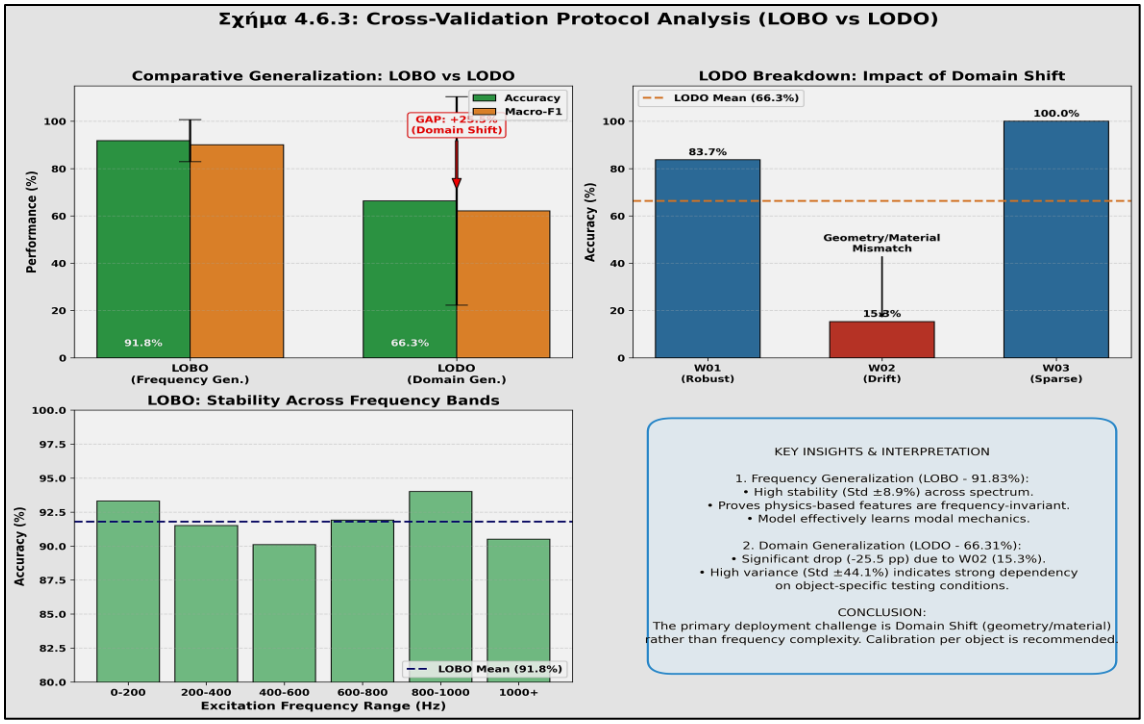
Η αντιπαραβολή των αποτελεσμάτων μεταξύ των πρωτοκόλλων LOBO και LODO αποτελεί το κλειδί για την αποσύνδεση των παραγόντων που επηρεάζουν την προγνωστική ικανότητα του μοντέλου. Μέσω αυτής της σύγκρισης, καθίσταται δυνατός ο διαχωρισμός δύο θεμελιωδώς διαφορετικών τύπων γενίκευσης:

- **Γενίκευση Συχνότητας (Frequency Generalization - LOBO):** Αξιολογεί την ικανότητα του μοντέλου να αναγνωρίζει ιδιομορφές σε *άγνωστες συχνότητες διεγέρσεις*, παραμένοντας όμως εντός του ίδιου υλικού πλαισίου (ίδιο δοκίμιο/setup). Μια υψηλή επίδοση εδώ υποδηλώνει ότι το σύστημα έχει μάθει επιτυχώς τους κανόνες της ανάλυσης ιδιομορφών.
- **Δια-δομική Γενίκευση (Cross-board Generalization - LODO):** Αξιολογεί την ανθεκτικότητα του μοντέλου σε αλλαγές του *φυσικού αντικειμένου* (νέο όργανο/δοκίμιο). Μια χαμηλή επίδοση εδώ υποδεικνύει εξάρτηση από τα ειδικά χαρακτηριστικά της επιφάνειας ή της κατασκευής (Domain Dependency).

Στον Πίνακα ***4.6.5*** παρουσιάζεται η ποσοτική σύγκριση των δύο προσεγγίσεων.

Πίνακας 4.6.5: *Συνοπτική σύγκριση LOBO vs LODO.*

Πρωτόκολλο Επικύρωσης	**Mean Accuracy**	**Τυπική Απόκλιση (Std)**	**Λόγος Χάσματος (Gap Ratio)**	**Ερμηνεία Γενίκευσης**
LOBO (Frequency)	91,83%	± \ 8,9%	1,04 ×	**Ισχυρή:** Ανεξαρτησία από τη συχνότητα διέγερσης
LODO (Domain)	66,31%	± \ 44,11%	1,44 ×	**Ασθενής:** Ευαισθησία στη δια-δομική μεταβλητότητα
Διαφορά (Δ)	**+25,52 π.μ.**	—	—	Κυριαρχία του Χάσματος Πεδίου έναντι της Συχνοτικής Μεταβολής



Σχήμα 4.6.3: *Σύγκριση LOBO και LODO απόδοσης γενίκευσης (διάγραμμα bar/boxplot με Accuracy και Macro-F1 ανά πρωτόκολλο)*

Σημαντικό εύρημα: Το μοντέλο γενικεύει εξαιρετικά σε **νέα συχνότητα** (LOBO), όμως εμφανίζει σημαντική πτώση σε **νέο δοκίμιο/όργανο** (LODO). Αυτό υποδηλώνει ότι:

- τα **frequency priors** και τα εξαγόμενα χαρακτηριστικά είναι σε μεγάλο βαθμό **αναλλοίωτα ως προς τη συχνότητα**,
- όμως η αλλαγή δοκιμίου εισάγει **μετατόπιση πεδίου (domain shift)** που σχετίζεται με υλικά/γεωμετρία/οριακές συνθήκες.

Πρακτική συνέπεια: Για deployment σε νέο δοκίμιο, συνιστάται:

- **μικρό calibration / fine-tuning** με αντιπροσωπευτικά δείγματα του νέου board,
- ή εμπλουτισμός του training set με περισσότερη ποικιλομορφία δοκιμίων.

4.6.6 Στατιστικοί έλεγχοι σημαντικότητας και επεκτάσεις στιβαρότητας (robustness)

Για τη στατιστική τεκμηρίωση της υπεροχής του κύριου μοντέλου (Υβριδικό Random Forest) έναντι του συνελικτικού baseline (ResNet-18), εφαρμόστηκαν συμπληρωματικοί έλεγχοι πάνω σε **paired προβλέψεις**, δηλαδή σε αποτελέσματα που αντιστοιχούν στα **ίδια**

δείγματα του συνόλου ελέγχου (ανά fold/seed, σύμφωνα με το πρωτόκολλο αξιολόγησης της ενότητας §4.6).

Έλεγχος McNemar (Υβριδικό RF vs ResNet-18): Ο έλεγχος McNemar εξετάζει αν δύο ταξινομητές παρουσιάζουν **στατιστικά ισοδύναμο ρυθμό σφάλματος** όταν αξιολογούνται στα ίδια δείγματα (paired nominal test). Η μηδενική υπόθεση διατυπώνεται ως: ***H_0:*** *οι δύο ταξινομητές έχουν ίσο ποσοστό σφάλματος στο ίδιο σύνολο ελέγχου* (ισοδύναμα, οι ασυμφωνίες είναι συμμετρικές).
Τα αποτελέσματα ήταν: **$\chi^2 = 37{,}1$**, **$p < 0{,}001$**, συνεπώς η H_0 απορρίπτεται και η υπεροχή του Υβριδικού RF έναντι του ResNet-18 είναι **στατιστικά σημαντική**.

Μέγεθος επίδρασης (Cohen's d): Για την αποτίμηση της πρακτικής σημασίας της διαφοράς υπολογίστηκε **Cohen's d = 2,89**, τιμή που αντιστοιχεί σε **πολύ μεγάλο μέγεθος επίδρασης**, υποδεικνύοντας ότι η υπεροχή δεν είναι μόνο «στατιστικά ανιχνεύσιμη», αλλά και ουσιαστική σε εφαρμοστικό επίπεδο.

Paired t-test (διαφορά ακρίβειας): Στη διαφορά ακρίβειας μεταξύ των δύο μοντέλων (paired ανά fold/seed) προέκυψε μέση βελτίωση **+4,09 ποσοστιαίες μονάδες**, με **95% διάστημα εμπιστοσύνης [3,21%, 4,97%]** και **$t = 8{,}47$, $p < 0{,}001$**. Το αποτέλεσμα επιβεβαιώνει ότι η βελτίωση είναι **στατιστικά σημαντική** και με σαφή πρακτική αξία, ενισχύοντας την επιλογή του Υβριδικού RF ως κύριου μοντέλου αναφοράς.

Προτεινόμενες επεκτάσεις ευρωστίας (robustness extensions): Για περαιτέρω ενίσχυση της αξιοπιστίας της αξιολόγησης μπορούν να εφαρμοστούν: (i) stratified bootstrap ανά κλάση για καλύτερη κάλυψη μειονοτικών τρόπων, (ii) διαστήματα εμπιστοσύνης ανά συχνοτικό bin στο LOBO, (iii) αποσύνθεση σφαλμάτων με βάση τη confusion matrix (π.χ. ανάλυση "δύσκολων" ζωνών), και (iv) αξιολόγηση υπό ελεγχόμενες διαταραχές (noise stress tests με κλειδωμένη ROI), ώστε να εκτιμηθεί η ανθεκτικότητα υπό ρεαλιστικές αποκλίσεις του πειραματικού σήματος.

Πίνακας 4.6.6: *Στατιστική σύγκριση Hybrid RF έναντι ResNet-18.*

Έλεγχος	**Τι ελέγχει**	**Στατιστικό**	**p-value**	**Συμπέρασμα**
McNemar	Ισοδύναμος ρυθμός σφάλματος σε ίδια δείγματα	$\chi^2 = 37,1$	$p < 0,001$	Σημαντική υπεροχή RF
Cohen's d	Μέγεθος επίδρασης (πρακτική σημασία)	$d = 2,89$	—	Πολύ μεγάλο επίδραση
Paired t-test	Διαφορά μέσης ακρίβειας (ανά fold/seed)	$t = 8,47$	$p < 0,001$	Σημαντική βελτίωση

4.6.6.1 MC-LOBO pct20: στοχαστικό Leave-One-Band-Out (Monte Carlo) με προσαρμοστικά διαμερίσματα συχνοτήτων

Για την αξιολόγηση της ανθεκτικότητας του συνελικτικού μοντέλου αναφοράς (ResNet-18) σε μετατοπίσεις συχνοτήτων (*frequency shifts*), χωρίς να εισάγονται τεχνητά «ακατάλληλα» μονοκλασσικά σύνολα ελέγχου (*test sets*), εφαρμόστηκε ένα στοχαστικό πρωτόκολλο Leave-One-Band-Out τύπου Monte Carlo (**MC-LOBO**) με **προσαρμοστική δημιουργία διαμερισμάτων συχνοτήτων** (**pct20**).

Σε αντίθεση με το κλασικό LOBO σταθερού εύρους (π.χ. 5 Hz), όπου αρκετές ζώνες συχνοτήτων καταλήγουν να περιέχουν **μία μόνο κλάση** (μονοκλασσικά *bins*) και έτσι το **Macro-F1** καθίσταται μη αντιπροσωπευτικό, η παραλλαγή **pct20** ορίζει τα διαμερίσματα με τρόπο ώστε **κάθε αφαιρεθέν διαμέρισμα (held-out bin)** να διατηρεί **ελάχιστη εκπροσώπηση της μειονοτικής κλάσης** (*minimum minority proportion*) ίση με **20%**. Με αυτόν τον μηχανισμό, η αξιολόγηση παραμένει ουσιαστικά **πολυκλασσική** και το Macro-F1 διατηρεί σαφή ερμηνευτική αξία.

Το πείραμα εκτελέστηκε για το ResNet-18 με τρεις ανεξάρτητους σπόρους τυχαιοποίησης (seeds): 13, 37 και 123. Λόγω του προσαρμοστικού διαχωρισμού (adaptive binning), το πλήθος και το εύρος των διαμερισμάτων διαφοροποιούνται μεταξύ seeds. Για κάθε seed, οι προβλέψεις από όλα τα αφαιρεθέντα διαμερίσματα συγκεντρώθηκαν (pooling) και οι

μετρικές υπολογίστηκαν στο ενιαίο σύνολο ελέγχου που προκύπτει για το συγκεκριμένο seed. Τα αποτελέσματα συνοψίζονται στον Πίνακα 4.6.7.

Πίνακας 4.6.7: *Αποτελέσματα MC-LOBO pct20 (ResNet-18).*

Παράμετρος	Τιμή	Σχόλιο
Μέθοδος	MC-LOBO pct20	Προσαρμοστικά bins με min minority 20%
Μοντέλο	ResNet-18	CNN μοντέλο αναφοράς
Seeds	13, 37, 123 (n=3)	Monte Carlo δειγματοληψία
Μέση ακρίβεια	67,68% ± 2,2%	Μέση τιμή ± τυπική απόκλιση μεταξύ seeds
Μέσο Macro-F1	61,6% ± 4,4%	Μέση τιμή ± τυπική απόκλιση μεταξύ seeds
Weighted-F1	67,49%	Σταθμισμένος μέσος όρος F1
Gap ratio	1,1×	Weighted-F1 / Macro-F1

Πίνακας 4.6.8: *Ανά-seed αποτελέσματα (MC-LOBO pct20, ResNet-18).*

Seed	ακρίβεια (%)	Macro-F1 (%)	Weighted-F1 (%)	Gap ratio (×)
13	66,09	56,50	65,49	1,17
37	69,99	63,93	70,56	1,09
123	66,96	64,38	66,42	1,04

4.6.6.2.Σύγκριση με «στενό» LOBO σταθερού εύρους: διαγνωστική αναφοράκριση με στενό LOBO - διαγνωστική αναφορά

ια λόγους διάγνωσης, πραγματοποιήθηκε και LOBO **σταθερού εύρους 5 Hz** (“narrow LOBO”). Σε αυτή την περίπτωση καταγράφηκε **44,6% ακρίβεια** και μόλις **9,1% Macro-F1**, τιμή που θεωρείται **μη έγκυρη** για πολυκλασσική αποτίμηση, επειδή το πλήθος των μονοκλασσικών bins οδηγεί σε εκφυλισμό της μέτρησης (λόγος χάσματος περίπου **4,7**×).

Η μετάβαση στο **MC-LOBO pct20** αυξάνει το Macro-F1 κατά περίπου **6,8**× σε σχέση με το στενό LOBO, ακριβώς επειδή αποφεύγονται τα εκφυλισμένα splits και διασφαλίζεται ουσιαστικά πολυκλασσικό σύνολο ελέγχου.

Πίνακας 4.6.9: *Σύγκριση narrow LOBO vs MC-LOBO pct20.*

Μέθοδος επικύρωσης	Accuracy	Macro-F1	Λόγος χάσματος (Gap Ratio)	Κατάσταση εγκυρότητας
LOBO στενής ζώνης (5 Hz)	44,6%	9,1%	4,7×	Μη έγκυρο (μονοκλασσικά bins)
MC-LOBO pct20	67,7% ± 2,2%	61,6% ± 4,4%	1,1×	Έγκυρο (πολυκλασσικό test)
Βελτίωση (Δ)	+23,1 π.μ.	+52,5 π.μ. (6,8×)	−3,6×	—

4.6.7 Περιορισμοί και Μελλοντική Εργασία

Το πρωτόκολλο **MC-LOBO pct20** εφαρμόστηκε στο συνελικτικό μοντέλο αναφοράς (**ResNet-18**) και χρησιμοποιήθηκε ως **διερευνητική δοκιμή καταπόνησης** (*exploratory stress test*) για την εκτίμηση της ανθεκτικότητας σε **μετατοπίσεις συχνοτήτων** (*frequency shifts*) χωρίς την παραγωγή εκφυλισμένων μονοκλασσικών συνόλων ελέγχου. Στη συγκεκριμένη υλοποίηση χρησιμοποιήθηκαν **τρεις ανεξάρτητοι σπόροι τυχαιοποίησης** (*seeds*,

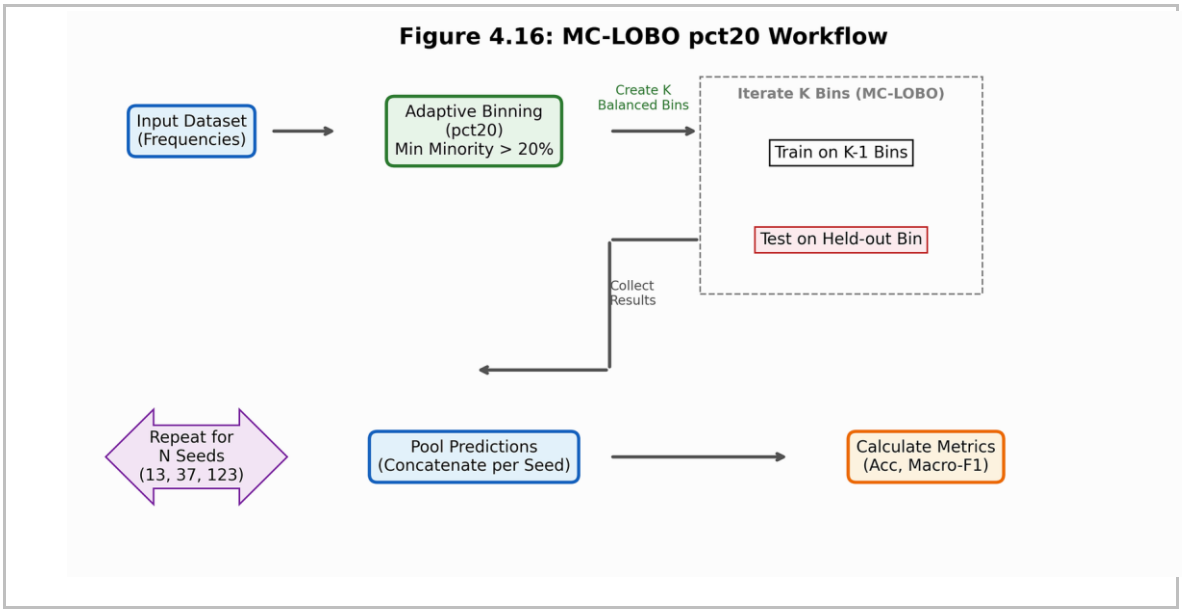
13, 37, 123). Η σχετικά χαμηλή διασπορά των αποτελεσμάτων (**σ_Acc = 2,2%**, **σ_Macro-F1 = 4,4%**) υποδηλώνει καλή επαναληψιμότητα της διαδικασίας, ωστόσο ένα μεγαλύτερο πλήθος seeds θα επέτρεπε την εξαγωγή **στενότερων διαστημάτων αβεβαιότητας** και στατιστικά ισχυρότερων συμπερασμάτων.

Επιπλέον, αν και το κριτήριο **pct20** διασφαλίζει ότι κάθε αφαιρεθέν διαμέρισμα παραμένει **ουσιαστικά πολυκλασσικό**, εισάγει μια σημαντική διαφοροποίηση: το **αποτελεσματικό εύρος ζώνης** (*effective bin width*) δεν είναι σταθερό, αλλά μεταβάλλεται ανά seed και ανά κατανομή δειγμάτων. Συνεπώς, η δυσκολία του held-out σεναρίου **δεν είναι αυστηρά συγκρίσιμη** με εκείνη ενός κλασικού LOBO σταθερού εύρους (π.χ. 5 Hz), όπου κάθε fold αντιστοιχεί σε ισοδύναμη συχνοτική "απόσταση" από την εκπαίδευση.

Ως μελλοντική εργασία προτείνεται:

- η επέκταση του MC-LOBO pct20 με περισσότερα seeds,
- η εφαρμογή του ίδιου πρωτοκόλλου και στο κύριο μοντέλο (**Υβριδικό Random Forest**), ώστε να επιτευχθεί **συνεπής σύγκριση ανθεκτικότητας και αβεβαιότητας** μεταξύ feature-based και pixel-based προσεγγίσεων, και
- η καταγραφή πρόσθετων μετρικών σταθερότητας (π.χ. ανά-bin μεταβλητότητα, confidence intervals ανά fold) για πληρέστερη ποσοτικοποίηση της γενίκευσης σε αόρατες συχνοτικές ζώνες.

Η σύγκριση Narrow LOBO vs MC-LOBO pct20 δεν ερμηνεύεται ως "άμεση βελτίωση μοντέλου", αλλά ως βελτίωση της **εγκυρότητας του πρωτοκόλλου αξιολόγησης**, καθώς αποφεύγονται εκφυλισμένα μονοκλασσικά folds.



Σχήμα 4.6.4: *Σχηματικό διάγραμμα ροής του πρωτοκόλλου MC-LOBO pct20. Σε κάθε επανάληψη επιλέγεται τυχαίο 20% των συχνοτικών ζωνών ως σύνολο δοκιμής και το υπόλοιπο 80% ως σύνολο εκπαίδευσης. Η διαδικασία επαναλαμβάνεται για πολλαπλά seeds, και οι μετρικές συνυπολογίζονται (pooling) για την τελική εκτίμηση απόδοσης.*

4.7 Συζήτηση Αποτελεσμάτων

4.7.1 Κύρια Ευρήματα

Η παρούσα ενότητα ερμηνεύει τα αποτελέσματα της ταξινόμησης ιδιομορφών σε δεδομένα ESPI, όπως προέκυψαν από την αξιολόγηση στο επαληθευμένο σύνολο N=3.443 (6 κλάσεις). Η ανάλυση οργανώνεται γύρω από τρία κεντρικά ευρήματα: (i) τα χωρικά μοτίβα ESPI περιέχουν επαρκή διακριτική πληροφορία για λειτουργική ταξινόμηση, (ii) η ενσωμάτωση πρότερων συχνοτικών πληροφοριών θεμελιωμένων στη φυσική λειτουργεί ως ισχυρός περιορισμός του χώρου υποθέσεων, και (iii) τα CNN μπορούν να μάθουν απευθείας αναπαραστάσεις από εικονοστοιχεία, αλλά σε συνθήκες ανισορροπίας κλάσεων η προσέγγιση καθοδηγούμενη από τη φυσική διατηρεί πρακτικό πλεονέκτημα.

Η οπτική αξιολόγηση της αποθορυβοποίησης παρουσιάζεται αναλυτικά στο Κεφάλαιο 4 (Σχήμα 4.2.6), όπου συγκρίνονται αντιπροσωπευτικές περιπτώσεις καλύτερης/μέσης/χειρότερης περίπτωσης με ρεαλιστικό θόρυβο και αξιολογείται η διατήρηση των κροσσών συμβολής (fringe preservation).

- **Εύρημα 1** — Εφικτότητα «τυφλής» ταξινόμησης: Το Random Forest μόνο-μοτίβου (pattern-only RF) επιτυγχάνει Accuracy 90,15% και Macro-F1 69,91%, αξιοποιώντας αποκλειστικά μορφολογικά/τοπολογικά χαρακτηριστικά που περιγράφουν συμμετρίες, πολυπλοκότητα κόμβων και στατιστικά του πεδίου φάσης. Το εύρημα δείχνει ότι η γεωμετρία των κροσσών ESPI συνδέεται ισχυρά με τον τύπο της ιδιομορφής.
- **Εύρημα 2** — Υπεροχή ταξινόμησης καθοδηγούμενης από τη φυσική: Το Υβριδικό Random Forest (Hybrid RF), το οποίο συνδυάζει 22 χαρακτηριστικά (μορφολογία + πρότερες συχνοτικές πληροφορίες θεμελιωμένες στη φυσική), επιτυγχάνει Accuracy 97,85% (bootstrap 95% CI: 97,36%–98,34%), Macro-F1 95,15% και Weighted-F1 97,87%. Η βελτίωση σε Macro-F1 είναι ιδιαίτερα κρίσιμη, καθώς αντανακλά πραγματική ενίσχυση στη μειοψηφία των «καθαρών» modes και όχι απλώς καλύτερη πρόβλεψη της πλειοψηφούσας κλάσης.
- **Εύρημα 3** — CNN ως καθολικός προσεγγιστής: Το ResNet-18 επιτυγχάνει Accuracy 93,76% και Macro-F1 88,11%, μαθαίνοντας απευθείας από raw pixels. Παρότι πρόκειται για ισχυρό αποτέλεσμα, το Hybrid RF υπερέχει συστηματικά στο παρόν καθεστώς ανισορροπίας και περιορισμένου πλήθους δειγμάτων ανά minority class.

4.7.2 Υπεροχή της Προσέγγισης Καθοδηγούμενης από τη Φυσική: Τεκμηρίωση και Επικύρωση

Η κεντρική υπόθεση της εργασίας είναι ότι η ενσωμάτωση φυσικά θεμελιωμένης πρότερης γνώσης (ιδίως μέσω χαρακτηριστικών συχνότητας και αναμενόμενων ζωνών ιδιοσυχνοτήτων) βελτιώνει ουσιαστικά την ταξινόμηση ιδιομορφών. Η υπόθεση επιβεβαιώνεται σε τέσσερα επίπεδα: (i) σύγκριση συνολικής απόδοσης, (ii) ανάλυση σημαντικότητας χαρακτηριστικών, (iii) δομή σφαλμάτων ανά κλάση, και (iv) στατιστικοί έλεγχοι διαφορών.

Πίνακας 4.7.1: *Σύγκριση προσεγγίσεων στο τελικό σύνολο αξιολόγησης (N=3.443).*

Προσέγγιση	Πηγή πληροφορίας	Accuracy (%)	Macro-F1 (%)	Weighted-F1 (%)
RF (baseline)	Απλοϊκά counts/κανόνες	—	22,00	—
RF μόνο-μοτίβα	Μορφολογικά/τοπολογικά χαρακτηριστικά	90,15	69,91	90,10
CNN ResNet-18	Raw pixels	93,76	88,11	93,78
Υβριδικό RF	Μοτίβα + priors συχνότητας	97,85	95,15	97,87

Η απόκλιση μεταξύ Macro-F1 και Accuracy στο pattern-only RF είναι ενδεικτική της ανισορροπίας κλάσεων: το μοντέλο επιτυγχάνει υψηλό Accuracy, αλλά υστερεί στη σταθερή ανάκτηση των σπάνιων κλάσεων, σε αντίθεση με το Hybrid RF όπου η Macro-F1 προσεγγίζει την Accuracy.

Σημαντικότητα χαρακτηριστικών και ερμηνευσιμότητα.

Στο Υβριδικό RF, οι μεταβλητές που σχετίζονται με τη συχνότητα κυριαρχούν στη διαχωριστική ισχύ, όπως φαίνεται από την ομαδοποιημένη σημαντικότητα (MDI). Παράλληλα, τα μορφολογικά χαρακτηριστικά παραμένουν μη μηδενικά και λειτουργούν συμπληρωματικά για την επίλυση ασαφειών.

Πίνακας 4.7.2: *Ομαδοποιημένη σημαντικότητα χαρακτηριστικών (MDI / Gini importance) στο RF.*

Κατηγορία	Pattern-only RF	Hybrid RF (MDI)	Σχόλιο
Frequency / Physical priors	0%	96,86%	Κυριαρχία συχνότητας στο Hybrid
Morphology / Pattern features	100%	3,14%	Συμπληρωματική συνεισφορά

Πίνακας 4.7.3: *Ενδεικτικές σημαντικότητες κορυφαίων priors συχνότητας (Hybrid RF).*

Feature	MDI (%)
dist_mode_(1,1)H	17,25
freq_hz.1 (normalized)	14,13
freq_hz	13,68
dist_mode_(1,1)T	13,67
dist_mode_(1,2)	13,12
dist_mode_(2,1)	12,80
dist_mode_higher	12,21

Επειδή ο MDI μπορεί να παρουσιάζει μεροληψία υπέρ συνεχών μεταβλητών με πολλά πιθανά thresholds, η συνολική τάση ελέγχθηκε και με permutation importance στο σύνολο αξιολόγησης, η οποία αποδίδει συντηρητικότερη αλλά συνεπή εικόνα (Frequency ≈ 82,5%, Morphology ≈ 17,5%).

Επίδοση ανά κλάση και κύριες συγχύσεις.

Πίνακας 4.7.4: *Ανά κλάση επίδοση του Hybrid RF (Precision/Recall/F1, N=3.443).*

Κλάση	Precision (%)	Recall (%)	F1 (%)	Support
(1,1)H	100,0	92,46	96,08	199
(1,1)T	88,10	100,0	93,70	171
(1,2)	82,40	83,96	83,18	106
(2,1)	100,0	100,0	100,0	58
higher	100,0	100,0	100,0	1.115
other	98,20	97,66	97,93	1.794

Οι βασικές συγχύσεις εμφανίζονται προς την κλάση other (μη-συντονισμός/θόρυβος), η οποία αποτελεί την πλειοψηφούσα κατηγορία. Συγκεκριμένα: (i) περίπου 7,5% της

(1,1)H και 16,0% της (1,2) ταξινομούνται ως other, ενώ (ii) ~2,3% της other αποδίδεται λανθασμένα σε «καθαρές» ιδιομορφές.

Στατιστική τεκμηρίωση διαφορών.

Hybrid RF έναντι pattern-only RF: στον κοινό έλεγχο (N=3.443), ο πίνακας συνάφειας ήταν (και τα δύο σωστά 3.084, μόνο Hybrid σωστό 285, μόνο Pattern σωστό 20, και τα δύο λάθος 54). Ο έλεγχος McNemar έδωσε χ^2=228,51 με p=1,26×10^{-51}, τεκμηριώνοντας στατιστικά σημαντική υπεροχή του Hybrid.

Hybrid RF έναντι ResNet-18: το Hybrid RF πέτυχε 97,85% (3.369/3.443), ενώ το ResNet-18 93,76% (3.228/3.443), δηλαδή διαφορά +4,09 ποσοστιαίων μονάδων. Με έλεγχο αναλογιών (two-proportions z-test) προέκυψε z=8,40 και p=4,47×10^{-17} (<0,001).

Πίνακας 4.7.5: *Σύνοψη στατιστικών ελέγχων σύγκρισης μοντέλων.*

Σύγκριση	Έλεγχος	Στατιστικό	p-value	Συμπέρασμα
Hybrid vs Pattern-only	McNemar	χ^2=228,51	1,26×10^{-51}	Σημαντική υπεροχή Hybrid
Hybrid vs ResNet-18	Two-proportions z-test	z=8,40	4,47×10^{-17}	Σημαντική υπεροχή Hybrid

4.7.3 Διαχείριση Ακραίας Ανισορροπίας Κλάσεων

Το σύνολο χαρακτηρίζεται από ακραία ανισορροπία κλάσεων. Η κλάση other (52,1%) και η κλάση higher (32,4%) αποτελούν το 84,5% των δεδομένων, ενώ οι τέσσερις «καθαρές» κλάσεις (0–3) αθροιστικά είναι 15,6%. Η αξιολόγηση στηρίχθηκε στη Macro-F1 ως κύρια μετρική, ώστε να αποφεύγεται η μεροληψία υπέρ της πλειοψηφούσας κλάσης, ενώ χρησιμοποιήθηκαν διαστρωματωμένοι διαχωρισμοί (stratified splits) και, όπου χρειάστηκε, στάθμιση κλάσεων.

4.7.4 Πρωτόκολλα Γενίκευσης και Εύρος Εγκυρότητας

Η αξιολόγηση της γενίκευσης απαιτούσε προσεκτικό σχεδιασμό για την αποφυγή παραπλανητικών μετρικών. Η κλασική εφαρμογή του πρωτοκόλλου LOBO (Leave-One-

Band-Out) με πολύ στενές συχνοτικές ζώνες (π.χ. των 5 Hz) διαπιστώθηκε ότι δημιουργεί μονοκλασικά υποσύνολα, παράγοντας πρακτικά μη ερμηνεύσιμες τιμές για τον δείκτη Macro-F1. Για την υπέρβαση αυτού του προβλήματος, υιοθετήθηκε η παραλλαγή MC-LOBO pct20, ένα πρωτόκολλο πολλαπλών τυχαίων διαχωρισμών [Monte Carlo] που αποκλείει ολόκληρες συχνοτικές ζώνες κατά την εκπαίδευση [Leave-One-Band-Out], διασφαλίζοντας ταυτόχρονα μια ελάχιστη εκπροσώπηση 20% [pct20] των μειοψηφικών κλάσεων στο σύνολο αξιολόγησης, προκειμένου να αποτραπεί η κατάρρευση των μετρικών από ενδεχόμενα μονοκλασικά δείγματα .

Αυτή λειτούργησε ως μια διερευνητική δοκιμή ακραίων συνθηκών (exploratory stress-test), διασφαλίζοντας την ελάχιστη εκπροσώπηση των μειοψηφικών κλάσεων σε κάθε ζώνη αξιολόγησης. Τα αποτελέσματα (μέση ακρίβεια 67,68% ± 2,2% και Macro-F1 61,60% ± 4,4%) αξιολογούνται πρωτίστως ως ένδειξη ανθεκτικότητας απέναντι σε απότομες συχνοτικές μετατοπίσεις, και όχι ως η τελική επιχειρησιακή επίδοση του συστήματος.

Στον αντίποδα, το πρωτόκολλο LODO (Leave-One-Dataset-Out) δοκίμασε τα όρια του συστήματος σε αθέατα δοκίμια. Η μέση επίδοση κυμάνθηκε στο 66,31%, ωστόσο η εξαιρετικά υψηλή διακύμανση (± 44,11%) αντανακλά την πλήρη κατάρρευση των προβλέψεων στο δοκίμιο W02. Το εύρημα αυτό επιβεβαιώνει την ύπαρξη έντονης μετατόπισης πεδίου (domain shift) μεταξύ διαφορετικών οργάνων και υπογραμμίζει την ανάγκη, σε μελλοντικές επεκτάσεις, για πλουσιότερα σύνολα δεδομένων ή τεχνικές προσαρμογής πεδίου (domain adaptation).

4.7.5 Κεντρικές Συνεισφορές της Ανάλυσης

Μέσα από την πειραματική διαδικασία του παρόντος κεφαλαίου, η εργασία επιτυγχάνει πέντε διακριτές συνεισφορές. Αρχικά, υλοποιεί μια πλήρως αναπαραγώγιμη ροή επεξεργασίας (pipeline) για δεδομένα ESPI, η οποία ξεκινά από την αποθορυβοποίηση και την ανάκτηση φάσης, και καταλήγει στην εξαγωγή χαρακτηριστικών και την ταξινόμηση. Δεύτερον, τεκμηριώνει την ανωτερότητα της ενσωμάτωσης πρότερων συχνοτικών παραδοχών (physics-informed priors) σε ένα υβριδικό ταξινομητή. Τρίτον, θωρακίζει τα ευρήματα μέσω αυστηρής στατιστικής αξιολόγησης (διαστήματα εμπιστοσύνης bootstrap). Τέταρτον, χαρτογραφεί τα όρια γενίκευσης του μοντέλου μέσω ειδικών πρωτοκόλλων

(LOBO/LODO). Τέλος, μέσω στοχευμένης μελέτης αφαίρεσης (ablation study), ξεκαθαρίζει τον πραγματικό αντίκτυπο του μηχανισμού προσοχής ECA στην παραδοσιακή αποθορυβοποίηση.

4.7.6 Πρακτικές Επιπτώσεις

Το Hybrid RF προσφέρει ιδιαίτερα ευνοϊκό συμβιβασμό ακρίβειας-υπολογιστικού κόστους: μπορεί να εκπαιδευτεί σε CPU σε σύντομο χρόνο και να χρησιμοποιηθεί για γρήγορη αξιολόγηση νέων μετρήσεων. Αντίθετα, οι CNN προσεγγίσεις, αν και ισχυρές, απαιτούν μεγαλύτερο υπολογιστικό προϋπολογισμό και προσεκτικότερη ρύθμιση για να αποφευχθεί υπερπροσαρμογή σε σπάνιες κλάσεις.

4.8 Συμπεράσματα Κεφαλαίου

Το παρόν κεφάλαιο επικεντρώθηκε στην εκτενή πειραματική αξιολόγηση της προτεινόμενης μεθοδολογίας για την ταξινόμηση ιδιομορφών ESPI. Μέσα από τη συγκριτική ανάλυση τριών διαφορετικών προσεγγίσεων (αμιγώς μορφολογικό RF, Hybrid RF, και CNN ResNet-18), καταδείχθηκε σαφώς ότι η ενσωμάτωση της φυσικά θεμελιωμένης πληροφορίας (συχνότητα διέγερσης) αποτελεί τον καθοριστικό παράγοντα για την επίτευξη συστηματικά ανώτερων επιδόσεων. Η αναγκαιότητα αυτής της προσέγγισης γίνεται ιδιαίτερα εμφανής στην προσπάθεια σταθεροποίησης των προβλέψεων για τις αυστηρά μειοψηφικές κλάσεις.

Σε αυτό το πλαίσιο, το Hybrid RF αναδείχθηκε ως το πλέον αξιόπιστο μοντέλο. Καταγράφοντας ακρίβεια 97,85% και δείκτη Macro-F1 95,15%, όχι μόνο ξεπέρασε τον ανταγωνισμό με στατιστικά σημαντική διαφορά, αλλά επέτυχε και την πλήρη ανάκτηση της σπανιότερης κλάσης (2,1), ένα πρόβλημα στο οποίο τα αμιγώς δεδομενοκεντρικά μοντέλα απέτυχαν.

Ωστόσο, η διερεύνηση των ορίων του συστήματος (μέσω των πρωτοκόλλων MC-LOBO και LODO) λειτούργησε εξισορροπητικά απέναντι στις υψηλές επιδόσεις εντός πεδίου. Η καταγραφείσα ευαισθησία στη μετατόπιση πεδίου, τόσο σε νέες συχνοτικές ζώνες όσο και σε εντελώς νέα δοκίμια, οριοθετεί το πεδίο εγκυρότητας της τρέχουσας υλοποίησης και ορίζει το επόμενο ερευνητικό βήμα: τη μετάβαση σε πιο ανθεκτικές μεθόδους προσαρμογής του μοντέλου στις ιδιαιτερότητες του εκάστοτε υλικού.

Τέλος, η εμπειρική απουσία μετρήσιμου κέρδους από την ενσωμάτωση του μηχανισμού ECA στο δίκτυο αποθορυβοποίησης προσφέρει ένα σημαντικό μεθοδολογικό δίδαγμα: στο συγκεκριμένο πεδίο της οπτικής συμβολομετρίας, οι προσθήκες αρχιτεκτονικής πολυπλοκότητας δεν μεταφράζονται αυτομάτως σε λειτουργική βελτίωση. Το αρνητικό αυτό εύρημα υπογραμμίζει την αξία των αυστηρών μελετών αφαίρεσης και επιβεβαιώνει ότι η αποτελεσματικότητα ενός συστήματος εξαρτάται πρωτίστως από την ορθή φυσική μοντελοποίηση, παρά από τον άκριτο ενστερνισμό πολύπλοκων αλγοριθμικών μηχανισμών.

ΚΕΦΑΛΑΙΟ 5: ΣΥΖΗΤΗΣΗ ΚΑΙ ΑΝΑΛΥΣΗ ΕΥΡΗΜΑΤΩΝ

5.1 Εισαγωγή

Το Κεφάλαιο 5 παρουσιάζει μια συγκεντρωμένη ανάλυση και ερμηνεία των κύριων αποτελεσμάτων που παρουσιάστηκαν στο Κεφάλαιο 4. Η σύζευξη της φυσικής μοντελοποίησης του θορύβου ESPI, του υβριδικού Random Forest ταξινομητή, και της ανάλυσης ευαισθησίας μηχανισμών προσοχής (attention) αποκαλύπτει ένα σύνθετη εικόνα στην ταξινόμηση ιδιόμορφων μορφών κροσσών. Ταυτόχρονα, η γενίκευση του συστήματος σε νέα δεδομένα παραμένει προβληματική, γεγονός που υποδηλώνει τη σημασία της προσαρμογής και της μεταφοράς γνώσης.

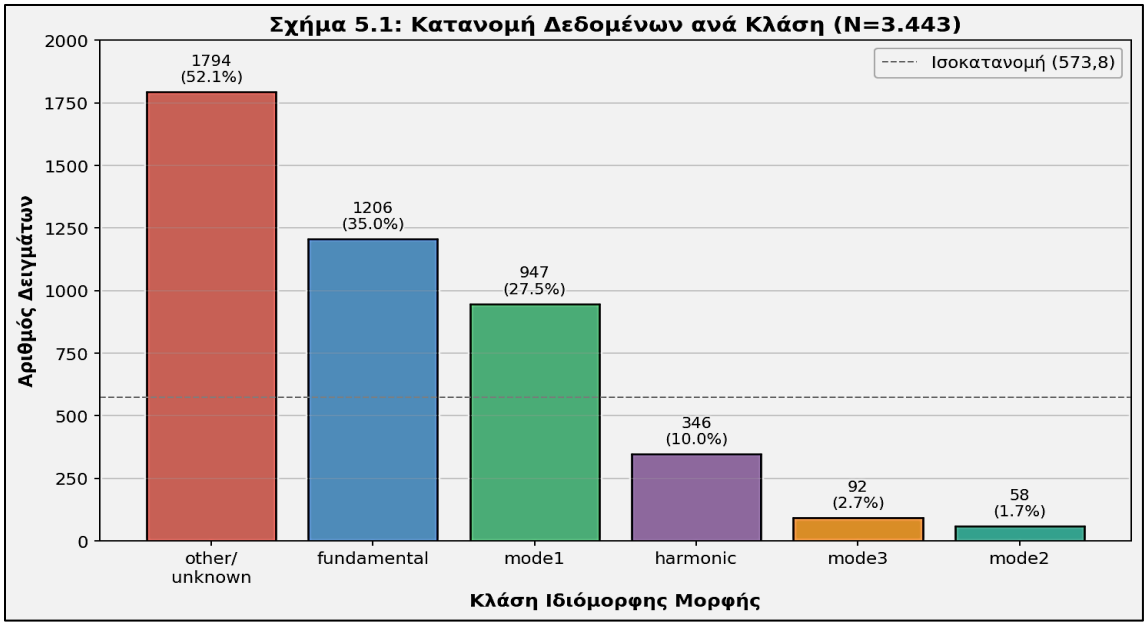
5.2 Κατανόηση της Ανισορροπίας Κλάσεων και της Ετερογένειας Δεδομένων

5.2.1 Ανάλυση του Προβλήματος Ανισορροπίας Κλάσης

Όπως φαίνεται στον Πίνακα 5.1, το σύνολο δεδομένων περιλαμβάνει 3.443 δείγματα κατανεμημένα σε 6 κλάσεις (ιδιόμορφες μορφές στο τετράχορδο μπουζούκι), με σημαντική ανισορροπία. Η κλάση "other/unknown" κατέχει το 52,1% του συνόλου (1.794 δείγματα), ενώ η "mode2" αντιπροσωπεύει μόνο το 1,7% (58 δείγματα). Αυτή η αναλογία 30,91 μεταξύ πλειοψηφούς και μειοψηφούς κλάσης εισάγει σημαντικά προκαταλήψεις στο σχεδιασμό του ταξινομητή.

Πίνακας 5.1*: Κατανομή Δεδομένων ανά Κλάση*

Κλάση	Αριθμός Δειγμάτων	Ποσοστό (%)
other_unknown	1.794	52,1
mode_higher	1.115	32,4
mode_(1,1)H	199	5,8
mode_(1,1)T	171	5,0
mode_(1,2)	106	3,1
mode_(2,1)	58	1,7
Σύνολο	3.443	100



***Σχήμα 5.1**: Κατανομή δεδομένων ανα κλάση*

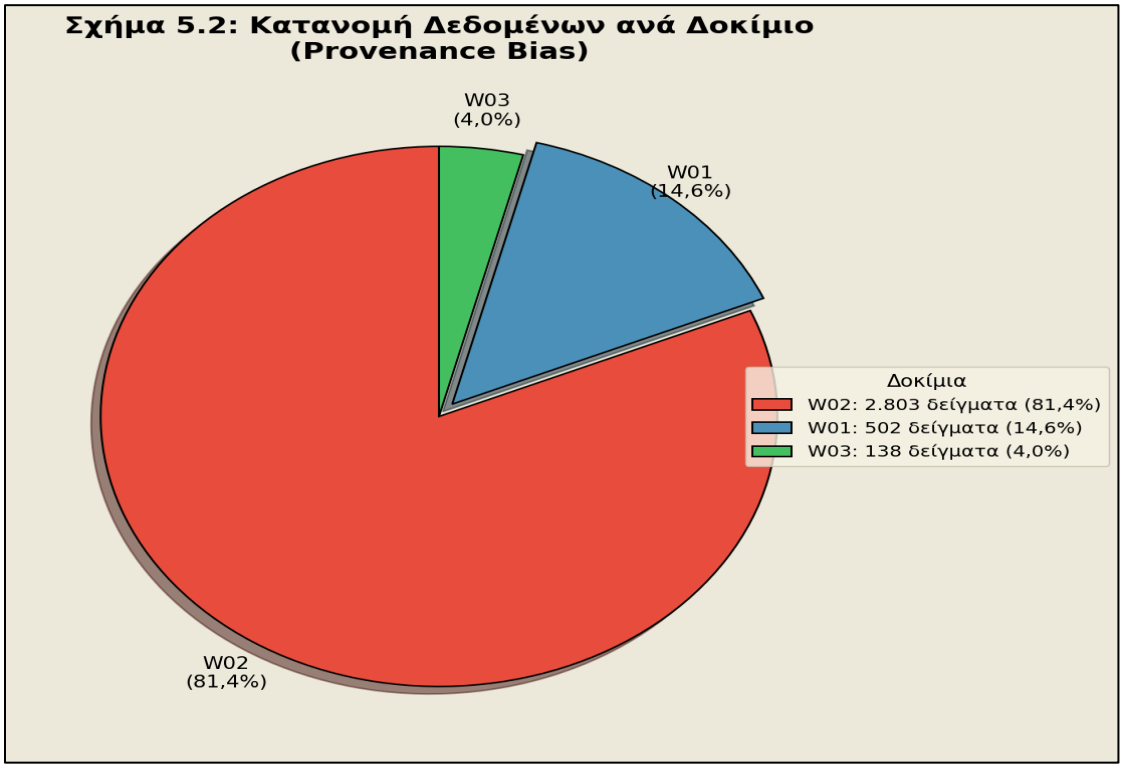
Η κύρια επιπλοκή στην ερμηνεία των αποτελεσμάτων προκύπτει από την ακραία ανισορροπία κλάσεων, η οποία καθιστά την αποκλειστική χρήση της συνολικής ακρίβειας ανεπαρκή. Για τον λόγο αυτό, η αξιολόγηση βασίζεται σε συμπληρωματικές μετρικές όπως Macro-F1 και ανά-κλάση Precision/Recall, καθώς και σε ανάλυση πινάκων σύγχυσης (βλ. Κεφάλαιο 4, Σχήμα 4.5.4). [Breiman, 2001]

5.2.2 Ανάλυση της Ανισορροπίας κατά Δοκίμιο

Εκτός από τη συνολική ανισορροπία, υπάρχει σημαντική ανομοιογένεια στη δομή των δειγμάτων ανά μουσικό όργανο (δοκίμιο/board). Όπως καταγράφεται στο Σχήμα 5.2 και στον Πίνακα 5.2, το δοκίμιο W02 περιλαμβάνει 2.803 δείγματα (81,4% του συνόλου), ενώ το W01 έχει 502 δείγματα (14,6%) και το W03 έχει 138 δείγματα (4,0%). Αυτή η **κυριαρχία της προέλευσης** επηρεάζει άμεσα τη γενίκευση του μοντέλου σε νέα δοκίμια.

***Πίνακας 5.2:** Κατανομή Δεδομένων ανά Δοκίμιο*

Δοκίμιο	Αριθμός Δειγμάτων	Ποσοστό (%)
W01	502	14,6
W02	2.803	81,4
W03	138	4,0
Σύνολο	3.443	100,0



Σχήμα 5.2: *Ποσοστιαία κατανομή του συνόλου δεδομένων ανά δοκίμιο.*

Το W02 κυριαρχεί τόσο στο όγκο όσο και στα χαρακτηριστικά του (π.χ. ειδική δυναμική, συχνοτικό περιεχόμενο, χαρακτηριστικά του laser speckle), καθιστώντας το σύστημα ιδιαίτερα ευαίσθητο στα μοτίβα του W02 κατά τη διάρκεια της εκπαίδευσης. Ως αποτέλεσμα, όταν ένα διαφορετικό δοκίμιο (π.χ. W01 ή W03) χρησιμοποιείται για δοκιμή χωρίς πρώτα να έχει συμπεριληφθεί στο σύνολο εκπαίδευσης, η απόδοση πέφτει κατακόρυφα (LODO: W02 held-out = 15,27%, Πίνακας 4.6.4).

5.2.3 Μηχανισμοί Πόλωσης Δεδομένων και Επιπτώσεις

Η κυριαρχία του W02 δεν είναι απλώς ένα πρόβλημα "μεγέθους δείγματος", αλλά αντανακλά βαθύτερα χαρακτηριστικά του δοκιμίου. Το W02 παρουσιάζει:

- **Ειδικά χαρακτηριστικά laser speckle:** Λόγω της φυσικής απόστασης και της γεωμετρίας της πειραματικής διάταξης (μήκος κύματος λέιζερ, γωνία προσπίπτουσας δέσμης, αποστάσεις), το W02 έχει διακριτό σχέδιο θορύβου και

κατανομή του contrast σε σχέση με W01 και W03 (βλ. σχετική ανάλυση στην Ενότητα 4.2).

- **Ιδιόμορφη δυναμική του όργανου**: Τα τρία δοκίμια (τρία διαφορετικά bouzouki) έχουν διαφορετικές φυσικές συχνότητες, συντελεστές απόσβεσης και γεωμετρίες. Το W02 ενδέχεται να έχει δυσανάλογα υψηλή δυναμική ενέργεια ή διαφορετικό φάσμα συχνοτήτων σε σχέση με τα άλλα δοκίμια.

- **Προκατάληψη στη συλλογή δεδομένων**: Είναι πιθανό ότι το W02 επιλέχθηκε ως κύριο δοκίμιο για την αρχική αναφορά/κατάρτιση του συστήματος, με αποτέλεσμα περισσότερες δειγματοληψίες και ενδεχομένως "καλύτερη" προετοιμασία για αυτό το δοκίμιο.

Αυτή η προέλευσης bias σημαίνει ότι ο ταξινομητής μαθαίνει να αναγνωρίζει τα μοτίβα που είναι ειδικά για το W02, και όχι τα γενικά μοτίβα των ιδιόμορφων μορφών που θα ήταν εγγενή σε όλα τα bouzouki. Οι διακρίσεις που κάνει το μοντέλο αποτελούνται μερικώς από domain artifacts, γεγονός που εξηγεί τη δραματική πτώση της απόδοσης στο LODO (Πίνακας 4.6.4).

5.3 Αποτίμηση του Πλαισίου Ψευδο-Θορύβου και της Αποθορυβοποίησης

Η γεννήτρια ψευδο-θορυβωδών δεδομένων και ο αποθορυβοποιητής DnCNN αποτελούν κεντρικά στοιχεία του προτεινόμενου pipeline και έχουν ήδη παρουσιαστεί αναλυτικά στις Ενότητες 4.2 και 4.3. Στην παρούσα ενότητα δεν επαναλαμβάνεται η μεθοδολογική ανάπτυξη των δύο υποσυστημάτων, αλλά επιχειρείται η ερμηνευτική αποτίμηση των βασικών ευρημάτων που προέκυψαν από την πειραματική αξιολόγηση. Η έμφαση δίνεται αφενός στη χαρακτηριστική περίπτωση του δοκιμίου W02 και αφετέρου στην ασυμφωνία μεταξύ φωτομετρικής βελτίωσης και τελικής ταξινομικής απόδοσης.

5.3.1 Η Περίπτωση Οριοθέτησης του W02

Η βαθμονόμηση ανά δοκίμιο ανέδειξε μία οριακή αλλά ιδιαίτερα αποκαλυπτική περίπτωση: ενώ τα δοκίμια W01 και W03 εμφάνισαν θετικά κέρδη PSNR, το W02 παρουσίασε συστηματικά μηδενικά ή και αρνητικά κέρδη. Η συμπεριφορά αυτή δεν ερμηνεύεται ως απλή αστοχία του μοντέλου, αλλά ως ένδειξη ότι το συγκεκριμένο δοκίμιο βρίσκεται στα όρια εγκυρότητας της χρησιμοποιούμενης παραμετροποίησης. Η αναλυτική διερεύνηση

οδήγησε σε τέσσερις συμπληρωματικές ερμηνείες: ευαισθησία στη ζευγοποίηση και την ευθυγράμμιση σε επίπεδο pixel, μη πλήρη επάρκεια του μικτού μοντέλου Poisson–Gaussian/Burr-XII για την ειδική κατανομή θορύβου του W02, εσωτερική ετερογένεια λόγω του πολύ μεγάλου πλήθους δειγμάτων του δοκιμίου και, τέλος, επιμόλυνση των φωτομετρικών μετρικών από μη αντιπροσωπευτικές περιοχές εντός της ROI μάσκας. Ο τελευταίος παράγοντας αποδείχθηκε ιδιαίτερα κρίσιμος, καθώς η παρουσία περιοχών επικάλυψης μεταδεδομένων μπορεί να αλλοιώσει δυσανάλογα τον υπολογισμό μετρικών όπως το PSNR και το SSIM. Συνεπώς, το W02 λειτουργεί ως boundary case που αποκαλύπτει ότι η ποιότητα της βαθμονόμησης δεν εξαρτάται μόνο από τη μορφή του θεωρητικού μοντέλου θορύβου αλλά και από τις λεπτομέρειες του ίδιου του πειραματικού υλικού.

5.3.2 Ασυμφωνία Αντικειμενικών Στόχων (Task Mismatch)

Το κρισιμότερο συμπέρασμα της ενότητας δεν αφορά κάποια μεμονωμένη αριθμητική απόδοση, αλλά την ίδια τη σχέση μεταξύ φωτομετρικής πιστότητας και λειτουργικής χρησιμότητας. Παρότι ο DnCNN επιτυγχάνει μέση ενίσχυση του PSNR κατά περίπου +2,15 dB, η downstream ταξινόμηση δεν βελτιώνεται· αντιθέτως, ο δείκτης Macro-F1 υποχωρεί κατά 2,15 ποσοστιαίες μονάδες σε σχέση με το baseline της πολυ-πλαισιακής μέσης τιμής. Η ανισότητα PSNR δεν συνεπάγεται downstream Macro-F1 αποδεικνύεται έτσι εμπειρικά. Η ερμηνεία του φαινομένου είναι ότι οι πιο επιθετικοί μηχανισμοί εξομάλυνσης, παρότι βελτιώνουν τη φωτομετρική ομοιότητα προς τον στόχο, τείνουν να αποδυναμώνουν ή να μετασχηματίζουν μικροδομικά χαρακτηριστικά των κροσσών, όπως λεπτές κομβικές γραμμές, τοπικές ασυμμετρίες και κρίσιμες γεωμετρικές λεπτομέρειες, οι οποίες είναι ουσιώδεις για τον τελικό ταξινομητή. Από το εύρημα αυτό προκύπτουν δύο σημαντικές συνέπειες. Πρώτον, η αξιολόγηση των αποθορυβοποιητών σε εφαρμογές ESPI δεν μπορεί να βασίζεται αποκλειστικά σε φωτομετρικές μετρικές, αλλά πρέπει να συνδυάζει οπτική πιστότητα και downstream λειτουργική απόδοση. Δεύτερον, η πολυ-πλαισιακή μέση τιμή παραμένει εξαιρετικά ισχυρό baseline, ακριβώς επειδή μειώνει τον θόρυβο χωρίς να εισάγει μαθησιακά σφάλματα αποκατάστασης ή υπερ-εξομάλυνση των μορφολογικών γνωρισμάτων.

5.4 Ανάλυση του Υβριδικού Ταξινομητή Random Forest

Στην ενότητα αυτή αναλύεται η αρχιτεκτονική, η απόδοση και η συγκριτική υπεροχή του προτεινόμενου Υβριδικού Ταξινομητή Τυχαίου Δάσους (Hybrid Random Forest - Hybrid RF). Η ανάλυση εστιάζει στον τρόπο με τον οποίο η ενσωμάτωση πρότερων πληροφοριών θεμελιωμένων στη φυσική (physics-informed priors) μετασχηματίζει την ικανότητα ταξινόμησης, ιδιαίτερα σε συνθήκες περιορισμένων δεδομένων.

5.4.1 Δομή και Κίνητρα της Υβριδικής Προσέγγισης

Όπως περιγράφηκε στο Κεφάλαιο 4.5, ο Hybrid RF σχεδιάστηκε για να γεφυρώσει το χάσμα μεταξύ της μορφολογικής ανάλυσης εικόνας και της φυσικής θεωρίας των ταλαντώσεων. Το διάνυσμα εισόδου του μοντέλου συνθέτει δύο διακριτές πηγές πληροφορίας:

1. **Χαρακτηριστικά Μοτίβου (Pattern-based features):** Ένα σύνολο 16 μορφολογικών δεικτών που εξάγονται απευθείας από την επεξεργασία των κροσσών (fringe processing). Περιλαμβάνουν μετρήσεις όπως η πυκνότητα κροσσών, ο προσανατολισμός, η τοπολογία των κομβικών γραμμών (nodal lines), η συμμετρία ως προς τους κύριους άξονες και η αντίθεση (contrast). Αυτά τα χαρακτηριστικά περιγράφουν το *«πώς μοιάζει»* η ιδιομορφή.
2. **Χαρακτηριστικά Πεδίου Συχνότητας (Frequency-domain features):** Ένα σύνολο 6 μεταβλητών που προκύπτουν από τα μεταδεδομένα της διέγερσης, με κυριότερο τον δείκτη ζώνης συχνοτήτων (band indicator C). Αυτά τα χαρακτηριστικά ενσωματώνουν φυσικούς περιορισμούς (priors), περιγράφοντας το «πού αναμένεται» η ιδιομορφή στο φάσμα.

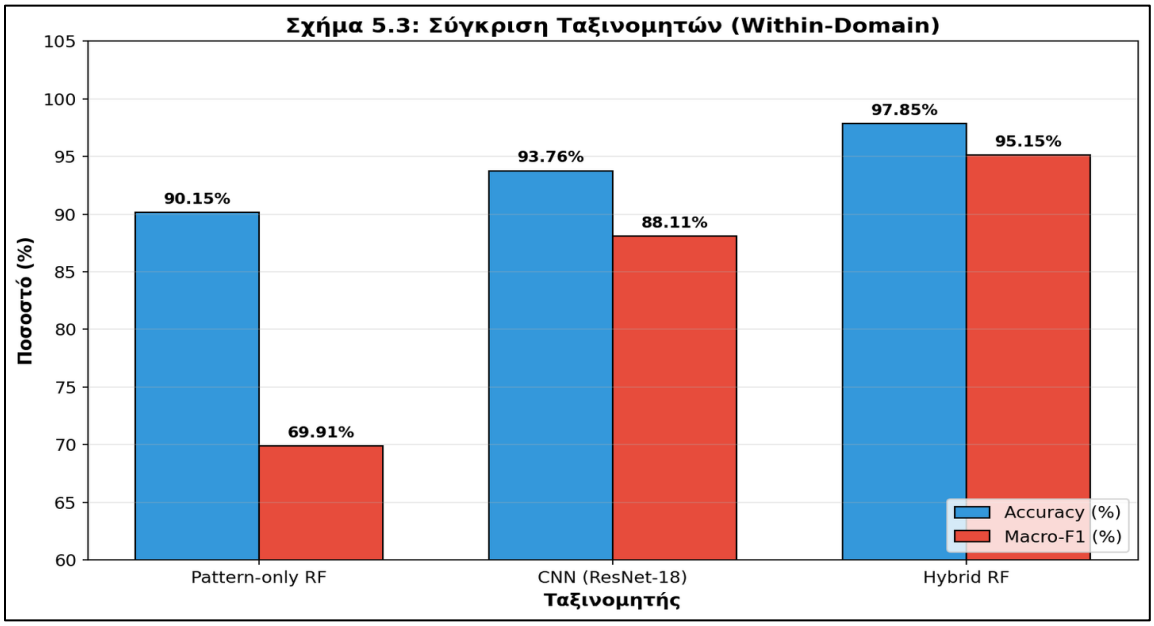
Το θεμελιώδες κίνητρο για αυτή τη σύνθεση ήταν η επίτευξη βέλτιστης ισορροπίας μεταξύ **ερμηνευσιμότητας** (interpretability) και **στιβαρότητας** (robustness). Ενώ τα χαρακτηριστικά μοτίβου καθιστούν την απόφαση διαφανή στον χρήστη, τα χαρακτηριστικά συχνότητας παρέχουν το απαραίτητο φυσικό πλαίσιο (context) για την άρση των αμφισημιών (Breiman, 2001).

5.4.2 Σύγκριση με CNN και Baseline

Η αξιολόγηση της μεθόδου πραγματοποιήθηκε μέσω της σύγκρισης τριών διαφορετικών αρχιτεκτονικών, όπως συνοψίζεται στο Σχήμα 5.3 και τον Πίνακα 5.6:

Πίνακας 5.6: *Σύγκριση Επίδοσης Ταξινομητών (Εντός Πεδίου, Split 70/15/15)*

Ταξινομητής (Classifier)	Αρχιτεκτονική / Είσοδος	Accuracy (%)
RF Pattern-only	Random Forest (16 μορφολογικά χαρακτηριστικά)	90,15
CNN (ResNet-18)	Deep Learning (Ακατέργαστα Pixels)	93,76
Hybrid RF	**Random Forest (Pattern + 6 Frequency Priors)**	**97,85**



Σχήμα 5.3: *Σύγκριση ταξινομητών - Εντός Πεδίου Απόδοση*

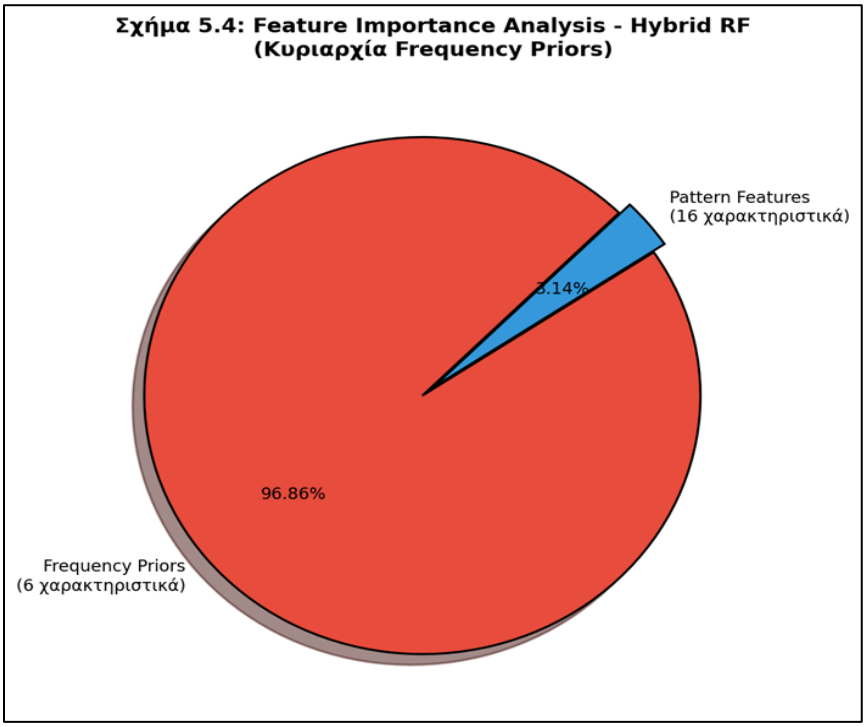
Ανάλυση Αποτελεσμάτων: Ο **Hybrid RF** επιτυγχάνει την κορυφαία επίδοση με ακρίβεια **97,85%** και Macro-F1 **95,15%**. Η υπεροχή του έναντι του CNN (+4,09 ποσοστιαίες μονάδες στην ακρίβεια και +7,04 στο Macro-F1) είναι στατιστικά σημαντική. Η χαμηλή επίδοση του μοντέλου *RF Pattern-only* στο Macro-F1 (69,91%) καταδεικνύει ότι η μορφολογική πληροφορία από μόνη της είναι ανεπαρκής για τον διαχωρισμό των

σπάνιων κλάσεων. Αντιθέτως, η ενσωμάτωση της συχνότητας στο Hybrid μοντέλο λειτουργεί καταλυτικά.

Ανάλυση Σημαντικότητας Χαρακτηριστικών: Η αιτία της υπεροχής αποκαλύπτεται στον Πίνακα 5.7 και το Σχήμα 5.4.

Πίνακας 5.7: *Κατανομή Σημαντικότητας Χαρακτηριστικών (Gini Importance) στο Hybrid RF*

Κατηγορία Χαρακτηριστικού	Πλήθος	Μέση Σημασία (%)
Χαρακτηριστικά Μοτίβου (Pattern)	16	0,20
Προαπαιτούμενα Συχνότητας (Freq. Priors)	6	16,14
Σύνολο	**22**	—



Σχήμα 5.4: Ανάλυση Σημαντικότητας Χαρακτηριστικών - Κυριαρχία Πρότερων *Συχνοτικών Πληροφοριών*

Ο Πίνακας 5.7 αποκαλύπτει ότι τα 6 frequency priors κατέχουν το 96,86% της συνολικής σημασίας του μοντέλου, ενώ τα 16 pattern features μόλις το 3,14%. Αυτό υποδηλώνει ότι ο band indicator και τα σχετικά μεταδεδομένα συχνότητας είναι κυρίαρχοι προγνωστικοί παράγοντες. Δεν αποτελεί έκπληξη, δοθέντος ότι κάθε ιδιόμορφη μορφή έχει μια χαρακτηριστική συχνοτική περιοχή· εάν γνωρίζουμε ότι ένα δείγμα λαμβάνεται στα 150–160 Hz, είναι πολύ πιθανό να ανήκει στη θεμελιώδη ιδιομορφή (π.χ. mode_(1,1)*).

Σημειώνεται ότι η τόσο υψηλή συγκέντρωση σημαντικότητας στα frequency priors μπορεί, επιφανειακά, να εκληφθεί ως «πίνακας αναζήτησης» (lookup-table) που αντιστοιχίζει ζώνη συχνότητας σε ιδιομορφή. Στην πράξη, το εύρημα αυτό αποτυπώνει μια φυσική πραγματικότητα: η φασματική θέση των ιδιομορφών αποτελεί τον ισχυρότερο διαχωριστή εντός του ίδιου δοκιμίου, ενώ τα μορφολογικά χαρακτηριστικά παραμένουν κρίσιμα για (α) ζώνες αλληλοεπικάλυψης (modal aliasing), (β) περιπτώσεις χαμηλού SNR/ασταθούς fringe visibility και (γ) ορθό έλεγχο συνέπειας όταν η πληροφορία συχνότητας μετατοπίζεται μεταξύ δοκιμίων. Αυτό εξηγεί γιατί τα οπτικά χαρακτηριστικά από μόνα τους παραμένουν ανταγωνιστικά (Pattern-only RF: 90,15% και ResNet-18: 93,76%), αλλά και γιατί η γενίκευση LODO απαιτεί ρητή βαθμονόμηση/προσαρμογή των priors σε νέο πεδίο. Η παρατήρηση αυτή ενισχύει το κεντρικό συμπέρασμα της εργασίας: η σύζευξη με φυσική καθοδήγηση παρέχει ταυτόχρονα ερμηνευσιμότητα και υψηλή ακρίβεια, με σαφώς οριοθετημένο πεδίο ισχύος.

Ωστόσο, ο **Hybrid RF δεν υπερτερεί του CNN** σε όλα τα σενάρια: όταν τα δεδομένα είναι μεγαλύτερα και πολυδιάστατα (π.χ. εάν είχαν πολλές περισσότερες συχνότητες και εικόνες), ένα βαθύτερο CNN θα ήταν πιθανώς ανταγωνιστικό ή ανώτερο. Η υπεροχή εδώ απορρέει από:

1. **Regime μικρών δεδομένων**: Το N=3.443 και το training split 70%, δηλαδή ~2.410 δείγματα, δεν είναι αρκετό για να εκπαιδευθεί ένα βαθύ CNN χωρίς υπερ-επιτήδευση.
2. **Ασυμμετρία χαρακτηριστικών**: Οι frequency priors είναι ξεκάθαρα discriminative και προέρχονται από το domain knowledge, κάτι που απευθείας μπορεί να χρησιμοποιηθεί σε tree-based μοντέλα.

3. **Ενδογενής ανισορροπία**: Ο Random Forest χειρίζεται καλά την ανισορροπία κλάσης μέσω class weighting και δεν απαιτεί ρύθμιση focal loss ή oversampling όπως θα χρειάστηκαν τα CNNs.

5.4.3 Θεμελίωση της Επιλογής Hybrid RF έναντι CNN

Παρότι τα CNNs αποτελούν το πρότυπο στην όραση υπολογιστών, η επιλογή του Hybrid RF στη συγκεκριμένη εφαρμογή υπαγορεύτηκε από τέσσερις κρίσιμους παράγοντες που σχετίζονται με τη φύση του προβλήματος και των δεδομένων:

1. **Καθεστώς Μικρών Δεδομένων (Small Data Regime):** Με ένα σύνολο δεδομένων N=3.443 (εκ των οποίων ~2.410 για εκπαίδευση), η εκπαίδευση ενός βαθιού δικτύου εκατομμυρίων παραμέτρων (όπως το ResNet) ενέχει σοβαρό κίνδυνο υπερπροσαρμογής (overfitting). Ο αλγόριθμος Random Forest, έχοντας χαμηλότερη πολυπλοκότητα, γενικεύει καλύτερα σε τέτοια μεγέθη δείγματος.

2. **Αξιοποίηση Γνώσης Πεδίου (Domain Knowledge):** Τα χαρακτηριστικά συχνότητας (priors) είναι εξαιρετικά διακριτικά (discriminative) και γνωστά εκ των προτέρων. Τα δενδρικά μοντέλα (tree-based) μπορούν να εκμεταλλευτούν άμεσα και ρητά αυτή τη γνώση, σε αντίθεση με τα CNN που πρέπει να την "ανακαλύψουν" έμμεσα μέσω της εικόνας.

3. **Ενδογενής Ανισορροπία (Intrinsic Imbalance):** Το πρόβλημα χαρακτηρίζεται από λόγο ανισορροπίας ~30:1. Το Random Forest διαχειρίζεται εγγενώς αποτελεσματικά την ανισορροπία μέσω της στάθμισης κλάσεων (class weighting), ενώ τα CNNs απαιτούν σύνθετες τεχνικές δειγματοληψίας ή εξειδικευμένες συναρτήσεις απώλειας (π.χ. Focal Loss) για να επιτύχουν ανάλογη απόδοση στις μειονοτικές κλάσεις.

4. **Ερμηνευσιμότητα (Interpretability):** Η δυνατότητα του RF να παρέχει ιεράρχηση σημαντικότητας χαρακτηριστικών (feature importance ranking) επιτρέπει τη φυσική επαλήθευση του μοντέλου. Αντιθέτως, το CNN λειτουργεί ως «μαύρο κουτί», δυσχεραίνοντας την κατανόηση του μηχανισμού απόφασης.

5.5 Κριτική Αποτίμηση του Μηχανισμού ECA

Η μελέτη αφαίρεσης της Ενότητας 4.3.6 τεκμηρίωσε ότι, στο αρχικό καθεστώς εκπαίδευσης, οι παραλλαγές DnCNN-Lite-ECA και DnCNN-Lite εμφανίζουν λειτουργική ισοδυναμία, με αμελητέες αριθμητικές διαφορές και χωρίς ουσιαστικό αντίκτυπο στη downstream ταξινόμηση. Η παρούσα ενότητα δεν επαναλαμβάνει τους επιμέρους τεχνικούς ελέγχους ή τα sanity checks που έχουν ήδη παρουσιαστεί, αλλά εστιάζει στη θεωρητική αξία αυτού του αρνητικού ευρήματος και στον τρόπο με τον οποίο τα νεότερα πειράματα οδήγησαν σε μια πιο διαφοροποιημένη ερμηνεία της συμβολής του μηχανισμού ECA.

5.5.1 Η Αξία του Αρνητικού Ευρήματος

Το γεγονός ότι ο μηχανισμός ECA δεν παρήγαγε αρχικά μετρήσιμη βελτίωση δεν πρέπει να εκληφθεί ως αποτυχία χωρίς επιστημονική αξία. Αντιθέτως, αποτελεί ένα ουσιώδες αρνητικό εύρημα, διότι δείχνει ότι οι μηχανισμοί προσοχής δεν επιφέρουν κατ' ανάγκην κέρδος ανεξαρτήτως του καθεστώτος εκπαίδευσης και της αρχιτεκτονικής στην οποία ενσωματώνονται. Η μη υπεροχή του ECA μπορεί να ερμηνευθεί από δύο αλληλένδετους παράγοντες: αφενός, από τις αλληλεπιδράσεις με τα στρώματα κανονικοποίησης, τα οποία είναι δυνατόν να απορροφούν ή να εξουδετερώνουν την κλιμάκωση καναλιών που επιχειρεί να επιβάλει το ECA, και αφετέρου από την περιορισμένη αντιστοίχιση μεταξύ συνθετικού και πραγματικού θορύβου. Υπό αυτή την έννοια, το αρνητικό αποτέλεσμα δεν αναιρεί τη θεωρητική χρησιμότητα της προσοχής καναλιών, αλλά οριοθετεί με σαφήνεια τις συνθήκες υπό τις οποίες η συνεισφορά της μπορεί να καταστεί μη παρατηρήσιμη.

5.5.2 Regime-Dependent Συμπεριφορά

Τα μεταγενέστερα πειράματα κατέδειξαν ότι η επίδραση του ECA δεν είναι καθολική, αλλά εξαρτάται ουσιαστικά από το καθεστώς εποπτείας και από την ένταση της ενσωμάτωσής του στην αρχιτεκτονική. Η μετάβαση από την εποπτεία με pseudo-noisy δεδομένα σε real-aligned supervision, όπου η μεμονωμένη λήψη αντιστοιχίζεται με χρονικό μέσο όρο υψηλού SNR, ανέδειξε μια σαφώς regime-dependent συμπεριφορά. Στο πλαίσιο αυτό, η ήπια παραλλαγή V4r κατέγραψε την καλύτερη ταξινομική επίδοση, ενώ η επιθετικότερη V5r δεν παρήγαγε αντίστοιχο πρόσθετο κέρδος. Η ερμηνεία είναι ότι η υπερβολική ενίσχυση των μηχανισμών attention μπορεί να οδηγεί σε oversmoothing και συνεπώς σε αποδυνάμωση των διαγνωστικών μορφολογικών μοτίβων. Το συμπέρασμα αυτό ενισχύεται

και από το πείραμα Averaged Swap, στο οποίο η απευθείας τροφοδοσία του ταξινομητή με εικόνες χρονικού μέσου όρου οδήγησε σε χαμηλότερη ταξινομική απόδοση παρά το υψηλότερο SNR. Η παρατήρηση αυτή υποδεικνύει ότι η απλή αύξηση του λόγου σήματος προς θόρυβο δεν αρκεί από μόνη της· εξίσου σημαντική είναι η διατήρηση της δειγματικής ποικιλομορφίας και της ιδιομορφίας κάθε λήψης. Συνολικά, η συνεισφορά του ECA αποδεικνύεται εξαρτώμενη από τρεις κυρίως άξονες: την ποιότητα της εποπτείας, το επίπεδο θορύβου και την ένταση ή τοποθέτηση του ίδιου του μηχανισμού μέσα στο δίκτυο.

5.6 Σύνθεση της Ανάλυσης Γενίκευσης: LOBO έναντι LODO

Τα πρωτόκολλα LOBO και LODO αξιολόγησαν δύο διαφορετικές όψεις της γενίκευσης του προτεινόμενου συστήματος. Καθώς η μεθοδολογική τους περιγραφή και τα επιμέρους αριθμητικά αποτελέσματα έχουν ήδη παρουσιαστεί εκτενώς στην Ενότητα 4.6, η παρούσα ενότητα περιορίζεται στη συνθετική αποτίμηση της μεταξύ τους ασυμμετρίας και στις δομικές αιτίες του λεγόμενου «χάσματος γενίκευσης».

5.6.1 Διχοτομία στη Συμπεριφορά Γενίκευσης

Η αντιπαραβολή των δύο πρωτοκόλλων αναδεικνύει μια σαφή διχοτομία. Η γενίκευση σε νέες συχνότητες, όπως αποτυπώνεται στο LOBO, παραμένει σε υψηλό επίπεδο, γεγονός που υποδηλώνει ότι το σύστημα εκμεταλλεύεται με επιτυχία τη συνέχεια των μορφολογικών μεταβολών που επιβάλλουν οι φυσικοί νόμοι των δονήσεων και ότι τα frequency priors προσδίδουν σταθερότητα στην αναπαράσταση. Αντιθέτως, η γενίκευση σε νέα δοκίμια, όπως αποτυπώνεται στο LODO, παρουσιάζει έντονη κατάρρευση σε ορισμένες περιπτώσεις, με πιο χαρακτηριστική εκείνη του W02. Το γεγονός αυτό δείχνει ότι το μοντέλο δεν μαθαίνει αποκλειστικά γενικές δομές των ιδιομορφών, αλλά σε έναν βαθμό απορροφά και ειδικά γνωρίσματα των ίδιων των οργάνων ή των συνθηκών μέτρησης, δηλαδή εμφανίζει origin bias. Κατά συνέπεια, ο βασικός περιοριστικός παράγοντας δεν είναι η μεταβολή της συχνότητας καθαυτή, αλλά η μετατόπιση πεδίου που προκύπτει από διαφορές στη γεωμετρία, στη μικροδομή του υλικού, στις κατασκευαστικές ανομοιογένειες και στη στατιστική συμπεριφορά του θορύβου. Η εξαιρετικά υψηλή διακύμανση της επίδοσης στο LODO υποδηλώνει ότι η μεταφορά γνώσης εξαρτάται κρίσιμα από τον βαθμό ομοιότητας μεταξύ των δοκιμίων εκπαίδευσης και του δοκιμίου αξιολόγησης. Το εύρημα αυτό τεκμηριώνει εμπειρικά την ανάγκη είτε για εμπλουτισμό του συνόλου εκπαίδευσης με μεγαλύτερη

ποικιλομορφία δοκιμίων είτε για μορφές ήπιας βαθμονόμησης ανά αντικείμενο, εφόσον επιδιώκεται σταθερότερη μεταφορά του μοντέλου σε νέα φυσικά συστήματα.

5.7 Συνολική Ερμηνεία και Σύνθεση Ευρημάτων

5.7.1 Σύνοψη Ευρημάτων

Η παρούσα διπλωματική εργασία ανέπτυξε και αξιολόγησε ένα πολυεπίπεδο σύστημα για την αυτόματη ταξινόμηση ιδιομορφών ESPI. Η σύνθεση των επιμέρους αναλύσεων του Κεφαλαίου 4 και 5 σκιαγραφεί το προφίλ ενός συστήματος που συνδυάζει τη φυσική γνώση με τη μηχανική μάθηση, αναδεικνύοντας τόσο τα ισχυρά σημεία όσο και τους περιορισμούς του.

- **Αποθορυβοποίηση: Η Ανάγκη για Προσαρμοστικότητα** Η εφαρμογή του φυσικά βασισμένου μοντέλου θορύβου (Burr-XII) με βαθμονόμηση ανά δοκίμιο έδειξε θετικά αποτελέσματα σε ορισμένες περιπτώσεις (π.χ. βελτίωση PSNR +0,307 dB στο W01), αλλά δεν επέτυχε καθολική βελτίωση (αστοχία στο W02). Αυτό καταδεικνύει ότι η στατική φυσική μοντελοποίηση είναι αναγκαία, αλλά όχι επαρκής· απαιτείται δυναμική ή επαναληπτική ρύθμιση για να καλυφθεί η μεταβλητότητα των πραγματικών συνθηκών.
- **Υπεροχή της Υβριδικής Προσέγγισης (Physics-Informed ML)** Ο ταξινομητής Hybrid Random Forest πέτυχε κορυφαία επίδοση (97,85%) στο εντός-πεδίου σενάριο, ξεπερνώντας τις εναλλακτικές μεθόδους. Η ανάλυση σημαντικότητας απέδωσε το 96,86% της διαχωριστικής ισχύος στα πρότερες συχνοτικές πληροφορίες θεμελιωμένες στη φυσική (frequency priors), επιβεβαιώνοντας ότι η ενσωμάτωση γνώσης πεδίου (domain knowledge) είναι κρίσιμη και ότι τα δενδρικά μοντέλα είναι ιδανικά για την αξιοποίησή της.
- **Αρχιτεκτονική Attention Channel**: Το Αρνητικό Εύρημα ECA Η ενσωμάτωση του μηχανισμού Efficient Channel Attention (ECA) δεν επέφερε μετρήσιμη βελτίωση (ούτε στο PSNR, ούτε στην ταξινόμηση). Το εύρημα αυτό υποδηλώνει ότι για τη συγκεκριμένη εφαρμογή αποθορυβοποίησης, η δυναμική ανακατανομή βαρών στα κανάλια δεν είναι κρίσιμη, πιθανώς λόγω της ομοιογένειας του θορύβου

κηλίδων στο φάσμα. Υπογραμμίζεται έτσι η αξία των μελετών αφαίρεσης (ablation studies) για την αποφυγή περιττής πολυπλοκότητας.

- **Στιβαρότητα LOBO: Επιτυχής Συχνοτική Γενίκευση** Η υψηλή μέση ακρίβεια (**91,83%**) στο πρωτόκολλο LOBO αποδεικνύει ότι το σύστημα έχει "μάθει" τους φυσικούς κανόνες που διέπουν την εξέλιξη των ιδιομορφών στο πεδίο της συχνότητας, επιτρέποντας την αξιόπιστη πρόβλεψη σε αθέατες συχνοτικές ζώνες.
- **Ευαισθησία LODO: Η Πρόκληση της Προέλευσης** Η μέτρια επίδοση (**66,31%**) και η εξαιρετικά υψηλή διακύμανση (**44,11%**) στο πρωτόκολλο LODO αποκαλύπτουν ότι το σύστημα υποφέρει από **μεροληψία προέλευσης (provenance bias)**. Η κατάρρευση της απόδοσης κατά την εξαίρεση του W02 (15,27%) επιβεβαιώνει ότι η γενίκευση σε νέα όργανα απαιτεί ρητές στρατηγικές προσαρμογής πεδίου (domain adaptation) για την υπέρβαση των υλικών διαφορών.

5.7.2 Κρίσιμοι Περιορισμοί των Ευρημάτων

Παρά την υψηλή επίδοση του υβριδικού μοντέλου, η ανάλυση ανέδειξε τέσσερις δομικούς περιορισμούς που οριοθετούν το εύρος εγκυρότητας των αποτελεσμάτων:

- **Καθεστώς Περιορισμένων Δεδομένων (Data Scarcity):** Το μέγεθος του συνόλου δεδομένων ($N = 3.443$) κρίνεται οριακό για την εκπαίδευση βαθιών νευρωνικών δικτύων (Deep Learning). Αυτός ο περιορισμός εξηγεί την υστέρηση του CNN και καθιστά αναγκαία την εξάρτηση από τη μηχανική χαρακτηριστικών (Hybrid RF) για την ενσωμάτωση γνώσης πεδίου.
- **Μεροληψία Προέλευσης (Provenance Bias):** Η κυριαρχία του δοκιμίου W02 (81,4% του συνόλου) εισάγει μια σοβαρή πληθυσμιακή μεροληψία. Το εκπαιδευμένο μοντέλο ενδέχεται να έχει μάθει να αναγνωρίζει την "υπογραφή" (γεωμετρία/υφή) του W02 αντί για τα καθολικά χαρακτηριστικά των ιδιομορφών. Αυτό δημιουργεί τον κίνδυνο υπερπροσαρμογής σε χαρακτηριστικά που δεν σχετίζονται με τη φυσική (nuisance features).
- **Ενδογενής Ανισορροπία Κλάσεων:** Ο λόγος ανισορροπίας 30,9:1 μεταξύ της πλειοψηφούσας (Other/Higher) και της μειοψηφούσας κλάσης παραμένει μια

μόνιμη πρόκληση. Αν και ο Hybrid RF διαχειρίζεται το πρόβλημα ικανοποιητικά μέσω στάθμισης, η σπανιότητα των θεμελιωδών modes (π.χ. 2,1) αυξάνει την αβεβαιότητα της πρόβλεψης σε οριακές περιπτώσεις.

- **Μονομορφία Οργάνων:** Η μελέτη περιορίστηκε αποκλειστικά σε τετράχορδα μπουζούκια. Η δυνατότητα γενίκευσης σε άλλα έγχορδα (π.χ. τρίχορδο, κιθάρα) ή διαφορετικά υλικά (π.χ. ανθρακονήματα) παραμένει αχαρτογράφητη.

5.8 Περιορισμοί της Μεθοδολογίας και της Πειραματικής Διαδικασίας

Παρά την υψηλή ταξινομική ακρίβεια και τη μεθοδολογική αρτιότητα που επιδείχθηκε στα προηγούμενα στάδια, το προτεινόμενο σύστημα υπόκειται σε συγκεκριμένους περιορισμούς, οι οποίοι οριοθετούν το τρέχον πεδίο εφαρμογής του. Η συστηματική καταγραφή τους κρίνεται επιστημονικά επιβεβλημένη, όχι ως υποτίμηση των ευρημάτων, αλλά ως απαραίτητη προϋπόθεση για την ορθή ερμηνεία τους και τον προσδιορισμό ρεαλιστικών μελλοντικών κατευθύνσεων.

5.8.1 Μεθοδολογικοί Περιορισμοί (Implementation Limitations)

Η πρώτη κατηγορία περιορισμών πηγάζει από τις συγκεκριμένες σχεδιαστικές επιλογές και την πρακτική υλοποίηση της προτεινόμενης αλγοριθμικής ροής (pipeline). Ειδικότερα, οι προκλήσεις αυτές αφορούν τον βαθμό αυτοματοποίησης των διαδικασιών, την εγγενή ευαισθησία των σταδίων προεπεξεργασίας, καθώς και τον στενό βαθμό εξάρτησης του μοντέλου από τη γεωμετρία του εκάστοτε δοκιμίου:

- **Χειροκίνητη Βαθμονόμηση του Θορύβου (Manual Calibration):** Η παραμετροποίηση του μοντέλου Burr-XII για την προσομοίωση του θορύβου απαιτεί χειροκίνητη ρύθμιση ανά δοκίμιο. Η απουσία μιας πλήρως αυτοματοποιημένης, προσαρμοστικής διαδικασίας βελτιστοποίησης (adaptive optimization) περιορίζει προσώρας την επεκτασιμότητα της μεθόδου σε ευρεία βιομηχανική κλίμακα.
- **Ευαισθησία στη Χωρική Ευθυγράμμιση (Registration Sensitivity):** Η απόδοση της αποθορυβοποίησης εξαρτάται κρίσιμα από την ακριβή χρονική και χωρική συνορθάμιση (alignment/registration) μεταξύ των μεμονωμένων λήψεων (single-shot) και των χρονικά ολοκληρωμένων εικόνων αναφοράς (time-averaged). Ακόμη

και ελάχιστες μικρο-μετατοπίσεις (sub-pixel shifts) κατά τη διάρκεια της λήψης μπορούν να επιφέρουν σημαντική τεχνητή μείωση του δείκτη PSNR.

- **Εξάρτηση από Χειροκίνητα Σχεδιασμένα Χαρακτηριστικά (Hand-crafted Features):** Η επιτυχία του υβριδικού ταξινομητή Random Forest (Hybrid RF) βασίζεται σε δομικά χαρακτηριστικά που σχεδιάστηκαν ειδικά για τη γεωμετρία του συγκεκριμένου οργάνου (μορφολογικά μοτίβα, συχνοτικές ζώνες). Η απευθείας μεταφορά της μεθόδου σε ριζικά διαφορετικές πειραματικές διατάξεις απαιτεί τον ανασχεδιασμό του διανύσματος των χαρακτηριστικών (feature re-engineering).

5.8.2 Πειραματικοί Περιορισμοί (Experimental Constraints)

Η δεύτερη κατηγορία περιορισμών σχετίζεται στενά με τον σχεδιασμό των πειραμάτων, τους διαθέσιμους υπολογιστικούς πόρους και τη φύση των δεδομένων που χρησιμοποιήθηκαν κατά τη φάση της εκπαίδευσης και αξιολόγησης:

- **Σταθερός Διαχωρισμός Δεδομένων (Fixed / Single Split):** Τα κύρια αποτελέσματα αξιολόγησης προέκυψαν από έναν σταθερό, τυχαίο διαχωρισμό του συνόλου δεδομένων (70/15/15). Παρότι τα ειδικά πρωτόκολλα LOBO και LODO προσφέρουν μια καθαρή εικόνα της διακύμανσης, ένα σχήμα πολλαπλής διασταυρούμενης επικύρωσης (π.χ., k-fold ή Monte Carlo CV) θα παρείχε μια ακόμη πιο αυστηρή εκτίμηση της στατιστικής αβεβαιότητας.
- **Περιορισμένη Αναζήτηση Υπερπαραμέτρων:** Λόγω υπολογιστικών και χρονικών περιορισμών, δεν κατέστη δυνατή η εκτέλεση μιας εξαντλητικής αναζήτησης πλέγματος (exhaustive grid search) για το σύνολο των υπερπαραμέτρων του Hybrid RF (π.χ., max_depth, min_samples_leaf). Συνεπώς, η αναφερόμενη υψηλή επίδοση ενδέχεται να μην αποτελεί το απόλυτο θεωρητικό ανώτατο όριο (upper bound) της μεθόδου.
- **Απουσία Εξωτερικής Επαλήθευσης (External Validation):** Το σύνολο των δεδομένων προέρχεται από μια ενιαία εργαστηριακή διάταξη. Η έλλειψη ενός εντελώς ανεξάρτητου συνόλου δεδομένων (external dataset) από διαφορετικό ερευνητικό κέντρο ή βιομηχανικό περιβάλλον στερεί από τη μελέτη την τελική εμπειρική επιβεβαίωση της καθολικής ισχύος της.

5.9 Συμπεράσματα και Τελική Αποτίμηση

Η ανάλυση του Κεφαλαίου 5 οδηγεί σε πέντε θεμελιώδη συμπεράσματα που συνοψίζουν την ταυτότητα και την ωριμότητα του προτεινόμενου συστήματος:

- **Η Φυσική Γνώση ως Πολλαπλασιαστής Ισχύος**: Η ενσωμάτωση συχνοτικών πρότερων πληροφοριών (Frequency Priors) στον αλγόριθμο Random Forest αποδείχθηκε η βέλτιστη στρατηγική για το συγκεκριμένο πρόβλημα, επιτυγχάνοντας ακρίβεια 97,85% και ξεπερνώντας τις λύσεις Deep Learning. Η επιτυχία αυτή επιβεβαιώνει ότι σε καθεστώτα περιορισμένων δεδομένων, η γνώση πεδίου είναι πολυτιμότερη από την αλγοριθμική πολυπλοκότητα.
- **Η Αποθορυβοποίηση απαιτεί Προσαρμογή:** Η φυσικά βασισμένη μοντελοποίηση θορύβου (Burr-XII) έδειξε δυνατότητες (π.χ. +0,307 dB στο W01) αλλά δεν είναι καθολική. Η αποτυχία στο δοκίμιο W02 υποδεικνύει ότι τα στατικά μοντέλα θορύβου είναι ανεπαρκή χωρίς μηχανισμούς προσαρμογής στο εκάστοτε πεδίο (domain adaptation).
- **Η Πολυπλοκότητα δεν εγγυάται Βελτίωση:** Το αρνητικό εύρημα σχετικά με τον μηχανισμό προσοχής ECA (μηδενική βελτίωση σε PSNR/SSIM) υπογραμμίζει τη σημασία της εμπειρικής επαλήθευσης. Στη συγκεκριμένη εφαρμογή, η χωρική πληροφορία υπερέχει της συσχέτισης καναλιών.
- **Το Χάσμα Γενίκευσης (The Generalization Gap):** Εντοπίστηκε μια σαφής διχοτομία στη στιβαρότητα του συστήματος. Ενώ η γενίκευση σε νέες συχνότητες είναι εξαιρετική (**LOBO: 91,83%**), η γενίκευση σε νέα όργανα είναι προβληματική (**LODO: 66,31%**). Η κατάρρευση της απόδοσης κατά την εξαίρεση του W02 (15,27%) αποκαλύπτει ότι η **μετατόπιση πεδίου (domain shift)** αποτελεί το κύριο εμπόδιο για την καθολική εφαρμογή.
- **Ετοιμότητα Ανάπτυξης (Deployment Readiness):** Το σύστημα επιτυγχάνει υψηλή αξιοπιστία κατά την αξιολόγηση γνωστών γραμμών παραγωγής (ίδιο μοντέλο οργάνου). Εντούτοις, η ικανότητα καθολικής γενίκευσής του σε άγνωστα δοκίμια παραμένει περιορισμένη χωρίς πρότερη προσαρμογή. Συνεπώς, για την άμεση (plug-and-play) χρήση του σε νέα όργανα, κρίνεται επιβεβλημένη η ενσωμάτωση μεθόδων μεταφοράς μάθησης (transfer learning) και επαναρρύθμισης (fine-tuning) του μοντέλου.

ΚΕΦΑΛΑΙΟ 6: ΣΥΜΠΕΡΑΣΜΑΤΑ

6.1 Σύνοψη

Η παρούσα διπλωματική εργασία ανέπτυξε και αξιολόγησε ένα ενοποιημένο πλαίσιο αυτοματοποιημένης ανάλυσης εικόνων Ηλεκτρονικής Συμβολομετρίας Συσχετιζόμενων Κηλίδων (ESPI) για την αναγνώριση ιδιομορφών δόνησης σε καπάκια μουσικών οργάνων. Ο κεντρικός άξονας της εργασίας ήταν ότι η ρητή ενσωμάτωση φυσικής γνώσης στη μαθησιακή διαδικασία, τόσο στο επίπεδο των χαρακτηριστικών όσο και στο επίπεδο της αξιολόγησης, μπορεί να βελτιώσει συγχρόνως την απόδοση, τη σταθερότητα και την ερμηνευσιμότητα του συστήματος.

Το προτεινόμενο σχήμα οργανώθηκε γύρω από τρεις αλληλοσυμπληρούμενους άξονες: αποθορυβοποίηση και προεπεξεργασία κατάλληλη για ESPI, υβριδική αναπαράσταση με συνδυασμό μορφολογικών περιγραφέων και φυσικά θεμελιωμένων συχνοτικών παραμέτρων, και αυστηρά πρωτόκολλα αξιολόγησης γενίκευσης. Στο κύριο πειραματικό αποτέλεσμα, ο Hybrid Random Forest, αξιοποιώντας 16 μορφολογικά χαρακτηριστικά και 6 συχνοτικά priors, επέτυχε Accuracy 97,85% και Macro-F1 95,15%, υπερβαίνοντας τόσο το Pattern-only Random Forest όσο και το αμιγώς δεδομενοκεντρικό ResNet-18.

Εξίσου σημαντικό εύρημα ήταν ότι η εργασία δεν περιορίστηκε στην ανάδειξη των θετικών αποτελεσμάτων, αλλά τεκμηρίωσε και αρνητικά ή οριακά ευρήματα. Η συμπεριφορά αυτή είναι ιδιαίτερα εμφανής στην περίπτωση του μηχανισμού ECA, όπου στο βασικό πρωτόκολλο δεν παρατηρήθηκε ουσιαστικό κέρδος, καθώς και στη δυσαναλογία μεταξύ βελτίωσης της ποιότητας εικόνας και τελικής ταξινομητικής απόδοσης. Έτσι, το παρόν κεφάλαιο δεν επαναλαμβάνει αναλυτικά τα αποτελέσματα των Κεφαλαίων 4 και 5, αλλά τα συνθέτει σε συμπεράσματα, θεωρητικές αποτιμήσεις, περιορισμούς και ρεαλιστικές προοπτικές συνέχειας.

6.2 Απαντήσεις στα ερευνητικά ερωτήματα

Στην ενότητα αυτή συνοψίζονται οι απαντήσεις στα πέντε ερευνητικά ερωτήματα που διατυπώθηκαν στο §1.2.2. Η διατύπωση παραμένει συνθετική και παραπέμπει στα αντίστοιχα κεφάλαια για την πλήρη τεκμηρίωση.

6.2.1 RQ1: Επιρροή της αποθορυβοποίησης στην ταξινόμηση

Το πρώτο ερώτημα αφορούσε το ποιος μηχανισμός αποθορυβοποίησης ισορροπεί αποτελεσματικότερα την καταστολή του speckle θορύβου με τη διατήρηση της πληροφορίας που είναι κρίσιμη για την ταξινόμηση. Το βασικό συμπέρασμα είναι ότι δεν υπάρχει

καθολικά άριστος μηχανισμός ανεξάρτητος από το καθεστώς εποπτείας και τον τελικό στόχο. Η μετάβαση από noisy σε denoised είσοδο βελτιώνει θεαματικά τη συνολική επίδοση του ταξινομητή, όμως η ανώτερη ποιότητα σε επίπεδο εικονοστοιχείου δεν εγγυάται κατ' ανάγκην ανώτερη ταξινομητική απόδοση. Ως εκ τούτου, η αποθορυβοποίηση πρέπει να αξιολογείται πρωτίστως με βάση το downstream έργο και όχι μόνο με φωτομετρικές μετρικές.

6.2.2 RQ2: Στρατηγική αντιμετώπισης της σπανιότητας δεδομένων

Το δεύτερο ερώτημα αφορούσε τον βαθμό στον οποίο η φυσικά καθοδηγούμενη σύνθεση ψευδο-θορυβωδών δεδομένων μπορεί να υποκαταστήσει περιορισμένα πραγματικά δεδομένα. Το συμπέρασμα είναι θετικό αλλά σαφώς οριοθετημένο. Η αλυσίδα υποβάθμισης speckle–Poisson–Gaussian αποδείχθηκε χρήσιμη όταν βαθμονομήθηκε με τρόπο συμβατό προς τα πραγματικά δεδομένα, λειτουργώντας ως ρεαλιστικό εργαλείο synthetic supervision. Ωστόσο, το όφελος δεν είναι αυτόματο· εξαρτάται από την αντιστοίχιση του μοντέλου θορύβου με τα στατιστικά κάθε δοκιμίου και από την ισορροπία του συνόλου εκπαίδευσης.

6.2.3 RQ3: Ο ρόλος της προσοχής καναλιών (ECA)

Το τρίτο ερώτημα διερεύνησε αν η ενσωμάτωση του μηχανισμού Efficient Channel Attention στο δίκτυο αποθορυβοποίησης βελτιώνει ουσιαστικά τη διατήρηση δομικών λεπτομερειών και τη downstream απόδοση. Στο κύριο πρωτόκολλο της εργασίας, το αποτέλεσμα ήταν αρνητικό: η προσθήκη ECA δεν οδήγησε σε στατιστικά σημαντική βελτίωση. Η ερμηνεία που προκύπτει είναι ότι, στο συγκεκριμένο καθεστώς, οι μικρές ανασταθμίσεις καναλιών απορροφώνται από το residual σχήμα και τα στρώματα κανονικοποίησης. Παρά ταύτα, μεταγενέστερα συμπληρωματικά πειράματα υπέδειξαν ότι η συμβολή του ECA δεν είναι απόλυτα μηδενική, αλλά εξαρτάται από το supervision regime και τη συνολική αρχιτεκτονική διαμόρφωση.

6.2.4 RQ4: Η αξία της πρότερης φυσικής γνώσης

Το τέταρτο ερώτημα αφορά την επίδραση της ενσωμάτωσης πρότερης φυσικής γνώσης στη διαχωριστική ικανότητα και στην ερμηνευσιμότητα του μοντέλου. Το εύρημα είναι έντονα καταφατικό. Η υβριδική σύζευξη μορφολογικών περιγραφέων και συχνοτικών priors οδήγησε στην υψηλότερη συνολική απόδοση της εργασίας και, ταυτόχρονα, προσέφερε σαφή φυσική ερμηνεία για την πηγή της διακριτικής ικανότητας του συστήματος. Το γεγονός ότι οι συχνοτικές παράμετροι συγκεντρώνουν το μεγαλύτερο ποσοστό της

προγνωστικής βαρύτητας επιβεβαιώνει ότι το μοντέλο δεν λειτουργεί ως αδιαφανής στατιστικός μηχανισμός, αλλά ως υβριδικό σχήμα που αξιοποιεί ρητά σχετική φυσική γνώση.

6.2.5 RQ5: Όρια γενίκευσης και ανθεκτικότητα

Το πέμπτο ερώτημα αφορούσε τις προϋποθέσεις υπό τις οποίες το μοντέλο διατηρεί την απόδοσή του σε νέα δεδομένα. Η βασική εικόνα είναι διττή. Από τη μία πλευρά, η γενίκευση σε άγνωστες συχνοτικές ζώνες εντός του ίδιου δοκιμίου παραμένει υψηλή, όπως δείχνει το πρωτόκολλο LOBO. Από την άλλη, η μετάβαση σε άγνωστο δοκίμιο στο πρωτόκολλο LODO είναι σαφώς δυσκολότερη, ιδίως όταν συνυπάρχουν ετερογένεια θορύβου και ανισορροπία δειγμάτων. Επομένως, η εργασία τεκμηριώνει ότι το προτεινόμενο πλαίσιο είναι ισχυρό εντός συγγενούς πεδίου, αλλά απαιτεί πρόσθετους μηχανισμούς προσαρμογής όταν μεταβάλλεται ουσιωδώς το πειραματικό περιβάλλον.

6.3 Θεωρητικές συνεισφορές

Η εργασία συνεισφέρει θεωρητικά σε τρεις άξονες. Πρώτον, τεκμηριώνει ότι σε προβλήματα ESPI με περιορισμένο όγκο δεδομένων η φυσικά καθοδηγούμενη αναπαράσταση μπορεί να λειτουργήσει ως αποτελεσματικός μηχανισμός μείωσης της διακύμανσης του μοντέλου χωρίς σημαντική απώλεια ευελιξίας. Δεύτερον, δείχνει εμπειρικά ότι η μορφολογία των fringe patterns και η συχνοτική πληροφορία είναι συμπληρωματικές αλλά όχι ισοδύναμες πηγές γνώσης: η πρώτη περιγράφει τη χωρική τοπολογία, ενώ η δεύτερη αγκυρώνει την κατηγοριοποίηση στη φυσική του συστήματος. Τρίτον, αναδεικνύει ότι η γενίκευση δεν είναι μονοσήμαντη έννοια· η επίδοση σε νέα συχνοτική ζώνη και η επίδοση σε νέο δοκίμιο αποτυπώνουν διαφορετικά είδη δυσκολίας και δεν πρέπει να συγχέονται.

Υπό αυτή την έννοια, το κυριότερο θεωρητικό μήνυμα της εργασίας είναι ότι η επιτυχία ενός υβριδικού μοντέλου δεν οφείλεται μόνο στην «προσθήκη περισσότερων χαρακτηριστικών», αλλά στη στοχευμένη εισαγωγή φυσικά σχετικής πληροφορίας. Η φυσική γνώση δρα ως περιορισμός του χώρου λύσεων και οδηγεί σε περισσότερο ερμηνεύσιμη και σταθερή μάθηση, ιδιαίτερα σε καθεστώτα σπανιότητας δεδομένων και έντονης στοχαστικότητας των μετρήσεων.

6.4 Πρωτοτυπία και κύριες νέες συνεισφορές

Η πρωτοτυπία της παρούσας εργασίας δεν εξαντλείται σε μία μεμονωμένη επίδοση, αλλά στη συγκρότηση ενός συνεκτικού πλαισίου ανάλυσης ESPI που συνδυάζει σχεδιασμό αναπαράστασης, φυσικά βαθμονομημένη σύνθεση δεδομένων, αυστηρά πρωτόκολλα γενίκευσης και ρητή καταγραφή ορίων. Η κεντρική συμβολή είναι ο σχεδιασμός και η

αξιοποίηση φυσικά θεμελιωμένων συχνοτικών χαρακτηριστικών, τα οποία συνδέθηκαν υβριδικά με μορφολογικούς περιγραφείς και οδήγησαν σε σημαντική ενίσχυση της απόδοσης.

Εξίσου ουσιώδης είναι η ανάπτυξη της φυσικά βαθμονομημένης γεννήτριας ψευδοθορύβου, η οποία δεν αντιμετωπίζεται ως απλό εργαλείο αύξησης δεδομένων, αλλά ως ελεγχόμενο πειραματικό περιβάλλον για τη μελέτη της σχέσης μεταξύ synthetic supervision και πραγματικής λειτουργικής απόδοσης. Στην ίδια λογική, η πλήρης τεκμηρίωση του null result για το ECA αποτελεί επιστημονική συνεισφορά, διότι οριοθετεί ρητά πότε η αύξηση αρχιτεκτονικής πολυπλοκότητας δεν μεταφράζεται σε ουσιαστικό κέρδος.

Τέλος, η συστηματική εφαρμογή των πρωτοκόλλων LOBO και LODO και η ανάλυση των failure cases, ιδίως της περίπτωσης W02, προσδίδουν στην εργασία μεθοδολογική ωριμότητα. Η συμβολή της εργασίας δεν είναι μόνο ότι παρουσιάζει ένα ισχυρό μοντέλο, αλλά ότι δείχνει με σαφήνεια πού το μοντέλο παραμένει αξιόπιστο και πού αρχίζουν τα όριά του.

6.5 Θεωρητικές προεκτάσεις

Η κωδικοποίηση φυσικής γνώσης μέσω συχνοτικών priors μετασχηματίζει το πρόβλημα από μία γενική διαδικασία αναγνώρισης προτύπων σε μία περισσότερο περιορισμένη διαδικασία εκτίμησης υπό φυσικές δεσμεύσεις. Το στοιχείο αυτό εξηγεί θεωρητικά γιατί ένα σχετικά μικρό και ερμηνεύσιμο μοντέλο, όπως ο Hybrid RF, μπορεί να υπερέχει έναντι ενός βαθύτερου δικτύου με πολύ περισσότερες παραμέτρους όταν το διαθέσιμο σύνολο δεδομένων είναι περιορισμένο.

Παράλληλα, η εργασία υποστηρίζει εμπειρικά την ανάγκη ολιστικής αξιολόγησης. Η βελτίωση μετρικών όπως τα PSNR και SSIM δεν μπορεί να θεωρείται επαρκές κριτήριο επιτυχίας όταν ο τελικός στόχος είναι η αναγνώριση ιδιομορφών. Η ασυμφωνία μεταξύ pixel-level βελτίωσης και downstream επίδοσης δείχνει ότι, στα ESPI συστήματα, η πραγματική πληροφορία δεν εξαντλείται στην οπτική καθαρότητα, αλλά στη διατήρηση της φυσικά ουσιώδους δομής των fringe patterns.

6.6 Περιορισμοί και αρνητικά ευρήματα

Η εργασία ανέδειξε τρεις βασικούς περιορισμούς. Πρώτον, η γενίκευση τύπου LODO μπορεί να υποβαθμιστεί έντονα όταν συνδυάζονται ετερογένεια θορύβου, ιδιαιτερότητες δοκιμίου και ανισορροπία δειγμάτων. Δεύτερον, η προσθήκη μηχανισμών attention στο στάδιο αποθορυβοποίησης δεν αποτελεί εξ ορισμού εγγύηση βελτίωσης· στο κύριο

πρωτόκολλο το ECA λειτούργησε ουσιαστικά ως null result. Τρίτον, η ακριβής αλληλεπίδραση attention και normalization δεν εξαντλήθηκε πλήρως στο πλαίσιο της παρούσας εργασίας και παραμένει ανοιχτό ερευνητικό ζήτημα.

Τα αρνητικά αυτά ευρήματα δεν υποβαθμίζουν τη συνεισφορά της μελέτης. Αντιθέτως, επιτρέπουν την οριοθέτηση των συμπερασμάτων και καθιστούν τη μελλοντική συνέχεια περισσότερο στοχευμένη. Η επιστημονική αξία της εργασίας έγκειται επίσης στο ότι αποφεύγει την υπεραπλούστευση και καταγράφει ρητά τόσο τα ισχυρά σημεία όσο και τα σημεία αστάθειας του προτεινόμενου πλαισίου.

6.7 Μελλοντικές προεκτάσεις της παρούσας έρευνας

Η παρούσα εργασία κατέδειξε ότι η ενσωμάτωση φυσικά θεμελιωμένων πρότερων πληροφοριών υπό τη μορφή έξι συχνοτικών παραμέτρων που κωδικοποιούν τις θεωρητικές ιδιοσυχνότητες κάθε κατηγορίας βελτιώνει ουσιαστικά την αυτόματη ταξινόμηση ιδιομορφών από εικόνες ESPI (Ewins, 2000· Inman, 2014). Συγκεκριμένα, το Hybrid Random Forest επέτυχε Accuracy 97,85% και Macro-F1 95,15%, έναντι 90,15% και 69,91% αντίστοιχα του μοντέλου που βασιζόταν αποκλειστικά σε μορφολογικά χαρακτηριστικά. Η διαφορά αυτή επιβεβαιώθηκε ως στατιστικά σημαντική μέσω του ελέγχου McNemar (Dietterich, 1998).

Ταυτόχρονα, όμως, η εργασία ανέδειξε με σαφήνεια και τα όρια της υφιστάμενης μεθοδολογίας. Η τρέχουσα αρχιτεκτονική βασίζεται σε διαδοχικό αγωγό επεξεργασίας δεδομένων, όπου η αποθορυβοποίηση, η εξαγωγή φάσης, η εξαγωγή χαρακτηριστικών και η τελική ταξινόμηση παραμένουν διακριτά στάδια (Hastie et al., 2009). Παρότι η δομή αυτή είναι μεθοδολογικά διαφανής, συνοδεύεται από περιορισμούς, όπως η διάδοση σφαλμάτων, η εξάρτηση από σταθερές παραμέτρους φασματικής ανάλυσης και η μειωμένη γενίκευση σε νέα υλικά ή νέα δοκίμια (Takeda et al., 1982). Οι διαπιστώσεις αυτές δεν αναιρούν την εγκυρότητα του μοντέλου· αντιθέτως, χαράσσουν τον φυσικό ορίζοντα της επόμενης ερευνητικής φάσης.

6.7.1 Θεμελίωση και βελτίωση του υφιστάμενου pipeline

Η πρώτη κατεύθυνση μελλοντικής εργασίας αφορά τη βελτιστοποίηση των επιμέρους υποσυστημάτων με γνώμονα το τελικό έργο και όχι αποκλειστικά την ποιότητα εικόνας. Το γεγονός ότι το DnCNN μπορεί να βελτιώνει τη φωτομετρική πιστότητα χωρίς αντίστοιχη βελτίωση στο downstream έργο δείχνει ότι οι μελλοντικοί αλγόριθμοι

αποθορυβοποίησης πρέπει να αξιολογούνται με κριτήριο κατά πόσον διατηρούν την τοπολογία των κομβικών γραμμών και τη συχνοχωρική δομή των κροσσών.

Στην ίδια κατεύθυνση, είναι σκόπιμη η διερεύνηση προσαρμοστικότερων μεθόδων φασματικής ανάλυσης, όπως ο Βραχύχρονος Μετασχηματισμός Fourier και οι αναλύσεις κυματιδίων, καθώς και η εισαγωγή μηχανισμών ποσοτικοποίησης της αβεβαιότητας στο τελικό στάδιο απόφασης (Allen & Rabiner, 1977· Mallat, 1999· Gal & Ghahramani, 2016). Σε πραγματικές εργαστηριακές συνθήκες, ένας τέτοιος δείκτης αβεβαιότητας μπορεί να λειτουργήσει ως κριτήριο αξιοπιστίας, επισημαίνοντας περιπτώσεις στις οποίες απαιτείται χειροκίνητος έλεγχος.

6.7.2 Γενίκευση σε σύνθετα υλικά και ετερογενή πειραματικά πεδία

Η δεύτερη κατεύθυνση αφορά τη μεταφορά της μεθοδολογίας σε νέα, ανομοιογενή υλικά. Η μετάβαση από ξύλινα δοκίμια σε σύνθετα υλικά ενισχυμένα με ανθρακονήματα αναμένεται να επιφέρει ουσιώδη μετατόπιση πεδίου, καθώς μεταβάλλονται τόσο η κατανομή των ιδιοσυχνοτήτων και η δυναμική συμπεριφορά της κατασκευής όσο και τα στατιστικά χαρακτηριστικά της οπτικής υφής και του θορύβου κηλίδων (Leissa, 1969· Goodman, 2007). Δεδομένου ότι το παρόν μοντέλο στηρίζεται έντονα στις συχνοτικές παραμέτρους, η άκριτη μεταφορά του ενέχει τον κίνδυνο shortcut learning, δηλαδή εκμετάλλευσης επιφανειακών γνωρισμάτων αντί ουσιαστικών φυσικών κανόνων (Geirhos et al., 2020).

Για τον λόγο αυτό, απαιτείται ιεραρχική στρατηγική προσαρμογής. Σε πρώτο επίπεδο, είναι αναγκαία η επανακανονικοποίηση των συχνοτικών priors και η ενίσχυση μορφολογικών χαρακτηριστικών που είναι λιγότερο εξαρτημένα από το υλικό. Σε δεύτερο επίπεδο, μπορεί να διερευνηθεί ήπια μετεκπαίδευση επιμέρους νευρωνικών υποσυστημάτων με περιορισμένο αριθμό νέων δειγμάτων, ώστε να επιτευχθεί προσαρμογή χωρίς πλήρη επανεκπαίδευση (Gonzalez & Woods, 2018· Yosinski et al., 2014).

6.7.3 Οριοθέτηση των μακροπρόθεσμων προεκτάσεων

Η τρίτη κατεύθυνση απαιτεί αυστηρή επιστημονική οριοθέτηση. Η έντονη πτώση της απόδοσης στο δοκίμιο W02 κατά τον έλεγχο LODO καθιστά σαφές ότι το παρόν σύστημα δεν συνιστά καθολική λύση για κάθε δονητικό πρόβλημα. Η βιβλιογραφία της φυσικά καθοδηγούμενης μηχανικής μάθησης έχει δείξει ότι η ενσωμάτωση θεωρητικών κανόνων ενισχύει τη γενίκευση μόνο όταν οι υποκείμενες φυσικές παραδοχές παραμένουν συμβατές με το νέο περιβάλλον εφαρμογής (Karpatne et al., 2017· Willard et al., 2022).

Ως εκ τούτου, ο μακροπρόθεσμος στόχος δεν είναι η άκριτη αύξηση της αρχιτεκτονικής πολυπλοκότητας, αλλά η σταδιακή μετάβαση προς περισσότερο συνεκτικά, φυσικά καθοδηγούμενα υπολογιστικά σχήματα. Μία πιθανή προοπτική είναι η διερεύνηση Physics-Informed Neural Networks, τα οποία μπορούν, σε κατάλληλα διατυπωμένα προβλήματα, να ενσωματώνουν άμεσα τις διαφορικές εξισώσεις που διέπουν τη μηχανική συμπεριφορά λεπτών πλακών, όπως οι εξισώσεις Kirchhoff–Love (Raissi et al., 2019).

Σε έναν ακόμη πιο μακροπρόθεσμο ορίζοντα, η παρούσα γραμμή θα μπορούσε να μετατοπιστεί από την αποκλειστική ταξινόμηση ιδιομορφών προς πλαίσια πρόβλεψης φυσικής απόκρισης, όπου οι interferometric παρατηρήσεις ESPI θα συνεξετάζονται με παραμέτρους υλικού, γεωμετρίας και οριακών συνθηκών για την εκτίμηση φασματικών μεγεθών ή λειτουργικών δεικτών της απόκρισης του συστήματος. Η προοπτική αυτή υπερβαίνει το άμεσο αντικείμενο της παρούσας διπλωματικής και προϋποθέτει εκτενέστερα δεδομένα, αυστηρότερα πρωτόκολλα γενίκευσης και συστηματική βαθμονόμηση της αβεβαιότητας (Willard et al., 2022· Raissi et al., 2019· Gal & Ghahramani, 2016).

6.8 Πρακτικές επιπτώσεις και κατευθυντήριες οδηγίες

Για εφαρμογές ESPI με περιορισμένο όγκο δεδομένων, η πλέον αξιόπιστη στρατηγική που αναδείχθηκε από την παρούσα εργασία είναι η ενσωμάτωση φυσικής γνώσης σε συνδυασμό με ερμηνεύσιμους ταξινομητές, αντί της άκριτης αύξησης της αρχιτεκτονικής πολυπλοκότητας. Η χρήση βαθιάς μάθησης στο στάδιο αποθορυβοποίησης έχει νόημα όταν αξιολογείται με κριτήρια προσανατολισμένα στο downstream έργο και όχι μόνο με ενδιάμεσες φωτομετρικές μετρικές.

Σε πρακτικό επίπεδο, το προτεινόμενο πλαίσιο μπορεί να λειτουργήσει ως υποβοηθητικό εργαλείο εργαστηριακής ανάλυσης και όχι ως πλήρως αυτόνομος μηχανισμός χωρίς ανθρώπινη εποπτεία. Η εισαγωγή δεικτών εμπιστοσύνης και η δρομολόγηση οριακών περιπτώσεων προς χειροκίνητο έλεγχο συνιστούν ρεαλιστική στρατηγική για τη μελλοντική αξιοποίηση του συστήματος σε πραγματικές συνθήκες μέτρησης (Gal & Ghahramani, 2016· Geifman & El-Yaniv, 2017).

6.9 Αναπαραγωγιμότητα

Η αναπαραγωγιμότητα της εργασίας υποστηρίζεται από τον σαφή διαχωρισμό κυρίου κειμένου και συμπληρωματικού υλικού, τη δημοσιοποίηση του κώδικα σε επιμέρους αποθετήρια και τη ρητή καταγραφή τόσο των θετικών όσο και των αρνητικών ευρημάτων.

Τα βασικά αποθετήρια που συνοδεύουν την εργασία είναι τα ESPI-DnCNN-ECA, ESPI-pseydonoisy-generator και espi-classification-models_2.

- **ESPI-DnCNN-ECA**: https://github.com/GeorgeSpy/ESPI-DnCNN-ECA
- **ESPI-pseudonoisy-generator**: https://github.com/GeorgeSpy/ESPI-pseydonoisy-generator
- **espi-classification-models_2**: https://github.com/GeorgeSpy/espi-classification-models_2

6.10 Συγκεντρωτικός πίνακας κύριων ευρημάτων

Ο Πίνακας 6.1 συνοψίζει τα κύρια ευρήματα της εργασίας και τα αντιστοιχίζει στα πέντε ερευνητικά ερωτήματα. Η σύνοψη αυτή λειτουργεί ως τελική χαρτογράφηση των πορισμάτων χωρίς να επαναλαμβάνει τις αναλυτικές μετρήσεις των Κεφαλαίων 4 και 5.

Πίνακας 6.1. *Συγκεντρωτική αντιστοίχιση κύριων ευρημάτων προς τα ερευνητικά ερωτήματα.*

Ερευνητικό ερώτημα	Κύριο συμπέρασμα	Κύριος δείκτης	Ενότητα αναφοράς
RQ1	Η αποθορυβοποίηση βελτιώνει ουσιαστικά την απόδοση, αλλά η καλύτερη φωτομετρική ποιότητα δεν ταυτίζεται πάντοτε με καλύτερο downstream αποτέλεσμα.	Noisy → denoised: +47,97pm	§4.3, Κεφ. 5
RQ2	Η φυσικά βαθμονομημένη σύνθεση pseudo-noisy δεδομένων είναι χρήσιμη όταν ευθυγραμμίζεται με τα στατιστικά των πραγματικών δοκιμίων.	Αποτελεσματική υπό specimen-wise βαθμονόμηση	§3.4, Κεφ. 5
RQ3	Στο βασικό πρωτόκολλο, το ECA λειτούργησε ως null result· η συμβολή του είναι καθεστωτικά εξαρτώμενη.	ΔPSNR = −0,12 dB	§4.3.6–§4.3.10
RQ4	Η ενσωμάτωση των frequency priors αποτελεί το κυρίαρχο θετικό εύρημα της εργασίας.	Acc 97,85% · Macro-F1 95,15%	§4.5, §4.7
RQ5	Το μοντέλο γενικεύει ισχυρά σε άγνωστες ζώνες εντός δοκιμίου, αλλά δυσκολεύεται σημαντικά σε άγνωστο δοκίμιο υπό domain shift.	LOBO 91,83% ± 8,90% · LODO 66,31% ± 44,11%	§4.6, §5.6

6.11 Τελικό συμπέρασμα

Συνολικά, η παρούσα διπλωματική εργασία δείχνει ότι, για την αυτοματοποιημένη ανάλυση συμβολομετρικών εικόνων ESPI, η πλέον αξιόπιστη οδός δεν είναι η διαρκής αύξηση της πολυπλοκότητας των μοντέλων, αλλά η ρητή ενσωμάτωση φυσικής γνώσης σε συνδυασμό με αυστηρά πρωτόκολλα αξιολόγησης. Ο Hybrid Random Forest, αξιοποιώντας 22 υβριδικά χαρακτηριστικά, επέτυχε Accuracy 97,85% και Macro-F1 95,15%, υπερέχοντας έναντι βαθύτερων αλλά λιγότερο ερμηνεύσιμων προσεγγίσεων.

Εξίσου σημαντικό είναι ότι ακόμη και τα αρνητικά ή οριακά ευρήματα της μελέτης λειτουργούν ως ουσιαστικοί ερευνητικοί δείκτες. Ο περιορισμένος ρόλος του ECA στο βασικό πρωτόκολλο, οι δυσκολίες της γενίκευσης τύπου LODO και η ασυμφωνία μεταξύ pixel-level βελτίωσης και τελικής ταξινόμησης δείχνουν πού ακριβώς αρχίζουν τα όρια ενός φυσικά καθοδηγούμενου συστήματος και πού απαιτείται ανασχεδιασμός ή προσαρμογή.

Κατά συνέπεια, η συμβολή της εργασίας δεν περιορίζεται στην επίτευξη υψηλής επίδοσης. Συνίσταται, κυρίως, στην τεκμηρίωση ενός διαφανούς και ερμηνεύσιμου πλαισίου ανάλυσης ESPI, το οποίο μπορεί να λειτουργήσει ως βάση για μελλοντικές επεκτάσεις σε νέα υλικά, σε πιο σύνθετα πρωτόκολλα γενίκευσης και, μακροπρόθεσμα, σε φυσικά καθοδηγούμενα σχήματα πρόβλεψης φυσικής απόκρισης.

ΠΑΡΑΡΤΗΜΑΤΑ

Στην ενότητα που ακολουθεί, παρατίθεται συμπληρωματικό τεχνικό και ερευνητικό υλικό που υποστηρίζει και εξειδικεύει τα ευρήματα της παρούσας διπλωματικής εργασίας. Στόχος είναι η παροχή λεπτομερών δεδομένων που, αν και κρίσιμα για την αναπαραγωγιμότητα των πειραμάτων και την πλήρη τεκμηρίωση της μεθοδολογίας, κρίθηκε σκόπιμο να διαχωριστούν από τη βασική ροή του κειμένου για λόγους συνοχής. Συγκεκριμένα, τα παραρτήματα περιλαμβάνουν την αναλυτική παρουσίαση των μελετών αφαίρεσης (ablation studies), τη διαδικασία επιλογής και μηχανικής χαρακτηριστικών, καθώς και τα αναλυτικά πρωτόκολλα και τις αρχιτεκτονικές που προτείνονται για τη μελλοντική επέκταση της έρευνας.

ΠΑΡΑΡΤΗΜΑ Α: ΤΕΧΝΙΚΕΣ ΛΕΠΤΟΜΕΡΕΙΕΣ ΥΛΟΠΟΙΗΣΗΣ

A.1 DnCNN-ECA Architecture

A.1.1 Βασική Δομή Δικτύου

Πίνακας Α.1: *Βασικές παράμετροι αρχιτεκτονικής (Α.1.1 Βασική Δομή Δικτύου)*

Παράμετρος	Τιμή
Layers	17 total (1 input + 15 intermediate + 1 output)
Channels	64
Kernel size	3×3 (internal), 5×5 (feature extraction)
Activation	ReLU
Normalization	Batch Normalization

Δομή Residual Learning: $\hat{y} = x - R(x; \Theta)$, όπου R ο θόρυβος που μαθαίνει το δίκτυο.

A.1.2 ECA Module Integration

Θέσεις ECA: Block 0-2 μετά από κάθε residual stage. Αρχιτεκτονική: Global Average Pooling → 1D Conv (k=5) → Sigmoid → Channel Weighting.

Αρνητικό Εύρημα: Το ECA δεν προσφέρει μετρήσιμο όφελος με Batch Normalization — η BN αντισταθμίζει τις επαναβαθμονομήσεις καναλιού.

A.1.3 Training Configuration

***Πίν**ακας Α.2: Ρυθμίσεις εκπαίδευσης (A.1.3 Training Configuration)*

Παράμετρος	Τιμή
Training Pairs	11.434 (8.712 real + 2.722 synthetic)
Learning rate	10^{-4} με ReduceLROnPlateau
Batch size	12
Epochs	20 (early stopping στο epoch 11)
Loss function	0.5×(1-SSIM) + 0.5×L1 + 0.1×EdgeLoss

A.2 Υλοποίηση Random Forest (implementation)

A.2.1 Feature Set - 16 Pattern Features

***Πίν**ακας Α.3: Κατηγορίες και χαρακτηριστικά features (A.2.1 Feature Set — 16 Pattern Features)*

Κατηγορία	Χαρακτηριστικά
Fringe/Density	total_fringes, m_count, n_count, avg_fringe_spacing
Geometry/Symmetry	centroid_x, centroid_y, hv_ratio, diag_ratio, symmetry_score
Moments	hu_moments (7 invariant moments)
Topology/Nodal	nodal_complexity, nodal_length, euler_number
Spectral	spectral_entropy, energy_concentration

A.2.2 Hybrid RF - 6 Frequency Features (Physics-Informed)

***Πίν**ακας Α.4: Ορισμός frequency features και περιγραφών (A.2.2 Hybrid RF — 6 Frequency Features (Physics-Informed))*

Feature	Περιγραφή	Κεντρική Συχν.
freq_hz	Συχνότητα διέγερσης	—
dist_mode_(1,1)H	Απόσταση από Helmholtz	165 Hz
dist_mode_(1,1)T	Απόσταση από Fundamental	310 Hz
dist_mode_(1,2)	Απόσταση από Longitudinal Dipole	450 Hz
dist_mode_(2,1)	Απόσταση από Transverse Dipole	520 Hz
dist_mode_higher	Απόσταση από Multipole transition	700 Hz

Total Feature Vector: 22 διαστάσεις (16 Pattern + 6 Frequency)

Α.3 Υλοποίηση CNN ResNet-18 (implementation)

Base: ResNet-18 (ImageNet pretrained). Modifications: 1-channel grayscale input, Layers 1-2 frozen, FC → 6 classes. Training: 64 batch, ~3.5h (RTX 3060).

ΠΑΡΑΡΤΗΜΑ Β: ΠΑΡΑΜΕΤΡΟΙ ΔΙΑΜΟΡΦΩΣΗΣ

Β.1 Διαμόρφωση συνόλου δεδομένων (σύνολο δεδομένων (dataset) configuration)

Πίνακας Β.1: *Κατανομή κλάσεων και δειγμάτων*

Κλάση	Ετικέτα	Samples	Ποσοστό
0	mode_(1,1)H	199	5.8%
1	mode_(1,1)T	171	5.0%
2	mode_(1,2)	106	3.1%
3	mode_(2,1)	58	1.7%
4	mode_higher	1,115	32.4%

5	other_unknown	1,794	52.1%
Σύνολο	—	**3,443**	100%

Imbalance Ratio: 30,9:1 (Majority vs Minority)

Noise Model: Burr Type XII (c=4.687, k=1189.53) + Poisson + Gaussian. Total Training Pairs: 11.434 (80/20 split).

B.2 Cross-Validation Protocols

- **Stratified K-Fold**: 5 splits, 80/20, διατήρηση αναλογίας κλάσεων.
- **LOBO (Leave-One-Band-Out):** 111 bands, 5-10 Hz εύρος, Present-only Accuracy.
- **LODO (Leave-One-Domain-Out):** Train {W02,W03}→Test W01, Train {W01,W03}→Test W02, Train {W01,W02}→Test W03.

ΠΑΡΑΡΤΗΜΑ Γ: ΛΕΠΤΟΜΕΡΗ ΑΠΟΤΕΛΕΣΜΑΤΑ

Γ.1 Σύνοψη αποτελεσμάτων ταξινόμησης (classification results summary)

Πίνακας Γ.1: *Σύνοψη αποτελεσμάτων ταξινόμησης μοντέλων (Γ.1 Σύνοψη αποτελεσμάτων ταξινόμησης (classification results summary))*

Μοντέλο	Accuracy	Macro-F1	Weighted-F1	Training
Baseline RF	55.3%	22.0%	50.0%	30 s
Pattern-only RF	90.15%	69.91%	88.53%	45 s
CNN ResNet-18	93.76%	88.11%	92.30%	~3.5 h
Hybrid RF	97,85%	95,15%	**97.87%**	52 s

Bootstrap 95% CI για Hybrid RF: [97.36%, 98.34%]

Γ.2 Per-Class Performance (Hybrid RF)

Πίνακας Γ.2*: Per-class επιδόσεις ταξινόμησης (Precision/Recall/F1)*

Class	Precision	Recall	F1-Score	Support
mode_(1,1)H	100.00%	92.46%	96.08%	199
mode_(1,1)T	88.14%	100.00%	93.70%	171
mode_(1,2)	82.41%	83.96%	83.18%	106
mode_(2,1)	100.00%	100.00%	100.00%	58
mode_higher	100.00%	100.00%	100.00%	1,115
other_unknown	98.21%	97.66%	97.93%	1,794
Macro Avg	**94.79%**	**95.68%**	95,15%	3,443

Γ.3 Ανάλυση Σημαντικότητας Χαρακτηριστικών (Feature Importance)

Η ανάλυση της σημαντικότητας των χαρακτηριστικών, υπολογισμένη βάσει του κριτηρίου μείωσης της ακαθαρσίας Gini (Gini Importance), τεκμηριώνει την απόλυτη κυριαρχία της φυσικής πληροφορίας έναντι της αμιγούς οπτικής μορφολογίας κατά τη διαδικασία λήψης αποφάσεων του υβριδικού μοντέλου.

Ειδικότερα, η κατανομή της διαχωριστικής ισχύος διαμορφώνεται ως εξής:

- **Φυσικά Θεμελιωμένες Παραδοχές (Physics-based Priors) — 96,86%:** Η συχνότητα διέγερσης (freq_hz) και οι σχετικές αποστάσεις από τις θεωρητικές ιδιομορφές (dist_mode_*) μονοπωλούν την κορυφή της κατάταξης. Τα έξι σημαντικότερα χαρακτηριστικά ανήκουν αποκλειστικά σε αυτή την κατηγορία: dist_mode_(1,1)H (17,25%), freq_hz (14,13%), dist_mode_(1,1)T (13,67%), dist_mode_(1,2) (13,12%), dist_mode_(2,1) (12,80%) και dist_mode_higher (12,21%).
- **Μορφολογικά Χαρακτηριστικά (Pattern Features) — 3,14%:** Στον αντίποδα, το σύνολο των οπτικών περιγραφέων των κροσσών εμφανίζει περιθωριακή αθροιστική συμβολή. Τα ισχυρότερα χαρακτηριστικά αυτής της ομάδας περιορίζονται σε συνεισφορές της τάξης του 1%, με επικρατέστερα το συνολικό πλήθος των κροσσών (total_fringes: 1,1%) και την πολυπλοκότητα των κομβικών γραμμών (nodal_complexity: 0,8%).

Γ.4 Generalization Tests

LOBO: Mean Accuracy 91,83% (−5.72 pp από CV) — Καλή γενίκευση σε αθέατες συχνότητες

LODO: Mean Accuracy 66,31% ± 44,11% — Σημαντικό μετατόπιση πεδίου (domain shift) μεταξύ δοκιμίων (τεκμηριώνει όρια γενίκευσης)

Γ.5 Statistical Tests

McNemar: Hybrid RF vs Pattern-only $p<0.001$, Hybrid RF vs CNN $p<0.001$ (Significant)

Cohen's d: Hybrid RF vs Pattern-only $d=2.89$ (Huge effect)

Οδηγίες και κώδικας αναπαραγωγής των πειραμάτων διατίθενται στα ακόλουθα αποθετήρια GitHub:

- https://github.com/GeorgeSpy/ESPI-DnCNN-ECA
- https://github.com/GeorgeSpy/ESPI-pseydonoisy-generator
- https://github.com/GeorgeSpy/espi-classification-models_2

ΠΑΡΑΡΤΗΜΑ Δ: ΟΔΗΓΙΕΣ ΑΝΑΠΑΡΑΓΩΓΙΜΟΤΗΤΑΣ

Δ.1 Environment Setup

Πίνακας Δ.1: *Περιβάλλον λογισμικού και εκδόσεις βιβλιοθηκών*

Package	Version
Python	3.8.10
PyTorch	1.12.1+ (CUDA 11.6)
Scikit-learn	1.1.2
OpenCV	4.6.0
NumPy	1.23.2

Hardware: NVIDIA RTX 3060 (12GB), AMD Ryzen 5 5600G, Ryzen 7 5700G-5700X, 32GB RAM

Δ.2 Execution Workflow

1. 01_generate_pseudonoisy.py → 11.434 pairs (~30 min)
2. 02_train_dncnn.py → Model checkpoint (~2 hours GPU)
3. 03_denoise_images.py → Denoised images
4. 04_extract_features.py → 22-dim vectors (~15 min)
5. 05_train_rf.py → RF model (<1 min)
6. 07_evaluate_all.py → Metrics report (06_* is omitted in the final pipeline)

ΠΑΡΑΡΤΗΜΑ Ε: ΘΕΩΡΗΤΙΚΗ ΑΝΑΛΥΣΗ ΑΡΧΙΤΕΚΤΟΝΙΚΩΝ

Ε.1 DnCNN vs Multi-frame Averaging

Το DnCNN μαθαίνει το noise residual R(x) = x - y. Το Multi-frame averaging μειώνει τη διασπορά κατά σ/√N.

Κρίσιμο Εύρημα: *Η «φυσική» αποθορυβοποίηση μέσω averaging διατηρεί καλύτερα τη φασική πληροφορία των κροσσών — το DnCNN μπορεί να εξομαλύνει υπερβολικά τις κομβικές γραμμές.*

Ε.2 ResNet-18 vs Deeper Networks

Με dataset 3.443 samples, το ResNet50/101 οδηγεί σε overfitting (>99% train, <91% val). Το ResNet-18 παρέχει την καλύτερη ισορροπία.

Ε.3 Hybrid RF: Σχεδιασμός Καθοδηγούμενος από τη Φυσική

Η διαφορά Macro-F1 69.91% → 95,15% (+25.24 pp) καταδεικνύει ότι το πρόβλημα είναι πρωτίστως πρόβλημα φυσικής.

Τα Frequency Priors λειτουργούν ως ισχυροί περιορισμοί — η συχνότητα καθορίζει την «οικογένεια» του τρόπου, τα pattern features επιλύουν αμφισημίες.

Πίνακας Ε.1: *Συγκριτική σύνοψη κριτηρίων επίδοσης Hybrid RF και CNN*

Κριτήριο	Hybrid RF	CNN
Accuracy	97,85%	93.76%
Macro-F1	95,15%	88.11%
Training Time	**52 sec**	~3.5 hours
Inference	**~1 ms**	~50 ms
Interpretability	**Feature importance**	Black-box

Συμπέρασμα: *Για προβλήματα με έντονη φυσική δομή, η ρητή εισαγωγή domain knowledge υπερτερεί της End-to-End μάθησης.*

ΠΑΡΑΡΤΗΜΑ Ζ: Συμπληρωματικό υλικό

Κώδικας Αναπαραγωγής για την Ανάλυση Feature Importance

Ζ.1 Εισαγωγή

Το παρόν παράρτημα παρέχει τον πλήρη κώδικα Python για την αναπαραγωγή της ανάλυσης σημαντικότητας χαρακτηριστικών (feature importance) που παρουσιάζεται στην ενότητα 2.7.4 και στο Κεφάλαιο 4. Ο κώδικας επιτρέπει την επαλήθευση του κεντρικού ευρήματος ότι τα 6 frequency priors συνεισφέρουν

96,86% της συνολικής discriminative power του Hybrid Random Forest.

Ζ.2 Υπολογισμός Gini Importance

Ζ.2.1 Θεωρητικό Υπόβαθρο

Η Gini Importance (ή Mean Decrease in Impurity - MDI) υπολογίζεται για κάθε χαρακτηριστικό j ως το άθροισμα της μείωσης του Gini impurity σε όλους τους κόμβους όπου χρησιμοποιείται το χαρακτηριστικό, σταθμισμένο με την αναλογία των δειγμάτων που φτάνουν σε κάθε κόμβο:

$$Importance(j) = \Sigma_t [p(t) \times \Delta Gini(t, j)]$$

όπου p(t) είναι η αναλογία δειγμάτων στον κόμβο t και ΔGini(t, j) είναι η μείωση του Gini impurity κατά το split με το χαρακτηριστικό j.

Ζ.2.2 Κώδικας Εξαγωγής Gini Importance

Αρχείο: feature_importance_gini.py

```
import numpy as np
import pandas as pd
from sklearn.ensemble import RandomForestClassifier
from sklearn.model_selection import train_test_split


# Φόρτωση δεδομένων
df = pd.read_csv('dataset_22_features.csv')
```

```
X = df.drop(['label', 'filename'], axis=1)
y = df['label']
# Ορισμός χαρακτηριστικά συχνότητας (frequency features)
FREQ_FEATURES = [
    'freq_hz',
    'dist_mode_(1,1)H',
    'dist_mode_(1,1)T',
    'dist_mode_(1,2)',
    'dist_mode_(2,1)',
    'dist_mode_higher'
]

# Train/Test split (stratified)
X_train, X_test, y_train, y_test = train_test_split(
    X, y, test_size=0.2, stratify=y, random_state=42)

# Εκπαίδευση Hybrid RF
rf = RandomForestClassifier(
    n_estimators=200,
    max_features='sqrt',
    min_samples_leaf=2,
    class_weight='balanced',
    random_state=42,
    n_jobs=-1)
```

```
rf.fit(X_train, y_train)


# Εξαγωγή Gini importance
importances = rf.feature_importances_
feature_names = X.columns.tolist()


# Δημιουργία DataFrame με ταξινόμηση
importance_df = pd.DataFrame({
    'feature': feature_names,
    'importance': importances
}).sort_values('importance', ascending=False)


print('Top 10 Features by Gini Importance:')
print(importance_df.head(10))
```

Ζ.2.3 Υπολογισμός Συνεισφοράς ανά Κατηγορία

Υπολογισμός συνολικής συνεισφοράς frequency vs pattern

```
freq_importance = importance_df[
    importance_df['feature'].isin(FREQ_FEATURES)
]['importance'].sum()


pattern_importance = importance_df[
    ~importance_df['feature'].isin(FREQ_FEATURES)
]['importance'].sum()
```

```
print(f'\nΣυνεισφορά Frequency Features: {freq_importance*100:.2f}%')
print(f'Συνεισφορά Pattern Features: {pattern_importance*100:.2f}%')

# Αναμενόμενο output:
# Συνεισφορά Frequency Features: 96,86%
# Συνεισφορά Pattern Features: 3.14%
```

Ζ.3 Επαλήθευση με Permutation Importance

Στην ενότητα Ζ.3 τεκμηριώνεται η διαδικασία υπολογισμού σημαντικότητας χαρακτηριστικών για το Υβριδικό Random Forest και η ερμηνεία της.

Ζ.3.1 Σημαντικότητα MDI/Gini (Mean Decrease in Impurity)

Στο βασικό μοντέλο Random Forest, η προεπιλεγμένη σημαντικότητα χαρακτηριστικών (feature_importances_) υπολογίζεται ως μέση μείωση ανομοιογένειας (MDI) βάσει του δείκτη Gini. Η μέθοδος αυτή είναι χρήσιμη ως «πρώτη ένδειξη» για το ποια χαρακτηριστικά κυριαρχούν στη λήψη αποφάσεων. Στην παρούσα εργασία, η ομαδοποιημένη MDI/Gini σημαντικότητα ανέδειξε έντονη κυριαρχία των χαρακτηριστικών συχνότητας (96,86%) έναντι των χαρακτηριστικών μοτίβου (3,14%) στο Hybrid RF (βλ. §4.5.4).

Ωστόσο, η MDI/Gini σημαντικότητα είναι γνωστό ότι εμφανίζει μεροληψία υπέρ συνεχών μεταβλητών υψηλής «πολυτιμικότητας» (πολλές δυνατές τομές), με αποτέλεσμα τα ποσοστά να μπορούν να εμφανιστούν «φουσκωμένα» όταν συνυπάρχουν συνεχείς και πιο διακριτές/δυαδικές μεταβλητές.

Ζ.3.2 Σημαντικότητα με αναδιάταξη (Permutation importance) ως επαλήθευση

Για την αμερόληπτη επαλήθευση της παραπάνω ένδειξης, εφαρμόστηκε permutation importance στο σύνολο αξιολόγησης: κάθε χαρακτηριστικό αναδιατάσσεται (permute) και μετράται η πτώση της επίδοσης. Με ομαδοποίηση ανά κατηγορία (Frequency/Physical Priors έναντι Morphology/Pattern Features), προέκυψε συντηρητικότερη αλλά συνεπής

εικόνα, όπου τα φυσικά priors διατηρούν την κυρίαρχη συνεισφορά (≈82,5%) και η μορφολογία παραμένει ουσιωδώς συμπληρωματική (≈17,5%). Τα ποσοστά αυτά χρησιμοποιούνται στη συζήτηση της γενίκευσης σε σύνθετα υλικά ως πιο ρεαλιστική αποτίμηση συνεισφοράς.

Παρακάτω παρατίθεται ενδεικτικός κώδικας για τους δύο υπολογισμούς (MDI/Gini και permutation) και για την ομαδοποίηση των importances ανά κατηγορία.

```
    # (A) MDI / Gini importance (RandomForest.feature_importances_)
gini_imp = rf_model.feature_importances_

# (B) Permutation importance (πτώση επίδοσης μετά από permute)
from sklearn.inspection import permutation_importance
perm = permutation_importance(
   rf_model,
   X_test,
   y_test,
   n_repeats=30,
   random_state=0,
)
perm_imp = perm.importances_mean

# (C) Ομαδοποίηση κατά κατηγορία (pattern vs frequency)
freq_features = [
   'freq_hz',
   'dist_mode_(1,1)H',
   'dist_mode_(1,1)T',
   'dist_mode_(1,2)',
   'dist_mode_(2,1)',
   'dist_mode_higher',
]
pattern_features = [f for f in feature_names if f not in freq_features]
```

```
def grouped_share(importances, feature_names):
    imp = dict(zip(feature_names, importances))
    freq_sum = sum(imp[f] for f in freq_features if f in imp)
    pat_sum  = sum(imp[f] for f in pattern_features if f in imp)
    tot = freq_sum + pat_sum
    return 100.0 * freq_sum / tot, 100.0 * pat_sum / tot

freq_gini, pat_gini = grouped_share(gini_imp, feature_names)
freq_perm, pat_perm = grouped_share(perm_imp, feature_names)

print('Grouped Gini:', freq_gini, pat_gini)
print('Grouped Perm:', freq_perm, pat_perm)
```

Πίνακας Ζ.1: *Ablation σύνοψη πειραμάτων και επίδοσης (Ζ.3.2 Σημαντικότητα με αναδιάταξη (Permutation importance) ως επαλήθευση)*

Πείραμα	**Features**	**Accuracy**	**Macro-F1**	**Δ F1**
Full (Hybrid RF)	22	97,85%	95,15%	baseline
Pattern-only (χωρίς freq)	16	90.15%	69.91%	**−25.24 pp**
Frequency-only (χωρίς pattern)	6	~95%	~93.5%	~−1.65 pp

Βιβλιοθήκη	**Έκδοση**	**Σκοπός**
Python	3.8.10	Γλώσσα προγραμματισμού
scikit-learn	1.1.2	Random Forest, metrics
pandas	1.5.0	Data manipulation
numpy	1.23.0	Numerical computing
matplotlib	3.6.0	Visualization
seaborn	0.12.0	Statistical plots

ΠΑΡΑΡΤΗΜΑ Η: ΜΑΘΗΜΑΤΙΚΗ ΘΕΜΕΛΙΩΣΗ

Η.0 Σκοπός και συμβάσεις

Το παρόν παράρτημα συγκεντρώνει τη μαθηματική διατύπωση των βασικών φυσικών μοντέλων (ESPI χρονικού μέσου όρου και σχηματισμός fringe maps), των μεθόδων επεξεργασίας (FFT/φάση), των μοντέλων θορύβου (speckle και Poisson-Gaussian), και των αλγορίθμων ML/DL (Random Forest, DnCNN με residual learning, ECA attention). Επιπλέον, παρουσιάζονται οι μετρικές και οι στατιστικοί έλεγχοι αξιολόγησης, καθώς και τα splits γενίκευσης (LOBO/LODO) που χρησιμοποιούνται στην εργασία.

Συμβολισμοί

Για τις ανάγκες της μαθηματικής περιγραφής, χρησιμοποιούνται οι κάτωθι συμβολισμοί:

- $(\boldsymbol{x}, \boldsymbol{y})$: Χωρικές συντεταγμένες
- $\boldsymbol{t}$: Χρόνος
- $\boldsymbol{\lambda}$: Μήκος κύματος
- **Re**$\{...\}$: Πραγματικό μέρος
- $(...)^*$: Μιγαδικό συζυγές

Η.1 Φυσική της Συμβολομετρίας (ESPI χρονικού μέσου όρου)

Η.1.1 Μιγαδικά πεδία και ένταση

Στο ESPI η καταγραφή προκύπτει από τη συμβολή ενός κύματος αναφοράς $U_r(x,y,t)$ και ενός κύματος αντικειμένου $U_o(x,y,t)$, με συνολικό πεδίο $U(x,y,t) = U_r(x,y,t) + U_o(x,y,t)$ (Jones & Wykes, 1989).
Η στιγμιαία ένταση στον αισθητήρα δίνεται από:

$$I_{\text{inst}}(x,y,t) = |\, U_r + U_o \,|^2 = |\, U_r \,|^2 + |\, U_o \,|^2 + 2\Re\{U_r U_o^*\}. \tag{Η.1}$$

Ο όρος $2\Re\{U_r U_o^*\}$είναι ο όρος συμβολής που μεταφέρει τη σχετική φάση και άρα την πληροφορία μετατόπισης/δόνησης (Rastogi, 2001).

Η.1.2 Ημιτονική out-of-plane δόνηση και φασική διαμόρφωση

Θεωρείται ημιτονική out-of-plane μετατόπιση της επιφάνειας: $z(x,y,t) = a(x,y)\cos(\Omega t)$, όπου $a(x,y)$ το πλάτος και Ω η γωνιακή συχνότητα διέγερσης. Σε τυπική γεωμετρία διπλού οπτικού δρόμου (ανάκλαση), η πρόσθετη φάση γράφεται:

$$\Delta\phi(x,y,t) = \beta(x,y)\cos(\Omega t)\,, \beta(x,y) = \frac{4\pi}{\lambda}a(x,y). \tag{Η.2}$$

Η ποσότητα $\beta(x,y)$είναι ο "modulation index" της time-average καταγραφής και συνδέει απευθείας το πλάτος δόνησης με την αντίθεση των κροσσών (Jones & Wykes, 1989; Kreis, 2005).

Η.1.3 Time averaging και εμφάνιση J_0(τεκμηρίωση)

Ο αισθητήρας καταγράφει χρονικό μέσο όρο έντασης για χρόνο έκθεσης Tπολύ μεγαλύτερο από την περίοδο της δόνησης, δηλαδή $T \gg \frac{2\pi}{\Omega}$ (Kreis, 2005). Ο time-averaged ορισμός της καταγεγραμμένης έντασης είναι:

$$I(x,y) = \frac{1}{T}\int_0^T I_{\text{inst}}(x,y,t)\,dt \tag{Η.3}$$

Για να αναδειχθεί ο μηχανισμός, θεωρούνται χρονικά σταθερά πλάτη εντός του Tκαι σταθερή σχετική φάση $\phi_0(x,y)$, ώστε ο όρος συμβολής να γράφεται τυπικά ως $\cos(\phi_0 + \beta\cos(\Omega t))$(Jones & Wykes, 1989; Rastogi, 2001).

Τότε η χρονική ολοκλήρωση ανάγεται (με αλλαγή μεταβλητής $\theta = \Omega t$) σε μέσο όρο μιας περιοδικής συνάρτησης στο $[0, 2\pi]$, λόγω της υπόθεσης $T \gg \frac{2\pi}{\Omega}$(Kreis, 2005).

Χρησιμοποιώντας την Jacobi-Anger ανάπτυξη: (Jacobi-Anger expansion, n.d.)

$$e^{\text{izcos}\,\theta} = \sum_{n=-\infty}^{\infty} i^n J_n(z) e^{in\theta} \tag{Η.4}$$

προκύπτει ότι ο μέσος όρος της $\cos(\text{zcos}\,\theta)$σε μια περίοδο ισούται με $J_0(z)$, άρα:

$$\frac{1}{T}\int_0^T \cos(\beta\cos(\Omega t))\;dt = J_0(\beta) \tag{Η.5}$$

Συνεπώς, η time-averaged ένταση γράφεται στη μορφή: (Kreis, 2005; Rastogi, 2001).

$$I(x,y) = I_{\text{bias}}(x,y) + I_{\text{mod}}(x,y)\,J_0\left(\beta(x,y)\right), \beta(x,y) = \frac{4\pi}{\lambda}a(x,y) \tag{Η.6}$$

οπου:

- $\boldsymbol{I_{bias}(x,y)}$: Η μέση ένταση υποβάθρου.
- $\boldsymbol{I_{mod}(x,y)}$: Το πλάτος διαμόρφωσης (βάθος των κροσσών).
- $\boldsymbol{J_0}$: Η συνάρτηση Bessel πρώτου είδους και μηδενικής τάξης.
- $\boldsymbol{a(x,y)}$: Το πλάτος ταλάντωσης στο συγκεκριμένο σημείο.
- $\boldsymbol{\lambda}$: Το μήκος κύματος του λέιζερ.

Σε πολλές πρακτικές απεικονίσεις/ανακατασκευές, η εξάρτηση εμφανίζεται ως $J_0^2(\beta)$, χωρίς να αλλάζει η φυσική ερμηνεία ότι οι σκοτεινοί κροσσοί αντιστοιχούν στις ρίζες της J_0και άρα σε ισοκαμπύλες πλάτους $a(x,y)$(Kreis, 2005).

Η.2 Fringe analysis με FFT (Takeda) και φάση

Η.2.1 Μοντέλο carrier fringes

Για fringe patterns με carrier, ένα κλασικό μοντέλο έντασης είναι: (Takeda et al., 1982)

$$I(x,y) = a(x,y) + b(x,y)\cos\big(2\pi f_c x + \varphi(x,y)\big) \qquad \text{(Η.7)}$$

όπου $a(x,y)$είναι background, $b(x,y)$modulation, f_cχωρική συχνότητα carrier και $\varphi(x,y)$η ζητούμενη φάση.

Η.2.2 Ανάκτηση φάσης με Fourier-transform μέθοδο

$\varphi(x,y)(-\pi,\pi]$Η Fourier-transform fringe analysis (Takeda) χρησιμοποιεί 2D FFT, φασματική απομόνωση του πλευρικού λοβού και ανάκτηση από το argument του μιγαδικού σήματος μετά από inverse FFT (Takeda et al., 1982). Η φάση που ανακτάται είναι τυλιγμένη στο και όταν απαιτείται ποσοτική συνέχεια εφαρμόζεται ξετύλιγμα φάσης (phase unwrapping) (Ghiglia & Pritt, 1998).

Η.3 Μοντελοποίηση δονήσεων και ιδιομορφών (modes/plates)

Η.3.1 Γενικό ιδιοτιμικό πρόβλημα modal ανάλυσης

Στη modal ανάλυση, μια διακριτή μορφή του προβλήματος ιδιοτιμών γράφεται ως:

$$K\phi_r = \omega_r^2 M\phi_r \qquad \text{(Η.8)}$$

όπου Kείναι ο πίνακας δυσκαμψίας, Mο πίνακας μάζας, ω_rη ιδιοσυχνότητα και ϕ_rη αντίστοιχη ιδιομορφή (Ewins, 2000). Η ορθογωνιότητα ως προς τη μάζα $\phi_r^T M \phi_s = 0$ για $r \neq s$ δικαιολογεί την αποσύνθεση της απόκρισης σε modes (Ewins, 2000).

Η.3.2 Ενδεικτική PDE λεπτής πλάκας (Kirchhoff-Love)

Για λεπτή ισότροπη πλάκα, μια ενδεικτική εξίσωση κάμψης είναι:

$$D\nabla^4 w(x,y,t) + \rho h\, \ddot{w}(x,y,t) = p(x,y,t), D = \frac{Eh^3}{12(1-\nu^2)} \quad \text{(Η.9)}$$

με w εγκάρσια μετατόπιση, ρ πυκνότητα, h πάχος, E μέτρο Young, ν λόγος Poisson και p φόρτιση (Leissa, 1969). Με χωρισμό μεταβλητών $w(x,y,t) = \Phi(x,y)\cos(\omega t)$προκύπτει πρόβλημα ιδιοτιμών για $\Phi(x,y)$που καθορίζει nodal lines/antinodes και έτσι τη μορφολογία των fringe maps που ταξινομούνται.

Η.4 Speckle / θόρυβος και averaging

Η.4.1 Speckle contrast

Σε fully developed speckle, ένα βασικό μέτρο είναι το speckle contrast: $C = \frac{\sigma_I}{\mu_I}$, με μ_Iμέση ένταση και σ_Iτυπική απόκλιση (Goodman, 2007).

Η.4.2 Multi-frame averaging και βελτίωση SNR

Για μέσο όρο Nανεξάρτητων καρέ, η διακύμανση ενός αθροιστικού θορύβου μειώνεται κατά περίπου $\frac{1}{N}$, άρα το SNR αυξάνει τυπικά ως $\sqrt{N}$υπό την υπόθεση ανεξαρτησίας (Kay, 1993).
Η παρατήρηση αυτή τεκμηριώνει το “physics-aligned” baseline μέσω averaging που συγκρίνεται με learned denoising στο κύριο κείμενο.

Η.4.3 Μικτό μοντέλο Speckle-Poisson-Gaussian και VST

Ένα πρακτικό μικτό μοντέλο θορύβου για imaging περιλαμβάνει πολλαπλασιαστικό speckle s, shot noise (Poisson) και readout (Gaussian): (Foi et al., 2008)

$$y = \mathcal{P}(x \cdot s) + n_g, n_g \sim \mathcal{N}(0, \sigma^2). \quad \text{(Η.10)}$$

Για Poisson-Gaussian θόρυβο, χρησιμοποιούνται generalized Anscombe variance-stabilizing transforms και κατάλληλες αντίστροφες για προσέγγιση Gaussian καθεστώτος πριν από denoising (Mäkitalo & Foi, 2013).

Η.5 Μηχανική Μάθηση: Random Forest

Η.5.1 Ensemble κανόνας απόφασης

Δίνεται ensemble Kδέντρων $\{h_k\}_{k=1}^{K}$, και η τελική πρόβλεψη ταξινόμησης δίνεται από πλειοψηφική ψήφο: (Breiman, 2001)

$$\hat{y}(x) = \arg\max_{c} \quad \sum_{k=1}^{K} \mathbb{I}(\, h_k(x) = c) \tag{Η.11}$$

Η.5.2 Gini impurity και επιλογή split

Για κόμβο με σύνολο Sκαι πιθανότητες κλάσεων p_c, ο δείκτης Gini ορίζεται ως: (Hastie et al., 2009)

$$G(S) = 1 - \sum_{c=1}^{C} p_c^2 \tag{Η.12}$$

Για split $S \to (S_L, S_R)$, η μείωση ακαθαρσίας είναι:

$$\Delta G = G(S) - \left(\frac{|S_L|}{|S|} G(S_L) + \frac{|S_R|}{|S|} G(S_R)\right) \tag{Η.13}$$

και επιλέγεται split που μεγιστοποιεί τη ΔG.

Η.5.3 Feature importance (MDI / Gini importance)

Η impurity-based σημαντικότητα (mean decrease in impurity) του χαρακτηριστικού X_jμπορεί να γραφεί ως:

$$Imp(X_j) = \frac{1}{K} \sum_{k=1}^{K} \sum_{n \in \mathcal{N}_k} \mathbb{I}(\, v_n = X_j)\, \Delta G_n, \tag{Η.14}$$

όπου $\mathcal{N}_k$ οι κόμβοι του k-οστού δέντρου και v_n το feature του split στον κόμβο n(Breiman, 2001).

Η.6 Βαθιά Μάθηση: DnCNN (Residual Learning)

Η.6.1 Διατύπωση προβλήματος denoising

Θεωρείται μια θορυβώδης εικόνα y η οποία μοντελοποιείται ως $y = x + v$, όπου x είναι η καθαρή εικόνα και v ο προσθετικός θόρυβος (Zhang et al., 2017). Το δίκτυο DnCNN εκπαιδεύεται με σκοπό να εκτιμήσει τον θόρυβο μέσω μάθησης υπολοίπου (residual mapping), σύμφωνα με τη σχέση:

$$\hat{v} = R(y;\Theta) \approx v, \quad \hat{x} = y - \hat{v} = y - R(y;\Theta) \tag{Η.15}$$

όπου $R(y;\Theta)$ είναι η έξοδος του νευρωνικού δικτύου με παραμέτρους Θ.

Η.6.2 Συνάρτηση κόστους (MSE στο residual)

Για ζεύγη εκπαίδευσης $\{(y_i, x_i)\}_{i=1}^{N}$, η απώλεια residual MSE γράφεται: (Zhang et al., 2017)

$$\mathcal{L}(\Theta) = \frac{1}{2N} \sum_{i=1}^{N} \| R(y_i;\Theta) - (y_i - x_i) \|_F^2 \tag{Η.16}$$

όπου $||\cdot||_F$είναι η νόρμα Frobenius.

Η.7 Efficient Channel Attention (ECA)

Η.7.1 GAP και channel descriptor

Έστω feature tensor $\mathcal{X} \in \mathbb{R}^{H\times W\times C}$ από συνελικτικό block. (Wang et al., 2020) Ο ECA ορίζει channel descriptor $z \in \mathbb{R}^{C}$ μέσω Global Average Pooling: (Wang et al., 2020)

$$z_c = \frac{1}{HW} \sum_{i=1}^{H} \sum_{j=1}^{W} \mathcal{X}_{i,j,c} \tag{Η.17}$$

Η.7.2 1D convolution, sigmoid και re-weighting

Τα βάρη καναλιών $w \in \mathbb{R}^{\mathbb{C}}$ προκύπτουν από μονοδιάστατη συνέλιξη (1D convolution) και την ενεργοποίηση sigmoid (Wang et al., 2020):

$$w = \sigma\big(\mathrm{Conv1D}_k(z)\big), \quad \sigma(u) = \frac{1}{1+e^{-u}} \tag{Η.18}$$

Η επαναζύγιση (re-weighting) εφαρμόζεται ανά κανάλι (channel-wise) ως εξής (Wang et al., 2020):

$$\mathcal{Y}_{i,j,c} = w_c \cdot \mathcal{X}_{i,j,c} \qquad \text{(H.19)}$$

όπου $\mathcal{X}$ είναι ο τανυστής εισόδου και $\mathcal{Y}$ ο τανυστής εξόδου μετά την προσοχή. Το μέγεθος του πυρήνα k της 1D συνέλιξης καθορίζει την εμβέλεια της διακαναλικής αλληλεπίδρασης και υπολογίζεται προσαρμοστικά βάσει του συνολικού πλήθους καναλιών C:

$$k = \left|\frac{\log_2(C)}{\gamma} + \frac{b}{\gamma}\right|_{\text{odd}} \qquad \text{(H.20)}$$

όπου $|t|_{\text{odd}}$ υποδηλώνει τον κοντινότερο περιττό ακέραιο αριθμό, με τις υπερπαραμέτρους να τίθενται συνήθως ως $\gamma = 2$ και $b = 1$.

Η.7.3 Προσαρμοστικό kernel size

Στο πλαίσιο του ECA, το μέγεθος του πυρήνα $\boldsymbol{k}$ καθορίζεται προσαρμοστικά ως συνάρτηση του πλήθους των καναλιών $\boldsymbol{C}$, μέσω μιας λογαριθμικής σχέσης που στρογγυλοποιείται στον πλησιέστερο περιττό ακέραιο (Wang et al., 2020):

$$k = \psi(C) = \left|\frac{\log_2(C)}{\gamma} + \frac{b}{\gamma}\right|_{odd} \qquad \text{(H.21)}$$

Η.8 Μετρικές αξιολόγησης (Denoising & Classification) - εκτενής διατύπωση

Η αξιολόγηση στο παρόν έργο διαχωρίζεται σε (α) **image-quality** μετρικές για denoising (MSE/PSNR/SSIM) και (β) **classification** μετρικές για modal ταξινόμηση (Precision/Recall/F1, Macro-F1). Οι μετρικές της (α) μετρούν πιστότητα ανακατασκευής σε επίπεδο pixel/δομής, ενώ οι μετρικές της (β) μετρούν χρησιμότητα ως προς το downstream task (σωστή κλάση mode), που δεν είναι πάντα μονοτονικά ευθυγραμμισμένη με PSNR/SSIM.

Η.8.1 MSE και PSNR

Ορισμοί

Έστω καθαρή εικόνα αναφοράς $x \in \mathbb{R}^{H\times W}$και ανακατασκευασμένη/denoised εικόνα $\hat{x} \in \mathbb{R}^{H\times W}$.

Ο μέσος τετραγωνικός σφάλματος (Mean Squared Error, MSE) ορίζεται ως:

$$MSE = \frac{1}{HW}\sum_{i=1}^{H}\sum_{j=1}^{W}(x_{i,j} - \hat{x}_{i,j})^2.$$

(H.22)

Το **PSNR** (Peak Signal-to-Noise Ratio) ορίζεται ως:

$$PSNR = 10\log_{10}\left(\frac{MAX_I^2}{MSE}\right) \quad \text{(H.23)}$$

όπου $\boldsymbol{MAX_I}$ είναι η μέγιστη δυνατή τιμή ενός pixel (π.χ. 255 για εικόνες 8-bit ή 1 για κανονικοποιημένες εικόνες στο διάστημα $[0,1]$).

Ερμηνεία και πρακτικές παρατηρήσεις

1. Το MSE είναι μια "ενεργειακή" απόσταση L_2ανά pixel: τιμωρεί έντονα μεγάλα σφάλματα και είναι ιδιαίτερα ευαίσθητο σε outliers (π.χ. τοπικά saturation, hot pixels, ή misalignment).

2. Το PSNR είναι λογαριθμική επανακλιμάκωση του MSE σε dB, ώστε να συγκρίνονται ευκολότερα διαφορετικές αποδόσεις (ιδίως όταν τα MSE είναι πολύ μικρά).

3. Από τον ορισμό του PSNR προκύπτει άμεσα ότι η αύξηση PSNR κατά ~3 dB αντιστοιχεί σε περίπου υποδιπλασιασμό του MSE (επειδή $10log_{10}(2) \approx 3.01$)

4. Το PSNR εξαρτάται από το MAX_I, άρα πρέπει να δηλώνεται ρητά η κλίμακα/bit-depth ή η κανονικοποίηση που χρησιμοποιείται, ειδικά όταν συγκρίνονται μοντέλα ή datasets με διαφορετική κωδικοποίηση.

5. Σε εφαρμογές όπου η "ορατή" δομή των fringes (ή η τοπολογία nodal lines) είναι κρίσιμη, ένα denoiser μπορεί να βελτιώνει PSNR αλλά να εξομαλύνει λεπτές

δομές που είναι σημαντικές για ταξινόμηση, άρα PSNR ≠ downstream χρησιμότητα.

Η.8.2 SSIM

Ορισμός

Ο δείκτης SSIM (Structural Similarity Index) συγκρίνει δύο εικόνες όχι μόνο με βάση σφάλμα έντασης, αλλά μέσω τριών όρων: φωτεινότητας (luminance), αντίθεσης (contrast) και δομής (structure). (Wang et al., 2004) Η κλασική μορφή ορίζεται ως: (Wang et al., 2004)

$$SSIM(x,\hat{x}) = \frac{(2\mu_x\mu_{\hat{x}} + C_1)(2\sigma_{x\hat{x}} + C_2)}{\left(\mu_x^2 + \mu_{\hat{x}}^2 + C_1\right)(\sigma_x^2 + \sigma_{\hat{x}}^2 + C_2)},$$

(Η.24)

όπου $\mu_x, \mu_{\hat{x}}$είναι μέσοι όροι, $\sigma_x^2, \sigma_{\hat{x}}^2$διακυμάνσεις, $\sigma_{x\hat{x}}$συνδιακύμανση και C_1, C_2σταθερές σταθεροποίησης. (Wang et al., 2004)

Ερμηνεία και πρακτικές παρατηρήσεις

1. Το SSIM παίρνει τιμές τυπικά στο $[-1,1]$(στην πράξη συχνά $[0, 1]$για φυσικές εικόνες/μη παθολογικές περιπτώσεις) και αυξάνει όταν οι δύο εικόνες έχουν παρόμοια τοπική δομή. (Wang et al., 2004)

2. Σε αντίθεση με PSNR/MSE που είναι καθαρά pixelwise, το SSIM ευνοεί ανακατασκευές που διατηρούν υφή/αντίθεση/συσχετίσεις (δηλαδή τη "δομή"), κάτι ιδιαίτερα σχετικό όταν ενδιαφέρει η διατήρηση fringe-μορφολογίας. (Wang et al., 2004)

3. Παρόλα αυτά, το SSIM εξακολουθεί να είναι μετρική ποιότητας εικόνας και όχι task-metric: μπορεί να μην προβλέπει πλήρως αν διατηρήθηκαν οι κρίσιμες "διακριτικές" λεπτομέρειες για σωστή κλάση mode.

Η.8.3 Precision, Recall, F1-score και Macro-F1 στην Πολυταξική Ταξινόμηση.

Ορισμοί βάσει Πίνακα Σύγχυσης: Για προβλήματα πολυταξικής ταξινόμησης με $\boldsymbol{K}$ κλάσεις, οι μετρικές ορίζονται ανά κλάση $\boldsymbol{c}$ (όπου $\boldsymbol{c} \in \boldsymbol{1} \ldots \boldsymbol{K}$) με τη θεώρηση "One-vs-Rest" (Μία-έναντι-Όλων):

1. **Αληθώς Θετικά (True Positives - $\boldsymbol{TP_c}$):** Δείγματα που ανήκουν πραγματικά στην κλάση c και προβλέφθηκαν σωστά ως c.

2. **Ψευδώς Θετικά (False Positives - $\boldsymbol{FP_c}$):** Δείγματα άλλων κλάσεων (όχι c) που προβλέφθηκαν λανθασμένα ως c.

3. **Ψευδώς Αρνητικά (False Negatives - $\boldsymbol{FN_c}$):** Δείγματα που ανήκουν στην κλάση c, αλλά προβλέφθηκαν λανθασμένα ως κάποια άλλη κλάση.

Precision / Recall / F1

Οι ορισμοί είναι:

$$Precision_c = \frac{TP_c}{TP_c + FP_c}, Recall_c = \frac{TP_c}{TP_c + FN_c},$$
$$F1_c = \frac{2\, Precision_c\, Recall_c}{Precision_c + Recall_c}.$$

(Η.25)

$\boldsymbol{Precision_c, Recall_c, F1_c}$: Το Precision(c) απαντά "*όταν το μοντέλο προβλέπει την κλάση c, πόσο συχνά έχει δίκιο;"*, ενώ το Recall(c) απαντά *"από όλα τα πραγματικά δείγματα της κλάσης c, πόσα εντόπισε;"*. Το F1(c) είναι ο αρμονικός μέσος Precision(c) και Recall(c), άρα μειώνεται έντονα όταν ένας από τους δύο όρους είναι χαμηλός.

Macro-F1 και γιατί είναι κρίσιμο σε imbalance

Ο Macro-F1 ορίζεται ως:

$$Macro\text{-}F1 = \frac{1}{C}\sum_{c=1}^{C} F\,1_c.$$

(Η.26)

Η Macro-μέση τιμή δίνει **ίσο βάρος** σε όλες τις κλάσεις ανεξαρτήτως support, άρα είναι κατάλληλη σε class imbalance γιατί δεν "κρύβει" κακή απόδοση στις μειονοτικές κλάσεις πίσω από πολύ καλή απόδοση στις πλειονοτικές. (He & Garcia, 2009) Αυτό είναι σημαντικό στο modal classification, όπου ορισμένες κατηγορίες/συνθήκες εμφανίζονται σπανιότερα και η "Accuracy" μπορεί να είναι παραπλανητικά υψηλή χωρίς να αποδίδει καλά στις μειονοτικές κλάσεις.

Πρακτικές λεπτομέρειες αναφοράς

1.Συνιστάται να αναφέρονται μαζί: Accuracy, Macro-F1, καθώς και per-class Recall/F1 για να φαίνεται πού αποτυγχάνει το μοντέλο (ιδίως σε σπάνιες κλάσεις).

2.Σε ακραίες ανισορροπίες, η Precision-Recall οπτικοποίηση/λογική είναι συχνά πιο διαγνωστική από ROC, ειδικά όταν το ενδιαφέρον είναι η ανάκτηση της μειονοτικής κλάσης.

3.$\boldsymbol{TP_c + FP_c = 0, Precision_c}$: Σε περιπτώσεις που TP_c + FP_c = 0 (το μοντέλο δεν προβλέπει ποτέ την κλάση c), το Precision(c) είναι μαθηματικά μη ορισμένο· πρακτικά ορίζεται με συμβάσεις (π.χ. 0) και πρέπει να δηλώνεται η σύμβαση του library/tool.

Η.9 Στατιστική τεκμηρίωση (Confidence intervals & significance)

Η.9.1 Bootstrap confidence intervals

Για μετρική mσε test set, κατασκευάζονται Bbootstrap δείγματα με επαναδειγματοληψία, υπολογίζονται $m_1, \dots, m_B$, και το 95% CI λαμβάνεται από τα ποσοστημόρια (2.5%, 97.5%) (Efron & Tibshirani, 1993).

Η.9.2 McNemar test

Για δύο ταξινομητές A, Bστο ίδιο test set, ορίζονται n_{01}(λάθος ο A, σωστός ο B) και n_{10}(σωστός ο A, λάθος ο B) (McNemar, 1947). Με continuity correction, ένα συχνό στατιστικό είναι:

$$\chi^2 = \frac{(|\, n_{01} - n_{10} \,| - 1)^2}{n_{01} + n_{10}}.$$

(Η.27)

Η.10 Μαθηματική διατύπωση splits γενίκευσης και leakage (LOBO/LODO)

Σε group-based αξιολόγηση, το dataset γράφεται ως $\mathcal{D} = \bigcup_{g \in \mathcal{G}} \mathcal{D}_g$, όπου gείναι group (π.χ. workpiece/board). Για να αποφευχθεί leakage, επιβάλλεται group-disjoint διάσπαση: $\mathcal{D}_{\text{train}} \cap \mathcal{D}_{\text{test}} = \emptyset$σε επίπεδο groups. Στο leave-one-group-out, για κάθε fold g: $\mathcal{D}_{\text{test}} = \mathcal{D}_g$και $\mathcal{D}_{\text{train}} = \mathcal{D} \setminus \mathcal{D}_g$, ώστε να αξιολογείται γενίκευση σε unseen group (Kohavi, 1995).

Η.11 Μαθηματικοί ορισμοί "Pattern features" (όπως στο Κεφ.2)

Παρακάτω παρατίθενται οι μαθηματικοί ορισμοί του πλήρους συνόλου των υποψήφιων χαρακτηριστικών, από το οποίο προέκυψε το τελικό διάνυσμα των 22 χαρακτηριστικών (16 Pattern + 6 Frequency) που χρησιμοποιήθηκε στο βέλτιστο μοντέλο:
- Pattern FringesGeometry: totalfringes, avgfringespacing, centroidxy, diagratio, hvratio.
- Pattern SymmetryMoments: symmetryscore, Hu moments.
- Pattern NodalTopology: nodallength, nodalcomplexity, eulernumber.
- Pattern Spectral (FFT-based): fftpeakmagnitude, energyconcentration.
- ROI features: validpx, areaextent.

Η.11.1 ROI features (validpx, areaextent)

Έστω $F(x, y)$ το fringe map και $M(x, y) \in \{0,1\}$ η μάσκα ROI (valid pixels). Ορίζεται:

$$\text{validpx} = N_{\text{valid}} = \sum_{(x,y)} M(x, y), \text{areaextent} = \frac{N_{\text{valid}}}{WH}. \tag{Η.28}$$

Τα features αυτά ποσοτικοποιούν την "έκταση" έγκυρης περιοχής στην οποία υπολογίζονται όλα τα υπόλοιπα μορφολογικά/φασματικά χαρακτηριστικά.

Η.11.2 Pattern FringesGeometry

totalfringes

Ορίζεται δυαδικός χάρτης γραμμών κροσσών $B_F(x, y) \in \{0,1\}$(ridge/valley map) εντός ROI, όπως προκύπτει από τη διαδικασία ανίχνευσης fringes του pipeline.

Θέτουμε $\tilde{B}_F = B_F \cdot M$ και $\mathcal{S}_F = \text{skeleton}(\tilde{B}_F)$.

Τότε:

$$\text{totalfringes} = C(\mathcal{S}_F),$$

(H.29)

όπου $C(\cdot)$είναι ο αριθμός connected components (π.χ. 8-γειτνίαση).

avgfringespacing

Έστω $D_F(x,y)$ ο distance transform από το σύνολο $\{(u,v): \mathcal{S}_F(u,v) = 1\}$. Μια μαθηματικά σαφής (και implementation-agnostic) εκτίμηση μέσης απόστασης γειτονικών fringes ορίζεται ως:

$$\text{avgfringespacing} = \frac{2}{N_{\text{valid}}} \sum_{(x,y)} M(x,y)\ D_F(x,y).$$

(H.30)

Ο παράγοντας 2 αιτιολογείται επειδή D_F μετρά απόσταση από τον πλησιέστερο κροσσό, ενώ η τυπική "απόσταση μεταξύ κροσσών" αντιστοιχεί σε διπλάσια απόσταση από την κεντρική γραμμή μέχρι το μέσο μεταξύ δύο γραμμών.

centroidxy (centroidx, centroidy)

Ορίζεται μη αρνητικός χάρτης βαρών $W_F(x,y) \geq 0$ (π.χ. $W_F = (F \cdot M)^2$). Το κεντροειδές (σε pixels) είναι:

$$\bar{x} = \frac{\sum x\, W_F(x,y)}{\sum W_F(x,y) + \varepsilon}, \bar{y} = \frac{\sum y\, W_F(x,y)}{\sum W_F(x,y) + \varepsilon}.$$

(H.31)

Για αδιάστατη κανονικοποίηση:

$$\text{centroidx} = \frac{\bar{x}}{W-1}, \text{centroidy} = \frac{\bar{y}}{H-1}.$$

(H.32)

Το "centroidxy" στο feature set υλοποιείται ως τα δύο scalars centroidx και centroidy.

hvratio

Ορίζονται τα gradients F_x, F_yπάνω στην F. Η οριζόντια/κατακόρυφη κατευθυντική ενέργεια είναι:

$$E_H = \sum M\, F_x^2\,, E_V = \sum M\, F_y^2\,,$$

και: (H.33)

$$\text{hvratio} = \frac{E_H}{E_V + \varepsilon}.$$

(H.34)

Το χαρακτηριστικό αυτό κωδικοποιεί αν οι δομές των fringes είναι κυρίως "κάθετες" ή "οριζόντιες" μέσω της κατευθυντικής ενέργειας.

diagratio

Ορίζονται διαγώνιες κατευθυντικές αποκρίσεις F_{45}, F_{135}(π.χ. από κατευθυντικά φίλτρα ή από γραμμικούς συνδυασμούς gradients). Ορίζεται:

$$E_D = \sum M\,(F_{45}^2 + F_{135}^2)\,, E_A = \sum M\,\left(F_x^2 + F_y^2\right), \text{diagratio} = \frac{E_D}{E_A + \varepsilon}.$$

(H.35)

Το diagratio ποσοτικοποιεί τη διαγώνια υφή/κατεύθυνση της fringe δομής.

H.11.3 Pattern SymmetryMoments

symmetryscore

Ορίζονται οι κατοπτρικές εκδοχές $F^{\leftrightarrow}(x,y) = F(W-1-x,y)$ και $F^{\updownarrow}(x,y) = F(x,H-1-y)$.
Θέτουμε $G = F \cdot M$ και υπολογίζουμε Pearson correlation ρ εντός ROI. Τότε:

$$\text{symmetryscore} = \frac{1}{2}\left(\rho(G, G^{\leftrightarrow}) + \rho\left(G, G^{\updownarrow}\right)\right).$$

(H.36)

Η συσχέτιση με κατοπτρική εικόνα αποτελεί καθαρό μαθηματικό τρόπο ποσοτικοποίησης συμμετρίας μοτίβων.

Hu moments (ως υποσύνολο $\boldsymbol{\phi_1, \dots, \phi_K}$)

Οι γεωμετρικές ροπές τάξης (p, q)ορίζονται ως $m_{pq} = \sum_x \sum_y x^p\, y^q W(x,y)$, όπου $W(x,y) \geq 0$είναι ένας χάρτης βαρών (π.χ. $W = (F \cdot M)^2$ή δυαδικός χάρτης δομών). (Hu, 1962)

Με κέντρο μάζας $\bar{x} = \frac{m_{10}}{m_{00}}$, $\bar{y} = \frac{m_{01}}{m_{00}}$, οι κεντρικές ροπές είναι $\mu_{pq} = \sum (x - \bar{x})^p (y - \bar{y})^q W(x,y)$, και οι κανονικοποιημένες $\eta_{pq} = \frac{\mu_{pq}}{\mu_{00}^{\gamma}}$ με $\gamma = \frac{p+q}{2} + 1$. (Hu, 1962)

Τα Hu invariants $\phi_1, \dots, \phi_7$ορίζονται ως συγκεκριμένοι συνδυασμοί των η_{pq}(Hu, 1962), και στο παρόν feature set χρησιμοποιείται υποσύνολο $\{\phi_1, \dots, \phi_K\}$(με Kίσο με τον αριθμό Hu-features που έχουν συμπεριληφθεί στο τελικό διάνυσμα χαρακτηριστικών).

Η.11.4 Pattern NodalTopology

nodallength

Ορίζεται δυαδικός χάρτης nodal δομής $B_N(x,y) \in \{0,1\}$εντός ROI, σύμφωνα με το pipeline εξαγωγής nodal lines/περιοχών που περιγράφεται στο κύριο κείμενο. Θέτουμε $\tilde{B}_N = B_N \cdot M$, $\mathcal{S}_N = \text{skeleton}(\tilde{B}_N)$. Τότε:

$$\text{nodallength} = \sum_{(x,y)} \mathcal{S}_N\,(x,y). \tag{Η.37}$$

Το nodallength είναι το συνολικό μήκος του nodal δικτύου σε pixels (ή σε φυσικές μονάδες αν είναι γνωστό mm/pixel).

nodalcomplexity

Θεωρούμε γράφο $G = (V, E)$πάνω στο σκελετό $\mathcal{S}_N$, με κορυφές Vτα pixels του σκελετού και ακμές μεταξύ γειτονικών pixels. Ορίζονται branch points ως κόμβοι με $\deg(v) \geq 3$, και:

$$B_{\text{branches}} = |\{v \in V : \deg(v) \geq 3\}|, \text{nodalcomplexity} = \frac{B_{\text{branches}}}{\text{nodallength} + \varepsilon}. \tag{H.38}$$

Ο ορισμός αυτός κανονικοποιεί το πλήθος διακλαδώσεων ως προς το μήκος του nodal δικτύου.

eulernumber

Για τη δυαδική εικόνα $\tilde{B}_N$, ο Euler number ορίζεται ως: $E = C - H$, όπου Cείναι ο αριθμός connected components και Hο αριθμός οπών. Τότε:

$$\text{Eulernumber} = E\left(\tilde{B}_N\right). \tag{H.39}$$

Το eulernumber λειτουργεί ως τοπολογικό χαρακτηριστικό της nodal δομής.

H.11.5 Pattern Spectral (FFT-based)

fftpeakmagnitude

Έστω $\mathcal{F}(u, v)$ο 2D DFT του $F \cdot M$(με ό,τι προεπεξεργασία/φιλτράρισμα ορίζει το pipeline).

Έστω Ω_Sφασματική ζώνη ενδιαφέροντος (π.χ. annular bandpass) που αντιστοιχεί στις χωρικές συχνότητες των fringes. Τότε:

$$\text{fftpeakmagnitude} = \max_{(u,v)\in\Omega_S} |\mathcal{F}(u, v)|.$$

Η ποσότητα αυτή κωδικοποιεί την κυρίαρχη φασματική κορυφή των fringes.

energyconcentration

Με Ω_Tτην συνολική περιοχή φάσματος που λαμβάνεται υπόψη:

$$\text{energyconcentration} = \frac{\sum_{(u,v)\in\Omega_S} |\mathcal{F}(u, v)|^2}{\sum_{(u,v)\in\Omega_T} |\mathcal{F}(u, v)|^2 + \varepsilon}. \tag{H.40}$$

Ο λόγος αυτός ποσοτικοποιεί πόσο συγκεντρωμένη είναι η φασματική ενέργεια στην “fringe band” έναντι του συνολικού φάσματος.

Η.12 Γέφυρα φυσικής → features → ταξινόμηση

Η ESPI χρονικού μέσου όρου χαρτογραφεί το πλάτος δόνησης σε φωτεινότητα μέσω του ή , με , άρα μετατρέπει τις ιδιομορφές σε σταθερά "μορφολογικά" fringe patterns (Kreis, 2005; Rastogi, 2001).Τα pattern features της Η.11 (FringesGeometry /SymmetryMoments/ NodalTopology/Spectral, καθώς και ROI features) αποτελούν μαθηματικούς τελεστές πάνω σε αυτά τα fringe maps ώστε να παραχθεί διάνυσμα χαρακτηριστικών για ML ταξινόμηση (Breiman, 2001; Hastie et al., 2009). Οι learned μέθοδοι (DnCNN/ECA) παρεμβάλλονται ως χαρτογράφηση πριν την εξαγωγή χαρακτηριστικών/ταξινόμηση, με διατυπώσεις residual learning και channel attention όπως ορίστηκαν στις Η.6-Η.7 (Zhang et al., 2017; Wang et al., 2020).$a(x,y)J_0(\beta)J_0^2(\beta)\beta = \frac{4\pi}{\lambda}a(x,y)y \mapsto \hat{x}$

ΠΑΡΑΡΤΗΜΑ Θ: Μελέτη Αφαίρεσης DnCNN-ECA — Μαθηματική Θεμελίωση και Εκτεταμένα Αποτελέσματα

Θ.0 Σύνδεση με τον κύριο κορμό

Ενώ στην Ενότητα 4.3.6 τεκμηριώθηκε η λειτουργική ισοδυναμία (functional equivalence) μεταξύ DnCNN-Lite-ECA και DnCNN-Lite σε ακρίβεια float32, στην §5.5 ερμηνεύτηκε η regime-dependent συμπεριφορά του μηχανισμού ECA υπό εναλλακτικές συνθήκες εποπτείας. Το παρόν παράρτημα συμπληρώνει αυτές τις ενότητες παρέχοντας: τη μαθηματική θεμελίωση της «απορρόφησης» (absorption) του channel scaling από στρώματα κανονικοποίησης, τις αρχιτεκτονικές προδιαγραφές των παραλλαγών V4/V5, τα συγκεντρωτικά αποτελέσματα ταξινόμησης ανά καθεστώς εποπτείας, καθώς και τα αποτελέσματα stress test και υπολογιστικού κόστους.

Τα αποτελέσματα ερμηνεύονται εντός του ειδικού πειραματικού πλαισίου του 5-class downstream πρωτοκόλλου, της εποπτείας τύπου pseudo έναντι real-aligned και των παραλλαγών V4/V5. Κατά συνέπεια, δεν συνιστούν άμεση ποσοτική συνέχεια της κύριας ablation αξιολόγησης του Κεφαλαίου 4, αλλά εκτεταμένη συμπληρωματική ανάλυση.

Θ.1 Ερευνητικό ερώτημα

Υπό ποιες μαθηματικές προϋποθέσεις ένας μηχανισμός επαναστάθμισης ανά κανάλι (channel-wise scaling), όπως ο ECA, μπορεί να «απορροφηθεί» από στρώματα κανονικοποίησης τύπου BN ή GN και από επόμενες συνελίξεις, καθιστώντας την επίδρασή του μη παρατηρήσιμη στην τελική συνάρτηση εισόδου-εξόδου; Και πότε, αντιθέτως, αποκτά μετρήσιμη συνεισφορά, ιδίως όταν η εποπτεία ευθυγραμμίζεται με τα στατιστικά του πραγματικού θορύβου;

Θ.2 Αρχιτεκτονικές παραλλαγές DnCNN-Lite

Ως βάση αναφοράς (baseline) ορίζεται το DnCNN-Lite (V3), με βάθος 17 στρωμάτων, πλάτος 32 καναλιών, κανονικοποίηση BN ή GN και 139.776 παραμέτρους. Η V4 εισάγει τρία ECA modules σε ρηχές θέσεις (light strategy, avg pooling), ενώ η V5 εισάγει επτά ECA modules με διπλή ομαδοποίηση (dual pooling, avg+max) και εκπαιδεύσιμο κέρδος και θερμοκρασία (learnable gain/temperature, aggressive strategy). Οι εκδόσεις V4R και V5R αντιστοιχούν σε εκπαίδευση με real-aligned εποπτεία, αξιοποιώντας 23.891 ευθυγραμμισμένα ζεύγη.

Πίνακας Θ.1. *Παραλλαγές attention στο DnCNN-Lite.*

Παραλλαγή	Θέσεις ECA	Pooling	Gating	Παράμετροι
V3 Base (χωρίς ECA)	—	—	—	139.776
V4 (Light ECA)	[0, 1, 2] (3 modules)	Avg	Σταθερά	139.791

V5 (Aggressive ECA)	[0, 1, 2, 3, 6, 10, 14] (7 modules)	Avg+Max	Learnable	139.860

Θ.2.1 Μαθηματική διατύπωση μηχανισμού ECA

Ο μηχανισμός ECA υλοποιεί επαναστάθμιση ανά κανάλι. Για τανυστή εισόδου με C κανάλια και χωρικές διαστάσεις H × W, υπολογίζεται αρχικά ο μέσος περιγραφέας ανά κανάλι, ακολουθεί μονοδιάστατη συνέλιξη μήκους k και στη συνέχεια εφαρμόζεται sigmoid gating. Η έξοδος του attention προκύπτει με σημειακό πολλαπλασιασμό των αρχικών ενεργοποιήσεων με τους αντίστοιχους συντελεστές πύλης. Η ακολουθία αυτή αποτυπώνεται στις Εξ. Θ.1–Θ.3.

$$z_c^{\text{avg}} = \frac{1}{HW}\sum_{h=1}^{H}\sum_{w=1}^{W} X_{c,h,w} \quad (\Theta.1)$$

$$s = \sigma\big(\text{Conv1D}_k(z^{\text{avg}})\big) \quad (\Theta.2)$$

$$\tilde{X}_{c,h,w} = s_c \cdot X_{c,h,w} \quad (\Theta.3)$$

Στην επιθετικότερη παραλλαγή V5 εισάγεται επιπλέον περιγραφέας μέγιστης απόκρισης ανά κανάλι, ο οποίος συνδυάζεται με τον μέσο περιγραφέα. Η τελική πύλη προκύπτει μετά από κλιμάκωση με gain και temperature, όπως φαίνεται στις Εξ. Θ.4–Θ.5.

$$z_c^{\max} = \max_{1\le h\le H,\ 1\le w\le W} X_{c,h,w} \quad (\Theta.4)$$

$$s = \sigma\left(\frac{g}{\tau}\text{Conv1D}_k(z^{\text{avg}} + z^{\max})\right) \quad (\Theta.5)$$

Θ.3 Μηχανισμοί απορρόφησης του channel scaling

Η κεντρική υπόθεση του παραρτήματος είναι ότι η έλλειψη παρατηρήσιμου οφέλους από το attention σε ορισμένα καθεστώτα εποπτείας δεν συνιστά απαραίτητα αποτυχία του μηχανισμού. Αντιθέτως, μπορεί να αποτελεί αναμενόμενη συνέπεια της αλληλεπίδρασής του με τη κανονικοποίηση, την παραμετρική ελαστικότητα των συνελίξεων και τη residual διατύπωση του DnCNN-Lite.

Θ.3.1 Αναλλοιότητα κλίμακας στην Batch Normalization

Για ενεργοποιήσεις ενός καναλιού x, η Batch Normalization γράφεται όπως στην Εξ. Θ.6. Αν πριν από τη BN εφαρμοστεί θετική κλιμάκωση a > 0, τότε οι πρώτες δύο ροπές μετασχηματίζονται αναλογικά. Η εξαρτημένη από το ε όρος μορφή που προκύπτει αποτυπώνεται στην Εξ. Θ.7. Συνεπώς, όταν ο σταθεροποιητικός όρος είναι μικρός σε σχέση με τη διακύμανση, η BN συμπεριφέρεται πρακτικά ως σχεδόν αναλλοίωτη ως προς θετικές κλιμακώσεις ανά κανάλι. Αυτό μπορεί να εξουδετερώνει πολλαπλασιαστικούς μηχανισμούς όπως το ECA όταν αυτοί προηγούνται της BN.

$$\mathrm{BN}(x) = \gamma \frac{x-\mu(x)}{\sqrt{\sigma^2(x)+\varepsilon}} + \beta \quad (\Theta.6)$$

$$\mathrm{BN}(ax) = \gamma \frac{x-\mu(x)}{\sqrt{\sigma^2(x)+\varepsilon/a^2}} + \beta, \qquad a > 0 \quad (\Theta.7)$$

Επιπλέον, οι εκπαιδεύσιμες affine παράμετροι (γ, β) επιτρέπουν στο δίκτυο να ανακατανείμει παραμετρικά την επίδραση σταθερών κλιμακώσεων. Το αποτέλεσμα δεν είναι απλώς αριθμητικό, αλλά δομικό: μέρος της συμβολής του attention μπορεί να απορροφηθεί ήδη στο επίπεδο της κανονικοποίησης.

Θ.3.2 Group Normalization

Η Group Normalization υπολογίζει στατιστικά ανά δείγμα και ανά ομάδα καναλιών, όπως φαίνεται στην Εξ. Θ.8. Παρότι δεν εξαρτάται από running statistics της δέσμης, όταν χρησιμοποιείται με affine=True διατηρεί ανά κανάλι παραμέτρους γc και βc, οι οποίες επιτρέπουν μερική αντιστάθμιση κλιμακώσεων.

$$\mathrm{GN}(x_c) = \gamma_c \frac{x_c-\mu_G(x)}{\sqrt{\sigma_G^2(x)+\varepsilon}} + \beta_c \quad (\Theta.8)$$

Η A/B αξιολόγηση ECA έναντι non-ECA πραγματοποιήθηκε και με GN χωρίς να αναδείξει καθαρό κέρδος. Επομένως, η απουσία υπεροχής δεν αποδίδεται μονοπαραγοντικά σε μηχανισμό BN-compensation, αλλά σε συνδυασμό παραγόντων.

Θ.3.3 Απορρόφηση σε επόμενη συνέλιξη

Αν μετά τον μηχανισμό attention ακολουθεί συνέλιξη με βάρη W, ο σταθερός παράγοντας κλιμάκωσης ανά κανάλι μπορεί να απορροφηθεί ακριβώς σε αναπαραμετροποίηση των βαρών, όπως φαίνεται στην Εξ. Θ.9. Η ισοδυναμία αυτή εξηγεί γιατί η επίδραση του attention μπορεί να γίνει μη παρατηρήσιμη ακόμη και όταν οι πύλες δεν είναι τετριμμένες.

$$y_o = \sum_{c,i,j} W_{o,c,i,j} \left(s_c X_{c,h-i,w-j}\right) = \sum_{c,i,j} W'_{o,c,i,j} X_{c,h-i,w-j}, \quad W'_{o,c,i,j} = s_c W_{o,c,i,j} \quad (\Theta.9)$$

Σε συνδυασμό με το residual inductive bias, το οποίο ευνοεί ήπιες διορθώσεις και όχι επιθετικές μετασχηματίσεις, οι τρεις μηχανισμοί — πρακτική αναλλοιότητα BN, μερική αντιστάθμιση GN και conv re-parameterization — παρέχουν συνεκτική ερμηνεία της λειτουργικής ισοδυναμίας που τεκμηριώθηκε στην §4.3.8.

Θ.4 Συγκεντρωτικά αποτελέσματα

Θ.4.1 Downstream ταξινόμηση ανά καθεστώς εποπτείας

Ο Πίνακας Θ.2 συνοψίζει τη downstream 5-class ταξινόμηση με ταξινομητή ResNet-18 για το raw σήμα και για τις εναλλακτικές denoise pipelines. Η σύγκριση αναδεικνύει δύο κεντρικά ευρήματα. Πρώτον, ο κυρίαρχος παράγοντας είναι το καθεστώς εποπτείας: στο pseudo regime η αποθορύβηση υποβαθμίζει τη downstream ταξινόμηση, ενώ στο real-

aligned regime βελτιώνει σταθερά τόσο την Accuracy όσο και το Macro-F1. Δεύτερον, η ήπια V4R ECA (light) υπερτερεί της επιθετικής V5R ECA (aggressive), επιβεβαιώνοντας ότι η υπερ-εξομάλυνση αποδυναμώνει τα διακριτικά στοιχεία του σήματος.

Πίνακας Θ.2. *Downstream 5-class ταξινόμηση (ResNet-18): Raw έναντι denoise pipelines.*

Pipeline	Regime denoiser	Accuracy (%)	Macro-F1 (%)	vs Raw (pp)
Raw (χωρίς denoise)	—	97,70	93,99	—
V4 ECA	Pseudo	94,77	84,21	−2,93
V4 NoECA	Pseudo	96,39	89,06	−1,31
Averaged Swap	—	96,12*	91,54*	−1,58
V4R ECA (light)	Real-aligned	98,87	96,64	+1,17
V4R NoECA	Real-aligned	98,76	96,07	+1,06
V5R NoECA	Real-aligned	98,87	96,01	+1,17
V5R ECA (aggressive)	Real-aligned	98,16	94,27	+0,46

Σημείωση*: Το «Averaged Swap» εμφάνισε αριθμητική αστάθεια· αναφέρεται το best epoch.*

Θ.4.2 Stress test υπό έντονο πρόσθετο θόρυβο (σ = 25)

Τα αποτελέσματα του stress test υπολογίσθηκαν ως μέσος όρος τριών σπόρων (seeds 42, 13 και 37), με επιλογή epoch μέσω του μέγιστου validation Macro-F1. Ο Πίνακας Θ.3 δείχνει ότι η V4R (Light ECA) διατηρεί σαφές πλεονέκτημα έναντι της raw εισόδου και της V5R υπό έντονο πρόσθετο θόρυβο.

Πίνακας Θ.3. *Stress test (σ = 25), 3-seed μέσος όρος (mean ± std, ddof = 0).*

Pipeline (σ = 25)	Acc@BestF1 (%)	Macro-F1@BestF1 (%)	F1 vs Raw (pp)
Raw (no denoiser)	94,22 ± 0,86	84,35 ± 0,84	—
V4R (Light ECA)	95,76 ± 0,49	87,65 ± 1,50	+3,30
V5R (Aggressive ECA)	94,37 ± 0,71	84,91 ± 1,87	+0,56

Ο έλεγχος paired t-test για τη σύγκριση V4R έναντι V5R στο Macro-F1, με n = 3 και df = 2, δίνει μέση διαφορά $\bar{d} = +2{,}74$ ποσοστιαίες μονάδες υπέρ της V4R, p = 0,0447 και Cohen's d = 2,64. Η ένδειξη στατιστικής σημαντικότητας πρέπει να ερμηνευθεί ως προκαταρκτική λόγω του μικρού δείγματος.

Θ.4.3 Υπολογιστική πολυπλοκότητα (RTX 3060, batch = 1, 256 × 256)

Ο Πίνακας Θ.4 συνοψίζει παραμέτρους και latency για τις κύριες παραλλαγές. Η παραλλαγή V4 εισάγει αμελητέο υπολογιστικό φόρτο, ενώ η V5 επιβαρύνει δυσανάλογα τον

χρόνο απόκρισης. Σε συνδυασμό με την υπεροχή της στο downstream πρωτόκολλο, η V4R αναδεικνύεται ως η πρακτικά βέλτιστη ισορροπία μεταξύ επίδοσης και κόστους.

Πίνακας Θ.4. *Παράμετροι και χρόνος απόκρισης (latency).*

Μοντέλο	Παράμετροι	Latency (ms)	Overhead vs Base
Base (χωρίς ECA)	139.776	6,621	—
V4 ECA (light)	139.791	6,912	+4,39%
V5 ECA (aggressive)	139.860	30,482	+360,38%

Θ.5 Σύνθεση και περιορισμοί

Η μη παρατηρήσιμη επίδραση του ECA υπό pseudo εποπτεία αποτελεί αναμενόμενο αποτέλεσμα των μηχανισμών απορρόφησης που αναλύθηκαν στην §Θ.3 και δεν συνιστά σφάλμα υλοποίησης. Το συμπέρασμα αυτό ενισχύεται από τους αυστηρούς ελέγχους ακεραιότητας — checkpoint fingerprinting και forward hook diagnostics — που παρουσιάστηκαν στην §4.3.7.

Η μετάβαση σε real-aligned εποπτεία αναδεικνύει regime-dependent συμπεριφορά. Η V4R ECA επιτυγχάνει το υψηλότερο Macro-F1 σε ονομαστικές συνθήκες (96,64%) και εμφανίζει βελτίωση +3,30 ποσοστιαίων μονάδων έναντι της raw εισόδου στο stress test, ενώ η aggressive V5R δεν προσφέρει αντίστοιχο κέρδος.

Παρά ταύτα, οι περιορισμοί του παρόντος παραρτήματος είναι σαφείς. Τα stress tests βασίζονται σε n = 3 seeds και paired design, άρα οι στατιστικοί έλεγχοι πρέπει να θεωρούνται προκαταρκτικοί. Η λειτουργική ισοδυναμία τεκμηριώνεται για το συγκεκριμένο backbone DnCNN-Lite 17×32 και δεν γενικεύεται αυτομάτως σε άλλες αρχιτεκτονικές. Ενδεικτικές μελλοντικές κατευθύνσεις περιλαμβάνουν χρήση GroupNorm χωρίς affine, τοποθέτηση ECA μετά το τελευταίο normalization και εισαγωγή regularization gates που ενθαρρύνουν μεγαλύτερη εντροπία ή διακύμανση στις πύλες προσοχής.

ΠΑΡΑΡΤΗΜΑ Ι: Μαθηματική και Πειραματική Διατύπωση των Ταξινομητών Random Forest

(Metadata-only, Pattern-only, Hybrid RF)

Σημείωση διασταύρωσης: *Οι γενικοί μαθηματικοί ορισμοί (Gini impurity, Macro-F1, LOBO/LODO) δίνονται στο Παράρτημα Η (§Η.5, §Η.8, §Η.10). Οι ορισμοί των 16 pattern features δίνονται στο §Η.11. Στο παρόν παράρτημα εξειδικεύονται στο πλαίσιο του Hybrid RF pipeline και συμπληρώνονται με τον μαθηματικό ορισμό των frequency priors (dist_mode_*), την ablation ladder τριών εκδοχών, και τους ελέγχους αποφυγής διαρροής πληροφορίας.*

Ι.1 Σκοπός και θέση στο pipeline

Στο παρόν παράρτημα δίνεται πλήρης, αυτοτελής περιγραφή των ταξινομητών Random Forest (RF) που χρησιμοποιούνται στη διπλωματική, σε τρεις διαδοχικές παραλλαγές (ablation ladder): (α) RF metadata-only (naïve baseline χωρίς μορφολογικά χαρακτηριστικά), (β) RF pattern-only (μόνο μορφολογικά/τοπολογικά χαρακτηριστικά από χάρτες αποτυλιγμένης φάσης), και (γ) Hybrid RF (pattern features + συχνοτικές πρότερες πληροφορίες θεμελιωμένες στη φυσική).

Ο RF εφαρμόζεται μετά την αλυσίδα φυσικής επεξεργασίας: (προαιρετικό) αποθορυβοποίηση → ROI masking (αφαίρεση overlays) → FFT-based phase retrieval (Takeda) → τυλιγμένη/αποτυλιγμένη φάση + χάρτης ποιότητας → Έλεγχος ποιότητας (Quality Control, QC) → εξαγωγή χαρακτηριστικών → ταξινόμηση.

Συνεπώς, ο RF δεν «βλέπει» ωμές ESPI εικόνες· λαμβάνει ένα διάνυσμα tabular χαρακτηριστικών που συμπυκνώνει (i) τη μορφολογία του mode shape και (ii) γνωστή πληροφορία πειραματικού ελέγχου (συχνότητα διέγερσης) ως πρότερη πληροφορία θεμελιωμένη στη φυσική.

Ι.2 Δεδομένα, κλάσεις και συμβολισμοί

Θεωρούμε σύνολο ταξινόμησης με $N = 3.443$ δείγματα (*Master Verified classification set*), μετά από QC και απομάκρυνση προβληματικών/αμφίσημων περιπτώσεων. Η ταξινόμηση γίνεται σε $K = 6$ κλάσεις με κλειδωμένο mapping:

Πίνακας Ι.1: *Συγκριτική σύνοψη των εκδόσεων RF*

ID	Κλάση	Ονομασία	Support (N)	Ποσοστό
0	(1,1)H	Helmholtz	199	5,8%
1	(1,1)T	Fundamental	171	5,0%
2	(1,2)	Long. Dipole	106	3,1%
3	(2,1)	Trans. Dipole	58	1,7%
4	higher	Multipole+	1.115	32,4%
5	other	Μη-ταξιν.	1.794	52,1%

Σημείωση: Τα ~12k–25k frames (single-shot/averaged/pseudo-noisy) αφορούν κυρίως την εκπαίδευση/βαθμονόμηση του denoiser και την αλυσίδα φυσικής επεξεργασίας. Το classification set είναι μικρότερο, επειδή κάθε δείγμα πρέπει να είναι (i) ποιοτικά αποδεκτό μετά το FFT/unwrapping, και (ii) αξιόπιστα επισημασμένο (label).

Ορίζουμε το dataset:

$$D = \{(P_i, f_i, y_i)\}_{i=1..N} \qquad (I.1)$$

όπου P_i είναι ο χάρτης αποτυλιγμένης φάσης μετά από QC, f_i η συχνότητα διέγερσης (Hz) από metadata, και $y_i \in \{0,\ldots,K-1\}$ η ετικέτα κλάσης.

Ορίζουμε δύο συναρτήσεις χαρακτηριστικών: $\varphi(P_i) \in \mathbb{R}^{16}$ (pattern/morphology, βλ. §H.11) και $\psi(f_i) \in \mathbb{R}^6$ (συχνοτικές πρότερες πληροφορίες θεμελιωμένες στη φυσική, βλ. §I.5).

I.3 Τρεις εκδόσεις RF (ablation ladder) και feature vectors

I.3.1 RF metadata-only (naïve baseline, χωρίς pattern features)

Στην πιο απλή γραμμή βάσης, ο RF λαμβάνει αποκλειστικά συχνοτικά μεταδεδομένα:

$x_i^{meta} = [f_i, \tilde{f}_i] \in \mathbb{R}^2$ (I.2)

όπου $\tilde{f}_i$ είναι κανονικοποιημένη συχνότητα (βλ. §I.4). Η παραλλαγή αυτή λειτουργεί ως sanity check: χωρίς καμία πληροφορία «σχήματος», η επίδοση αναμένεται κοντά σε επίπεδα naïve πρόβλεψης για ανισόρροπο multi-class πρόβλημα (τυπικά τάξης ~50% Accuracy λόγω ισχυρών majority classes).

I.3.2 RF pattern-only (baseline με 16 μορφολογικά features)

Στη δεύτερη παραλλαγή, ο RF τροφοδοτείται μόνο με μορφολογικά/τοπολογικά χαρακτηριστικά από τον χάρτη αποτυλιγμένης φάσης (βλ. §Η.11 για ορισμούς):

$x_i^{pat} = \varphi(P_i) \in \mathbb{R}^{16}$ (I.3)

Κλειδωμένα αποτελέσματα (*in-field*): *Accuracy* = 90,15% και *Macro-F1* = 69,91%.

I.3.3 Hybrid RF (16 pattern + 6 priors = 22 features)

Η τελική παραλλαγή (κύρια συνεισφορά) συνδυάζει pattern features και πρότερες πληροφορίες θεμελιωμένες στη φυσική:

$x_i^{hyb} = [\varphi(P_i), \psi(f_i)] \in \mathbb{R}^{22}$ (I.4)

Κλειδωμένα αποτελέσματα: *Accuracy* = 97,85% (95% CI: [97,36%, 98,34%]) και *Macro-F1* = 95,15%.

Αποτελέσματα γενίκευσης: LOBO mean Accuracy = 91,83% ± 8,87% και LODO mean Accuracy = 66,31% ± 44,11%.

Πίνακας I.2: *Ορισμός συχνοτικών διαστημάτων για τα frequency priors (κλειδωμένες τιμές)*

Μοντέλο	Διάνυσμα εισόδου	# features	Πηγή πληροφορίας	Accuracy	Macro-F1
RF metadata-only	[f, f̃]	2	metadata	≈50%	—

RF pattern-only	φ(P)	16	Αποτυλιγμένη φάση	90,15%	69,91%
Hybrid RF	[φ(P), ψ(f)]	22 (16+6)	phase + priors	97,85%	95,15%

***Σημείωση**: Το «in-field / upper-bound» αναφέρεται σε αξιολόγηση εντός του ίδιου πεδίου δεδομένων όπου τα priors είναι διαθέσιμα. Τα πρωτόκολλα LOBO (Leave-One-Band-Out) και LODO (Leave-One-Dataset-Out) χρησιμοποιούνται για αυστηρότερο έλεγχο γενίκευσης σε μη-παρατηρημένες συχνότητες και σε νέο δοκίμιο/όργανο αντίστοιχα (βλ. §Η.10).*

Ι.4 Κανονικοποίηση συχνότητας

Χρησιμοποιείται z-score κανονικοποίηση στο training set (ανά fold):

$$\tilde{f}_i = (f_i - \mu\text{train}) / (\sigma\text{train} + \varepsilon) \qquad \text{(I.5)}$$

με μικρό ε > 0 για αποφυγή διαίρεσης με μηδέν. **Κρίσιμο:** μ*train* και σ*train* υπολογίζονται **μόνο** από τα δεδομένα εκπαίδευσης του εκάστοτε fold, ώστε να αποφεύγεται leakage.

Ι.5 Ορισμός frequency priors τύπου dist_mode_* (πυρήνας του Hybrid)

Για κάθε βασικό mode *m* ορίζεται ένα αναμενόμενο συχνοτικό διάστημα $B_m = [L_m, U_m]$, με $0 < L_m < U_m$. Η πληροφορία αυτή κωδικοποιείται ως κανονικοποιημένη απόσταση της διέγερσης *f* από το διάστημα.

Ορισμός *distance-to-interval*:

$$\Delta_m(f) = 0, \quad \alpha\nu\ f \in [L_m, U_m] \qquad \text{(I.6a)}$$

$$\Delta_m(f) = \min(|f - L_m|, |f - U_m|), \quad \alpha\lambda\lambda\iota\acute{\omega}\varsigma \qquad \text{(I.6b)}$$

Κανονικοποιημένη απόσταση:

$$d_m(f) = \Delta_m(f) / ((U_m - L_m) + \varepsilon) \qquad \text{(I.7)}$$

Η κανονικοποίηση με το εύρος του διαστήματος καθιστά τα priors συγκρίσιμα μεταξύ modes με διαφορετικό bandwidth.

Πίνακας Ι.3: *Ορισμός frequency features και περιγραφών (Ι.5 Ορισμός frequency priors τύπου dist_mode_* (πυρήνας του Hybrid))*

Feature	Mode	L_m (Hz)	U_m (Hz)	Κέντρο (Hz)
dist_mode_(1,1)H	Helmholtz	155	175	165
dist_mode_(1,1)T	Fundamental	320	345	332,5
dist_mode_(1,2)	Long. Dipole	500	525	512,5
dist_mode_(2,1)	Trans. Dipole	540	570	555
dist_mode_higher	Multipole+	680	1.500	—

Ενδεικτικός ορισμός ψ(*f*):

$\psi(f_i) = [freq_hz, \tilde{f}, d_{(1,1)}H(f_i), d_{(1,1)}T(f_i), d_{(1,2)}(f_i), d_{(2,1)}(f_i)]$ (Ι.8)

Σημείωση: Τα ακριβή εύρη [L_m, U_m] καθορίστηκαν εμπειρικά από τα μετρημένα δεδομένα και τη βιβλιογραφία ακουστικής του μπουζουκιού (βλ. Κεφ. 4, §4.5). Η ακριβής επιλογή τεκμηριώνεται στα κλειδωμένα artefacts.

Ι.6 Random Forest: ορισμός, πρόβλεψη και κριτήριο split

Ένας Random Forest αποτελείται από T δέντρα αποφάσεων $\{h_t\}_{t=1..T}$, εκπαιδευμένα σε bootstrap δείγματα του training set. Κάθε δέντρο επιστρέφει κατανομή πιθανοτήτων $p_t(y=c \mid x)$. Η συνολική πρόβλεψη δίνεται από τον μέσο όρο (βλ. §Η.5 για αναλυτική θεμελίωση):

$p(y=c \mid x) = (1/T) \cdot \Sigma_{t=1}^{T} p_t(y=c \mid x)$ (Ι.9)

$\hat{y} = argmax_c \; p(y=c \mid x)$ (Ι.10)

Για τα splits χρησιμοποιείται κριτήριο ακαθαρσίας Gini (βλ. §Η.5.2):

$$Gini(S) = 1 - \Sigma_{c=0}^{K-1} (n_o/|S|)^2 \quad \text{(I.11)}$$

Στην παρούσα εργασία: $T = 200$ δέντρα, $max_features = \sqrt{d}$, $min_samples_leaf = 2$, $class_weight$ = 'balanced', $random_state = 42$.

I.7 Μετρικές και framing αξιολόγησης

Λόγω έντονης ανισορροπίας κλάσεων (imbalance ratio 30,9:1), η κύρια μετρική είναι το Macro-F1, ώστε κάθε κλάση να συνεισφέρει ισότιμα (βλ. §H.8.3 για ορισμό):

$$F1_c = 2 \cdot (Prec_c \cdot Rec_c) / (Prec_c + Rec_c + \varepsilon) \quad \text{(I.12)}$$

$$Macro\text{-}F1 = (1/K) \cdot \Sigma_{c=0}^{K-1} F1_c \quad \text{(I.13)}$$

Το Accuracy παρατίθεται συμπληρωματικά. Για robustness/γενίκευση χρησιμοποιούνται πρωτόκολλα LOBO (Leave-One-Band-Out, 111 frequency bands, §H.10) και LODO (Leave-One-Dataset-Out, 3 workpieces).

I.8 Έλεγχοι αποφυγής διαρροής πληροφορίας (leakage) και QC

Για να διασφαλιστεί ότι οι επιδόσεις δεν είναι τεχνητά φουσκωμένες, εφαρμόζονται οι ακόλουθοι έλεγχοι:

- Η συχνότητα εισάγεται ως γνωστή μεταβλητή πειραματικού ελέγχου (*metadata*) και **όχι** ως οπτική πληροφορία. Τα overlays αφαιρούνται με ROI masking ώστε να μην μπορεί κανένα μοντέλο να «διαβάσει» Hz από την εικόνα.
- Η κανονικοποίηση συχνότητας (μ*train*, σ*train*) υπολογίζεται μόνο στο training split/fold (βλ. §I.4).
- Quality Control (QC) σε χάρτες τυλιγμένης/αποτυλιγμένης φάσης και ποιότητας απορρίπτει αποτυχημένες περιπτώσεις ανάκτησης φάσης (π.χ. αποτυχίες ξετυλίγματος, υπερβολικό zero fraction, χαμηλό valid_px).
- *Near-duplicate filtering/deduplication* αποτρέπει leakage από σχεδόν ίδια frames σε train και test.
- Για στατιστικό *sanity check*, εφαρμόζεται και *label-shuffle / negative control* ώστε να επιβεβαιώνεται ότι το σύστημα δεν αποδίδει υψηλά χωρίς πραγματικό σήμα.

Ι.9 Αναπαραγωγιμότητα και συμπέρασμα

Τα κλειδωμένα νούμερα RF (Pattern-only / Hybrid) και τα πρωτόκολλα LOBO/LODO τεκμηριώνονται στα αποθηκευμένα artefacts των runs (βλ. Παράρτημα Δ για πλήρη οδηγίες αναπαραγωγής).

Με τα παραπάνω, ο Hybrid RF αιτιολογείται ως ταξινομητής μικρών δεδομένων καθοδηγούμενος από τη φυσική: η συχνότητα λειτουργεί ως soft constraint που περιορίζει τον χώρο υποθέσεων σε περιπτώσεις μορφολογικής επικάλυψης, ενώ τα pattern features διατηρούν την αναγκαία πληροφορία γεωμετρίας των mode shapes. Η σαφής αύξηση Macro-F1 κατά +25,24 pp (από 69,91% σε 95,15%) με την εισαγωγή μόλις 6 πρότερων πληροφοριών θεμελιωμένων στη φυσική αποτελεί ισχυρή εμπειρική απόδειξη της αξίας της προσέγγισης καθοδηγούμενης από τη φυσική.

ΠΑΡΑΡΤΗΜΑ Κ: Μαθηματική και Μεθοδολογική Θεμελίωση της Βαθμονομημένης Γεννήτριας Συνθετικού Θορύβου ESPI

Κ.0 Σύνδεση με τον Κύριο Κορμό και Σύνοψη Μεθοδολογίας

Η εκπαίδευση νευρωνικών δικτύων αποθορυβοποίησης στην ESPI προσκρούει σε ένα θεμελιώδες πρακτικό όριο: η απόκτηση πραγματικά καθαρών εικόνων αναφοράς είναι, στην πράξη, αδύνατη, επειδή ο θόρυβος κηλίδων αποτελεί εγγενές χαρακτηριστικό της σύμφωνης απεικόνισης. Για τον λόγο αυτό, ως προσεγγιστικές εικόνες υψηλότερου λόγου σήματος προς θόρυβο χρησιμοποιούνται οι χρονικά ολοκληρωμένες λήψεις (multi-frame averaged), ενώ η γεννήτρια ψευδο-θορύβου αναλαμβάνει να παράγει ρεαλιστικά θορυβώδεις εκδοχές τους, ώστε να δημιουργούνται ελεγχόμενα ζεύγη εκπαίδευσης για τον αποθορυβοποιητή.

Η σχεδιαστική αρχή της γεννήτριας είναι ότι ο θόρυβος στην ESPI δεν μπορεί να προσεγγισθεί επαρκώς ως απλός προσθετικός θόρυβος Gauss. Αντιθέτως, η παρατηρούμενη εικόνα προκύπτει από διαδοχική αλυσίδα φυσικών μηχανισμών, η οποία συνοψίζεται ως Speckle → Poisson → Gaussian. Αν το x συμβολίζει τη μέση εικόνα αναφοράς, τότε η τελική έξοδος y μπορεί να παρασταθεί συνοπτικά ως εξής:

$$y = \text{clip}\left(G_\sigma\left(P_p\left(S_k(x)\right)\right)\right) \qquad \textbf{(K.1)}$$

Στο σχήμα αυτό, ο τελεστής S_k περιγράφει την πολλαπλασιαστική διαμόρφωση speckle, ο τελεστής P_p τον εξαρτώμενο από το σήμα θόρυβο βολής και ο G_σ τον προσθετικό θόρυβο ανάγνωσης του αισθητήρα. Η σειρά εφαρμογής είναι κρίσιμη, επειδή ακολουθεί τη φυσική ροή παραγωγής της οπτικής πληροφορίας: πρώτα η συνεκτική speckle διαμόρφωση, κατόπιν η φωτοηλεκτρική δειγματοληψία Poisson και τέλος ο ηλεκτρονικός θόρυβος ανάγνωσης.

Το καθοριστικό σημείο που διαφοροποιεί τη γεννήτρια από απλές ad hoc προσεγγίσεις είναι η εμπειρική βαθμονόμηση των παραμέτρων της από πραγματικά ζεύγη μεμονωμένων (single-shot) και ολοκληρωμένων (averaged) εικόνων. Οι παράμετροι θ = (k, p, σ) δεν επιλέγονται ευρετικά, αλλά προσαρμόζονται μέσω αντιστοίχισης στατιστικών ροπών ανάμεσα στη συνθετική έξοδο και στις πραγματικές μεμονωμένες λήψεις. Η βαθμονόμηση v2.0 κατέληξε στο κανονικό σημείο λειτουργίας k = 1,89, p = 12,5 και σ = 0,0919, το οποίο χρησιμοποιήθηκε ως σταθερό σημείο αναφοράς στις κύριες συγκρίσεις.

Η αναγκαιότητα της φυσικής βαθμονόμησης αποδεικνύεται από δύο κεντρικά εμπειρικά ευρήματα. Πρώτον, χωρίς επαρκή αντιστοίχιση του συνθετικού καθεστώτος με τις πραγματικές λήψεις εμφανίζεται χάσμα πεδίου (domain gap), το οποίο μπορεί να οδηγήσει σε αρνητικά ή οριακά κέρδη PSNR σε πραγματικά δεδομένα, παρά την καλή επίδοση σε συνθετικά ζεύγη. Δεύτερον, αναδεικνύεται ασυμφωνία αντικειμενικών στόχων (task

mismatch): η βελτίωση φωτομετρικών μετρικών, όπως του PSNR ή του SSIM, δεν συνεπάγεται κατ' ανάγκην βελτίωση της μεταγενέστερης ταξινόμησης, επειδή η υπερβολική εξομάλυνση μπορεί να αλλοιώσει κρίσιμες μικροδομές των κροσσών.

Συνεπώς, η παραγωγή ψευδο-θορυβωδών δεδομένων στην παρούσα εργασία δεν αντιμετωπίζεται ως απλή τεχνική αύξησης δεδομένων, αλλά ως φυσικά εμπνευσμένο και πειραματικά ελέγξιμο πλαίσιο συνθετικής εποπτείας. Η πλήρης μαθηματική διατύπωση των τελεστών, η αναλυτική περιγραφή των πρωτοκόλλων βαθμονόμησης, οι μελέτες αφαίρεσης της αλυσίδας διαφθοράς, καθώς και τα εκτεταμένα πειραματικά αποτελέσματα παρατίθενται στο παρόν Παράρτημα Κ.

Κ.1 Σύνδεση με τον κύριο κορμό της εργασίας

Στην Ενότητα 2.4.6 του Κεφαλαίου 2 παρουσιάστηκε σε συμπυκνωμένη μορφή η φυσική αλυσίδα θορύβου Speckle → Poisson → Gaussian, η βασική αρχή λειτουργίας της γεννήτριας ψευδο-θορύβου και η ανάγκη εμπειρικής βαθμονόμησης από πραγματικά ζεύγη λήψεων. Το παρόν παράρτημα συγκεντρώνει σε ενιαία μορφή το πλήρες μαθηματικό και μεθοδολογικό υπόβαθρο της γεννήτριας, τα πρωτόκολλα εκτέλεσης και τα κύρια συγκεντρωτικά αποτελέσματα που τεκμηριώνουν τη χρήση της ως ελέγξιμου πειραματικού αντικειμένου.

Η βασική θέση του παραρτήματος είναι ότι η συνθετική εποπτεία στην ESPI δεν πρέπει να προσεγγίζεται ως ad hoc διαδικασία προσθήκης τυχαίου θορύβου, αλλά ως φυσικά εμπνευσμένο, εμπειρικά βαθμονομημένο και αναπαραγώγιμο εργαλείο. Στο πλαίσιο αυτό, ο αποθορυβοποιητής δεν αντιμετωπίζεται ως ο κύριος στόχος σύγκρισης, αλλά ως ένας σταθερός ανιχνευτής αξιολόγησης της ίδιας της γεννήτριας και των λειτουργικών καθεστώτων της.

Κ.2 Σκοπός, συμβολισμοί και φυσικό μοντέλο παρατήρησης

Η συμβολή της γεννήτριας ψευδο-θορύβου δεν εξαντλείται στην παραγωγή οπτικά πειστικών αλλοιώσεων. Η ουσιαστική της σημασία έγκειται στο ότι μετατρέπει τη συνθετική εποπτεία από γενική πρακτική αύξησης δεδομένων σε ελεγχόμενο πειραματικό αντικείμενο. Σε ένα πρόβλημα ESPI με περιορισμένα πραγματικά ζεύγη noisy-clean, το κρίσιμο ερώτημα δεν είναι μόνο η χωρητικότητα του αποθορυβοποιητή, αλλά κυρίως η φυσική πιστότητα του corruption model και η βαθμονόμησή του ως προς τις μετρημένες στατιστικές πραγματικών λήψεων.

Πίνακας Κ.1. Βασικοί συμβολισμοί του μοντέλου παρατήρησης και της γεννήτριας.

Σύμβολο	Ερμηνεία
x	averaged εικόνα αναφοράς υψηλότερου λόγου σήματος προς θόρυβο

Σύμβολο	Ερμηνεία
y	τελική ψευδο-θορυβώδης έξοδος της γεννήτριας
B_f	προαιρετικός τελεστής εξομάλυνσης ή frequency-aware smoothing
S_k	πολλαπλασιαστικός τελεστής speckle
P_p	τελεστής Poisson που εισάγει signal-dependent shot noise
G_σ	προσθετικός Gaussian θόρυβος ανάγνωσης του αισθητήρα
θ = (k, p, σ)	διάνυσμα παραμέτρων της γεννήτριας ψευδο-θορύβου

Η χρήση ρητών συμβολισμών επιτρέπει τη σαφή διάκριση των επιμέρους συνιστωσών και καθιστά ελέγξιμη τόσο τη βαθμονόμηση όσο και τις μελέτες αφαίρεσης. Η παρατηρούμενη εικόνα στην ESPI δεν υποβαθμίζεται αποκλειστικά από έναν προσθετικό λευκό θόρυβο. Η συνεκτική φύση της απεικόνισης εισάγει έντονη υφή speckle με πολλαπλασιαστικό χαρακτήρα, ενώ η φωτομετρική διαδικασία του αισθητήρα προσθέτει shot noise εξαρτώμενο από την ένταση και, τελικά, ηλεκτρονικό θόρυβο ανάγνωσης.

Για τον λόγο αυτό, η averaged αναφορά x οδηγείται στην τελική έξοδο y μέσω μιας διαδοχικής αλυσίδας τελεστών, η οποία, στη γενικευμένη της μορφή, γράφεται ως εξής:

$$y = \mathrm{clip}\left(G_\sigma\left(P_p\left(S_k\left(B_f(x)\right)\right)\right)\right) \qquad \textbf{(K.2)}$$

Η μορφή αυτή είναι κρίσιμη, επειδή επιτρέπει τόσο μια φυσικά ερμηνεύσιμη μοντελοποίηση όσο και την πειραματικά ελέγξιμη αφαίρεση συνιστωσών. Στο στάδιο speckle, η εικόνα διαμορφώνεται πολλαπλασιαστικά. Στο στάδιο Poisson, η διακύμανση εξαρτάται από την ένταση του σήματος και δεν μπορεί να θεωρηθεί σταθερή. Ο Gaussian όρος παριστάνει το τελικό υπολειπόμενο στοιχείο του αισθητήρα. Επιπλέον, η γεννήτρια διατηρεί τη δυνατότητα προαιρετικής θόλωσης ή εξομάλυνσης βάσει συχνότητας χωρίς να μεταβάλλει τη βασική δομή της αλυσίδας.

Το διάνυσμα παραμέτρων της γεννήτριας λαμβάνει τη μορφή:

$$\theta = (k,\ p,\ \sigma) \qquad \textbf{(K.3)}$$

Κ.3 Βαθμονόμηση της γεννήτριας από πραγματικά ζεύγη

Η βασική διαφορά της τελικής γεννήτριας από τις πρώιμες ad hoc εκδοχές είναι ότι οι παράμετροι δεν επιλέγονται εμπειρικά με αισθητικό τρόπο, αλλά εκτιμώνται από πραγματικά ζεύγη single-shot / averaged. Η βαθμονόμηση διατυπώνεται ως πρόβλημα ελαχιστοποίησης της στατιστικής απόκλισης μεταξύ της συνθετικής εξόδου και της πραγματικής θορυβώδους λήψης. Στην πράξη, αυτό υλοποιείται μέσω αντιστοίχισης ροπών, δηλαδή μέσω της αντιστοίχισης της μέσης τιμής και της διακύμανσης ανάμεσα στη συνθετική και την πραγματική εικόνα.

Το κανονικό μεσαίο σημείο λειτουργίας που χρησιμοποιήθηκε στις κύριες συγκρίσεις είναι k = 1,89, p = 12,5 και σ = 0,0919. Η ύπαρξη αυτού του παγιωμένου σημείου αναφοράς είναι καθοριστική, διότι επιτρέπει αυστηρές και επαναλήψιμες συγκρίσεις μεταξύ διαφορετικών καθεστώτων και μελετών αφαίρεσης.

Πίνακας Κ.2. *Τυπικό μεσαίο (Mid) σημείο λειτουργίας της βαθμονόμησης (canonical Mid operating point)..*

Σημείο αναφοράς	k	p	σ
Τιμές βαθμονόμησης	1,89	12,5	0,0919

Κ.4 Πρωτόκολλο αξιολόγησης και ρόλος του fixed probe

Η αξιολόγηση της γεννήτριας οργανώνεται σε δύο συμπληρωματικά επίπεδα. Στο επίπεδο της γεννήτριας εξετάζονται μετρικές όπως το PSNR, το SSIM και, όπου χρειάζεται, το Edge-F1 ή άλλοι δομικά ευαίσθητοι δείκτες. Στο επίπεδο του ανιχνευτή χρησιμοποιείται ένας σταθερός αποθορυβοποιητής V4 DnCNN-Lite-ECA ως όργανο αξιολόγησης της εκπαιδευσιμότητας του συνθετικού καθεστώτος. Με αυτή τη λογική, μια συνθετική διαδικασία θεωρείται επιστημονικά χρήσιμη όχι επειδή παράγει μόνο οπτικά πειστικές αλλοιώσεις, αλλά επειδή οδηγεί σε δομικά συνεπή και λειτουργικά χρήσιμη συμπεριφορά του fixed probe.

Τα προκαταρκτικά στάδια πριν από τη βαθμονόμηση v2.0 έδειξαν ότι το βασικό πρόβλημα δεν ήταν απλώς η επιλογή καλύτερων υπερπαραμέτρων, αλλά η ανεπαρκής αγκύρωση της διαδικασίας συνθετικής αλλοίωσης στις στατιστικές των πραγματικών λήψεων. Η μετάβαση στη βαθμονομημένη εκδοχή κατέστησε δυνατή την ανάπτυξη ενός canonical Mid regime, μελετών αφαίρεσης ελεγχόμενης δριμύτητας και αυστηρότερων πρωτοκόλλων αναπαραγωγιμότητας, χωρίς να συγχέεται η επιστημονική σύγκριση με την εξέλιξη του λογισμικού.

Κ.5 Μελέτη Αφαίρεσης υπό Ελεγχόμενη Σφοδρότητα (Severity-Controlled Ablation) και Ερμηνεία των Καθεστώτων Λειτουργίας

Η μελέτη αφαίρεσης ελεγχόμενης δριμύτητας ανέδειξε ότι η πλήρης αλυσίδα διαφθοράς δεν κρίνεται δίκαια σε μη αντιστοιχισμένες συγκρίσεις, διότι τα απλούστερα μοντέλα είναι συχνά ηπιότερα και παράγουν τεχνητά καλύτερες μετρικές πιστότητας. Όταν όμως οι εκδοχές Poisson+Gaussian και Gaussian-only εξισωθούν ως προς τη δριμύτητα, η πλήρης αλυσίδα εμφανίζει ευνοϊκότερη ευθυγράμμιση με τον κύριο στόχο επικύρωσης του fixed probe, παρότι απλούστερα baselines μπορεί να διατηρούν μικρό πλεονέκτημα σε ορισμένες δομικά ευαίσθητες μετρικές.

Το εύρημα αυτό υποστηρίζει ότι η αξιολόγηση της γεννήτριας εξαρτάται αναγκαστικά από τις μετρικές και ότι η φυσική πιστότητα δεν ταυτίζεται με τη βελτίωση μίας και μόνο μετρικής. Η διαγνωστική σύγκριση των καθεστώτων λειτουργίας Mid και High έδειξε επιπλέον ότι οι αριθμητικές διαφορές δεν πρέπει να ερμηνεύονται επιφανειακά ως ένδειξη ότι μία περιοχή λειτουργίας είναι εγγενώς ευκολότερη. Αντιθέτως, οι αποκλίσεις μεταξύ των regimes εξαρτώνται από τη δομή των καθαρών αναφορών, τη συχνοτική τους κατανομή, την τοπική υφή των κροσσών και την επίδραση της ίδιας της διαδικασίας συνθετικής αλλοίωσης.

Κ.6 Μεθοδολογική αναπαραγωγιμότητα και v3.2

Η αναβάθμιση της μεθοδολογίας v3.2 δεν πρέπει να ερμηνευθεί ως μια νέα γεννήτρια με καθολικά καλύτερες επιδόσεις, αλλά ως ένα αυστηρότερο επίπεδο εκτέλεσης που προσθέτει ντετερμινισμό, ανεξαρτησία από τη σειρά εκτέλεσης, εξάρτηση από δηλωτικά και πλήρη ιχνηλασιμότητα. Οι έλεγχοι backward compatibility, order invariance και replayability έδειξαν πανομοιότυπα αποτελέσματα στα αντίστοιχα ελεγχόμενα υποσύνολα, γεγονός που μετατρέπει τη συνθετική παραγωγή σε ένα περισσότερο διαφανές και αναπαραγώγιμο πειραματικό όργανο.

Πίνακας Κ.3. *Άξονες ελέγχου της μεθοδολογικής αναπαραγωγιμότητας στη v3.2.*

Άξονας ελέγχου	Στόχος
Backward compatibility	Έλεγχος συμβατότητας με το frozen canonical μονοπάτι.
Order invariance	Αποκλεισμός εξάρτησης της εξόδου από τη σειρά των αρχείων.
Replayability / provenance	Αναπαραγωγή της εξόδου από καταγεγραμμένα artifacts και manifest-driven conditioning.

Κ.7 Σύνθεση και όρια εγκυρότητας

Συνολικά, από το παρόν παράρτημα προκύπτουν τέσσερα βασικά συμπεράσματα. Πρώτον, η οπτική αληθοφάνεια από μόνη της δεν αρκεί για να θεωρηθεί χρήσιμη ως προς τον ανιχνευτή. Δεύτερον, η βαθμονόμηση από πραγματικά ζεύγη single-shot / averaged είναι αναγκαία για τη μείωση του χάσματος μεταξύ συνθετικών και πραγματικών δεδομένων. Τρίτον, οι συγκρίσεις ελεγχόμενης δριμύτητας είναι απαραίτητες ώστε να αποφεύγονται παραπλανητικά συμπεράσματα υπέρ ηπιότερων baselines. Τέταρτον, η αναπαραγωγιμότητα της εκτέλεσης αποτελεί δομικό μέρος της επιστημονικής εγκυρότητας της γεννήτριας και όχι δευτερεύουσα τεχνική λεπτομέρεια.

Υπό αυτή την έννοια, η γεννήτρια ψευδο-θορύβου δεν αποτελεί μια περιφερειακή τεχνική προσθήκη, αλλά κεντρικό στοιχείο της προσπάθειας γεφύρωσης του synthetic-to-real gap στην ESPI υπό συνθήκες σπανιότητας δεδομένων. Η αξία της δεν βρίσκεται μόνο σε μία μεμονωμένη τιμή PSNR, αλλά στο ότι συγκροτεί ένα πλαίσιο μέσα στο οποίο η συνθετική εποπτεία μπορεί να μελετηθεί ως ένα φυσικά ερμηνεύσιμο, μετρήσιμο και πειραματικά ελέγξιμο αντικείμενο.

Μια πρόσθετη, οριοθετημένη ένδειξη της εξωτερικής εγκυρότητας (external validity) του προτεινόμενου πλαισίου προκύπτει από τη μεταγενέστερη αξιολόγηση μεταφοράς από ξύλο σε ανθρακόνημα (wood-to-carbon). Στη συγκεκριμένη δοκιμή χρησιμοποιήθηκαν μοντέλα εκπαιδευμένα αποκλειστικά σε ξύλινα δοκίμια με σταθερό ανιχνευτή (wood-trained fixed-probe checkpoints), χωρίς καμία μικρορύθμιση (fine-tuning) ή επανεκπαίδευση στο νέο υποσύνολο δεδομένων από ανθρακόνημα.

Υπό αυτήν την οριοθετημένη μετατόπιση υλικού (bounded material shift), η πλήρης αλυσίδα προσομοίωσης του θορύβου (corruption chain) διατήρησε την ανωτερότητά της ως προς την πρωτεύουσα μετρική αξιολόγησης έναντι των απλοϊκών προτύπων αναφοράς αντίστοιχης σφοδρότητας (severity-matched baselines).

Το συγκεκριμένο εύρημα δεν αποδεικνύει καθολική αμεταβλητότητα (invariance) του συστήματος ως προς το υλικό κατασκευής. Εντούτοις, ενισχύει την ερμηνεία ότι η φυσικά βαθμονομημένη σύνθεση παρασιτικών πηγών θορύβου (nuisance sources) διαθέτει ουσιαστική λειτουργική αξία, η οποία δεν περιορίζεται αυστηρά στο αρχικό πειραματικό περιβάλλον των ξύλινων ηχείων (wood-board setting). Για λόγους συνοχής του κειμένου, η εν λόγω διερεύνηση παρατίθεται στο παρόν σημείο αποκλειστικά ως συμπληρωματική ένδειξη της ικανότητας μεταφοράς (transferability), και όχι ως ένας νέος, αυτόνομος πειραματικός πυρήνας του παραρτήματος.

ΓΛΩΣΣΑΡΙ ΟΡΩΝ

Το παρόν γλωσσάρι συγκεντρώνει τους βασικούς τεχνικούς όρους που χρησιμοποιούνται στη διπλωματική εργασία. Για κάθε λήμμα παρατίθενται ο όρος στην αγγλική και την ελληνική μορφή του, σύντομος λειτουργικός ορισμός, το κριτήριο επιλογής της απόδοσης που υιοθετείται στην παρούσα εργασία και ενδεικτική βιβλιογραφική τεκμηρίωση.

Α. Οπτική Συμβολομετρία και ESPI

Πίνακας Γλωσσαρίου Α.1: *Όροι οπτικής συμβολομετρίας και ESPI*

Πρωτότυπος Όρος / Απόδοση ορολογίας στη διπλωματικη	**Ορισμός**	**Κριτήριο απόδοσης**	**Ενδεικτική βιβλιογραφία**
Electronic Speckle Pattern Interferometry (ESPI) Ηλεκτρονική Συμβολομετρία Κηλίδων	Μη καταστροφική οπτική τεχνική πλήρους πεδίου για μέτρηση μικρομετατοπίσεων και ανάλυση fringe patterns από φωτισμό laser.	Διατηρείται το ακρωνύμιο ESPI ως διεθνώς αναγνωρίσιμη ονομασία, ενώ η απόδοση «Ηλεκτρονική Συμβολομετρία Κηλίδων» υιοθετείται στην παρούσα εργασία ως η συνεπής ελληνική μορφή. Ο όρος «κηλίδες» επιλέγεται για να αποδοθεί με φυσική ακρίβεια το speckle.	Jones & Wykes (1989)
Interference fringes Κροσσοί συμβολής	Εναλλασσόμενες φωτεινές και σκοτεινές ζώνες που προκύπτουν από την ενισχυτική και αποσβεστική συμβολή συνεκτικού φωτός.	Επιλέγεται η καθιερωμένη ορολογία της κυματικής οπτικής αντί περιγραφικών αποδόσεων όπως «γραμμές» ή «λωρίδες».	Hecht (2016)
Speckle noise Θόρυβος κηλίδων	Εγγενής, κυρίως πολλαπλασιαστικός θόρυβος των συστημάτων συνεκτικής απεικόνισης που αλλοιώνει την αντίθεση και την καθαρότητα των fringe patterns.	Η απόδοση διατηρεί τον πυρήνα «κηλίδες» ώστε να παραμένει συνεπής με το φυσικό φαινόμενο speckle και να διακρίνεται από τον ηλεκτρονικό ή Gaussian θόρυβο.	Goodman (2007)
Time-averaged ESPI ESPI χρονικού μέσου όρου	Παραλλαγή της ESPI όπου ο χρόνος έκθεσης υπερβαίνει την περίοδο της ταλάντωσης και καταγράφεται ο χρονικός μέσος της	Η απόδοση «ESPI χρονικού μέσου όρου» επιλέγεται στην παρούσα εργασία ως η καθιερωμένη και σαφέστερη μορφή	Cloud (1998)

Πρωτότυπος Όρος / Απόδοση ορολογίας στη διπλωματικη	Ορισμός	Κριτήριο απόδοσης	Ενδεικτική βιβλιογραφία
	έντασης κατά τη διάρκεια της έκθεσης.	για τη συγκεκριμένη παραλλαγή της μεθόδου.	
Bessel function J_0 Συνάρτηση Bessel πρώτου είδους μηδενικής τάξης	Μαθηματική συνάρτηση που εμφανίζεται στη θεωρητική περιγραφή της έντασης των fringe patterns στο time-averaged ESPI.	Διατηρείται η τυπική ονοματολογία της μαθηματικής φυσικής, επειδή προσδιορίζει με ακρίβεια τη συγκεκριμένη μορφή της συνάρτησης.	Vest (1979)
Phase unwrapping Ξετύλιγμα φάσης	Αλγοριθμική διαδικασία μετατροπής τυλιγμένης φάσης modulo 2π σε συνεχή αναπαράσταση.	Επιλέγεται η απόδοση «ξετύλιγμα φάσης» ως η σταθερή μορφή της παρούσας εργασίας, ενώ αποφεύγονται εναλλακτικές διατυπώσεις που θα εισήγαγαν ορολογική ασυνέπεια.	Ghiglia & Pritt (1998)

Β. Ακουστική, Δονήσεις και Ανάλυση Ιδιομορφών

Πίνακας Γλωσσαρίου Β.1: Όροι ακουστικής, δονήσεων και ανάλυσης ιδιομορφών

Όρος	Ορισμός	Κριτήριο απόδοσης	Ενδεικτική βιβλιογραφία
Modal analysis Ανάλυση ιδιομορφών	Μεθοδολογία μελέτης των ιδιοσυχνοτήτων, ιδιομορφών και, όπου απαιτείται, των χαρακτηριστικών απόσβεσης ενός δομικού συστήματος.	Η απόδοση «ανάλυση ιδιομορφών» διατηρείται ως ο βασικός καθιερωμένος όρος. Στο ειδικό πλαίσιο της παρούσας physics-informed μεθοδολογίας, ο όρος αποσαφηνίζεται λειτουργικά ως ανάλυση ιδιοσυχνοτήτων και ιδιομορφών, επειδή οι ιδιομορφές τροφοδοτούν το μορφολογικό σκέλος της αναπαράστασης, ενώ οι ιδιοσυχνότητες παρέχουν τις συχνοτικές πρότερες πληροφορίες (frequency priors).	Ewins (2000)

Όρος	Ορισμός	Κριτήριο απόδοσης	Ενδεικτική βιβλιογραφία
Mode shape Ιδιομορφή ταλάντωσης	Χωρικό πρότυπο παραμόρφωσης που αντιστοιχεί σε συγκεκριμένο τρόπο ταλάντωσης και σε συγκεκριμένη ιδιοσυχνότητα.	Η απόδοση συνδέεται άμεσα με τη θεωρία ιδιοτιμών και ιδιοδιανυσμάτων, που αποτελεί το μαθηματικό υπόβαθρο της δυναμικής ανάλυσης.	Chopra (2011)
Nodal line Κομβική γραμμή	Γεωμετρικός τόπος σημείων με μηδενικό πλάτος μετατόπισης πάνω στη δονούμενη επιφάνεια.	Επιλέγεται η καθιερωμένη ορολογία της κυματικής φυσικής και της ανάλυσης ιδιομορφών, ιδίως επειδή στην παρούσα εργασία οι κομβικές γραμμές είναι βασικά μορφολογικά χαρακτηριστικά.	Fletcher & Rossing (1998)
Antinode Κοιλία	Περιοχή της δονούμενης επιφάνειας στην οποία το πλάτος ταλάντωσης λαμβάνει μέγιστες τιμές.	Η λέξη «κοιλία» αποτελεί τον κλασικό αντιθετικό όρο του «κόμβου» στη θεωρία στάσιμων κυμάτων.	Kinsler et al. (2000)
Soundboard Καπάκι	Κύρια δονούμενη επιφάνεια του αντηχείου ενός έγχορδου οργάνου μέσω της οποίας μεταφέρεται η μηχανική ενέργεια των χορδών στον αέρα.	Επιλέγεται ο όρος «καπάκι», επειδή είναι ο πιο φυσικός και λειτουργικός στην ελληνόγλωσση οργανοποιητική και ακουστική πρακτική.	Rossing (2010)

Γ. Μηχανική Μάθηση και Αξιολόγηση

Πίνακας Γλωσσαρίου Γ.1*: Όροι μηχανικής μάθησης και αξιολόγησης*

Όρος	Ορισμός	Κριτήριο απόδοσης	Ενδεικτική βιβλιογραφία
Random Forest Random Forest	Συνδυαστικό μοντέλο μηχανικής μάθησης που βασίζεται στη συλλογική πρόβλεψη πολλών δέντρων αποφάσεων.	Ο όρος διατηρείται αμετάφραστος, επειδή η αγγλική ονομασία είναι πλήρως παγιωμένη στη διεθνή και ελληνόγλωσση τεχνική βιβλιογραφία.	Breiman (2001)
Accuracy	Μετρική που εκφράζει το συνολικό ποσοστό ορθών ταξινομήσεων.	Ο όρος διατηρείται στα αγγλικά στην παρούσα εργασία, ώστε να αποφεύγεται σύγχυση με το Precision και να παραμένει συμβατός με τη διεθνή	He & Garcia (2009)

Όρος	Ορισμός	Κριτήριο απόδοσης	Ενδεικτική βιβλιογραφία
		βιβλιογραφία και τα λογισμικά αξιολόγησης.	
Macro-F1 Macro-F1	Ασταθμιστος μέσος όρος των F1-scores όλων των κλάσεων, ιδιαίτερα χρήσιμος σε ανισόρροπα προβλήματα ταξινόμησης.	Ο όρος διατηρείται στα αγγλικά λόγω τυποποίησης στη βιβλιογραφία και στα λογισμικά πλαίσια αξιολόγησης.	He & Garcia (2009)
Baseline Μοντέλο αναφοράς	Πρότυπο σύγκρισης έναντι του οποίου αξιολογείται μια νέα μέθοδος ή αρχιτεκτονική.	Η ελληνική απόδοση θεωρείται επαρκώς ακριβής, ενώ ο αγγλικός όρος μπορεί να διατηρείται συμπληρωματικά όπου χρειάζεται.	Goodfellow et al. (2016)
Domain shift Μετατόπιση πεδίου / κατανομής	Διαφοροποίηση των στατιστικών χαρακτηριστικών μεταξύ συνόλου εκπαίδευσης και συνόλου δοκιμής ή εφαρμογής.	Διατηρείται συχνά και ο αγγλικός όρος, επειδή είναι ιδιαίτερα αναγνωρίσιμος στη βιβλιογραφία μηχανικής μάθησης.	Quiñonero-Candela et al. (2009)
Pipeline Ροή επεξεργασίας	Αλληλουχία διαδοχικών υπολογιστικών σταδίων από την είσοδο έως το τελικό αποτέλεσμα.	Η απόδοση «ροή επεξεργασίας» ή «ροή εργασίας» προτιμάται από τη γενικότερη «διαδικασία», επειδή αποδίδει τη σειριακή και δομημένη φύση των σταδίων.	Abadi et al. (2016)
Residual learning Υπολειματική μάθηση	Στρατηγική εκπαίδευσης κατά την οποία Το δίκτυο μαθαίνει το residual μεταξύ εισόδου και στόχου, δηλαδή εδώ κυρίως τον θόρυβο που πρέπει να αφαιρεθεί.	Η ελληνική απόδοση χρησιμοποιείται για να Αποσαφηνίζεται η μαθηματική έννοια του residual, χωρίς να αποκλείεται η συμπληρωματική χρήση του αγγλικού όρου.	He et al. (2016) & Zhang et al. (2017)
Efficient Channel Attention (ECA) ECA	Ελαφριά μονάδα attention που επιτρέπει δυναμική επαναστάθμιση των καναλιών χαρακτηριστικών σε συνελικτικά δίκτυα.	Διατηρείται το ακρωνύμιο, επειδή αποτελεί την καθιερωμένη ονομασία της αρχιτεκτονικής στη διεθνή βιβλιογραφία.	Wang et al. (2020)
LOBO / LODO LOBO / LODO	Αυστηρά πρωτόκολλα αξιολόγησης γενίκευσης στα οποία εξαιρείται από την	Τα ακρωνύμια διατηρούνται αμετάφραστα ως τεχνικές ονομασίες πειραματικού σχεδιασμού και	Bishop (2006)

Όρος	Ορισμός	Κριτήριο απόδοσης	Ενδεικτική βιβλιογραφία
	εκπαίδευση ένα ολόκληρο δοκίμιο ή ένα ολόκληρο σύνολο δεδομένων.	χρησιμοποιούνται επεξηγηματικά με πλήρη ανάπτυξη κατά την πρώτη εμφάνιση.	
Feature importance Σημαντικότητα χαρακτηριστικών	Σύνολο μεθόδων με τις οποίες εκτιμάται η σχετική συμβολή κάθε χαρακτηριστικού στις τελικές αποφάσεις ενός μοντέλου.	Η ελληνική απόδοση θεωρείται επαρκώς ακριβής, ενώ ειδικότερα σχήματα όπως MDI και permutation importance διατηρούνται συχνά στα αγγλικά.	Breiman (2001)

ΑΝΑΛΥΤΙΚΗ ΒΙΒΛΙΟΓΡΑΦΙΑ

Allen, J. B., & Rabiner, L. R. (1977). A unified approach to short-time Fourier analysis and synthesis. Proceedings of the IEEE, 65(11), 1558–1564. https://doi.org/10.1109/PROC.1977.10770

Bakarezos, E., Orphanos, Y., Kaselouris, E., Dimitriou, V., Tatarakis, M., & Papadogiannis, N. A. (2019). Laser-based interferometric techniques for the study of musical instruments. In R. Bader (Ed.), Computational phonogram archiving (Current Research in Systematic Musicology, Vol. 5, pp. 251–268). Springer. https://doi.org/10.1007/978-3-030-02695-0_12

Bavigadda, V. (2013). A new versatile electronic speckle pattern interferometer for vibration measurements. Doctoral dissertation, Technological University Dublin.

Bishop, C. M. (2006). Pattern recognition and machine learning. Springer.

Blau, Y., & Michaeli, T. (2018). The perception-distortion tradeoff. In Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (pp. 6228–6237). IEEE. https://doi.org/10.1109/CVPR.2018.00652

Branco, P., Torgo, L., & Ribeiro, R. P. (2016). A survey of predictive modeling on imbalanced domains. ACM Computing Surveys, 49(2), 31.

Breiman, L. (1996). Bagging predictors. Machine Learning, 24(2), 123–140.

Breiman, L. (2001). Random forests. Machine Learning, 45(1), 5–32. https://doi.org/10.1023/A:1010933404324

Brezas, S., et al. (2023). An integrated method for the vibroacoustic evaluation of a carbon fiber bouzouki. Applied Sciences, 13(7), 4585. https://www.mdpi.com/2076-3417/13/7/4585

Burger, H. C., Schuler, C. J., & Harmeling, S. (2012). Image denoising: Can plain neural networks compete with BM3D? In IEEE Conference on Computer Vision and Pattern Recognition (pp. 2392–2399). https://doi.org/10.1109/CVPR.2012.6247952

Burr, I. W. (1942). Cumulative frequency functions. The Annals of Mathematical Statistics, 13(2), 215–232. https://doi.org/10.1214/aoms/1177731607

Chatterjee, P., & Milanfar, P. (2010). Is denoising dead? IEEE Transactions on Image Processing, 19(4), 895–911. https://doi.org/10.1109/TIP.2009.2037087

Chawla, N. V., Bowyer, K. W., Hall, L. O., & Kegelmeyer, W. P. (2002). SMOTE: Synthetic minority over-sampling technique. Journal of Artificial Intelligence Research, 16, 321–357.

Cohen, J. (1988). Statistical power analysis for the behavioral sciences (2nd ed.). Lawrence Erlbaum Associates.

Costantini, M., & Rosen, P. A. (1999). A generalized phase unwrapping approach for sparse data. In IEEE 1999 International Geoscience and Remote Sensing Symposium, IGARSS'99 (Vol. 1, pp. 267–269). IEEE.

Creath, K. (1988). Phase-measurement interferometry techniques. In E. Wolf (Ed.), Progress in Optics (Vol. 26, pp. 349–393). Elsevier.

Cremer, L., Heckl, M., & Petersson, B. A. T. (2004). Structure-borne sound: Structural vibrations and sound radiation at audio frequencies (3rd ed.). Springer-Verlag.

Dabov, K., Foi, A., Katkovnik, V., & Egiazarian, K. (2007). Image denoising by sparse 3D transform-domain collaborative filtering. IEEE Transactions on Image Processing, 16(8), 2080–2095.

Dainty, J. C. (Ed.). (1984). Laser speckle and related phenomena (2nd ed.). Springer-Verlag. https://doi.org/10.1007/978-3-540-39066-1

Demšar, J. (2006). Statistical comparisons of classifiers over multiple data sets. Journal of Machine Learning Research, 7, 1–30.

Deng, J., Dong, W., Socher, R., Li, L.-J., Li, K., & Fei-Fei, L. (2009). ImageNet: A large-scale hierarchical image database. In Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (pp. 248–255). https://doi.org/10.1109/CVPR.2009.5206848

Dietterich, T. G. (1998). Approximate statistical tests for comparing supervised classification learning algorithms. Neural Computation, 10(7), 1895–1923. https://doi.org/10.1162/089976698300017197

Dong, Z., & Chen, Z. (2018). Advanced Fourier transform analysis method for phase retrieval from a single-shot spatial carrier fringe pattern. Optics and Lasers in Engineering, 107, 149–160. https://doi.org/10.1016/j.optlaseng.2018.03.033

Efron, B. (1979). Bootstrap methods: Another look at the jackknife. Annals of Statistics, 7(1), 1–26. https://doi.org/10.1214/aos/1176344552

Efron, B., & Tibshirani, R. J. (1993). An introduction to the bootstrap. Chapman & Hall/CRC.

Estrada, J. C., Servin, M., & Quiroga, J. A. (2017). Reconstruction of local frequencies for recovering the unwrapped phase. Scientific Reports, 7, 8015. https://doi.org/10.1038/s41598-017-06801-z

Ewins, D. J. (2000). Modal testing: Theory, practice and application (2nd ed.). Research Studies Press.

Fletcher, N. H., & Rossing, T. D. (1998). The physics of musical instruments (2nd ed.). Springer.

Foi, A., Trimeche, M., Katkovnik, V., & Egiazarian, K. (2008). Practical Poissonian-Gaussian noise modeling and fitting for single-image raw data. IEEE Transactions on Image Processing, 17(10), 1737–1754. https://doi.org/10.1109/TIP.2008.2001399

Gabor, D. (1946). Theory of communication. Part 1: The analysis of information. Journal of the Institution of Electrical Engineers - Part III: Radio and Communication Engineering, 93(26), 429–441.

Gal, Y., & Ghahramani, Z. (2016). Dropout as a Bayesian approximation: Representing model uncertainty in deep learning. In International Conference on Machine Learning (pp. 1050–1059). PMLR.

Gao, C., Gao, Z., Niu, Y., Wang, X., Zhao, J., & Deng, L. (2021). Micro vibration measurement with microscopic speckle interferometry based on orthogonal phase. Applied Sciences, 11(11), 5251. https://doi.org/10.3390/app11115251

Geifman, Y., & El-Yaniv, R. (2017). Selective classification for deep neural networks. In Advances in Neural Information Processing Systems (Vol. 30, pp. 4878–4887). Curran Associates, Inc.

Geirhos, R., Jacobsen, J.-H., Michaelis, C., Zemel, R., Brendel, W., Bethge, M., & Wichmann, F. A. (2020). Shortcut learning in deep neural networks. Nature Machine Intelligence, 2(11), 665–673. https://doi.org/10.1038/s42256-020-00257-z

Georgas, P. (2012). Simultaneous measurement of full-field vibration modes using electronic speckle pattern interferometry. Master's thesis, University of British Columbia.

Ghiglia, D. C., & Pritt, M. D. (1998). Two-dimensional phase unwrapping: Theory, algorithms, and software. Wiley-Interscience.

Gonzalez, R. C., & Woods, R. E. (2018). Digital image processing (4th ed.). Pearson Education.

Goodfellow, I., Bengio, Y., & Courville, A. (2016). Deep learning. MIT Press.

Goodman, J. W. (1984). Statistical properties of laser speckle patterns. In J. C. Dainty (Ed.), Laser speckle and related phenomena (2nd ed., pp. 9–75). Springer-Verlag.

Goodman, J. W. (2007). Speckle phenomena in optics: Theory and applications. Roberts and Company Publishers.

Graham, G. (1996). Whole-field modal analysis using electronic speckle pattern interferometry. In Proceedings of SPIE (Vol. 2868). https://doi.org/10.1117/12.2307110

Hastie, T., Tibshirani, R., & Friedman, J. (2009). The elements of statistical learning: Data mining, inference, and prediction (2nd ed.). Springer. https://doi.org/10.1007/978-0-387-84858-7

He, H., & Garcia, E. A. (2009). Learning from imbalanced data. IEEE Transactions on Knowledge and Data Engineering, 21(9), 1263–1284.

He, K., Zhang, X., Ren, S., & Sun, J. (2016). Deep residual learning for image recognition. In Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (pp. 770–778). https://doi.org/10.1109/CVPR.2016.90

Ho, T. K. (1995). Random decision forests. In Proceedings of the 3rd International Conference on Document Analysis and Recognition (Vol. 1, pp. 278–282). IEEE.

Hu, M. K. (1962). Visual pattern recognition by moment invariants. IRE Transactions on Information Theory, 8(2), 179–187. https://doi.org/10.1109/TIT.1962.1057692

Inman, D. J. (2014). Engineering vibration (4th ed.). Pearson.

Ioffe, S., & Szegedy, C. (2015). Batch normalization: Accelerating deep network training by reducing internal covariate shift. In Proceedings of the 32nd International Conference on Machine Learning (pp. 448–456). https://arxiv.org/abs/1502.03167

Jakeman, E., & Tough, R. J. A. (1987). Generalized K distribution: A statistical model for weak scattering. Journal of the Optical Society of America A, 4(9), 1764–1772. https://doi.org/10.1364/JOSAA.4.001764

Jiang, W., Ren, T., & Fu, Q. (2024). Deep learning in the phase extraction of electronic speckle pattern interferometry. Electronics, 13(2), 418. https://doi.org/10.3390/electronics13020418

Johnson, J. M., & Khoshgoftaar, T. M. (2019). Survey on deep learning with class imbalance. Journal of Big Data, 6(1), 27.

Jones, R., & Wykes, C. (1989). Holographic and speckle interferometry: A discussion of the theory, practice and application of the technique (2nd ed.). Cambridge University Press.

Kaleris, K., Kaniolakis-Kaloudis, E., Aravantinos-Zafiris, N., Katerelos, D. T. G., Dimitriou, V. M., Bakarezos, M., Tatarakis, M., Mourjopoulos, J., Sigalas, M. M., & Papadogiannis, N. A. (2024). Acoustic metamaterials characterization via laser plasma sound sources. Communications Materials, 5, 93. https://doi.org/10.1038/s43246-024-00529-w

Karpatne, A., Atluri, G., Faghmous, J. H., Steinbach, M., Banerjee, A., Ganguly, A., Shekhar, S., Samatova, N., & Kumar, V. (2017). Theory-guided data science: A new

paradigm for scientific discovery from data. IEEE Transactions on Knowledge and Data Engineering, 29(10), 2318–2331. https://doi.org/10.1109/TKDE.2017.2720168

Kay, S. M. (1993). Fundamentals of statistical signal processing: Estimation theory (Vol. 1). Prentice Hall.

Kingma, D. P., & Ba, J. (2015). Adam: A method for stochastic optimization. In International Conference on Learning Representations. https://arxiv.org/abs/1412.6980

Kreis, T. (2005). Handbook of holographic interferometry: Optical and digital methods. Wiley-VCH. https://doi.org/10.1002/3527604154

LeCun, Y., Bottou, L., Bengio, Y., & Haffner, P. (1998). Gradient-based learning applied to document recognition. Proceedings of the IEEE, 86(11), 2278–2324.

Leissa, A. W. (1969). Vibration of plates. NASA Special Publication SP-160.

Lundberg, S. M., & Lee, S.-I. (2017). A unified approach to interpreting model predictions. In Advances in Neural Information Processing Systems (Vol. 30, pp. 4765–4774). Curran Associates, Inc.

Mallat, S. (1999). A wavelet tour of signal processing (2nd ed.). Academic Press.

McNemar, Q. (1947). Note on the sampling error of the difference between correlated proportions or percentages. Psychometrika, 12(2), 153–157. https://doi.org/10.1007/BF02295996

Mitchell, T. M. (1997). Machine learning. McGraw-Hill.

Molnar, C. (2022). Interpretable machine learning (2nd ed.). https://christophm.github.io/interpretable-ml-book/

Oliver, C., & Quegan, S. (2004). Understanding synthetic aperture radar images. SciTech Publishing.

Oppenheim, A. V., Schafer, R. W., & Buck, J. R. (2009). Discrete-time signal processing (3rd ed.). Prentice Hall Press.

Ovadia, Y., Fertig, E., Ren, J., Nado, Z., Sculley, D., Nowozin, S., Dillon, J. V., Lakshminarayanan, B., & Snoek, J. (2019). Can you trust your model's uncertainty? Evaluating predictive uncertainty under dataset shift. In Advances in Neural Information Processing Systems (Vol. 32, pp. 13991–14002). Curran Associates, Inc.

Park, J., Woo, S., Lee, J. Y., & Kweon, I. S. (2018). BAM: Bottleneck Attention Module. In British Machine Vision Conference (pp. 147–151).

Paszke, A., Gross, S., Massa, F., Lerer, A., Bradbury, J., Chanan, G., ... & Chintala, S. (2019). PyTorch: An imperative style, high-performance deep learning library. In Advances in Neural Information Processing Systems 32 (pp. 8024–8035). https://arxiv.org/abs/1912.01703

Pedregosa, F., Varoquaux, G., Gramfort, A., Michel, V., Thirion, B., Grisel, O., ... & Duchesnay, E. (2011). Scikit-learn: Machine learning in Python. Journal of Machine Learning Research, 12, 2825–2830.

Perez, L., & Wang, J. (2017). The effectiveness of data augmentation in image classification using deep learning. arXiv preprint arXiv:1712.04621.

Proakis, J. G., & Manolakis, D. G. (2006). Digital signal processing (4th ed.). Pearson Education.

Raissi, M., Perdikaris, P., & Karniadakis, G. E. (2019). Physics-informed neural networks: A deep learning framework for solving forward and inverse problems involving nonlinear partial differential equations. Journal of Computational Physics, 378, 686–707. https://doi.org/10.1016/j.jcp.2018.10.045

Rastogi, P. K. (Ed.). (2001). Digital speckle pattern interferometry and related techniques. John Wiley & Sons.

Recht, B., Roelofs, R., Schmidt, L., & Shankar, V. (2019). Do ImageNet classifiers generalize to ImageNet? In Proceedings of the 36th International Conference on Machine Learning (Vol. 97, pp. 5389–5400). PMLR.

Ronneberger, O., Fischer, P., & Brox, T. (2015). U-Net: Convolutional networks for biomedical image segmentation. In International Conference on Medical Image Computing and Computer-Assisted Intervention (pp. 234–241). Springer.

Rossing, T. D. (Ed.). (2007). Handbook of acoustics. Springer Science+Business Media.

Ruder, S. (2016). An overview of gradient descent optimization algorithms. arXiv preprint arXiv:1609.04747.

Russakovsky, O., Deng, J., Su, H., Krause, J., Satheesh, S., Ma, S., ... & Fei-Fei, L. (2015). ImageNet large scale visual recognition challenge. International Journal of Computer Vision, 115(3), 211–252. https://doi.org/10.1007/s11263-015-0816-y

Santurkar, S., Tsipras, D., Ilyas, A., & Madry, A. (2018). How does batch normalization help optimization? In Advances in Neural Information Processing Systems (pp. 2483–2493).

Simonyan, K., & Zisserman, A. (2015). Very deep convolutional networks for large-scale image recognition. In International Conference on Learning Representations (ICLR).

Strobl, C., Boulesteix, A.-L., Zeileis, A., & Hothorn, T. (2007). Bias in random forest variable importance measures: Illustrations, sources and a solution. BMC Bioinformatics, 8, 25. https://doi.org/10.1186/1471-2105-8-25

Takeda, M., Ina, H., & Kobayashi, S. (1982). Fourier-transform method of fringe-pattern analysis for computer-based topography and interferometry. Journal of the Optical Society of America, 72(1), 156–160. https://doi.org/10.1364/JOSA.72.000156

Teague, M. R. (1980). Image analysis via the general theory of moments. Journal of the Optical Society of America, 70(8), 920–930.

Tian, C., Fei, L., Zheng, W., Xu, Y., Zuo, W., & Lin, C.-W. (2020). Deep learning on image denoising: An overview. Neural Networks, 131, 251–275.

Ulyanov, D., Vedaldi, A., & Lempitsky, V. (2016). Instance normalization: The missing ingredient for fast stylization. arXiv preprint arXiv:1607.08022.

Varoquaux, G. (2018). Cross-validation failure: Small sample sizes lead to large error bars. NeuroImage, 180(Pt A), 68–77. https://doi.org/10.1016/j.neuroimage.2017.06.061

von Rueden, L., Mayer, S., Beckh, K., Georgiev, B., Giesselbach, S., Heese, R., Kirsch, B., Pfrommer, J., Pick, A., Ramamurthy, R., Walczak, M., Garcke, J., Bauckhage, C., & Schuecker, J. (2021). Informed machine learning: A taxonomy and survey of integrating prior knowledge into learning systems. IEEE Transactions on Knowledge and Data Engineering. Advance online publication. https://doi.org/10.1109/TKDE.2021.3079836

Wang, Q., Wu, B., Zhu, P., Li, P., Zuo, W., & Hu, Q. (2020). ECA-Net: Efficient channel attention for deep convolutional neural networks. In Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (pp. 11534–11542). https://arxiv.org/abs/1910.03151

Wang, Z., Bovik, A. C., Sheikh, H. R., & Simoncelli, E. P. (2004). Image quality assessment: From error visibility to structural similarity. IEEE Transactions on Image Processing, 13(4), 600–612. https://doi.org/10.1109/TIP.2003.819861

Willard, J., Jia, X., Xu, S., Steinbach, M., & Kumar, V. (2022). Integrating scientific knowledge with machine learning for engineering and environmental systems. ACM Computing Surveys, 55(4), Article 66, 1–37. https://doi.org/10.1145/3514228

Wu, Y., & He, K. (2018). Group normalization. In Proceedings of the European Conference on Computer Vision (pp. 3–19). https://arxiv.org/abs/1803.08494

Yosinski, J., Clune, J., Bengio, Y., & Lipson, H. (2014). How transferable are features in deep neural networks? In Advances in Neural Information Processing Systems (Vol. 27, pp. 3320–3328). Curran Associates, Inc.

Zhang, K., Zuo, W., Chen, Y., Meng, D., & Zhang, L. (2017). Beyond a Gaussian denoiser: Residual learning of deep CNN for image denoising. IEEE Transactions on Image Processing, 26(7), 3142–3155. https://doi.org/10.1109/TIP.2017.2662206

ΕΛΛΗΝΙΚΗ ΒΙΒΛΙΟΓΡΑΦΙΑ

Χαρτοφύλακας, Λ. (2009). Ακουστική και ηχητική ανάλυση των οργάνων της οικογένειας του μπουζουκιού. Μεταπτυχιακή διπλωματική εργασία, Ιόνιο Πανεπιστήμιο & ΤΕΙ Κρήτης.

Στρατηγός, Φ. Κ. (2021). Ψηφιακή ολογραφική συμβολομετρία για την ανάλυση δονήσεων. Διδακτορική διπλωματική εργασία, Πανεπιστήμιο Θεσσαλίας.